

文章编号: 1006-2475(2017) 05-0037-03

基于 Q-学习和行为树的 CGF 空战行为决策

方 君, 闫文君, 邓向阳, 凌 青

(海军航空工程学院信息融合研究所, 山东 烟台 264001)

摘要: 空战行为决策的智能性是学术界关注的重要问题之一。提出一种基于 Q-学习和行为树的 CGF 空战行为决策方法。通过构建 CGF 空战行为树模型, 实现 CGF 智能行为; 通过在行为树上的 Q-学习, 使 CGF 具有不断进化的能力。仿真结果表明, 该算法在与传统算法对抗中, 性能优势明显且学习能力较强。

关键词: 空战决策; 人工智能; 行为树; Q-学习

中图分类号: TP301

文献标识码: A

doi: 10.3969/j.issn.1006-2475.2017.05.007

Air Bat Strategies of CGF Based on Q-learning and Behavior Tree

FANG Jun, YAN Wen-jun, DENG Xiang-yang, LING Qing

(Institute of Information Fusion, Naval Aeronautical and Astronautical University, Yantai 264001, China)

Abstract: The intelligence of air bat strategies is one of the important problems. A new method for air bat strategies of CGF was proposed based on Q-learning and behavior tree. The intelligence of CGF was formed through establishing behavior tree. And through Q-learning on behavior tree, the evolutionary ability was gained for CGF. Simulation shows that the method performs better and with a stronger learning ability when it combats with traditional algorithm.

Key words: air bat strategies; artificial intelligence; behavior tree; Q-learning

0 引 言

飞行模拟器研制工作中, CGF 的空战决策一直是备受关注的重要问题之一, 它影响着模拟器仿真的真实性, 也影响着飞行员训练效果。针对 CGF 空战决策问题的研究一直是各国研究的重点^[1]。传统的空战决策方法涉及神经网络^[2]、遗传算法^[3]等, 均取得了不错的效果。理想的 CGF 空战决策算法应该具有 2 个特点: 一是智能性, 二是学习性。传统的 CGF 空战决策模型在智能性上研究较多, 模型自主对抗能力较强, 但不能在训练时根据胜负结果自动更新模型数据, 不断学习。

R. Dey^[4] 等将 Q-学习和行为树相结合研究了强化学习对于行为树的影响, 为本文研究打下基础, 但应用到 CGF 空战模型中, 还有以下问题:

- 1) 基于行为树的空战模型建立问题;
- 2) 利用 Q 值表深度学习问题;
- 3) Q 学习算法易收敛到局部最优解的问题。

本文提出一种基于 Q-学习和行为树相结合的

CGF 空战行为决策模型, 通过构建行为树, 使 CGF 飞机具有一定的智能行为, 基于 Q 值表在初始化阶段的前期学习和训练中不断强化学习, 提高 CGF 模型的智能性和 CGF 空战能力, 通过动态贪婪策略使得 Q 学习算法收敛到最优解, 具有很高的工程应用价值。

1 行为树设置

1.1 行为树

行为树是有限状态机和层次有限状态机的改进, 它在形式上分层呈树形^[5]。行为树中节点类型分为 4 种: 顺序节点、选择节点、条件节点、执行节点。

- 1) 顺序节点(Sequence)。顺序执行所属子节点;
- 2) 选择节点(Selector)。根据规则选择其中一个子节点执行;
- 3) 条件节点(Condition)。判断条件是否成立;
- 4) 执行节点(Action)。执行行为。

行为树一般结构如图 1 所示。其中“?”为选择节点, S 为顺序节点, A 为执行节点, C 为条件节点。

收稿日期: 2017-01-20

基金项目: 国家自然科学基金重大研究计划(91538201); 泰山学者专项基金资助项目(ts201511020)

作者简介: 方君(1979-), 男, 安徽怀宁人, 海军航空工程学院信息融合研究所讲师, 硕士, 研究方向: 作战仿真, 飞行仿真。




图1 一般行为树设置

1.2 CGF 状态空间

考虑空战需要,CGF 状态空间设置为是否接敌、是否面对敌机、弹药数量、健康状态4个环境和自身状态指标。其中弹药数量和健康状态是连续的,因此,将上述4个指标离散化后得到如下状态空间描述:

- 1) 是否接敌: IsAttack(Yes, No) ;
- 2) 是否面对敌机: IsConfront(Yes, No) ;
- 3) 弹药数量: Ammo(None, Low, Medium, High) ;
- 4) 健康状态: Health(None, Low, Medium, High) 。

其中,弹药数量中, None 表示无弹药, Low 表示弹药不足, High 表示弹药充足; 健康状态中, None 表示飞机被摧毁, Low 表示严重毁伤, Medium 表示轻微毁伤, High 表示完好。

1.3 CGF 行为空间

CGF 中飞机具有以下4种自主行为:

- 1) 巡逻(Patrol) : 飞机按照预定路线巡逻;
- 2) 攻击(Attack) : 飞机攻击;
- 3) 转向攻击(TurnAround) : 如果接敌时, 敌人没有视野内, 采用转向方式面对敌人进行攻击;
- 4) 逃跑(Flee) : 在弹药数量和健康状态不理想时, 进行逃逸。

1.4 CGF 行为树设置

考虑状态空间和行为空间, CGF 行为可设置为如图2所示的行为树。其中, CGF 行为执行的条件如表1所示。




图2 CGF 行为树设置

表1 CGF 行为发生条件

行为	条件
巡逻	未接敌, 健康
攻击	接敌, 面对敌机, 有弹药, 健康
转向攻击	接敌, 未面对敌机, 有弹药, 健康
逃跑	接敌, 无弹药, 健康

2 基于 Q-学习的学习过程

2.1 Q-学习




图3 一个与环境交互的 Agent

强化学习能够使 Agent 感知周围环境, 通过学习达到最优的选择策略目的的机器学习方式^[6-8]。它具有延迟汇报、探索、部分可观察状态和终生学习的特点。强化学习的一般流程如图3所示。一个 Agent 生存在环境 S 中, 它通过执行动作 a 作用于环境 S, 环境 S 接收到 Agent 的动作后其状态发生变化, 同时反馈给强化学习系统一个回报值(奖励或惩罚), Agent 感知环境 S 状态和强化学习系统状态选择下一个动作。Agent 执行动作的原则是使得奖励的值最大化。

Q-学习是强化学习的一种。在强化学习中的每个动作的执行都对应相应的 Q 值, 在 Q-学习的过程中, Q 值根据环境反馈的汇报值不断更新, 直到收敛。Q-学习的过程如式(1)所示。

$$Q(s, a) = R(s, a) + \gamma \max_{A'} Q(s', A') \quad (1)$$

其中, $Q(s, a)$ 为评价函数, 它的值是从状态 s 开始并使用 a 作为执行动作时的最大折算累积回报, s 为当前状态, s' 为下一状态, a 为当前执行动作, A 为下一状态所有可能执行的动作集合; $R(s, a)$ 为立即回报序列, γ 为回报因子, 这里 $0 \leq \gamma < 1$ 为常量。因此, Q 的值为状态 s 执行动作 a 的立即回报加上遵循最优策略的值(使用回报因子 γ 计算)。

可以看出, Agent 只需考虑其当前状态 s 下可执行的动作 a, 选择其中使 Q 最大化的动作。

2.2 动态贪婪策略

Q-学习算法的缺点在于容易收敛到局部最优解, 因此本文采用动态贪婪策略(ε-greedy) 解决这一问题^[9-10]。ε 为搜索和应用之间的比例, ε 的值随着搜索的进行做出自适应调整。其表达式为:

$$\epsilon(k) = 1 - \frac{k}{M} \times 0.99 \quad (2)$$

其中, k 为学习次数, M 为总学习次数。当 $k=1$ 时, $\epsilon \approx 1$ 表示学习开始时只搜索不应用; 当 $k=M$ 时, $\epsilon \approx 0$ 表示只应用不搜索; 0.99 是为了避免 ε 取得 0 或者 1 这种无意义的数值。

2.3 学习原则

使用 Q-学习的方法得到收敛后的 Q 表后, 将 Q 表对应到行为树中。在行为树中对每个节点引入 Q 值, 如图4所示。






图 4 行为树中引入 Q 值

对于动作 1, 有 3 个状态与之对应, 分别是 A, B, C, 在顺序节点 S 下, 对 3 个状态按照 Q 值进行排列, 这样行为条件判断过程中, 将按照 Q 值大小进行判断。同时, 对顺序节点 S 赋予最大的状态的 Q 值, 即图 4 中顺序节点 S 的 Q 值应对应状态 C 的 Q 值 9。

子节点排列完毕后, 需要对父节点进行排列, 父节点的 Q 值为子节点 Q 值的最大值, 行为树的节点按照 Q 值由大到小排列, Q 值排列过程示意如图 5 所示。



(a) 父节点 Q 值排列前



(b) 父节点 Q 值排列后

图 5 父节点 Q 值排列

2.4 算法流程

1) 构建基于 Q-学习和行为树的 CGF 空战的初始化模型;

2) 对奖励函数进行更新, 使 Q 值表收敛;

3) 根据 Q 值表更新行为树节点的 Q 值, 若行为树节点有更新, 则继续学习, 若无更新则结束学习, 基于 Q-学习和行为树的 CGF 空战决策模型建立完毕。

3 实验与结果分析

利用某型飞机模拟系统对 CGF 空战决策模型进行学习, 数据来源于飞行员在模拟系统中的训练数据, 并与基于层次有限状态机的 CGF 空战决策模型进行对抗。为叙述方便, 将基于 Q-学习和行为树的

CGF 空战决策模型定义为红方, 将基于层次有限状态机的 CGF 空战决策模型定义为蓝方。

为减少测试时间, 在对抗中, 将红蓝双方设置在钓鱼岛上空 50 平方公里的范围内进行三对三对抗模拟, 定义从对抗开始到其中一方全军覆没为一回合。设置 Q-学习公式 (1) 中: $\alpha = 0.8$, $\gamma = 0.5$ 。100 局内对抗结果如图 6 所示, 图中横坐标为回合数, 纵坐标为红方飞机存活数量, 具体描述为:

- 1) 红方存活数为 0 时, 表示蓝军取胜, 红军全军覆没;
- 2) 红方存活数为 1 时, 表示蓝军全军覆没, 红军存活飞机数为 1;
- 3) 红方存活数为 2 时, 表示蓝军全军覆没, 红军存活飞机数为 2;
- 4) 红方存活数为 3 时, 表示蓝军全军覆没, 红军存活飞机数为 3。




图 6 红蓝对抗中红方存活数量

由图 6 所示, 红方飞机剩余 1 架或 2 架的情况居多, 全军覆没的情况较少, 排除偶然性, 基于 Q-学习和行为树的 CGF 空战决策模型优于基于层次有限状态机的 CGF 空战决策模型。另外, 随着回合数增加, 红方飞机存活数量逐渐增加, 全军覆没的情况逐渐减少, 说明通过 Q-学习和行为树相结合, CGF 空战模型具有较好的学习能力, 增强了 CGF 空战模型行为的智能性。

4 结束语

本文针对飞行模拟中 CGF 空战决策问题, 提出了一种基于 Q-学习和行为树的 CGF 空战行为决策方法。围绕空战决策模拟的 3 个关键问题智能性和学习性展开研究, 通过行为树和 Q-学习分别给出了解决方案, 取得了不错的效果。本算法能够通过初始化训练获得初始智能行为, 并在后期实战训练自我进化, 能够应用到飞行模拟器的研制中。

(下转第 44 页)

采用有向图对整个保障演练规程进行序列化描述。如图9描述了树型有向图结构,图10所示交互规程控件。




图9 树型特征有向图结构




图10 操作规程控件

操作条目采用树型的显示方式,值得注意的是指针是在加载文件后设置的,在保存文件时,必须有另外的变量来标识条目的树型层级关系。

3 结束语

以某型舰船为背景,构建了一套基于PC机的分

布式协同保障模拟训练系统,应用仿真训练平台实现了单人单战位训练、虚拟仿真协同训练、虚实结合训练、训练监控与管理、辅助教学、拆装原理与展示和多种舰面交互保障扩展等功能。应用表明该模拟训练系统,既可以用于部队模拟训练,也可以用于教学训练和专业考核,同时可以实现与其他训练器、模拟器联网使用,是各专业理论学习、设备实习、保障训练、方案推演、保障流程研究与论证中不可缺少的手段。

参考文献:

- [1] 郭广利,高正,孙传伟. 直升机多机协同飞行训练模拟器低成本方案[J]. 系统仿真学报, 2005,17(5): 1097-1100.
- [2] 韩朝阳,左涛,左修伟. 基于活动的模拟训练系统训练需求分析方法[J]. 四川兵工学报, 2011,32(8): 83-85.
- [3] 谢晓钢,安建祝,岳玉芳,等. 分布式仿真训练系统通用开发框架研究[J]. 计算机工程与设计, 2012,33(11): 4283-4287.
- [4] 吴金平,陆铭华,李践飞. 潜艇综合训练仿真系统 HLA 联邦设计与开发研究[J]. 系统仿真学报, 2011,23(3): 486-489.
- [5] 欧海英,于辉,李晓宇. 基于 HLA 和组件技术的仿真训练系统扩展[J]. 系统仿真学报, 2009,21(11): 3273-3276.
- [6] 付战平,周秀芝,于辉,等. 某型飞机飞行训练器的设计与实现[J]. 青岛理工大学学报, 2009,30(2): 75-79.
- [7] 王志乐,于辉,许路航. 基于 ActiveX 的交互视景仿真平台封装的研究与实现[J]. 科学技术与工程, 2009,9(24): 7386-7389.
- [8] 陈青华,谢晓方,高波,等. 虚拟座舱显控系统的分步式仿真[J]. 计算机应用与软件, 2005,22(10): 135-136.
- [9] 严蔚敏. 数据结构[M]. 北京: 清华大学出版社, 1999: 178-200.

(上接第39页)

参考文献:

- [1] 傅莉,李伟. 战机空战决策方法及分析[J]. 沈阳航空航天大学学报, 2013,30(6): 48-52.
- [2] 王凯,李望西,轩永波. 基于 BP 神经网络的空空导弹攻击区解算及其仿真[J]. 弹箭与制导学报, 2010,30(1): 75-77.
- [3] 周锐,陈宗基. 遗传算法在逃逸机动策略中的应用研究[J]. 控制与决策, 2001,16(4): 465-468,472.
- [4] Dey R, Child C. QL-BT: Enhancing behaviour tree design and implementation with Q-learning[C] // IEEE Conference on Computational Intelligence in Games (CIG). 2013: 1-8.
- [5] 米巧丽,贡可荣. 基于行为树与软件故障树的需求缺陷分析[J]. 计算机与数字工程, 2010,38(8): 150-155.
- [6] Wstkins C J C H, Dayan P. Q-learning[J]. Machine Learning, 1992,8(3): 279-292.
- [7] 赵振华,李振龙,于泉,等. 基于切换模型的两交叉口信号灯 Q 学习协调控制[J]. 北京工业大学学报, 2007,33(11): 1148-1152.
- [8] 卢守峰,张术,刘喜敏. 单交叉口多相位在线 Q 学习交通控制模型[J]. 交通科学与工程, 2014,30(1): 72-79.
- [9] Gomes E R, Kowalczyk R. Dynamic analysis of multi-agent Q-learning with ϵ -greedy exploration[C] // Proceedings of the 26th International Conference on Machine Learning. 2009: 369-376.
- [10] Akramizadeh A, Afshar A, Menhaj M B. Exploration strategies in n-person general-sum multiagent reinforcement learning with sequential action selection[J]. Intelligent Data Analysis, 2011,15(6): 913-929.