

江南大学

全日制专业硕士学位论文

题 目： 基于 Q 学习的模型参数未知
固定翼飞行器鲁棒控制

英文并列题目： Robust Control for Fixed-Wing
Aircraft with Unknown Model Parameters
Based on Q-Learning

研 究 生： 林奕宏 专 业 领 域： 控制工程

研 究 方 向： 控制工程及应用

导 师 ① 姓 名： 栾小丽 职 称： 教授

导 师 ② 姓 名： 高丰 职 称： 高级工程师

指导小组成员：

学位授予日期： 2025 年 6 月

答辩委员会主席： 潘丰

江 南 大 学

地址：无锡市蠡湖大道 1800 号

二〇二五年六月

摘要

固定翼飞行器凭借其高速、远航程的优势，在军事侦察、民用运输等领域得到广泛应用。但在极端工况下，强非线性气动耦合现象的存在，增加了系统的复杂性与不确定性。此外，获取风洞试验数据成本高昂，试验环境与实际飞行的复杂条件存在差异，使得风洞数据难以精准地反映飞行器的运行状态。传统鲁棒控制策略高度依赖精确的被控对象数学模型，当面对参数未知的系统模型时，难以确保系统在实际飞行过程中的稳定性与鲁棒性。针对上述问题，围绕模型参数不确定性、有限时间域内的暂态性能优化以及 Q 学习算法的在线学习效率提升三个方面，提出基于 Q 学习的模型参数未知固定翼飞行器鲁棒控制算法，以此提升固定翼飞行器在复杂环境下的鲁棒性能。具体内容如下：

（1）考虑到固定翼飞行器因气动参数时变特性引发模型参数未知的问题，提出一种强化学习与滚动优化深度融合的 H_2/H_∞ 鲁棒控制算法。首先，将 H_2/H_∞ 控制问题转化为以线性矩阵不等式表示的优化问题形式，初步构建求解框架。其次，利用系统的输入输出数据，动态拟合包含系统动态信息的矩阵，再通过最小化混合性能指标迭代优化控制增益。并在每个时间步进行滚动优化，实时调整控制器以适应系统动态变化和扰动影响。该方法通过数据驱动，避免传统鲁棒控制方法对风洞试验数据的先验性依赖，实现对模型参数未知固定翼飞行器在干扰环境下的鲁棒控制。

（2）针对固定翼飞行器在面临短时强约束工况时，传统基于渐近稳定性理论的控制方法存在暂态性能不足的问题，提出一种基于 Q 学习的有限时间鲁棒控制算法。具体而言，利用策略迭代技术，通过系统输入输出数据估计包含系统动力学知识的动态正定矩阵。同时，将有限时间约束条件转化为可数值求解的线性矩阵不等式形式，进而通过求解最小化问题迭代更新得到控制策略。该方法确保系统状态在预定的有限时间内达到并维持在期望轨迹，增强固定翼飞行器在短时强约束复杂工况下的暂态控制性能。

（3）在模型参数未知的固定翼飞行器控制中，为解决 Q 学习方法因受固定学习窗口的限制导致在线学习效率低的问题，提出基于自适应窗口的固定翼飞行器有限时间鲁棒控制策略。定义影响力函数来衡量每个输入输出数据点对学习性能的影响程度。通过数据与学习性能之间的定量关系，筛选出对学习性能有正向贡献的数据。在算法运行过程中，会动态剔除那些产生负向贡献的数据，实现自适应学习窗口来更新控制器参数。该方法充分利用高质量数据，有效避免低质量数据对学习结果的干扰，进而提高有限时间鲁棒控制算法的学习效率，为固定翼飞行器在复杂环境下的稳定控制提供了更可靠的保障。

关键词：固定翼飞行器；模型参数未知；Q 学习；滚动优化；有限时间控制

Abstract

Fixed-wing aircraft, with the advantages of high speed and long range, have been widely applied in fields such as military reconnaissance and civil transportation. However, under extreme working conditions, the existence of strong nonlinear aerodynamic coupling phenomena increases the complexity and uncertainty of the system. In addition, obtaining wind tunnel test data is costly, and there are differences between the test environment and the complex conditions of actual flight, making it difficult for the wind tunnel data to accurately reflect the operating state of the aircraft. Traditional robust control strategies highly rely on an accurate mathematical model of the controlled object. When facing a system model with unknown parameters, it is difficult to ensure the stability and robustness of the system during actual flight. Aiming at the above problems, this paper focuses on three aspects: model parameter uncertainty, transient performance optimization within a finite time domain, and the improvement of the online learning efficiency of the Q-learning algorithm. A robust control algorithm for fixed-wing aircraft with unknown model parameters based on Q-learning is proposed to enhance the robust performance of fixed-wing aircraft in complex environments. The specific contents are as follows:

(1) Considering the problem of unknown model parameters of fixed-wing aircraft caused by the time-varying characteristics of aerodynamic parameters, this chapter proposes an H_2/H_∞ robust control algorithm that deeply integrates reinforcement learning and receding horizon optimization. Firstly, the H_2/H_∞ control problem is transformed into the form of an optimization problem represented by linear matrix inequalities, and a preliminary solution framework is constructed. Secondly, by using the input and output data of the system, a matrix containing the system dynamic information is dynamically fitted, and then the control gain is iteratively optimized by minimizing the mixed performance index. Receding horizon optimization is carried out at each time step, and the controller is adjusted in real time to adapt to the dynamic changes of the system and the influence of disturbances. This method, driven by data, avoids the prior dependence of traditional robust control methods on wind tunnel test data, and realizes the robust control of fixed-wing aircraft with unknown model parameters in a disturbed environment.

(2) Aiming at the problem that when fixed-wing aircraft face short-term strong constraint working conditions, the traditional control method based on the theory of asymptotic stability has insufficient transient performance, this chapter proposes a finite-time robust control algorithm based on Q-learning. Specifically, using the policy iteration technique, a dynamic positive definite matrix containing the knowledge of system dynamics is estimated through the input and output data of the system. At the same time, the finite-time constraint conditions are transformed into the form of linear matrix inequalities that can be numerically solved, and then the control strategy is iteratively updated by solving the minimization problem. This method ensures that the system state reaches and remains on the desired trajectory within the predetermined finite time, enhancing the transient control performance of fixed-wing aircraft under complex working conditions with short-term strong constraints.

(3) In the control of fixed-wing aircraft with unknown model parameters, to solve the problem that the Q-learning method has a low online learning efficiency due to the limitation of the fixed learning window, this chapter proposes a finite-time robust control strategy for fixed-wing aircraft based on an adaptive window. An influence function is defined to measure the influence degree of each input and output data point on the learning performance. Through the quantitative relationship between the data and the learning performance, the data that have a positive contribution to the learning performance are screened out. During the operation of the algorithm, the data that generate negative contributions will be dynamically eliminated, and an adaptive learning window is realized to update the controller parameters. This method makes full use of high-quality data, effectively avoids the interference of low-quality data on the learning results, and thus improves the learning efficiency of the finite-time robust control algorithm, providing a more reliable guarantee for the stable control of fixed-wing aircraft in complex environments.

Keywords: Fixed-wing aircraft; Unknown model parameters; Q-learning; Receding horizon optimization; Finite-time control

目 录

第一章 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	2
1.2.1 固定翼飞行器控制研究现状.....	2
1.2.2 固定翼飞行器强化学习控制研究现状	4
1.3 现有研究的不足.....	5
1.4 本文主要研究内容.....	6
第二章 固定翼飞行器系统描述与控制理论基础	9
2.1 引言.....	9
2.2 固定翼飞行器系统描述.....	9
2.3 H_2/H_∞ 控制方法.....	12
2.4 Q 学习基本算法.....	14
2.5 本章小结.....	15
第三章 基于滚动优化的模型参数未知固定翼飞行器鲁棒控制	17
3.1 引言.....	17
3.2 问题描述.....	17
3.3 基于滚动优化的 Q 学习鲁棒控制算法.....	18
3.4 固定翼飞行器被控系统稳定性分析	22
3.5 仿真示例.....	23
3.6 本章小结.....	27
第四章 考虑短时强约束的固定翼飞行器有限时间鲁棒控制	29
4.1 引言.....	29
4.2 问题描述.....	29
4.3 固定翼飞行器无模型有限时间鲁棒控制	32
4.4 固定翼飞行器被控系统有限时间有界性分析	35
4.5 仿真示例.....	36
4.6 本章小结.....	39
第五章 基于自适应窗口的固定翼飞行器有限时间鲁棒控制	41
5.1 引言.....	41
5.2 问题描述.....	41
5.3 基于影响力函数的学习窗口长度调节	42
5.4 基于自适应窗口的无模型有限时间鲁棒控制	45
5.5 仿真示例.....	46
5.6 本章小结.....	51

第六章 主要结论与展望	53
6.1 主要结论.....	53
6.2 展望.....	53
参考文献.....	55

第一章 绪论

1.1 研究背景和意义

在当今航空技术飞速发展的时代，固定翼飞行器以其独特的优势，在军事和民用领域都展现出了极为广泛的应用前景^[1]。在军事领域，固定翼飞行器作为现代战争中的重要作战装备，承担着诸如空中侦察、精确打击、制空权争夺等关键任务。先进的战斗机能够凭借其高速飞行和强大的武器系统，对敌方目标实施快速有效的打击，为战争的胜利提供有力支持。在民用领域，固定翼飞行器同样发挥着不可或缺的作用，民航客机承担着全球大量的人员和物资运输任务，极大地促进了世界各地的经济交流与合作。此外，在航空测绘、森林防火、应急救援等方面，固定翼飞行器也凭借其高效、灵活的特点，成为保障社会稳定和发展的重要力量^[2]。

然而，当固定翼飞行器遭遇极端工况运行场景时，强非线性气动耦合问题成为制约其系统稳定性与控制性能的关键瓶颈。从系统动力学建模角度分析，在诸如强风切变、大气紊流等极端环境激励下，飞行器所受的气动力与气动力矩呈现出高度复杂的非线性耦合特性，各气动参数之间存在强耦合的非线性映射关系，这使得基于传统线性化假设的飞行器动力学模型难以精确表征其实际运行状态，导致模型失配问题严重。在控制策略设计中，传统的基于精确模型的控制律，如经典的 PID（比例-积分-微分）控制、基于状态空间模型的线性二次型最优控制等，由于对模型精确性的强依赖，在面对此类模型不确定性时，控制算法的鲁棒性与适应性急剧下降，难以实现对飞行器状态变量的精确跟踪控制与干扰抑制，严重威胁飞行安全与任务执行效能。与此同时，风洞试验作为获取飞行器精确气动参数的重要手段，在固定翼飞行器的动力学建模与控制设计流程中占据关键地位。但风洞试验系统的建设、运行与维护成本高昂，且每次试验过程涉及多学科、多环节的协同作业，需要投入大量的人力、物力与时间资源。这不仅限制了对飞行器在全工况、全飞行包线内的气动特性进行全面、深入的研究，也使得依赖风洞试验数据构建精确模型的传统控制策略在实际工程应用中面临巨大的成本与效率挑战^[3,4]。

传统鲁棒控制理论旨在通过设计特定的控制律，使控制系统在存在模型不确定性、外部干扰以及未建模动态等不利因素的情况下，仍能保证闭环系统的稳定性与一定的性能指标。但在固定翼飞行器控制场景下，由于极端工况引发的强非线性、模型参数不确定性以及获取精确模型的困难，传统鲁棒控制策略，如基于 H_∞ 控制理论的鲁棒控制器、滑模控制等，往往难以有效克服模型失配与外部干扰的影响。同时，传统渐近稳定控制方法在应对暂态性能约束方面存在明显局限^[5]，无法满足飞行器在复杂环境下对稳定性、快速性与准确性等多性能指标的严格要求。强化学习控制技术虽然在一定程度上缓解了模型依赖问题，但同样面临诸多困境。在固定翼飞行器的飞行控制中，强化学习控制需要大量的飞行数据来进行模型训练和策略优化^[6]。然而，目前的强化学习控制算法存在学习效率与数据利用率不足的问题。一方面，飞行数据的获取往往受到实际飞行条件、安全限制等因素的制约，难以获得足够全面和大量的数据样本；另一方面，现有的算法

在数据处理过程中,未能充分挖掘数据中的有效信息,导致学习过程缓慢,收敛速度慢,难以快速适应飞行器在复杂环境中的动态变化^[7]。

在此背景下,本研究以固定翼飞行器为研究对象,针对模型参数未知、有限时间暂态性能优化以及 Q 学习算法效率提升的问题,展开深入的讨论和研究。通过提出基于滚动优化的模型参数未知系统鲁棒控制算法,仅依靠飞行器的飞行状态数据和舵面偏转数据,动态逼近系统模型参数,摆脱了传统方法对精确气动模型的依赖。同时,引入滚动优化策略,提高了系统在干扰变化下的鲁棒性,实现了干扰衰减与动态性能的良好平衡,为固定翼飞行器的精准控制提供了全新且有效的解决方案。本研究通过在控制算法上改进的设计,为复杂飞行环境下的固定翼飞行器自主控制提供新的控制算法。这一算法能够提升飞行器在复杂环境下的飞行性能和安全可靠性,具有重要的理论研究价值和实际应用意义。

1.2 国内外研究现状

1.2.1 固定翼飞行器控制研究现状

在全球航空科技持续革新的浪潮中,固定翼飞行器如图 1-1 固定翼飞行器凭借其广泛的应用价值,始终占据着航空领域的核心地位^[8]。以美国、欧洲等为代表的航空发达国家和地区,在固定翼飞行器领域展现出强大的技术实力。在军事方面,美国的 F-35 战斗机无疑是集先进控制技术之大成者^[9,10]。在超视距空战中,通过对雷达、电子战等多信息的融合处理,飞行控制系统可迅速调整飞机姿态,实现对目标的快速锁定与攻击,极大提升了作战效能。在民用航空领域,波音和空客带领着整个行业发展。以波音 787 为例,其在应对强风、紊流气象条件时,控制系统能够快速响应,维持飞机的平稳飞行,为乘客提供舒适、安全的飞行体验^[11,12]。



(a) F-35 战斗机



(b) 波音 787



(c) 歼-20



(d) 国产 C919

图 1-1 固定翼飞行器

近年来,我国在固定翼飞行器领域取得了举世瞩目的成就。在军事方面,歼-20 战斗机的成功彰显了中国航空工业的崛起^[13,14]。歼-20 在复杂电磁环境下,飞行控制系统能够通过智能算法有效抑制干扰,确保飞机稳定飞行的同时,可以实现对目标的精确打击。歼-20 的诞生标志着我国在先进战斗机控制技术领域已迈入世界先进行列。另外,在民用航空领域,国产飞机 C919 的研制是我国航空工业的重大里程碑^[15]。C919 采用先进的电传飞控系统,以电信号传输指令,取代传统机械操控,大幅提升响应速度与控制精度。C919 在应对复杂气流干扰时,能迅速调整机翼和尾翼的控制面,保障飞行稳定性。同时,其研发和生产带动了相关产业的发展,促进了控制工程领域技术的进步和人才培养,为我国航空产业的可持续发展奠定了坚实基础。

近年来,国际上已经有许多研究者发表了关于固定翼飞行器控制问题的文章^[16-18]。Brelje 等学者^[19]明确了固定翼飞行器的动力学建模及结构体系。早期,研究者们受限于理论发展,主要凭借经典控制理论来设计控制律。其中,Mobarez 等人^[20]提出的 PID 控制,凭借其简洁的结构与良好的可操作性,在业界得到了广泛推广与应用。Wenfan 等人^[21]和郑光廷等人^[22]则在此基础上另辟蹊径,通过调整 PID 控制器的参数,实现了对飞行器姿态、速度等关键状态的精准调控,进一步拓展了 PID 控制的应用范畴。Ghiglini^[23]依据实时飞行状况动态调整 PID 参数,将进化群算法这一新兴智能算法引入飞行器 PID 控制领域,为飞行器控制算法设计开辟了全新路径。与此同时,Wendel 等人^[24]成功地自由飞行风洞模型设计出适用于大攻角的控制律,为飞行器在大攻角状态下的控制提供了新的技术途径。不可否认,PID 设计方法在原理的简洁性、适应的广泛性、设计的便捷性以及系统的可靠性等方面有着诸多优势,但其局限性也逐渐显现。传统 PID 控制基于线性模型设计,而固定翼飞行器在实际飞行过程中,受气流、飞行速度、飞行姿态等多种因素影响,呈现出高度的非线性与时间变化特性,这使得传统 PID 控制难以精准应对复杂多变的飞行环境,从而限制了飞行器在一些特殊飞行状态下的性能表现^[25,26]。

固定翼飞行器作为一种典型的非线性、强耦合、时变系统,在飞行控制过程中需应对复杂气动干扰以及外部不确定性等多重挑战^[27-29]。在此背景下,鲁棒控制理论因对系统不确定性具备有效的处理能力,逐渐成为该领域的研究热点。2020 年,Sariyildiz 等人^[30]针对鲁棒控制理论发表综述文章,指出鲁棒控制的核心在于系统参数存在不确定性或遭受外部扰动的情况下,设计出一种能使系统维持稳定性能并实现期望动态响应的控制器。常见的鲁棒控制理论涵盖 H_∞ 鲁棒控制、 μ 综合控制等方法。这些方法通过优化控制器的性能指标,确保系统即便在最坏情况下,依然能够保持稳定的性能^[31]。

H_∞ 鲁棒控制是一种基于频域的设计方法,它通过最小化系统传递函数的 H_∞ 范数,来抑制外部扰动对系统性能的影响^[31,33]。在固定翼飞行器控制中, H_∞ 鲁棒控制被用于设计姿态控制器、轨迹跟踪控制器等,以提高飞行器的抗干扰能力和鲁棒稳定性。例如,Nami 团队^[34]提出将 H_∞ 鲁棒控制与多模型方法结合的新框架,通过频域设计规范明确姿态指令到误差的响应特性,在过渡飞行阶段实现了姿态角波动幅值降低 42%的显著效果。Uyulan^[35]则针对固定翼飞行器的非线性动力学特性,结合结构奇异值分析与 H_∞ 优化,成功处理了模型不确定性问题,并验证了 H_∞ 控制在小型固定翼无人机抗干扰导航中的可

行性。 H_∞ 控制在处理系统不确定性方面展现出独特优势,它能够确保系统在存在外部扰动与参数摄动的情况下,依然保持稳定的性能输出^[36,37]。Ge 等人^[38]基于 H_∞ 线性参数变化设计了一种输出反馈控制器,不仅实现了速度跟踪的鲁棒性,还兼顾了扰动抑制与模型不确定性容限,为气动弹性控制提供了标准化流程。Akyurek^[39]采用 H_∞ 回路成形控制方法,实现了姿态动力学的稳定,为中小型固定翼无人机提供了高性价比的解决方案,该方法已成功应用于欧盟城市物流无人机适航认证项目。

滑模控制作为一种强鲁棒性控制方法,在固定翼飞行器控制领域展现出独特优势。其通过精心设计滑模面与滑模控制律,使系统状态在滑模面上稳定滑动,从而有效抑制系统不确定性和外部扰动。在固定翼飞行器的姿态控制、轨迹跟踪等方面,滑模控制被广泛应用,可显著提高飞行器的控制精度和鲁棒性^[40-42]。Castañeda 等人^[43]创新性地提出了一种基于自适应二阶滑模控制与扩展观测器的复合控制框架,针对固定翼无人机姿态与空速控制问题,在无需扰动先验边界条件下实现了多工况鲁棒稳定。Espinoza^[44]通过设计并对比反步法、滑模控制及其五类复合控制器,实现了固定翼无人机自主飞行中的高度、偏航与横滚控制。Ziquan 等人^[45]的研究则更具前瞻性,他们提出了一种基于分布式滑模估计器、动态面控制架构、神经网络与干扰观测器的自适应容错控制方案,实现了多固定翼无人机在领航机尾涡干扰与部分执行器故障共存场景下的预设时变编队跟踪。这些研究不仅丰富了滑模控制理论,更为固定翼飞行器控制技术的发展提供了新的思路和方法。

传统鲁棒控制方法具有显著缺陷,其高度依赖精确的系统模型^[46]。然而,在实际工程应用中,这些模型通常难以准确获取,有时甚至完全无法获得,这极大地限制了传统鲁棒控制方法在复杂现实场景中的有效应用。为突破这一瓶颈,智能控制方法逐渐在固定翼飞行器控制领域崭露头角,其中模糊控制、神经网络控制及强化学习控制等方向备受关注,成为当前的研究热点^[47,48]。模糊控制通过模拟人类思维中的模糊逻辑,能够对固定翼飞行器的控制问题进行近似处理,有效应对非线性、不确定性以及复杂环境下的控制难题。神经网络控制则利用神经网络强大的学习能力,对飞行器的动态特性进行逼近和学习,从而实现对飞行器的精准控制。强化学习控制更是独辟蹊径,通过让飞行器在与环境的交互过程中自主学习最优控制策略,实现了从数据到控制策略的直接映射,有效降低了对精确模型的依赖程度。

综上所述,固定翼飞行器控制研究经历了从经典控制到现代控制再到智能控制的演变过程。面对复杂环境和模型不确定性的挑战,研究者们不断探索新的控制方法和技术,以提高固定翼飞行器的控制精度、稳定性和鲁棒性。未来,随着控制理论的深入发展和技术的持续革新,固定翼飞行器控制研究将呈现更加多元化和智能化的趋势。

1.2.2 固定翼飞行器强化学习控制研究现状

随着人工智能技术的快速发展,强化学习作为机器学习控制的关键分支,凭借其无需精确模型、适应复杂环境的独特优势,在固定翼飞行器控制领域展现出巨大的应用潜力^[49,50]。强化学习通过让飞行器在与环境的交互中自主学习并优化控制策略,以实现长

期累积奖励的最大化,这种基于试错学习和环境反馈的特性,使其在处理复杂、非线性及不确定性环境下的控制问题时具有显著优势^[51]。

早期强化学习算法研究主要聚焦于 Q 学习、策略梯度方法等基础算法在飞行器模拟环境中的应用探索。研究人员通过构建简化的飞行器模型,开展了一系列仿真试验,旨在验证强化学习算法在飞行器起飞、巡航、着陆等基本飞行阶段的控制效能。近年来,相关研究取得了显著进展。例如, Wang 等人^[52]通过融合深度学习着陆视觉系统与基于记忆强化 TD3 的深度强化学习控制框架,实现了四旋翼无人机在未知地面无车运动动力学条件下的实时视觉跟踪与精准自主着陆。Hung^[53]则借助 Q 学习框架,实现了小型固定翼无人机群在风力扰动、控制噪声等非稳态随机环境下的自主集群协同。这些成果不仅展示了强化学习在处理复杂飞行控制问题上的巨大潜力,也为未来飞行器自主控制技术的发展提供了新的思路和方法。

随着深度学习技术的迅猛发展,深度强化学习在固定翼飞行器控制中的应用已成为该领域的研究热点。深度 Q 网络及其改进算法^[54,55]被广泛应用于更为复杂的飞行场景,如多飞行器协同作战、空中加油等任务。这些算法通过深度神经网络来近似 Q 值函数,能够处理高维的飞行状态空间和复杂的控制任务。Chao 团队^[56]提出了基于深度强化学习的 MA2D3QN 算法,通过融合动态环境状态编码、局部碰撞风险态势图构建、参考点动作选择策略与自适应学习机制,成功实现了固定翼无人机群在 AIoT 网络中的可变规模无碰撞集群飞行。深度强化学习算法通过不断的试错学习过程,能够逐渐掌握飞行器的控制策略,适应多变的飞行状态和环境条件。Shreyas 等人^[57]则通过深度 Q 学习策略的变体,在仅依赖局部邻域信息的条件下,利用信息素地图动态整合区域覆盖历史数据,实现了固定翼无人机群在未知区域搜索任务中覆盖效率与实时基站连接性的协同优化。这些研究成果充分展示了深度强化学习在固定翼飞行器控制领域的巨大潜力,为未来飞行器自主控制技术的发展提供了新的思路和方法。

尽管强化学习在固定翼飞行器控制领域已取得显著成果,但目前仍面临诸多问题亟待解决。首先,强化学习算法的学习效率和稳定性尚需提升,特别是在处理高维状态空间和连续动作空间时,算法性能常受限,导致学习速度减慢、收敛不稳定等问题,影响其实用性。其次,强化学习算法对数据高度依赖,海量训练数据的需求使其在实际应用中面临数据获取与处理的困境,数据不足会限制算法的优化,而数据质量不佳则可能引入噪声,降低策略的有效性。未来研究应聚焦于这些关键问题,深入探索创新的算法架构和优化策略,以提高强化学习在固定翼飞行器控制中的适应性和可靠性,为其自主控制提供更优质、高效的解决方案。

1.3 现有研究的不足

尽管针对固定翼飞行器控制的研究在近年来取得了显著进展,但在面对复杂飞行环境下的模型不确定性以及突发扰动下的收敛延迟等问题时,现有研究依然存在以下的不足。

第一，固定翼飞行器的传统鲁棒控制方法极度依赖精确气动模型。这些模型通常需要通过风洞试验等手段获得，成本高且耗时。此外，由于实际飞行环境的复杂性，这些模型很难覆盖所有可能的情况，导致控制方法在面对未知或变化环境时的适应性不足^[58,59]。尽管部分研究尝试引入自适应控制，但这类方法仍需要依赖参数辨识或专家经验，难以实现完全无模型的动态鲁棒性。

第二，传统渐近稳定理论用于固定翼飞行器控制时存在局限。传统渐近稳定性主要关注系统的无限时间收敛，忽视了系统状态暂态性能的问题。在实际飞行过程中，飞行器可能会遇到突发的强阵风等扰动，这要求控制系统状态在短时间内收敛至目标区域。然而，传统渐近稳定仅保证系统状态随时间趋于无穷大时逼近平衡点，但无法在有限时间内实现精确收敛，导致响应延迟，无法满足高动态任务的实时性需求。

第三，Q 学习在线学习效率低。基于强化学习的固定翼飞行器控制方法虽能缓解模型依赖问题，但存在预设固定学习周期导致的在线学习效率瓶颈，在系统动态特性变化时数据贡献度不同的问题^[60]。预设的固定学习窗口可能包含突风发生前的无效数据，降低控制策略更新速度。这不仅增加了计算负担，还限制了控制方法的实际应用。

综上所述，现有固定翼飞行器控制研究存在对模型精确度依赖性高、渐近稳定理论局限性、强化学习控制的学习效率低等不足。这些问题限制了现有控制方法的性能和应用范围。针对这些问题，提出了基于滚动优化的模型参数未知系统鲁棒控制、短时强约束的无模型系统有限时间鲁棒控制、基于自适应窗口的无模型系统有限时间鲁棒控制等新方法，旨在为复杂飞行环境下的自主控制提供新的方法论基础，并推动固定翼飞行器控制技术的发展和應用。

1.4 本文主要研究内容

以提升固定翼飞行器在复杂动态环境下的控制性能为核心目标展开控制方法的研究。全文共分为六章，章节逻辑紧密衔接，逐层递进，兼顾理论深度与实践验证。具体内容安排如下：

第一章，首先介绍了研究背景和意义。系统梳理固定翼飞行器控制领域的核心问题与研究现状。随后分析了国内外研究现状，涵盖固定翼飞行器控制、强化学习控制以及鲁棒控制等方面，指出当前研究在模型依赖、被控系统渐近稳定、控制算法学习效率低等方面存在的不足，进而明确研究方向。

第二章，叙述固定翼飞行器系统与理论基础。详细介绍了固定翼飞行器的结构和工作原理，能够更好地分析飞行器在不同飞行条件下的性能表现，为控制系统的设计与优化提供重要的参考。同时建立固定翼飞行器的六自由度非线性动力学模型，为后续章节提供理论框架。接着引入 Q 学习理论基础与鲁棒控制基础，为后续章节的研究提供理论支撑。

第三章，探讨基于滚动优化的模型参数未知固定翼飞行器鲁棒控制。固定翼飞行器面临模型参数未知的问题，传统鲁棒控制依赖风洞试验数据。本章提出基于滚动优化的模型参数未知系统鲁棒控制算法，该算法借助飞行器飞行状态数据与舵面偏转数据，采

用策略迭代解算法近似处理系统参数模型，在基于 Q 学习的鲁棒控制中融入滚动优化策略，动态逼近系统模型参数，摆脱先验数据依赖，实现干扰衰减与动态性能的平衡，优化控制律的同时消除模型失配影响，为固定翼飞行器控制提供新方案。最后，通过仿真验证控制方案的有效性。

第四章，考虑到短时强约束的固定翼飞行器无模型有限时间鲁棒控制展开研究。实际飞行中突发强阵风扰动引发收敛时间不可控的问题。本章提出无模型有限时间有界性控制设计方案，通过构建动态正定矩阵描述状态约束边界，将有限时间安全需求转化为矩阵不等式约束。从输入输出数据学习最优控制策略，限制飞行器攻角和角速率，解决传统理论局限，确保突发扰动下飞行器安全飞行，实验验证了该方法能实现短时间内飞行器系统状态受限运动。

第五章，围绕基于自适应窗口的固定翼飞行器无模型有限时间鲁棒控制。强化学习控制时，固定翼飞行器存在预设固定学习周期导致的在线学习效率瓶颈。本章提出基于影响力函数的学习窗口动态调整算法，利用影响力函数构建飞行数据与策略更新定量关系，设计窗口长度自适应策略，根据实际动态调整学习窗口长度，充分利用数据，显著提高模型参数未知系统有限时间鲁棒控制的学习效率，为高效控制提供技术支撑。最后，通过仿真实验验证了该方法的有效性。

第六章，本章对全文进行了总结，回顾了论文的主要研究内容和创新点。然后，对研究过程中遇到的问题和挑战进行了反思，指出了未来的研究方向和可能的改进措施。最后，对本论文的研究成果进行了展望，强调了其在固定翼飞行器控制领域的应用前景和潜在价值。

第二章 固定翼飞行器系统描述与控制理论基础

2.1 引言

固定翼飞行器的外部环境复杂，模型参数不确定性，这对飞行器的控制精度与稳定性提出了极高要求。鲁棒控制确保控制系统在外界干扰的情况下，仍然维持稳定且具备一定性能指标。Q 学习作为一种先进的强化学习方法，通过与环境进行交互来学习最优控制策略，具有强大的自适应能力和鲁棒性。在固定翼飞行器的控制问题中，Q 学习可以应对模型不确定性、气动特性复杂多变等挑战，设计出更加高效、稳定的控制器。

本章将基于固定翼飞行器的系统特性描述，以及 Q 学习算法和鲁棒控制策略的相关理论。通过对这些内容的深入探讨，为后续探索复杂飞行环境下固定翼飞行器的先进控制方法奠定坚实的理论基础。

2.2 固定翼飞行器系统描述

固定翼飞行器是一类通过固定机翼产生空气动力学升力实现飞行的航空器，其核心特点是机翼与机身刚性连接且无需旋转部件。这类飞行器的典型代表包括民航客机、战斗机和货运飞机等。其飞行依赖于机翼与气流的相互作用：当飞行器向前运动时，机翼上下表面的气流速度差异形成压力差，从而产生升力。同时，发动机或螺旋桨提供的推力用于克服空气阻力，维持飞行速度。控制飞行姿态则通过尾翼和机翼上的可动舵面实现，分别调节滚转、俯仰和偏航运动。




图 2-1 固定翼飞行器结构

如图 2-1 所示，机翼是固定翼飞行器产生升力的核心部件，其设计和性能直接影响飞行器的飞行特性。从结构上看，机翼通常由翼梁、翼肋、蒙皮等组成，这些结构部件相互连接，形成一个坚固而轻巧的整体^[61]。翼梁是机翼的主要承力构件，承受着飞行过程中的各种载荷；翼肋则起到维持机翼剖面形状的作用；蒙皮则覆盖在机翼表面，提供光滑的气动外形。机身是固定翼飞行器的主体部分，它连接着机翼、尾翼、起落架和动力系统等各个部件，同时也是搭载人员、货物和设备空间。机身的设计需要综合考虑

多个因素,如结构强度、空气动力学性能、内部空间布局等。水平尾翼由固定的水平安定面和可活动的升降舵组成。水平安定面提供纵向稳定性,使飞行器在飞行过程中保持水平姿态;升降舵则用于控制飞行器的俯仰运动,通过改变升降舵的角度,可以使飞行器抬头或低头。垂直尾翼由固定的垂直安定面和可活动的方向舵组成。垂直安定面提供方向稳定性,使飞行器在飞行过程中保持直线飞行;方向舵则用于控制飞行器的偏航运动,通过改变方向舵的角度,可以使飞行器向左或向右转弯。起落架是固定翼飞行器在起飞、降落和地面滑行时支撑飞行器重量的装置。它不仅要承受飞行器的静态重量,还要承受起飞和降落过程中的动态载荷。动力系统是固定翼飞行器的动力来源,为飞行器提供前进的推力。常见的动力系统有活塞发动机、涡轮喷气发动机、涡轮风扇发动机等。固定翼飞行器的基本构造是其实现飞行功能的物质基础,各组成部分紧密协作,共同保障飞行器的正常运行。

固定翼飞行器的工作原理基于空气动力学和牛顿运动定律,通过各部件的协同工作,实现飞行器的起飞、飞行和降落^[62]。升力是固定翼飞行器能够在空中飞行的关键。根据伯努利原理,当空气流经机翼时,由于机翼上表面的曲率较大,空气流速较快,压力较低;而机翼下表面的曲率较小,空气流速较慢,压力较高。这种压力差产生了向上的升力,使飞行器能够克服重力在空中飞行。推力是固定翼飞行器前进的动力。不同类型的动力系统产生推力的方式不同。对于涡轮喷气发动机和涡轮风扇发动机,它们通过将空气压缩、燃烧后高速喷出,产生向后的气流。根据牛顿第三定律,向后的气流会对发动机产生一个向前的反作用力,即推力。固定翼飞行器的稳定性是保证飞行安全和飞行性能的重要因素。稳定性是指飞行器在受到外界干扰后,能够自动恢复到原来飞行状态的能力。飞行器的稳定性主要包括纵向稳定性、横向稳定性和方向稳定性。纵向稳定性主要由水平尾翼和机翼的设计来保证;横向稳定性主要由机翼的上反角、后掠角和垂直尾翼的设计来保证;方向稳定性主要由垂直尾翼的设计来保证。

综上所述,固定翼飞行器的基本构造和工作原理是一个复杂而又相互关联的系统。深入了解这些知识,对于研究固定翼飞行器的控制问题,具有重要的基础支撑作用。为了对固定翼飞行器系统有更加深入的理解,在仿真时以固定翼 F-18 飞行器^[64]为研究对象,接下来讨论其数学模型。

固定翼 F-18 飞行器的设计旨在满足特殊飞行要求,尤其是大迎角和低动压操作条件。为实现这一目标,固定翼 F-18 飞行器结合了传统空气动力面与额外的推力矢量喷管。传统空气动力面的控制输入涵盖升降舵、副翼、方向舵以及前缘襟翼;而推力矢量喷管在对称偏转时可提供俯仰和偏航力矩,非对称偏转时则能提供滚转力矩。

为便于对固定翼 F-18 飞行器的飞行特性进行分析,需做出以下假设:将飞机视为刚体,假定飞机质量不随时间变化,并且以地球作为固定的惯性参考系。基于这些假设,运用机体轴坐标系和牛顿第二运动定律,可构建固定翼 F-18 飞行器的非线性模型,该模型由六自由度飞机运动方程组成。当飞机处于直线平飞且无加速状态时,这六个方程可解耦为三个纵向方程和三个横向方程。




图 2-2 固定翼飞行器的受力分析示意图

在论文中，仅分析纵向方程，横向动力学也可采用相同方法。图 2-2 固定翼飞行器的受力分析示意图展示了 F-18 飞行器的纵向轴系，其中 X 、 Z 是外力， M 是力矩， U 、 W 是总平移速度 V_T 的坐标分量，与 V_T 对应的总迎角记为 α_T ，俯仰角记为 θ ， Q 表示转动惯量为 I_y 时的角速率。那么，F-18 飞行器的纵向运动方程建模如下：

$$\begin{aligned} m[\dot{U} + QW + g\sin\theta] &= X, \\ m[\dot{W} - QU - g\cos\theta] &= Z, \\ \dot{Q}I_y &= M, \end{aligned} \quad (2.1)$$

其中 m 是飞机质量， g 是重力加速度。

首先，考虑在直线平飞协调飞行的假设下，旋转速率和侧速度为零的配平条件。换句话说，总控制效果恰好抵消作用在 F-18 飞行器上的重力和空气动力及力矩。平衡值由图 2-2 固定翼飞行器的受力分析示意图中带有“0”的变量表示。此外，配平条件的假设意味着 $Q_0=0$ 、 $M_0=0$ 和 $W_0=0$ 。通过力的分解，在配平条件下可得：

$$\begin{aligned} mg \sin\theta_0 &= X_0, \\ -mg \cos\theta_0 &= Z_0. \end{aligned} \quad (2.2)$$

其次，引入平移速度的扰动变量 u 、俯仰角速率的扰动变量 q 以及俯仰角的扰动变量 θ 。将 (2.2) 式以及以下等式：

$$\begin{aligned} U &= U_0 + u, W = w, Q = q, \theta = \theta_0 + \theta, \\ X &= X_0 + \Delta X, Z = Z_0 + \Delta Z, M = \Delta M, \end{aligned} \quad (2.3)$$

代入 (2.1) 式，可得：

$$\begin{aligned} m[\dot{u} + (g\cos\theta_0)\theta] &= \Delta X, \\ m[\dot{w} - qU_0 + (g\sin\theta_0)\theta] &= \Delta Z, \\ \dot{q}I_y &= \Delta M, \end{aligned} \quad (2.4)$$

其中, ΔX , ΔZ 和 ΔM 是关于 u 和 α 的线性函数。注意, 在短时间内速度近似为常数, 即 $\dot{u}=0$ 。响应主要由迎角 α 和俯仰速率 q 决定。本研究不考虑传统空气动力面的对固定翼 F-18 飞行器的影响。因此, F-18 战斗机的纵向线性方程简化为以下形式:

$$\begin{bmatrix} \dot{\alpha} \\ \dot{q} \end{bmatrix} = \begin{bmatrix} Z_{\alpha} & Z_q \\ M_{\alpha} & M_q \end{bmatrix} \begin{bmatrix} \alpha \\ q \end{bmatrix} + \begin{bmatrix} Z_{\delta E} \\ M_{\delta E} \end{bmatrix} \delta_E, \quad (2.5)$$

其中, $\alpha = \alpha_T - \alpha_0$ 。 Z_{α} 、 Z_q 、 M_{α} 和 M_q 是纵向稳定性导数, $Z_{\delta E}$ 和 $M_{\delta E}$ 是纵向控制导数, 它们由飞机结构和飞行条件决定。

在固定翼飞行器的实际飞行过程中, 飞行状态的变化会导致空气动力和质量特性的改变, 而大气环境的复杂多变、风扰动和气流干扰等因素进一步增加了模型参数的不确定性。飞行器的物理特性和空气动力学行为复杂多变, 难以用精确的数学模型全面描述。即使通过大量的实验和理论分析建立的模型, 也可能存在显著的误差和不确定性。这种复杂性使得传统的控制方法在保证飞行器稳定性方面面临挑战。虽然鲁棒控制能够在一定程度上应对不确定性, 但设计一个既具有鲁棒性又具有良好性能的控制器的仍然是一个难题。下面将介绍 H_2/H_{∞} 控制方法和 Q 学习基本算法的基础知识, 为后续提出的算法奠定理论基础。

2.3 H_2/H_{∞} 控制方法

鲁棒控制是闭环系统的关键研究领域, 始于 20 世纪 50 年代, 旨在设计能够在参数摄动和外部干扰下维持特定性能的系统。所谓“鲁棒性”, 是指控制系统在一定的参数摄动下, 维持某些性能的特性。根据对性能的不同定义, 鲁棒性可分为稳定鲁棒性和性能鲁棒性^[65]。以闭环系统的鲁棒性作为目标设计得到的固定控制器称为鲁棒控制器。

本文的研究以 H_{∞} 鲁棒控制为主。 H_{∞} 控制是专门针对一类不确定性系统的控制方法, 用来削弱外部扰动带来的影响。 H_{∞} 控制属于鲁棒控制问题中的一种, H_{∞} 中的“ ∞ ”代表无穷范数, 即扰动传递函数的无穷范数最小, 也即最大幅值最小。




图 2-3 H_{∞} 标准问题框图

图 2-3 由输入信号 u , w 到输出信号 z , y 的传递函数阵称为增广被控对象, 它包括实际被控对象和为了描述设计指标而设定的加权函数等。传递函数阵的状态空间可以写为:

$$\begin{bmatrix} z \\ y \end{bmatrix} = G(s) \begin{bmatrix} w \\ u \end{bmatrix} = \begin{bmatrix} G_{11}(s) & G_{12}(s) \\ G_{21}(s) & G_{22}(s) \end{bmatrix} \begin{bmatrix} w \\ u \end{bmatrix}. \quad (2.6)$$

考虑动态反馈控制器 $u = K(s)y$ 时，可以推导出 w 到 z 的闭环传递函数为：

$$T_{zw} = G_{11}(s) + G_{12}(s)K(s)(I - G_{22}(s)K(s))^{-1}G_{21}(s). \quad (2.7)$$

标准设计问题就是对于给定增广被控对象 $G(s)$ ，判定是否存在反馈控制器 $K(s)$ ，使得闭环系统内部稳定，且使

$$\|T_{zw}(s)\|_{\infty} < \gamma. \quad (2.8)$$

H_2/H_{∞} 控制融合了 H_2 控制与 H_{∞} 控制的优势，旨在同时提升系统的性能与鲁棒性。它通过设计单一控制器，使系统在满足 H_2 范数性能优化的同时，达成 H_{∞} 范数的鲁棒性要求。 H_2 控制专注于最小化系统输出误差的均方值，从而实现最优性能；而 H_{∞} 控制则致力于最小化系统传递函数的 H_{∞} 范数，以增强系统对不确定性及外部扰动的抵御能力。 H_2/H_{∞} 混合控制通过巧妙结合这两种控制策略，使系统在复杂环境下既能保持优良的性能表现，又能有效应对不确定性因素的挑战。




图 2-4 鲁棒 H_2/H_{∞} 混合优化标准控制模型

图 2-4 所对应的公式如下所示：

$$\begin{cases} \dot{x}(t) = Ax(t) + B_1w(t) + B_2u(t) \\ z_{\infty}(t) = C_1x(t) + D_{11}w(t) + D_{12}u(t) \\ z_2(t) = C_2x(t) + D_{21}w(t) + D_{22}u(t) \\ y(t) = C_0x(t) + D_0w(t), \end{cases} \quad (2.9)$$

上述公式中， z_0 对应 $z_{\infty}(t)$ ， z_1 对应 $z_2(t)$ 。

对于以上的被控对象，设计出的输出反馈动态控制器，满足以下设计准则：

- (1) 闭环系统内稳定；
- (2) 闭环传函阵 $G_{z_1w}(s)$ 满足： $\|G_{z_1w}(s)\|_{\infty} \leq \gamma$ ；
- (3) 闭环传函阵 $G_{z_0w}(s)$ 满足： $\min_K \|G_{z_0w}(s)\|_2$ 。

响应得到的控制器 $K(s)$ 则为 H_2/H_{∞} 混合最优控制器。

与强化学习相比, H_2/H_∞ 控制更侧重于系统的稳定性与鲁棒性, 而强化学习则在适应未知环境和动态优化方面具有独特优势。将两者相结合, 可以为复杂系统的控制提供更为全面和高效的解决方案。

2.4 Q学习基本算法

Q 学习是一种基于强化学习的算法, 能够在缺乏先验知识的环境下, 通过与环境的动态交互自主学习最优控制策略^[66]。与传统依赖预先准备数据集的方法不同, Q 学习通过主动探索未知环境和利用已获得的经验, 不断试错、积累数据, 从而自主优化行为策略。其核心思想是利用一个称为 Q 表的数据结构来存储状态-动作对的值, 这些值代表在特定状态下执行某个动作的预期回报。通过持续更新 Q 表, 算法能够逐渐掌握在每个状态下选择何种动作以获得最大的长期累积回报, 进而实现对复杂系统的有效控制。

Q 学习的核心思路在于借助不断地探索, 来得到最优的 Q 值函数。该算法起始于一个初始的 Q 表, 在每一个时间步 t 里, 智能体根据当前所处的状态 s 以及 Q 表的内容来挑选一个行动方案, 接着执行这一动作 a , 并从所处的环境中获取奖励信号以及接下来的状态信息 a' 。随后, 利用所观察到的反馈信息对当前状态下对应动作的 Q 值 $Q(s, a)$ 进行更新操作。经过更新的 Q 表, 能够更精准地对长期奖励进行评估, 进而可以更为有效地指引后续的行动决策。




图 2-5 强化学习基本原理框架

Q 学习算法的核心更新规则如下：

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_a Q(s', a') - Q(s, a)], \quad (2.10)$$

其参数定义如下表：

表 2-1 Q 学习参数定义表

参数	定义
$Q(s, a)$	智能体在当前状态-动作对 (s, a) 得到的延时奖励的折现预期;
r	智能体在当前状态 s 下根据策略选择动作 a 得到的即时奖励;
γ	折扣因子, $0 < \gamma < 1$, 影响当前状态-动作对得到的延时奖励;
α	学习率, $0 < \alpha < 1$;
$\max_a Q(s', a')$	下一状态 s' 下 Q 值的最大值。

在选择动作的过程中，需要用到合适的搜索策略来平衡强化学习中“探索”与“利用”的关系。探索使智能体能够尝试所有可行动作，避免陷入局部最优解；利用使智能体倾向选择之前受到奖励的动作，保证可以获得较高奖励值。在更新 Q 值的过程中，则直接选择下一状态所对应的最大 Q 值，与搜索策略无关。

Q 学习算法的具体步骤为：

算法 2.1: Q 学习算法

```
1  初始化  $Q(s, a)$ 
2  for 序列  $e = 1 \rightarrow E$  do:
3      得到初始状态  $s$ 
4      for 时间步  $t = 1 \rightarrow T$  do:
5          用  $\epsilon$ -贪婪策略根据  $Q$  选择当前状态  $s$  下的动作  $a$ 
6          得到环境反馈的  $r, s'$ 
7           $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_a Q(s', a') - Q(s, a)]$ 
8           $s \leftarrow s'$ 
9      end for
10 end for
```

Q 学习算法作为一种强大的强化学习工具，在多个领域都展现出了广泛的应用前景。其核心优势在于能够在缺乏先验知识的环境中，通过与环境的交互自主学习最优策略，无需依赖预先准备的数据集。这种自主学习能力使得 Q 学习在面对复杂、动态和不确定的系统时具有独特的优势。通过不断地探索和试错， Q 学习算法能够逐步优化行为策略，以实现长期累积回报的最大化。深入理解 Q 学习算法的基本原理和发展方向，有助于把握其在不同场景下的适用性，为解决实际问题提供新的思路和方法。

2.5 本章小结

本章通过对固定翼飞行器系统的深入理解，以及对 Q 学习和鲁棒控制理论的介绍，为后续章节提出的基于滚动优化的鲁棒控制算法、有限时间有界性控制设计方案以及基于影响力函数的学习窗口动态调整算法等研究内容，提供了不可或缺的理论支持和实践基础。

第三章 基于滚动优化的模型参数未知固定翼飞行器鲁棒控制

3.1 引言

固定翼飞行器面临大迎角机动与低动压起降等极端工况的严峻挑战。此类工况下，飞行器呈现出复杂的强非线性气动耦合现象，致使俯仰力矩极性发生反转，同时伴有时变惯量特性与舵效衰减问题^[67]。这一系列复杂特性使得传统依赖精确模型的控制方法难以有效适用^[68]。

鉴于上述问题，本章以固定翼飞行器的纵向运动为具体研究对象，本章提出基于滚动优化的 Q 学习鲁棒控制算法，旨在探索出一种能有效应对模型参数未知情况的固定翼飞行器鲁棒控制方法，避免对显式气动参数的依赖，进一步提高被控系统的鲁棒性。

3.2 问题描述

针对由离散状态空间方程 (2.5) 所表示的固定翼飞行器控制系统，首先阐述基于滚动优化的模型参数未知固定翼飞行器鲁棒控制的基本概念。虽然研究的是模型参数未知的系统，但为便于控制算法的公式推导和分析，先假设系统参数已知。而且在之后的仿真过程中并未用到模型的参数。

该策略可以通过以下数学公式进行表述

$$\begin{aligned} x_{k+1} &= Ax_k + Bu_k + Ew_k, \\ z_k &= Cx_k + Du_k, \end{aligned} \quad (3.1)$$

其中， $x_k \in \mathbb{R}^{n_x}$ 为系统状态， $u_k \in \mathbb{R}^{n_u}$ 为控制输入， $z_k \in \mathbb{R}^{n_z}$ 为被控输出，系统动力学矩阵 A 、 B 、 C 、 D 、 E 为常数矩阵。 $w_k \in \mathbb{R}^{n_w}$ 为有界干扰，且满足

$$\sum_{k=0}^{\infty} w_k^T w_k \leq d^2, d \geq 0. \quad (3.2)$$

在本研究中，每个采样时刻 k 的控制目标是在确保最小化控制输入能量消耗的同时，设计一个实现 H_2/H_∞ 性能的控制器的。

$$u_k = K_k x_k. \quad (3.3)$$

其中， u_k 为控制律， K_k 表示在时刻 k 求解得到的反馈增益，其目的是在满足 H_2 性能要求的同时，最小化从 w_k 到 z_k 的增益。定义一个价值函数 $\Psi \in \mathbb{R}$ 为

$$\Psi = \sum_{k=0}^{\infty} z_k^T z_k + \rho \gamma^2, \quad (3.4)$$

其中， ρ 为加权参数， γ 表示 H_∞ 性能指标。

与传统的基于模型的控制方法不同，本研究提出了一种基于滚动优化的模型参数未知固定翼飞行器鲁棒控制策略。该方法通过直接从测量的输入输出数据中推导最优控制策略，从而有效避免了传统方法对精确系统参数的依赖，显著提升了控制系统的适应性和鲁棒性，为固定翼飞行器的控制提供了更为灵活且高效的新途径，具有重要的理论与应用价值。

3.3 基于滚动优化的Q学习鲁棒控制算法

在本节中, 介绍基于滚动优化的 Q 学习鲁棒控制算法。首先为便于控制算法的公式推导和分析, 先假设固定翼飞行器系统参数已知。然后, 给出了一个定理来描述基于滚动优化的鲁棒控制方法。在此之前, 先引入关于 H_∞ 和 H_2 性能指标的定义。

定义 3.1^[69] 针对离散系统 (3.1), 其中 $w_k \in \mathbb{R}^{n_w}$ 为能量有界外部扰动, $z_k \in \mathbb{R}^{n_z}$ 为被控输出。称系统满足 H_∞ 性能指标 γ , 若在零初始条件下, 对任意 $w_k \in \ell_2[0, \infty)$, 输出满足

$$\|z\|_{\ell_2}^2 = \sum_{k=0}^{\infty} z_k^T z_k \leq \gamma^2 \|w\|_{\ell_2}^2 = \gamma^2 \sum_{k=0}^{\infty} w_k^T w_k. \quad (3.5)$$

定义 3.2^[69] 针对离散系统 (3.1), 其中 $w_k \in \mathbb{R}^{n_w}$ 为能量有界外部扰动, $z_k \in \mathbb{R}^{n_z}$ 为被控输出。称系统满足 H_2 性能, 当输出信号的均方值满足

$$\|z\|_2^2 = \sum_{k=0}^{\infty} z_k^T z_k \leq \alpha. \quad (3.6)$$

定理 3.1 对于线性离散时间系统 (3.1), 在 k 时的控制增益 K_k 可以通过以下问题来求解

$$\mathcal{P}: \min_{X_k, Y_k} \Psi \quad (3.7)$$

$$s.t. \begin{bmatrix} \alpha - \gamma^2 \bar{w}^2 & x_k \\ * & X_k \end{bmatrix} \geq 0, \quad (3.8)$$

$$\begin{bmatrix} -X_k & 0 & X_k A^T + Y_k^T B^T & X_k^T C^T & Y_k^T D^T \\ & -\gamma^2 & E^T & 0 & 0 \\ & * & -X_k & 0 & 0 \\ & * & * & -I & 0 \\ & * & * & * & -I \end{bmatrix} \leq 0, \quad (3.9)$$

其中 $K_k = Y_k X_k^{-1}$, $P_k = X_k^{-1}$ 。

证明: 定义二次函数:

$$V(x) = x^T P x. \quad (3.10)$$

$$J_p = x_{k+1}^T P x_{k+1} - x_k^T P x_k + z_k^T z_k - \gamma^2 w_k^T w_k. \quad (3.11)$$

根据式 (3.3) 可以将 (3.11) 写成

$$J_p = [x_k^T \quad w_k^T] \begin{bmatrix} \Omega & (A + BK_k)^T P E \\ * & E^T P E - \gamma^2 \end{bmatrix} \begin{bmatrix} x_k \\ w_k \end{bmatrix}. \quad (3.12)$$

$$\Omega = (A + BK_k)^T P (A + BK_k) - P + C^T C + K_k^T D^T D K_k \quad (3.13)$$

对于控制系统 (3.1) 来说, 如果 J_p 在 (3.11) 中 k 从 0 到无穷, 这意味着过一段时间之后 $V(x_{k+1}) - V(x_k) < 0$ 。

因此, 当 k 趋近于无穷时 $V(x_{k+1})$ 将为 0。把 $K_k = Y_k X_k^{-1}$, $P_k = X_k^{-1}$ 带入 (3.9) 可以看到 (3.9) 等价于 $J_p < 0$ 。然后, 可以通过将 $J_p < 0$ 从 $k = 0$ 相加到 $k \rightarrow \infty$ 得到

$$x_\infty^T P x_\infty - x_0^T P x_0 + \sum_{k=0}^{\infty} [z_k^T z_k - \gamma^2 w_k^T w_k] \leq 0. \quad (3.14)$$

当 $k \rightarrow \infty$, 之后 $x_\infty^T P x_\infty \rightarrow 0$ 。对于初始条件 $x_0 = 0$, 有

$$\sum_{k=0}^{\infty} z_k^T z_k \leq \sum_{k=0}^{\infty} \gamma^2 w_k^T w_k, \quad (3.15)$$

即可以满足 H_∞ 的性能要求。

接下来, 将 $J_p < 0$ 从 $k = i$ 相加到 $k = \infty$ 得到

$$x_\infty^T P x_\infty - x_i^T P x_i + \sum_{k=i}^{\infty} [z_k^T z_k - \gamma^2 w_k^T w_k] \leq 0. \quad (3.16)$$

假定 $x_\infty^T P x_\infty \rightarrow 0$ 很容易推导出 $V(k) + \gamma^2 \bar{w}^2 \geq x_i^T P_i x_i + \gamma^2 \sum_{k=i}^{\infty} w_k^T w_k \geq \sum_{k=i}^{\infty} z_k^T z_k$ 。这就给出了 H_2 性能的上限。

然后通过定义 3.1, 让上界满足

$$x_k^T P_k x_k + \gamma^2 \bar{w}^2 \leq \alpha. \quad (3.17)$$

这就等于公式 (3.8)。正如上文所示, 通过优化问题 $\mathcal{P}$ 实现了对价值函数 (3.4) 的优化, 证明完成。

在固定翼飞行器的控制领域, 当系统参数已知时, 传统的控制方法能够较为容易地解决问题。然而, 实际应用场景中存在一个关键问题, 通过风洞试验获取的数据, 在真实飞行场景中的置信度较低^[70]。鉴于此, 提出了一种基于滚动优化的模型参数未知固定翼飞行器鲁棒控制算法。

与传统方法不同, 这一创新性的设计思路仅依赖于实际测量的数据, 而不需要精确的系统模型。这不仅降低了对系统模型精确性的要求, 还提高了算法在实际应用中的鲁棒性和适应性, 为固定翼飞行器的控制提供了新的解决方案。为了方便对所提算法的理解, 接下来将给出引理。

引理 3.1^[71] (Schur 补引理) 在对称矩阵 $F(x) = \begin{bmatrix} Q(x) & S(x) \\ S^T(x) & R(x) \end{bmatrix}$ 中, 若 $Q(x) = Q^T(x)$,

$S(x)$ 与 $R(x) = R^T(x)$ 均为关于 x 的仿射函数, 那么下列三个条件等价

- (1) $F(x) < 0$;
- (2) $Q(x) < 0, R(x) - S^T(x)Q(x)^{-1}S(x) < 0$;
- (3) $R(x) < 0, Q(x) - S(x)R(x)^{-1}S^T(x) < 0$.

引理 3.2^[72] 考虑二次函数

$$f(a, b) = \begin{bmatrix} a^T & b^T \end{bmatrix} \begin{bmatrix} X_{11} & X_{12} \\ X_{12}^T & X_{22} \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix}, \quad (3.18)$$

具有常数矩阵的 $X_{11} = X_{11}^T \in R^{p \times p}$, $X_{22} = X_{22}^T \in R^{q \times q}$ 。之后有

$$\begin{aligned} \text{(i)} \quad \max_{\forall b; X_{22} < 0} f(a, b) &= a^T (X_{11} - X_{12} X_{22}^{-1} X_{12}^T) a \\ &\geq a^T X_{11} a. \end{aligned} \quad (3.19)$$

$$\begin{aligned} \text{(ii)} \quad \max_{\forall b; X_{22} < 0} f(a, b) &= a^T (X_{11} - X_{12} X_{22}^{-1} X_{12}^T) a \\ &\leq a^T X_{11} a. \end{aligned} \quad (3.20)$$

在 (i) 和 (ii) 这两种情况下, 具有最优值 $b^* = -(X_{22}^{-1} X_{12}^T)$ 。

接下来, 将对基于滚动优化的 Q 学习鲁棒控制算法进行阐述。该算法将 Q 学习方法引入其中, 从而有效消除了对显式系统动力学模型的依赖。针对问题 $\mathcal{P}$, 借助预测控制的滚动优化策略加以解决。在每个时刻, 学习过程持续进行, 使得控制器能够依据当前状态及时调整系统, 以实现系统状态的精准控制。

在此基础上, 推导出一个线性矩阵不等式公式, 用于估计控制目标。然而, 在算法的最终实现阶段, 仅需利用系统的测量状态和控制输入即可完成控制任务。因此, 为了确保算法的有效实施, 首先假设能够获取整个固定翼飞行器系统的状态测量值。

首先, 可以将 (3.11) 重写成一个矩阵-向量的二次形式

$$J_p = \xi_k^T G_p^\gamma \xi_k, \quad (3.21)$$

其中 $\xi_k^T = [x_k^T \quad u_k^T \quad w_k^T]$,

$$G_p^\gamma = \begin{bmatrix} \Phi = A^T P_k A - P_k + C^T C & A^T P_k B & A^T P_k E \\ * & B^T P_k B + D^T D & B^T P_k E \\ * & * & E^T P_k E - \gamma^2 \end{bmatrix}. \quad (3.22)$$

二次函数 J_p 对应用控制 u_k 的依赖关系可以在方程 (3.21) 中观察到。 H_2/H_∞ 控制问题的目标是确定最优控制 $u_k = K_k x_k$, 在最小化 γ 的同时, 确保约束 $J_p < 0$ 的实现。然而, 获得最优控制 $u_k = K_k x_k$ 需要使用矩阵 G_p^γ , 它包括不可获得的系统矩阵。

为了解决以上问题, 提出基于 Q 学习的无模型 H_2/H_∞ 预测控制算法, 在不使用系统参数矩阵的情况下, 使用系统响应数据 $\{x_k\}$, $\{z_k\}$, $\{u_k\}$, $\{w_k\}$ 来估计当前稳定控制策略的矩阵 G_p^γ 。为了实现这一点, 定义一个与 (3.21) 中与 J_p 有相同结构的二次函数

$$Q_H = \xi_k^T H \xi_k, \quad (3.23)$$

其中 $H \in \mathbb{R}$ 。

然后, 从公式 (3.21) 和 (3.23) 可以看出, 这两个矩阵 G_p^γ 和 H 具有相同的结构, 并且 G_p^γ 和 H 都是关于 x_k 、 u_k 、 w_k 的二次函数。

因此, 对于给定的 γ , 可以对于给定的 P 和 γ , 对于给定的 $u_k = K_k x_k$, 可以从等式 $Q_H = J_p$ 中找到矩阵 H 。从 $Q_H = J_p$, 得到以下 N 个公式

$$\begin{cases} \xi_1^T H \xi_1 = J_p(x_1, w_1) \\ \xi_2^T H \xi_2 = J_p(x_2, w_2) \\ \vdots \\ \xi_n^T H \xi_n = J_p(x_n, w_n). \end{cases} \quad (3.24)$$

在公式 (3.24) 中, 为了满足 $Q_H = J_p$ 的条件, 需要方程的数量 N 足够大, 并且干扰 w_k 应充分激励系统。通过使用式 (3.24), 可以基于数据 $\{x_k\}_{k=1}^{N+1}, \{z_k\}_{k=1}^N, \{u_k\}_{k=1}^N, \{w_k\}_{k=1}^N$ 来找到矩阵 $Q_H = J_p$, 而无需系统矩阵的信息。

解决了这个问题后, 按照上述步骤, 可以用矩阵 H 代替矩阵 G_p^Y , 从而得到一种新的改进控制 $u_k = K_{new}x_k$, 在满足 $J_p < 0$ 的同时最小化增益 γ 。

接下来, 引入一个优化问题来学习参数 H 并在每一个时刻求解控制输入。这个优化问题是由定义 3.1 中的混合 H_2/H_∞ 预测控制的问题 $\mathcal{P}$ 推导而来的。对于参数未知的系统, 可以利用采样数据 $\{x_k\}, \{z_k\}, \{u_k\}, \{w_k\}$, 其中 k 的取值应足够丰富, 通过以下问题

$$\mathcal{P}_1: \min_{P, H_k} \Psi \quad (3.25)$$

$$\text{s.t. } x_k^T P_k x_k + \gamma^2 \bar{w}^2 \leq \alpha, \quad (3.26)$$

$$x_{k+1}^T P x_{k+1} - x_k^T P x_k + z_k^T z_k - \gamma^2 w_k^T w_k \leq 0, \quad (3.27)$$

$$\begin{bmatrix} \varepsilon & Q_H - J_p \\ * & \varepsilon \end{bmatrix} \geq 0, \quad (3.28)$$

其中 $P > 0$, H 、 α 、 γ 是决策变量, ρ 是给定的权重常数, ε 是一个足够小的值。

但显然, 对于问题 $\mathcal{P}_1$ 中不包含任何系统参数。正如公式 (3.26) 所示, 在每一个 k 时刻, 根据系统状态通过求解优化问题 $\mathcal{P}_1$, 实现一次滚动优化策略, 在线求解控制器, 进一步提高算法的鲁棒性。在不同的时间步, 会根据新的测量数据和系统状态更新这些优化问题的参数和约束条件, 重新求解以得到当前最优的控制输入。这种在每个时间步都进行优化的方式, 利用滚动优化不断滚动进行局部优化的特点, 通过不断更新优化来适应系统的动态变化。

采用 w_k 足够丰富这一条件, 意味着它对系统的干扰足以逼近最坏情况下的干扰。一个足够丰富的 w_k 应该具有多个频率分量和幅值上的多种变化, 实际中一个较好的选择是随机信号。

此外, 由于系统动力学矩阵未知, 仅通过系统测量状态和控制输入很难一次性找到 $\mathcal{P}_1$ 的最优解。所以, 本研究使用策略迭代方法来迭代求解。在本文中, 当前控制策略指的是控制律 $u_k = Kx_k$ 中的当前反馈矩阵 K 。下面的策略迭代方法是针对给定 w_k 求解 (3.25) 中最小化问题 $\mathcal{P}_1$ 的方案。

由于 $Q_H = J_p$ 是一个非线性方程, 因此很难直接求解。为了简化问题, 利用线性矩阵不等式的可处理性将 $Q_H = J_p$ 近似为 $|Q_H - J_p| \leq \varepsilon$, 其中 ε 是一个足够小的正数。

这将问题转化为一个线性矩阵不等式, 可以用现有的求解器来求解^[73], 得到满足约束条件的矩阵 H 。接下来, 将公式 (3.23) 中的矩阵 H 分解为

$$H := \begin{bmatrix} H_{xx} & H_{xu} & H_{xw} \\ * & H_{uu} & H_{uw} \\ * & * & H_{ww} \end{bmatrix}, \quad (3.29)$$

并令 $\begin{bmatrix} \bar{H}_{xx} & \bar{H}_{xu} \\ * & \bar{H}_{uu} \end{bmatrix} \& := \begin{bmatrix} H_{xx} & H_{xu} \\ * & H_{uu} \end{bmatrix} - \begin{bmatrix} H_{xw} \\ H_{uw} \end{bmatrix} H_{ww}^{-1} [H_{xw}^T \ H_{uw}^T]$ 。

然后, 因为 $Q_H = J_p < 0, \forall w_k$ 。由于 u_k 和 w_k 是相互独立的, 得到

$$\begin{aligned} & \min_{u_k} \{Q_H(x_k, u_k, w_k), \forall w_k\} \\ &= \min_{u_k} \max_{w_k} Q_H(x_k, u_k, w_k) \\ &= \min_{u_k} \max_{w_k} [x_k^T \ u_k^T \ w_k^T] H \begin{bmatrix} x_k \\ u_k \\ w_k \end{bmatrix} \\ &= \min_{u_k} [x_k^T \ u_k^T] \begin{bmatrix} \bar{H}_{xx} & \bar{H}_{xu} \\ * & \bar{H}_{uu} \end{bmatrix} \begin{bmatrix} x_k \\ u_k \end{bmatrix} \\ &= x_k^T (\bar{H}_{xx} - \bar{H}_{xu} \bar{H}_{uu}^{-1} \bar{H}_{xu}^T) x_k. \end{aligned} \quad (3.30)$$

根据引理 3.1, 可以计算出 u_k 的最优值 u_k^* 由

$$u_k^* = K^* x_k; K^* = -\bar{H}_{uu}^{-1} \bar{H}_{xu}^T \quad (3.31)$$

得到。最后, 得到基于滚动优化的 Q 学习鲁棒控制算法。

为了获得系统响应, 将控制 $u_k = Kx_k + v_k$ 应用于系统, 然后获得数据集 $\{x_k\}_{k=1}^{m+1}, \{z_k\}_{k=1}^m, \{u_k\}_{k=1}^m, \{w_k\}_{k=1}^m$ 。这里, $v_k (v_k \approx 0)$ 是为持续激励系统而添加的可忽略探测噪声。最后, 得到基于滚动优化的 Q 学习鲁棒控制算法如下。

算法 3.1: 基于滚动优化的 Q 学习鲁棒控制算法

- 1 初始化: 加权参数 ρ , 初始学习窗口 m , 初始控制增益 K_0 ;
 - 2 while $k \in \mathbb{N}_{[0, m-1]}$ do
 - 3 采用控制策略 $u_k = K_0 x_k + v_k$ 采集系统数据 $\{x_i\}_{i=0}^m, \{z_i\}_{i=0}^{m-1}, \{u_i\}_{i=0}^{m-1}, \{w_i\}_{i=0}^{m-1}$;
 - 4 If $k = 0, 1, \dots, m$ do
 - 5 根据定理 3.1 求解优化问题 $\mathcal{P}_1$, 获取矩阵 H_k ;
 - 6 得到 $u_k = -\bar{H}_{uu}^{-1} \bar{H}_{xu}^T x_k$;
 - 10 end if
 - 11 将 u_k 应用于系统, 设置 $k = k + 1$, 获得数据 $\{x_k\}, \{z_{k-1}\}, \{u_{k-1}\}, \{w_{k-1}\}$;
 - 12 end while
-

3.4 固定翼飞行器被控系统稳定性分析

本节将给出基于滚动优化的 Q 学习鲁棒控制算法的系统稳定性分析。

定理 3.2 考虑初始控制增益为 K_0 的无模型的有限时间预测控制算法, 并假设扰动 w_k 和观测噪声 v_k 足以用 $v_k \approx 0$ 持续激发系统。如果式 (3.25) 在 ε 是一个足够小的正数

时可行, 那么控制量 $u_k = Kx_k$ 在算法 3.1 的每次迭代中都是稳定的。对于选定的 w_k , 存在由输入输出数据从式 (3.25) 中获得的最优值 γ_{opt} 和 K_{opt} 。

证明: 注意 $u_k = Kx_k + v_k$ 中的探测噪声 v_k 可以忽略不计, 因此在证明中将其忽略。更新后的控制 $u_k = Kx_k$ 使得 Q_H 最小, 由此可得

$$Q_H(x_k, u_k, w_k)|_{u_k=K(k)x_k} \leq Q_H(x_k, u_k, w_k)|_{u_k=K(k-1)x_k}. \quad (3.32)$$

在 $\varepsilon \approx 0$ 的条件下, 这等价于

$$N_k(x_k, w_k) \leq N_{k-1}(x_k, w_k) \leq 0. \quad (3.33)$$

结合 $N(k) < 0$, 这意味着系统是稳定的, 只要 $u_k = K_k x_k$ 能使闭环系统稳定, 那么 $u_k = K_{k+1} x_k$ 就能使闭环系统稳定。

所以, 如果 $u_k = K_0 x_k$ 能使系统稳定, 那么 $u_k = K_k x_k$ 就能使系统稳定。与上述稳定性证明类似, 这意味着存在 $\gamma_{(k+1)} \leq \gamma_{(k)}$ 。因此, 依赖于所施加的 w_k , γ_{opt} 和 K_{opt} 是式 (4.22) 的最优解。证明完成。

3.5 仿真示例

在本节中, 将固定翼 F-18 飞行器系统选定为仿真案例, 验证基于滚动优化的 Q 学习鲁棒控制算法在 F-18 飞行器系统参数未知条件下的优势。

为构建准确的仿真模型, 首先依据公式 (2.5), 对 F-18 飞行器的纵向线性方程进行处理。考虑到实际研究需求和计算复杂度, 将原本复杂的方程转化为更易于分析和计算的形式。该简化过程充分考虑了飞行器在飞行过程中的关键动力学特性和影响因素, 在保留主要特征的同时, 去除对整体性能影响较小的部分。简化后的方程具体表述如下

$$\dot{x} = \begin{bmatrix} Z_\alpha & Z_q \\ M_\alpha & M_q \end{bmatrix} x + \begin{bmatrix} Z_{\delta E} \\ M_{\delta E} \end{bmatrix} u, \quad (3.34)$$

其中 $x = [\alpha \quad q]^T$ 为系统状态向量。

在本节研究中, 为充分证明基于滚动优化的 Q 学习鲁棒控制算法的有效性, 需要借助从风洞试验和飞行试验中获取的空气动力学数据。通过对这些数据进行深入分析和处理, 能够得到固定翼飞行器在模型参数已知情况下的最优值。虽然这些模型参数能够证明算法的有效性, 但在基于滚动优化的 Q 学习鲁棒控制算法的仿真过程中, 并不会实际使用 F-18 飞行器的系统参数。

本节主要探讨 F-18 飞机在马赫数为 0.8、飞行高度为 10 千英尺的稳定运行状态下的线性化纵向动力学问题^[74]。通过对这一特定工况的研究, 可以评估算法在实际飞行条件下的控制性能和效果。

$$\begin{aligned} x_{k+1} &= \begin{bmatrix} -1.675 & 0.9853 \\ -16.16 & -1.212 \end{bmatrix} x_k + \begin{bmatrix} -0.2449 \\ -28.34 \end{bmatrix} u_k + \begin{bmatrix} 1 \\ 0 \end{bmatrix} w_k, \\ z_k &= [1 \quad 0] x_k. \end{aligned} \quad (3.35)$$


在实现基于滚动优化的 Q 学习鲁棒控制算法时,需要进行采样的状态信息。在飞行过程中,传感器被用来测量实时的攻角和俯仰率。每个传感器上都安装有一个产生采样周期 h 的时钟的 A/D 转换器,以处理传感器的输出。


然后,将采样状态 α 和 q 提供给数字计算机,从而计算系统的控制输入端 δ_E 。考虑到稳定性、计算成本和传输带宽等因素,选择了固定的采样频率 2 Hz,即 $h = 0.5 \text{ s}$ 。同时,假设控制器和采样状态是同步刷新。为模拟实际飞行中存在的干扰因素,分别选用方差为 1 和 10^{-6} 的零均值白噪声随机信号作为 u_k 和 v_k 。其中,方差为 1 的信号 u_k 用于模拟相对较强的干扰,而方差为 10^{-6} 的信号 v_k 则代表微弱的干扰。这些干扰信号的引入,能够更真实地反映飞行器在复杂环境下的运行情况,有助于评估基于滚动优化的 Q 学习鲁棒控制算法的鲁棒性。对于算法中的其他相关参数如表 3-1 参数初始值所示。

表 3-1 参数初始值

参数	赋值
学习窗口 m	300
加权参数 ρ	100
x_0	$[7 \ 2]^T$
初始控制增益 K_0	$[-0.1 \ 0.1]$


为了评估基于滚动优化的 Q 学习鲁棒控制算法的性能,将其与传统无模型 H_∞ 控制方法进行对比。在相关仿真结果图中,红色直线代表本章提出的基于滚动优化的 Q 学习鲁棒控制算法。而蓝色直线对应的是传统无模型 H_∞ 控制方法。以下是得到的模型参数未知的固定翼 F-18 飞行器控制性能的仿真结果图。这些图从控制增益的变化、系统状态轨迹以及 H_∞ 性能的趋势。通过对这些直观可视化的结果进行分析,可以看出基于滚动优化的 Q 学习鲁棒控制算法的有效性。


图 3-1 x_1 状态轨迹


 图 3-2 x_2 状态轨迹

x_1 为状态变量攻角，从图 3-1 固定翼飞行器的 x_1 状态轨迹图可知，基于滚动优化的 Q 学习鲁棒控制算法下，状态变量攻角初始值约为 7，随后快速下降，在 6.32 s 时收敛至约 5，并保持稳定。而传统无模型鲁棒控制下的状态变量攻角，在 0-25 s 内，虽有波动变化，但始终未能收敛到一个稳定值。

x_2 代表俯仰角速度，再看图 3-2 的 x_2 状态轨迹图，基于滚动优化的 Q 学习鲁棒控制算法，俯仰角速度初始值约为 2，迅速减小，在 4.36 s 时就收敛到 0 并维持稳定。反观传统无模型鲁棒控制，在 25 s 的时间范围内，俯仰角速度不仅没有收敛，还呈现出较大的波动，表现出不稳定的特性。由此可见，基于滚动优化的 Q 学习鲁棒控制算法在状态变量的收敛速度和稳定性上，均显著优于传统无模型鲁棒控制。



 图 3-3 K_1 的控制增益的趋势

图 3-4 K_2 的控制增益的趋势

从图 3-3 和图 3-4 中固定翼飞行器的控制增益随时间变化曲线可以看出，基于滚动优化的 Q 学习鲁棒控制算法在学习步数达到 2100 步时，控制增益 K_1 趋于稳定，稳定值约为 -0.4035；在学习步数达到 1500 步时，控制增益 K_2 趋于稳定，稳定值约为 0.5631。

与之相比，传统无模型鲁棒控制在参数稳定的速度和最终的增益取值上均不如基于滚动优化的 Q 学习鲁棒控制算法。在整个学习过程中，传统无模型鲁棒控制的增益参数变化相对较为迟缓，且最终稳定值与基于滚动优化的 Q 学习鲁棒控制算法得到的 $K = [-0.4035 \quad 0.5631]$ 存在一定差距，并且提出的算法更接近模型参数已知时的最优值 $K_{opt} = [-0.4054 \quad 0.5762]$ 。

对于模型参数未知的固定翼飞行器，基于滚动优化的 Q 学习鲁棒控制算法在增益学习方面效果显著优于传统无模型鲁棒控制，其得到的增益值 K 也更趋近于模型参数已知情况下的控制最优值，展现出更好的控制性能。

图 3-5 H_∞ 性能的趋势

在模型参数已知的情况下，固定翼飞行器闭环系统的 H_∞ 干扰抑制水平最优值为 $\gamma_{opt} = 1.5026$ 。从图 3-5 展示的 H_∞ 性能随时间变化趋势可以清晰看到，基于滚动优化的 Q 学习鲁棒控制算法最终得到的 γ 值为 1.5122，相较于传统无模型 H_∞ 控制算法得到的 γ 值，该算法得到的结果与最优值 1.5026 更为接近。

此外，在收敛速度方面，基于滚动优化的 Q 学习鲁棒控制算法也展现出明显优势。在学习初期，传统无模型 H_∞ 控制算法的 γ 值下降较为缓慢，且波动较大；而基于滚动优化的 Q 学习鲁棒控制算法的 γ 值迅速下降，并在约 1000 步时就趋于稳定，明显快于传统无模型 H_∞ 控制算法的收敛速度。这表明本章所提出的基于滚动优化的 Q 学习鲁棒控制算法在 H_∞ 性能优化上更具优势。

3.6 本章小结

本章创新性地提出了基于滚动优化的 Q 学习鲁棒控制算法方法。此算法避免了对风洞试验数据的先验依赖，仅依靠飞行器实时的输入输出数据，就能实现对系统动态特性的动态逼近。在具体实现环节，采用策略迭代解算法对飞行器的系统参数模型进行近似处理，同时引入滚动优化策略至基于 Q 学习的 H_2/H_∞ 控制中。通过仿真表明，在模型参数未知情况下学习到最优控制增益。该算法提升了飞行器在面对模型不确定性时的控制性能与鲁棒性。

第四章 考虑短时强约束的固定翼飞行器有限时间鲁棒控制

4.1 引言

固定翼飞行器执行低空侦察任务时,若突遇强阵风,飞行器的飞行姿态会瞬间发生剧烈变化。传统的渐近稳定理论,虽在飞行器的长期稳定控制方面有一定成效,但在应对此类突发扰动下的暂态性能问题时,暴露出明显的局限性。第三章提出的滚动优化鲁棒控制算法在模型参数未知条件下实现了对固定翼飞行器的鲁棒控制,但无法保证系统状态在预定的有限时间内达到并维持在期望轨迹。

本章将深入研究面向固定翼飞行器的短时强约束无模型有限时间控制,通过构建动态正定矩阵,将有限时间安全需求转化为可求解的矩阵不等式约束形式,并直接从测量所得的输入输出数据中学习最优控制策略,克服传统理论和算法的局限性,为固定翼飞行器在极端扰动下的高可靠控制提供理论支持与技术解决方案。

4.2 问题描述

针对由离散状态空间方程 (2.5) 所表示的固定翼 F-18 飞行器控制系统,首先阐述无模型有限时间控制策略的基本概念。

虽然本文研究的是无模型控制系统,但为便于控制算法的公式推导和分析,先假设系统参数已知。该策略可以通过以下数学公式进行表述

$$\begin{aligned} x_{k+1} &= Ax_k + Bu_k + Ew_k, \\ z_k &= Cx_k + Du_k, \end{aligned} \quad (4.1)$$

其中, $x_k \in \mathbb{R}^{n_x}$ 为系统状态, $u_k \in \mathbb{R}^{n_u}$ 为控制输入, $z_k \in \mathbb{R}^{n_z}$ 为被控输出, 系统动力学矩阵 A 、 B 、 C 、 D 、 E 为常数矩阵。 $w_k \in \mathbb{R}^{n_w}$ 为有界干扰, 且满足

$$\sum_{k=0}^{\infty} w_k^T w_k \leq d^2, d \geq 0. \quad (4.2)$$

在本研究中,每个采样时刻 k 的目标是设计一个无模型有限时间控制器,确保有限时间稳定性的同时满足 H_2/H_∞ 性能指标。

$$u_k = K_k x_k, \quad (4.3)$$

其中, u_k 为控制律, K_k 表示在时刻 k 求解得到的反馈增益,其目的是在满足有限时间性能指标的同时,最小化从 w_k 到 z_k 的增益。

下面将引入有限时间有界和有限时间稳定的定义来证明本文的算法。

定义 4.1^[75] 针对离散时间系统 (4.1) 是关于 (c_1, c_2, R, N, d) 的有限时间有界, 其中 $x_k \in \mathbb{R}^{n_x}$, $u_k \in \mathbb{R}^{n_u}$, $\sum_{k=0}^{\infty} w_k^T w_k \leq d^2$, $d \geq 0$ 分别表示状态量、控制输入和外部扰动。当且仅当满足以下条件:

(1) $0 < c_1 < c_2$, $R > 0$ 为对称正定加权矩阵, $N \in \mathbb{Z}_{k \geq 0}$ 为时间窗口长度, δ 为扰动上界。

(2) 对任意满足 $x_0^T R x_0 \leq c_1$ 的初始状态 x_0 , 存在控制策略 $u_k = K(x_k)$, 使得

$$x_k^T R x_k \leq c_2, \forall k \in \{1, 2 \dots N\}, \quad (4.4)$$

且在扰动作用下仍保持该约束。

定义 4.2^[75] 系统 (4.1) 是关于 $(c_1, c_2, R, N, \gamma, d)$ 的有限时间稳定且具有扰动衰减水平 γ ，其中 $0 < c_1 < c_2, R > 0, \gamma > 0$ ，当满足以下条件：

(1) 在零初始条件 ($x_0 = 0$) 下，对任意允许扰动序列 $\{w_k\}$ ，输出满足

$$\|z\|_2^2 = \sum_{k=0}^N z_k^T z_k \leq \alpha, \quad (4.5)$$

其中 $\alpha = \gamma^2 \|w\|_2^2 + \beta, \beta \geq 0$ 为系统固有能量耗散项。

(2) 存在标量 $\gamma > 0$ 使得

$$\sum_{k=0}^N z_k^T z_k \leq \gamma^2 \sum_{k=0}^N w_k^T w_k. \quad (4.6)$$

(3) 若非零初始状态 $x_0^T R x_0 \leq c_1$ ，需同时满足状态轨迹约束

$$x_k^T R x_k \leq c_2, \forall k \in \{1, 2 \dots N\}. \quad (4.7)$$

接下来，提供了线性离散时间系统 (4.1) 的 H_2/H_∞ 有限时间稳定分析。然后，建立了线性矩阵不等式条件，证明了系统具有有限时间有界性，输出值 z_k 和 w_k 满足约束条件 (4.6)。

定理 4.1 对于 $(c_1, c_2, R, N, \gamma, \mu, d)$ ，如果存在标量 $\mu \geq 1, c_2 \geq 0, \gamma \geq 0$ ，以及对称正定矩阵 P ，使得以下不等式成立，则线性离散时间系统 (4.1) 是 H_2/H_∞ 有限时间稳定的

$$\begin{bmatrix} \Omega & * \\ E^T P(A+BK) & E^T P E - \gamma^2 \mu^{-N} I \end{bmatrix} < 0, \quad (4.8)$$

$$\lambda_{\max}(\tilde{P}_1) c_1^2 + \mu^{-N} \gamma^2 \bar{w}^2 < \lambda_{\min}(\tilde{P}_1) \mu^{-N} c_2^2, \quad (4.9)$$

其中 $\Omega = (A+BK)^T P(A+BK) - \mu P + \begin{bmatrix} C \\ DK \end{bmatrix}^T \begin{bmatrix} C \\ DK \end{bmatrix}$ 。

证明：定义一个二次函数

$$V(x) = x^T P x. \quad (4.10)$$

由有限时间有界性可以推断

$$\begin{aligned} & V(x_{k+1}) - \mu V(x_k) \\ &= N(k) + \gamma^2 w^T(k) w(k) - z^T(k) z(k), \end{aligned} \quad (4.11)$$

其中 $N(k)$ 可以写成

$$N(k) = \begin{bmatrix} x(k) \\ w(k) \end{bmatrix}^T \psi \begin{bmatrix} x(k) \\ w(k) \end{bmatrix}. \quad (4.12)$$

其中 $\psi = \begin{bmatrix} \Omega & * \\ E^T P(A+BK) & E^T P E - \gamma^2 \mu^{-N} I \end{bmatrix}^{\circ}$

对两边进行累加, 可得

$$\begin{aligned} -x^T(k)Px(k) &= \sum_{k=0}^{\infty} [-z^T(k)z(k) + \gamma^2 w^T(k)w(k)] \\ &\quad + \sum_{k=0}^{\infty} N(k). \end{aligned} \quad (4.13)$$

如果 $\sum_{k=0}^{\infty} N(k) \leq 0$ 且 $x(k) = 0$, 则满足 H_{∞} 性能 $\sum_{k=0}^{\infty} [z^T(k)z(k) - \gamma^2 w^T(k)w(k)] \leq 0$ 。

在 $\sum_{k=0}^{\infty} N(k) \leq 0$ 的条件下, 则满足 H_2 性能 $\sum_{k=0}^{\infty} [z^T(k)z(k)] \leq x^T(k)Px(k) + \gamma^2 \bar{w} \leq \alpha$ 。

设 $V((x(k), w(k))) = x^T(k)P_1x(k) + w^T(k)P_2w(k)$, 简单计算表明 (4.8) 式意味着

$$V((x(k+1), w(k+1))) < \mu V((x(k), w(k))), \quad (4.14)$$

其中 $x(k+1)$ 和 $w(k+1)$ 是根据系统 (4.1) 的解通过计算得到的。

对 (4.14) 式进行迭代, 可得

$$V((x(k), w(k))) < \mu^k V((x(0), w(0))), k = 1, \dots, N. \quad (4.15)$$

现在, 令 $\tilde{P}_1 = R^{-1/2}P_1R^{-1/2}$, 并且利用 $\mu \geq 1$ 这一事实, 可得

$$\begin{aligned} \mu^k V((x(0), w(0))) &= \mu^k [x^T(0)P_1x(0) + w^T(0)P_2w(0)] \\ &\leq \mu^k [\lambda_{\max}(\tilde{P}_1)x^T(0)Rx(0)] \\ &\quad + \lambda_{\max}(P_2)w^T(0)w(0) \\ &\leq \mu^N [\lambda_{\max}(\tilde{P}_1)c_1^2 + \lambda_{\max}(P_2)d^2], \end{aligned} \quad (4.16)$$

以及

$$\begin{aligned} V((x(k), w(k))) &= x^T(k)P_1x(k) + w^T(k)P_2w(k) \\ &\geq x^T(k)P_1x(k) \\ &\geq \lambda_{\min}(\tilde{P}_1)x^T(k)Rx(k). \end{aligned} \quad (4.17)$$

将 (4.15)、(4.16)、(4.17) 式联立, 可得

$$\begin{aligned} x^T(k)Rx(k) &< \frac{1}{\lambda_{\min}(\tilde{P}_1)} [\lambda_{\max}(\tilde{P}_1)c_1^2 + \lambda_{\max}(P_2)d^2] \mu^N. \end{aligned} \quad (4.18)$$

由式结合定义 4.2 可以得出, (4.9) 式意味着对于所有 $k = 1, 2, \dots, N$, $x^T(k)Rx(k) < \epsilon^2$ 。证明已完成。

定义一个价值函数 $\Phi \in \mathbb{R}$ 为

$$\Phi = \sum_{k=0}^{\infty} z_k^T z_k + \rho \gamma^2, \quad (4.19)$$

其中, ρ 为加权参数, γ 表示 H_{∞} 性能指标。

4.3 固定翼飞行器无模型有限时间鲁棒控制

为解决系统状态超出预设边界的问题，提出了无模型有限时间鲁棒控制算法。本节介绍了一个为具有未知参数的线性离散时间系统设计的 Q 学习有限时间预测控制算法的推导。该算法利用 Q 学习，消除了显式系统动力学的影响。

首先，将 (4.12) 式改写为矩阵-向量二次型

$$N(k) = \xi_k^T G_p^{\gamma, \mu} \xi_k, \quad (4.20)$$

其中 $\xi_k^T = [x_k^T \quad u_k^T \quad w_k^T]$ ，以及 $G_p^{\gamma, \mu} = \begin{bmatrix} \psi & * \\ E^T P(A + BK) & E^T P E - \gamma^2 \mu^{-N} I \end{bmatrix}$ 。

从 (4.20) 式可以观察到二次函数 $N(k)$ 对所应用控制 u_k 的依赖关系。有限时间预测控制问题的目标是确定最优控制 $u_k = K_k x_k$ ，在确保满足有限时间控制约束 $N(k) \leq 0$ 的同时，最小化 (4.19) 式。

然而，要获得使 Ψ 最小化的最优控制 $u_k = K_k x_k$ ，需要用到矩阵 $G_p^{\gamma, \mu}$ ，但其中包含目前无法获取的系统矩阵。

因此，借助第一章中提到的无模型控制设计技术，该技术不需要精确的系统模型，仅依赖于系统运行过程中可获取的输入输出数据。给出一种适用于固定翼 F-18 飞行器系统的无模型有限时间预测控制器设计方法的推导过程。

为实现该算法，定义一个与 (4.20) 式子中有相同结构的二次函数

$$Q_H(x_k, u_k, w_k) := \xi_k^T H_k \xi_k, \quad (4.21)$$

其中 $H \in \mathcal{R}$ 。然后，从 (4.20) 和 (4.21) 式子可以看出，矩阵 $G_p^{\gamma, \mu}$ 和 H_k 结构相同。因此，对于给定的 P 、 γ 、 μ ，对于给定的 $u_k = K_k x_k$ ，可以从等式 $Q_H = N(k)$ 中找到矩阵 H_k 。由 $Q_H = N(k)$ ，可以得到以下方程组

$$\begin{cases} \xi_1^T H_k \xi_1 = N(1) \\ \xi_2^T H_k \xi_2 = N(2) \\ \vdots \\ \xi_m^T H_k \xi_m = N(m), \end{cases} \quad (4.22)$$

其中， m 是学习窗口长度。

在 (4.22) 式中，为满足 $Q_H = N(k)$ 的条件，需要 $N(k)$ 的方程数量足够多，并且干扰 w_k 应该能充分激励系统。

利用 (4.22) 式，可以基于数据 $\{x_k\}_{k=1}^{m+1}$ ， $\{z_k\}_{k=1}^m$ ， $\{u_k\}_{k=1}^m$ ， $\{w_k\}_{k=1}^m$ 找到矩阵 $Q_H = N(k)$ ，而无需系统矩阵的信息。解决此问题后，按照上述步骤，使用矩阵 H_k 代替矩阵 $G_p^{\gamma, \mu}$ ，以获得新的改进控制 $u_k = K_{new} x_k$ ，该控制算法在满足 $N(k) < 0$ 的同时最小化增益 γ 。

接下来，构建定理来求解每个时刻的参数 H_k 和控制输入。

定理 4.2 对于参数未知的固定翼 F-18 飞行器控制系统 (4.1)，如果存在标量 $\mu \geq 1$ ，

$c_2 \geq 0$, $\gamma \geq 0$ 以及对称正定矩阵 P , 以及通过 Q 学习得到的参数矩阵 H_k , 使得以下线性矩阵不等式成立

$$\begin{cases} \begin{bmatrix} \varepsilon & Q_H(x_k, u_k, w_k) - N(x_k, u_k, w_k) \\ \star & \varepsilon \end{bmatrix} \geq 0 \\ N(k) \leq 0, k = 1, 2, \dots, m \\ \begin{bmatrix} \alpha - \gamma^2 \bar{w} & \star \\ x_k & Q \end{bmatrix} \geq 0 \\ \begin{bmatrix} \mu^{-N}(c_2^2 - \gamma^2 \bar{w}^2) & \star \\ c_1 & 1 \end{bmatrix} \geq 0, \end{cases} \quad (4.23)$$

其中, ε 表示为一个足够小的正数, $\bar{w}$ 是干扰上界, $Q_H(x_k, u_k, w_k)$ 和 $N(x_k, u_k, w_k)$ 分别是系统约束函数和学习得到的二次函数。在这种情况下, 学习得到的矩阵 H_k 可以满足代价函数 (4.19)。利用学习得到的矩阵 H_k , 可以计算出相应的控制输入。

证明: 对于系统 (4.1), k 时刻的控制增益 K_k 可以通过以下规划问题求解

$$\mathcal{P}_2: \min_{P, Q, \alpha, \gamma, \mu} \Phi \quad (4.24)$$

$$\text{s. t. } \begin{bmatrix} \alpha - \gamma^2 \bar{w} & \star \\ x(k) & Q \end{bmatrix} \geq 0, \quad (4.25)$$

$$\begin{bmatrix} \mu^{-N}(c_2^2 - \gamma^2 \bar{w}^2) & \star \\ c_1 & I \end{bmatrix} \geq 0, \quad (4.26)$$

$$\begin{bmatrix} -\mu Q & 0 & \star & \star & \star \\ 0 & -\mu^{-N} \gamma^2 & \star & \star & \star \\ (AQ + BY) & E & -Q & \star & \star \\ CQ & 0 & 0 & -I & \star \\ DY & 0 & 0 & 0 & -I \end{bmatrix} \leq 0, \quad (4.27)$$

其中 $K = YQ^{-1}$, $Q = P^{-1}$ 。根据 (4.8) 式, 可以改写为

$$\begin{aligned} \psi = & \begin{bmatrix} -P & 0 \\ 0 & -\gamma^2 I \end{bmatrix} + \begin{bmatrix} (A + BK)^T \\ E^T \end{bmatrix} P \begin{bmatrix} (A + BK)^T \\ E^T \end{bmatrix} \\ & + \begin{bmatrix} (DK) \\ 0 \end{bmatrix} \begin{bmatrix} (DK)^T \\ 0 \end{bmatrix} + \begin{bmatrix} C \\ 0 \end{bmatrix} \begin{bmatrix} C^T \\ 0 \end{bmatrix}. \end{aligned} \quad (4.28)$$

通过引理 3.1, 得到

$$\begin{bmatrix} P^{-1} & 0 & \star & \star & \star \\ 0 & \gamma^2 & \star & \star & \star \\ (A + BK) & E & P^{-1} & \star & \star \\ C & 0 & 0 & I & \star \\ DK & 0 & 0 & 0 & I \end{bmatrix} \geq 0. \quad (4.29)$$

同样地, 利用引理 3.1, $\sum_{k=0}^{\infty} [z^T(k)z(k)] \leq x^T(k)Px(k) + \gamma^2 \bar{w} \leq \alpha$ 可以转换成

$$\begin{bmatrix} \alpha - \gamma^2 \bar{w} & * \\ x(k) & Q \end{bmatrix} \geq 0, \quad (4.30)$$

然后 (4.9) 式可以转换成

$$\begin{bmatrix} \mu^{-N}(c_2^2 - \gamma^2 \bar{w}^2) & * \\ c_1 & n \end{bmatrix} \geq 0, \quad (4.31)$$

其中, n 是一个常数。

由于 $Q_H = N(k)$ 是一个非线性方程, 直接求解较为困难。故将 $Q_H = N(k)$ 近似为 $|Q_H - N(k)| \leq \varepsilon$, 其中 ε 是一个足够小的正数。

这将问题转化为线性矩阵不等式问题, 可使用现有求解器求解^[73], 以获得满足约束条件的矩阵 H_k 。利用学习得到的矩阵 H_k , 可以计算相应的控制输入, 并通过策略迭代更新控制策略, 逐步逼近最优控制策略。证明完毕。

同样通过求解上述问题, 可以得到学习得到的矩阵 H_k 。可以用到第一章中提到的方法将矩阵 H_k 分解为

$$H_k := \begin{bmatrix} H_{xx} & H_{xu} & H_{xw} \\ * & H_{uu} & H_{uw} \\ * & * & H_{ww} \end{bmatrix}, \quad (4.32)$$

$$\text{并且令 } \begin{bmatrix} \bar{H}_{xx} & \bar{H}_{xu} \\ * & \bar{H}_{uu} \end{bmatrix} \&:= \begin{bmatrix} H_{xx} & H_{xu} \\ * & H_{uu} \end{bmatrix} - \begin{bmatrix} H_{xw} \\ H_{uw} \end{bmatrix} H_{ww}^{-1} [H_{xw}^T & H_{uw}^T].$$

由于 $Q_H = N(k) \leq 0$, 对于任意 w_k , 有 $H_{ww} < 0$ 。因此, 考虑到 u_k 和 w_k 是相互独立的, 有

$$\begin{aligned} & \min_{u_k} \{Q_H(x_k, u_k, w_k), \forall w_k\} \\ &= \min_{u_k} \max_{w_k} Q_H(x_k, u_k, w_k) \\ &= \min_{u_k} \max_{w_k} [x_k^T \quad u_k^T \quad w_k^T] H \begin{bmatrix} x_k \\ u_k \\ w_k \end{bmatrix}. \\ &= \min_{u_k} [x_k^T \quad u_k^T] \begin{bmatrix} \bar{H}_{xx} & \bar{H}_{xu} \\ * & \bar{H}_{uu} \end{bmatrix} \begin{bmatrix} x_k \\ u_k \end{bmatrix} \\ &= x_k^T (\bar{H}_{xx} - \bar{H}_{xu} \bar{H}_{uu}^{-1} \bar{H}_{xu}^T) x_k \end{aligned} \quad (4.33)$$

根据引理 3.2, 可以推断出 u_k 的最优值 u_k^* 为

$$u_k^* = K^* x_k; K^* = -\bar{H}_{uu}^{-1} \bar{H}_{xu}^T. \quad (4.34)$$

为了获得系统响应, 将控制 $u_k = Kx_k + v_k$ 应用于系统, 然后获得数据集 $\{x_k\}_{k=1}^{m+1}$, $\{z_k\}_{k=1}^m$, $\{u_k\}_{k=1}^m$, $\{w_k\}_{k=1}^m$ 。这里, $v_k (v_k \approx 0)$ 是为持续激励系统而添加的可忽略探测噪声。

最后, 得到无模型有限时间预测控制算法如下。

算法 4.1: 无模型有限时间鲁棒控制

```

1  初始化: 加权参数  $\rho$ , 初始学习窗口  $m$ , 初始控制增益  $K_0$ , 有限时间参数  $c_1, c_2, \mu, N$  初始控制增益  $K_0$ ;
2  while  $k \in \mathbb{N}_{[0, m-1]}$  do
3      采用控制策略  $u_k = K_0 x_k + v_k$  采集系统数据  $\{x_i\}_{i=0}^m, \{z_i\}_{i=0}^{m-1}, \{u_i\}_{i=0}^{m-1}, \{w_i\}_{i=0}^{m-1}$ ;
4      If  $k = 0, 1, \dots, m$  do
5          根据定理 3.1 求解优化问题  $\mathcal{P}_1$ , 获取矩阵  $H_k$ ;
6          得到  $u_k = -\bar{H}_{uu}^{-1} \bar{H}_{xu}^T x_k$ ;
10     end if
11     将  $u_k$  应用于系统, 设置  $k = k + 1$ , 获得数据  $\{x_k\}, \{z_{k-1}\}, \{u_{k-1}\}, \{w_{k-1}\}$ ;
12 end while

```

4.4 固定翼飞行器被控系统有限时间有界性分析

本节将进行固定翼飞行器无模型有限时间鲁棒控制有限时间有界性分析。

定理 4.3 考虑具有初始稳定控制增益 K_0 的算法。假设选择两个信号 w_k 和 v_k 来持续激发系统, $v_k \approx 0$ 一个零均值白噪声信号, 用于模拟实际系统中的测量误差。如果控制输入 $u_k = Kx_k$ 是有限时间界的。

证明: 首先定义一个李亚普诺夫函数 $V(x) = x^T P x$, 其中, P 是一个对称的正定矩阵。根据有限时间稳定性的定义, 有 (4.13)。

如果 $\sum_{k=0}^{\infty} N(k) \leq 0$ 和 $x_k = 0$, 则满足 H_{∞} 性能: $\sum_{k=0}^N z_k^T z_k - \gamma^2 \sum_{k=0}^N w_k^T w_k \leq 0$ 。在 $\sum_{k=0}^{\infty} N(k) \leq 0$ 的条件下, 则 H_2 性能得到满足: $\sum_{k=0}^{\infty} [z^T(k)z(k)] \leq x^T(k)Px(k) + \gamma^2 \bar{w} \leq \alpha$ 。

根据引理 3.1 和引理 3.2, 可以证明

$$V(x_{k+1}) \leq \mu V(x_k). \quad (4.35)$$

迭代上述不等式, 得到

$$V(x_k) \leq \mu^k V(x_0), k = 1, 2, \dots, N. \quad (4.36)$$

由于 P 是一个正定矩阵, 而 $V(x) > 0$, 所以有

$$x_k^T R x_k \leq \mu^k V(x_0). \quad (4.37)$$

最终得到

$$x_k^T R x_k \leq \epsilon^2. \quad (4.38)$$

其中 ϵ 是一个足够小的正数。如果优化问题 (4.23) 有一个解, 则闭环系统的状态轨迹在有限的时间内是有界的, 证明完成。

4.5 仿真示例

在本节的仿真研究中，选用固定翼 F-18 飞行器系统作为仿真对象，该系统的离散状态空间方程如公式 (3.34) 所示。本次研究的核心目的在于，通过仿真全面且直观地展现固定翼飞行器无模型有限时间鲁棒控制算法的有效性。

为了对比无模型有限时间鲁棒控制算法与其他算法的效果，需要从风洞试验以及飞行试验所获取的数据中，提取精确的空气动力学数据。这些数据主要用于佐证所提出算法的有效性。但在整个仿真过程中，并未实际采用固定翼 F-18 飞行器的具体系统参数，以此突出算法的无模型特性。

本节着重探讨 F-18 飞机在马赫数为 0.8、飞行高度为 12 千英尺这一稳定运行状态下的线性化纵向动力学问题，相关理论依据参考文献^[74]。通过对这一特定工况的研究，能更精准地评估算法在实际应用场景中的性能表现。

$$x_{k+1} = \begin{bmatrix} -1.562 & 0.9862 \\ -14.96 & -1.132 \end{bmatrix} x_k + \begin{bmatrix} -0.2316 \\ -26.48 \end{bmatrix} u_k + \begin{bmatrix} 1 \\ 0 \end{bmatrix} w_k. \quad (4.39)$$

$$z_k = [1 \quad 0] x_k.$$

在本节仿真中，为模拟实际环境中的干扰因素，对信号 u_k 和 v_k 分别选用零均值白噪声随机信号。其中，赋予信号 u_k 的零均值白噪声随机信号方差为 1，这相对较大的方差意味着该信号将引入较为显著的干扰波动；而信号 v_k 所采用的零均值白噪声随机信号方差设定为 10^{-6} ，此极小的方差表示该信号带来的干扰幅度极为微小。此外，对于其他相关参数如表 4-1 参数初始值 所示，这些参数的精确设定对于整个系统的模拟和分析起着关键作用。

表 4-1 参数初始值

参数	赋值
学习窗口 m	300
加权参数 ρ	100
初始控制增益 K_0	$[-0.1 \quad 0.1]$
N	8
c_1	1
c_2	5
μ	1.01
x_0	$[1.5 \quad 0.9]^T$

为充分验证无模型固定翼飞行系统在特定控制算法下的控制效果，将所提出的无模型有限时间控制算法与基于滚动优化的 Q 学习鲁棒控制方法进行对比分析。在下列图示中，红色线条代表本章所提的无模型有限时间控制算法的状态变化和控制增益等。从图中可以观察到，该算法下系统相关参数的变化趋势具有一定的规律。而蓝色线条对应的基于滚动优化的 Q 学习鲁棒控制方法，呈现出与红色线条不同的变化特点。通过对二者线条走势、波动情况、收敛速度等多方面的对比，可以直观地看出两种控制方法在对无模型固定翼飞行系统控制过程中的差异，从而为评估无模型有限时间控制算法的有效性提供直观且有力的依据。




图 4-1 开环系统的状态轨迹






图 4-2 闭环系统的状态轨迹

图 4-1 展示了固定翼 F-18 飞行器开环系统的状态轨迹，图 4-2 则呈现了其闭环系统的状态轨迹。在图 4-1 中，代表开环系统状态的曲线（标记为 x ），在运行过程中明显穿越了由 c_1 和 c_2 所界定的给定上界范围，这表明开环固定翼 F-18 飞行器系统无法在有限时间内将状态保持在特定界限内，不满足有限时间有界性的条件。

相比之下，图 4-2 在应用了控制器后，闭环系统的状态轨迹（同样标记为 x ）始终被限制在由 c_1 和 c_2 界定的范围内，说明闭环控制系统能够在有限时间内将系统状态维持在特定界限内，满足有限时间有界性。这一对比清晰地展现出，本章所提出的无模型有限时间鲁棒控制算法能够有效约束固定翼 F-18 飞行器系统的状态轨迹，使其满足有限时间有界性要求，验证了该算法的有效性。

图 4-3 K_1 的控制增益的趋势图 4-4 K_2 的控制增益的趋势

在固定翼飞行器系统参数已知的前提下，其闭环系统控制增益的最优值为 $K_{opt} = [-0.5574 \quad 0.4183]$ 。这一数值为评估不同控制算法的性能提供了重要参考。从图 4-3 关于控制增益 K_1 随学习步数变化的曲线来看，红色曲线代表的无模型有限时间鲁棒控制算法，初始值约为-0.1。该算法在学习步数达到 2100 步时， K_1 就趋于稳定，最终稳定值约为-0.5126。而蓝色曲线所示的传统无模型鲁棒控制算法，起始值同样接近-0.1，但其下降过程较为缓慢，且需更多步数才趋向稳定。很明显，无模型有限时间鲁棒控制算法对 K_1 的学习效率要远高于传统算法。

再看图 4-4 中控制增益 K_2 的变化情况，两种算法在开始阶段的学习进度相近，无模型有限时间鲁棒控制算法和基于滚动优化的 Q 学习鲁棒控制的 K_2 初始值分别都为 0.15。随着学习步数的增加，无模型有限时间鲁棒控制算法在 3000 步左右时， K_2 达到稳定，稳定值约为 0.4284；基于滚动优化的 Q 学习鲁棒控制算法随后也趋于稳定，但其稳定值

略低于无模型有限时间鲁棒控制算法。尽管在 K_2 的学习速度上二者差异不大，但无模型有限时间鲁棒控制算法最终得到的 K_2 值更接近最优值 0.4183。




图 4-5 H_∞ 性能的趋势

在固定翼飞行器系统参数已知的条件下，其闭环系统的 H_∞ 干扰抑制水平最优值为 $\gamma_{opt} = 1.8026$ 。观察图 4-5 中 H_∞ 性能随学习步数的变化趋势，红色曲线代表的无模型有限时间鲁棒控制算法，在学习过程中迅速下降，在大约 1500 步时就趋近稳定，最终稳定值约为 1.8749。而蓝色曲线所示的基于滚动优化的 Q 学习鲁棒控制算法下降过程相对缓慢，稳定值高于无模型有限时间鲁棒控制算法。

由此可见，无模型有限时间鲁棒控制算法在收敛速度上略快于基于滚动优化的 Q 学习鲁棒控制算法，能够更快地达到接近最优值的状态，而且其最终获得的 γ 值 1.8749 相较于基于滚动优化的 Q 学习鲁棒控制算法更趋近于最优值 1.8026，充分表明本章所提出的无模型有限时间鲁棒控制算法能够实现更优的 H_∞ 性能指标，在抑制干扰方面表现更为有效。

4.6 本章小结

本章考虑到固定翼飞行器在短时强约束的难题，提出了基于 Q 学习的无模型有限时间鲁棒控制算法。通过构建时变正定矩阵，将有限时间有界性约束转化为动态线性矩阵不等式，克服传统渐近稳定方法无限时间域的局限性。

仿真结果清晰地表明，短时强约束无模型有限时间控制算法确保固定翼飞行器的系统状态轨迹能实现受限运动。本章提出的短时强约束无模型有限时间控制算法，显著提升固定翼飞行器的鲁棒性，适用于高动态复杂环境下的精确控制需求。

第五章 基于自适应窗口的固定翼飞行器有限时间鲁棒控制

5.1 引言

在固定翼飞行器的无模型控制领域, Q 学习算法通过数据驱动特性有效降低了模型依赖性, 但其预设固定学习周期导致在线学习效率低的问题。尽管第四章提出的有限时间鲁棒控制算法通过动态约束机制提升了扰动抑制的时效性, 但实际飞行中持续采集的输入输出数据存在显著的信息重叠现象。传统方法采用固定时间窗口进行经验回放, 无法动态评估数据价值与学习目标的关联度。

本章提出一种基于影响力函数的无模型有限时间鲁棒控制, 它通过构建飞行数据与策略更新之间的定量关系, 设计出能够根据实际情况自适应调整学习窗口长度的策略, 从而实现对动态数据的高效筛选和利用。核心思想在于构建数据影响力函数, 量化当前数据集对性能指标的梯度贡献率。通过动态调节窗口长度, 当贡献度低时, 将数据周期缩短, 为固定翼飞行器在复杂飞行环境下实现高效控制提供支撑。

5.2 问题描述

针对由离散状态空间方程 (2.5) 所表示的固定翼飞行器控制系统, 首先阐述自适应 Q 学习窗口鲁棒控制策略的基本概念。

虽然研究的是无模型控制系统, 但为便于控制算法的公式推导和分析, 先假设系统参数已知。该策略可以通过以下数学公式进行表述

$$\begin{aligned} x_{k+1} &= Ax_k + Bu_k + Ew_k, \\ z_k &= Cx_k + Du_k, \end{aligned} \quad (5.1)$$

其中, $x_k \in \mathbb{R}^{n_x}$ 为系统状态, $u_k \in \mathbb{R}^{n_u}$ 为控制输入, $z_k \in \mathbb{R}^{n_z}$ 为被控输出, 系统动力学矩阵 A 、 B 、 C 、 D 、 E 为常数矩阵。 $w_k \in \mathbb{R}^{n_w}$ 为有界干扰, 且满足

$$\sum_{k=0}^{\infty} w_k^T w_k \leq d^2, d \geq 0. \quad (5.2)$$

在本研究中, 为 Q 学习算法设定一个学习窗口, 从而不仅可以估计固定翼 F-18 飞行器控制系统的参数矩阵, 同时基于最大化影响力函数对 Q 学习算法选择最优的学习窗口长度, 使得在系统模型信息发生干扰的情况下能选择最优学习窗口长度。最后实现在每个采样时刻 k 的目标是设计一个自适应 Q 学习窗口鲁棒控制器

$$u_k = K_k x_k, \quad (5.3)$$

其中, u_k 为控制律, K_k 表示在时刻 k 求解得到的反馈增益。

为了介绍基于自适应窗口的固定翼飞行器无模型有限时间鲁棒控制算法, 下面首先将会介绍影响力函数。

影响力函数是鲁棒统计学中的重要工具, 用于量化单个数据点对模型参数的敏感程度, 可以提供一种高效的近似方法。

考虑一个从输入空间 $\mathcal{X}$ 到输出空间 $\mathcal{Y}$ 的预测问题。给定训练点 $z_1, \dots, z_n$, 其中 $z_i = (x_i, y_i) \in \mathcal{X} \times \mathcal{Y}$ 。对于一个点 z 和参数 $\theta \in \Theta$, 令 $L(z, \theta)$ 为损失函数, $\frac{1}{n} \sum_{i=1}^n L(z_i, \theta)$ 为经验风险。

经验风险最小化表示为

$$\hat{\theta} \stackrel{\text{def}}{=} \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n L(z_i, \theta). \quad (5.4)$$

假设经验风险关于 θ 二阶可微且严格凸。从形式上讲, 这种变化是 $\hat{\theta}_{-z} - \hat{\theta}$, 其中

$$\hat{\theta}_{-z} \stackrel{\text{def}}{=} \arg \min_{\theta \in \Theta} \sum_{z_i \neq z} L(z_i, \theta). \quad (5.5)$$

其核心思想是计算如果的权重提升了一个较小的 ϵ 时参数的变化, 这样就能得到新的参数

$$\hat{\theta}_{\epsilon, z} \stackrel{\text{def}}{=} \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n L(z_i, \theta) + \epsilon L(z, \theta). \quad (5.6)$$

一个经典的结论表明^[76], 提升 z 的权重对参数 $\hat{\theta}$ 的影响可以由下式给出

$$J_{\text{up, params}}(z) \stackrel{\text{def}}{=} \left. \frac{d\hat{\theta}_{\epsilon, z}}{d\epsilon} \right|_{\epsilon=0} = -H_{\hat{\theta}}^{-1} \nabla_{\theta} L(z, \hat{\theta}), \quad (5.7)$$

其中, $H_{\hat{\theta}} \stackrel{\text{def}}{=} \frac{1}{n} \sum_{i=1}^n \nabla_{\theta}^2 L(z_i, \hat{\theta})$ 是海森矩阵, 根据假设它是正定的。本质上, 是在 $\hat{\theta}$ 的附近对经验风险进行二次近似, 并执行一次牛顿迭代。

由于移除一个点 z 等同于将其权重提升 $\epsilon = -\frac{1}{n}$, 可以通过计算

$$\hat{\theta}_{-z} - \hat{\theta} \approx -\frac{1}{n} J_{\text{up, params}}(z), \quad (5.8)$$

来线性近似移除 z 所导致的参数变化, 而无需重新训练模型。

接下来, 应用链式法则来衡量提升 z 的权重如何改变 $\hat{\theta}$ 的函数。特别地, 提升 z 的权重对测试点 z_{test} 处损失的影响同样有一个封闭形式的表达式

$$\begin{aligned} J_{\text{up, loss}}(z, z_{\text{test}}) &\stackrel{\text{def}}{=} \left. \frac{dL(z_{\text{test}}, \hat{\theta}_{\epsilon, z})}{d\epsilon} \right|_{\epsilon=0} \\ &= \nabla_{\theta} L(z_{\text{test}}, \hat{\theta})^{\top} \left. \frac{d\hat{\theta}_{\epsilon, z}}{d\epsilon} \right|_{\epsilon=0} \\ &= -\nabla_{\theta} L(z_{\text{test}}, \hat{\theta})^{\top} H_{\hat{\theta}}^{-1} \nabla_{\theta} L(z, \hat{\theta}). \end{aligned} \quad (5.9)$$

公式 (5.9) 即为影响力函数公式。

5.3 基于影响力函数的学习窗口长度调节

通过第三章和第四章可以知道在固定翼 F-18 飞行器控制系统模型参数未知的情况下, 为了得到控制输入式 (5.3), 需要

$$N(k) = \xi_k^{\top} G_p^{\gamma, \mu} \xi_k, \quad (5.10)$$

中的 $G_p^{\gamma, \mu} = \begin{bmatrix} \psi & * \\ E^T P(A + BK) & E^T P E - \gamma^2 \mu^{-N} I \end{bmatrix}$ 。采用 Q 学习的方法可以仅利用 $\{x_k\}_{k=1}^{m+1}$, $\{z_k\}_{k=1}^m$, $\{u_k\}_{k=1}^m$, $\{w_k\}_{k=1}^m$ 的固定 m 步数据, 学习当前控制策略下的 $G_p^{\gamma, \mu}$ 。

本章所设计自适应 Q 学习窗口鲁棒控制算法, 以 m 步数据为初始学习步长, 通过影响力函数的方法自适应调节学习窗口长度。

通过构建 $N(k)$ 和 Q_H 之间的定量关系, 然后通过期望条件进行数据筛选, 剔除掉不符合条件的数据。

令 $z_i = [x_i^T \quad x_i u_i \quad x_i w_i \quad u_i^2 \quad u_i w_i \quad w_i^2]^T$, 并且将 θ 定义为与 $\widehat{H}_k$ 有相对应元素的向量, 且满足 $\xi_i^T \widehat{H}_k \xi_i = z_i^T \theta$ 。对于给定初始学习窗口的 m , 以下给出测量数据 z_i 在 k 时刻的影响力函数。

定理 5.1 对于初始学习窗口长度 m 和相应的学习参数 $\widehat{H}_k$ 的数据, 可以计算出测量数据 z_i 对 k 时学习性能的影响程度

$$J_{\text{up,loss}}(z, z_j) = 2\hat{\theta}^T z_j z_j^T \left(\frac{2}{m} \sum_{i=1}^m z_i z_i^T \right)^{-1} 2z(z^T \hat{\theta}), \quad (5.11)$$

其中 $i, j \in \mathbb{N}_{[k-m, k-1]}$, $\hat{\theta} = \arg \min_{\theta} \frac{1}{m} \sum_{i=k-m}^{k-1} L(z_i, \theta)$, $L(z_i, \theta)$ 表示学习性能。

证明: 定义一个损失函数

$$L(z_i, \theta) = (z_i^T \theta)^2, i \in \mathbb{N}_{[k-m, k-1]}, \quad (5.12)$$

其中 z_i 是在 i 时刻的测量数据, θ 相当于学习的 $\widehat{H}_k$ 系统参数。

该损失函数可基于任意时刻 $i \in \mathbb{N}_{[k-m, k-1]}$ 的测量数据的学习性能的定量关系。值得一提的是, 损失函数应该是关于 θ 二阶可导且严格凸, 这将在后续推导中用到。

由初始学习步长得到的最优参数为

$$\hat{\theta} = \arg \min_{\theta} \frac{1}{m} \sum_{i=k-m}^{k-1} L(z_i, \theta). \quad (5.13)$$

由于删除数据 z_i 而导致的参数变化为 $\hat{\theta}_{-z_i} - \hat{\theta}$

$$\hat{\theta}_{-z_i} = \arg \min_{\theta} \frac{1}{m} \sum_{z_i \neq z} L(z_i, \theta). \quad (5.14)$$

通过计算 $\hat{\theta}_{-z} - \hat{\theta} \approx -\frac{1}{m} J_{\text{up}}(z)$ 来重新训练模型, 线性近似由于去除 z_i 而引起的参数变化。

如果的权重提升了一个较小的 ϵ 时参数的变化, 这样就能得到新的参数

$$\hat{\theta}_{\epsilon, z_i} = \arg \min_{\theta} \frac{1}{m} \sum_{i=k-m}^{k-1} L(z_i, \theta) + \epsilon L(z, \theta). \quad (5.15)$$

$\hat{\theta}$ 将经验风险最小化, 即

$$R(\theta) = \frac{1}{m} \sum_{i=k-m}^{k-1} L(z_i, \theta). \quad (5.16)$$

进一步假设 $R(\theta)$ 是二次可微且强凸的, 即

$$H_{\hat{\theta}} = \nabla^2 R(\hat{\theta}) = \frac{1}{m} \sum_{i=k-m}^{k-1} \nabla_{\theta}^2 L(z_i, \hat{\theta}), \quad (5.17)$$

其中 $H_{\hat{\theta}}$ 是海森矩阵且是正定的。

定义参数变化 $\Delta_{\epsilon} = \hat{\theta}_{\epsilon,z} - \hat{\theta}$ ，并注意其中的 $\hat{\theta}$ 并不依赖于 ϵ 。所以将这个计算的量表示为

$$\frac{d\hat{\theta}_{\epsilon,z}}{d\epsilon} = \frac{d\Delta_{\epsilon}}{d\epsilon}, \quad (5.18)$$

由于 $\hat{\theta}_{\epsilon,z}$ 是公式 (5.15) 的最小值，其第一阶最优性条件为

$$\nabla R(\hat{\theta}_{\epsilon,z}) + \epsilon \nabla L(z, \hat{\theta}_{\epsilon,z}) = 0. \quad (5.19)$$

接下来，由于当 $\epsilon \rightarrow 0$ 时， $\hat{\theta}_{\epsilon,z} \rightarrow \hat{\theta}$ ，在左边进行泰勒展开式展开

$$[\nabla R(\hat{\theta}) + \epsilon \nabla L(z, \hat{\theta})] + [\nabla^2 R(\hat{\theta}) + \epsilon \nabla^2 L(z, \hat{\theta})] \Delta_{\epsilon} \approx 0, \quad (5.20)$$

其中去掉了 $o(\|\Delta_{\epsilon}\|)$ 项。

然后，可以求解参数变化

$$\Delta_{\epsilon} \approx -[\nabla^2 R(\hat{\theta}) + \epsilon \nabla^2 L(z, \hat{\theta})]^{-1} [\nabla R(\hat{\theta}) + \epsilon \nabla L(z, \hat{\theta})]. \quad (5.21)$$

从公式 (5.13) 有

$$\nabla R(\theta) = \frac{1}{m} \sum_{k=m}^{k-1} \nabla L(z, \hat{\theta}) = 0. \quad (5.22)$$

去掉了 $o(\|\Delta_{\epsilon}\|)$ 项则有

$$\Delta_{\epsilon} \approx -\nabla^2 R(\hat{\theta})^{-1} \nabla L(z, \hat{\theta}) \epsilon. \quad (5.23)$$

结合 (5.17) 和 (5.18)，得出这个结论

$$\begin{aligned} \frac{d\hat{\theta}_{\epsilon,z}}{d\epsilon} \Big|_{\epsilon=0} &= -H_{\hat{\theta}}^{-1} \nabla L(z, \hat{\theta}) \\ &= J_{\text{up}}(z). \end{aligned} \quad (5.24)$$

接下来，应用链规则来衡量加权 z 如何改变 $\hat{\theta}$ 函数。

$$\begin{aligned} J_{\text{up,loss}}(z, z_j) &= \frac{dL(z_j, \hat{\theta}_{\epsilon,z})}{d\epsilon} \Big|_{\epsilon=0} \\ &= \nabla_{\theta} L(z_j, \hat{\theta})^T \frac{d\hat{\theta}_{\epsilon,z}}{d\epsilon} \Big|_{\epsilon=0} \\ &= -\nabla_{\theta} L(z_j, \hat{\theta})^T H_{\hat{\theta}}^{-1} \nabla_{\theta} L(z, \hat{\theta}). \end{aligned} \quad (5.25)$$

结合损失函数 (5.12)，可以得到

$$\nabla_{\theta} L(z_j, \hat{\theta}) = 2z_j(z_j^T \hat{\theta}), j \in \mathbb{N}_{[k-m, k-1]}, \quad (5.26)$$

$$\nabla_{\theta} L(z, \hat{\theta}) = 2z(z^T \hat{\theta}), \quad (5.27)$$

$$H_{\hat{\theta}} = \frac{1}{m} \sum_{i=k-m}^{k-1} \nabla_{\theta}^2 L(z_i, \hat{\theta}) = \frac{2}{m} \sum_{i=k-m}^{k-1} z_i z_i^T. \quad (5.28)$$

测量数据 z_i 在 k 时对学习性能的影响程度为

$$J_{\text{up,loss}}(z, z_j) = 2\hat{\theta}^T z_j z_j^T \left(\frac{2}{m} \sum_{i=1}^m z_i z_i^T \right)^{-1} 2z(z^T \hat{\theta}). \quad (5.29)$$

证明完成。

利用定理 5.1 计算的任意测量数据 z_j 对学习性能的影响程度, 可以计算出剔除学习数据 z_j 的近似损失函数。因此, 学习窗口的长度可以以最小化损失函数为目标进行调整。

由于删除一个点 z_j 与在 (5.15) 中用 $\epsilon = \frac{1}{m}$ 加权它是相同的, 所以得到

$$L(z, \hat{\theta}_{-z_j, k}) - L(z, \hat{\theta}) \approx -\frac{1}{m} J_{\text{up, loss}}(z, z_j), \quad (5.30)$$

而近似的损失函数 $L(z, \hat{\theta}_{-z_j, k})$ 可以写成

$$L(z, \hat{\theta}_{-z_j, k}) \approx \hat{\theta}^T z_j (z_j^T \hat{\theta}) - 2 \hat{\theta}^T z_j z_j^T \left(\frac{2}{m} \sum_{i=1}^m z_i z_i^T \right)^{-1} 2 z (z^T \hat{\theta}) \quad (5.31)$$

根据第四章可知, Q_H 是学习 $N(k)$, 所以最好 $L(z, \hat{\theta}) = (Q_H)^2 = (z_i^T \theta)^2 \rightarrow 0$ 。因此, 可以通过影响函数来调整学习窗口长度, 得到更小的损失函数。

从 (5.30) 可知, 如果 $J_{\text{up, loss}}(z, z_j) > 0$, 则损失函数近似为 $L(z, \hat{\theta}) > L(z, \hat{\theta}_{-z_j, k})$ 。然后利用新的学习窗口 $\Omega = \{j | j \in \mathbb{N}_{[k-m, k-1]}, J_{\text{up, loss}}(z, z_j) < 0\}$ 来获取数据 $\{x_j\}$, $\{u_j\}$, $\{w_j\}$ 并求解新的学习参数 $\hat{H}_k$ 。

5.4 基于自适应窗口的无模型有限时间鲁棒控制

接下来, 根据第四章算法引入一个优化问题来学习参数 $\hat{H}_k$, 并求解每个时刻的控制输入。该优化问题来自于定理 3.2。当系统没有已知的动力学模型时, 使用 Q 学习来计算控制器 (5.3)。

在系统参数未知的情况下, 在 k 时刻通过求解以下优化问题, 找到采样数据 $\{x_j\}$, $\{z_j\}$, $\{u_j\}$, $\{w_j\}$, $j \in \Omega$ 的控制增益。

$$\mathcal{P}_3: \min_{P, Q, \hat{H}_k, \alpha, \gamma, \mu} \Phi \quad (5.32)$$

$$\text{s. t. } \begin{bmatrix} \alpha - \gamma^2 \bar{w} & * \\ x(k) & Q \end{bmatrix} \geq 0, \quad (5.33)$$

$$\begin{bmatrix} \mu^{-N}(c_2^2 - \gamma^2 \bar{w}^2) & * \\ c_1 & 1 \end{bmatrix} \geq 0, \quad (5.34)$$

$$\begin{bmatrix} \varepsilon & Q_{\hat{H}_k}(x_k, u_k, w_k) - N(x_k, u_k, w_k) \\ * & \varepsilon \end{bmatrix} \geq 0, \quad (5.35)$$

其中 $\hat{H}_k, \alpha, \gamma, \mu$ 是决策变量, $Q_H(x_k, u_k, w_k) = \xi_k^T \hat{H}_k \xi_k$, $N(x_k, u_k, w_k) = x_{k+1}^T P x_{k+1} - x_k^T P x_k + z_k^T z_k - \gamma^2 w_k^T w_k$, 以及 ε 是足够小的数。

从具有 $j \in \Omega$ 的等式 $Q_H = N(k)$ 中找到矩阵 $\hat{H}_k$ 。在干扰 w_k 足够丰富的情况下, 方程 $Q_H = N(k)$ 的数量应该足够大, 以满足条件 $\hat{H}_k = G_p^{\gamma, \mu}$ 。

通过求解优化问题 $\mathcal{P}_3$, 学习到的矩阵 $\hat{H}_k$ 可以满足代价函数 Φ 。通过第四章的内容可以知道, 利用学习到的矩阵 $\hat{H}_k$, 可以计算出相应的控制输入。将矩阵 $\hat{H}_k$ 分解为

$$\widehat{H}_k := \begin{bmatrix} H_{xx} & H_{xu} & H_{xw} \\ * & H_{uu} & H_{uw} \\ * & * & H_{ww} \end{bmatrix}, \quad (5.36)$$

并且令 $\begin{bmatrix} \bar{H}_{xx} & \bar{H}_{xu} \\ * & \bar{H}_{uu} \end{bmatrix} \& := \begin{bmatrix} H_{xx} & H_{xu} \\ * & H_{uu} \end{bmatrix} - \begin{bmatrix} H_{xw} \\ H_{uw} \end{bmatrix} H_{ww}^{-1} [H_{xw}^T \ H_{uw}^T]$.

由于 $Q_{\widehat{H}_k} = N \leq 0$, 对于任意 w_k , 有 $H_{ww} < 0$. 因此, 考虑到 u_k 和 w_k 是相互独立的, 有

$$\begin{aligned} & \min_{u_k} \{Q_{\widehat{H}_k}(x_k, u_k, w_k), \forall w_k\} \\ &= \min_{u_k} \max_{w_k} Q_{\widehat{H}_k}(x_k, u_k, w_k) \\ &= \min_{u_k} \max_{w_k} [x_k^T \ u_k^T \ w_k^T] \widehat{H}_k \begin{bmatrix} x_k \\ u_k \\ w_k \end{bmatrix}. \\ &= \min_{u_k} [x_k^T \ u_k^T] \begin{bmatrix} \bar{H}_{xx} & \bar{H}_{xu} \\ * & \bar{H}_{uu} \end{bmatrix} \begin{bmatrix} x_k \\ u_k \end{bmatrix} \\ &= x_k^T (\bar{H}_{xx} - \bar{H}_{xu} \bar{H}_{uu}^{-1} \bar{H}_{xu}^T) x_k \end{aligned} \quad (5.37)$$

根据引理 3.2, 可以推断出 u_k 的最优值 u_k^* 为:

$$u_k^* = K^* x_k; K^* = -\bar{H}_{uu}^{-1} \bar{H}_{xu}^T. \quad (5.38)$$

最后, 得到自适应 Q 学习窗口鲁棒控制算法如下。

算法 5.1: 基于影响力函数的无模型有限时间鲁棒控制

```

1  初始化: 加权参数  $\rho$ , 初始学习窗口  $m$ , 有限时间参数  $c_1, c_2, \mu, N$ , 初始控制增益  $K_0$ ;
2  while  $k \in \mathbb{N}_{[0, m-1]}$  do
3      采用控制策略  $u_k = K_0 x_k + v_k$  采集系统数据  $\{x_i\}_{i=0}^m, \{z_i\}_{i=0}^{m-1}, \{u_i\}_{i=0}^{m-1}, \{w_i\}_{i=0}^{m-1}$ ;
4      for  $i \in \mathbb{N}_{[k-m, k-1]}$  do
5          在初始学习窗口  $m$  时, 求解优化问题  $\mathcal{P}_3$ , 获取矩阵  $H_k$ ;
6          通过定理 5.1 计算  $z_i, i \in \mathbb{N}_{[k-m, k-1]}$  的影响力函数  $J_{\text{up, loss}}(z, z_i)$ ;
7          得到自适应学习窗口  $\Omega = \{j | j \in \mathbb{N}_{[k-m, k-1]}, I_{\text{up, loss}}(z, z_j) < 0\}$ ;
8          利用自适应的学习窗口解决优化问题  $\mathcal{P}_3$ , 得到学习到的矩阵  $\widehat{H}_k$ ;
9          得到  $u_k = -\bar{H}_{uu}^{-1} \bar{H}_{xu}^T x_k$ ;
10     end if
11     将  $u_k$  应用于系统, 设置  $k = k + 1$ , 获得数据  $\{x_k\}, \{z_{k-1}\}, \{u_{k-1}\}, \{w_{k-1}\}$ ;
12 end while
```

5.5 仿真示例

在本节的仿真研究中, 依旧选用固定翼 F-18 飞行器系统作为研究对象, 其离散状态空间方程详细展示于公式 (3.34)。本节重点突显自适应 Q 学习窗口鲁棒控制算法相较于其他算法的显著优势, 通过严谨的对比分析, 探究该算法在实际应用中的性能表现。

为了充分证明基于影响力函数的无模型有限时间鲁棒控制的有效性,需要借助从风洞试验和飞行试验数据中获取的精确空气动力学数据。这些数据主要用于为算法有效性提供有力的证明。但在整个仿真过程中,并未使用固定翼 F-18 飞行器的具体系统参数,以此证明算法在无模型条件下的有效性。

本节主要探讨 F-18 飞机在马赫数为 0.8、飞行高度为 11 千英尺的稳定运行状态下的线性化纵向动力学问题,相关理论依据可参考文献^[74]。通过对这一特定工况的研究,能够更加精准地评估算法在实际飞行条件下的控制效果和鲁棒性。

$$x_{k+1} = \begin{bmatrix} -1.3582 & 0.84 \\ -15.86 & -1.25 \end{bmatrix} x_k + \begin{bmatrix} -0.359 \\ -22.62 \end{bmatrix} u_k + \begin{bmatrix} 1 \\ 0 \end{bmatrix} w_k. \quad (5.39)$$

$$z_k = [1 \quad 0] x_k.$$

在本节仿真中,为模拟实际环境中的干扰因素,对信号 u_k 和 v_k 分别选用零均值白噪声随机信号。其中,赋予信号 u_k 的零均值白噪声随机信号方差为 1,这相对较大的方差意味着该信号将引入较为显著的干扰波动;而信号 v_k 所采用的零均值白噪声随机信号方差设定为 10^{-6} ,此极小的方差表示该信号带来的干扰幅度极为微小。此外,对于其他相关参数如表 5-1 参数初始值所示,这些参数的精确设定对于整个系统的模拟和分析起着关键作用。

表 5-1 参数初始值

参数	赋值
初始学习窗口 m	75
加权参数 ρ	100
初始控制增益 K_0	$[1 \quad 1]$
N	8
x_0	$[5 \quad 2]^T$
c_1	1
c_2	5
μ	1.01

为全面评估算法性能,将自适应 Q 学习窗口鲁棒控制算法与第四章提出的无模型有限时间鲁棒控制方法进行对比分析。在下列图示里,红色直线代表着本章提出的自适应 Q 学习窗口鲁棒控制算法。该算法在系统控制过程中的状态变化、控制增益等情况,均可通过这条红色直线直观呈现。而蓝色直线则对应着无模型有限时间鲁棒控制方法,其在相同条件下的控制表现也能清晰展现。

通过对图中红、蓝两条直线在走势、波动幅度、收敛速度以及最终稳定状态等多方面特征的对比,可以深入了解两种控制算法在处理固定翼飞行器相关控制问题时的差异,进而为判断自适应 Q 学习窗口鲁棒控制算法的优势与特点的可视化。





图 5-1 基于影响力函数的 Q 学习控制的学习窗口长度

图 5-1 直观呈现了固定翼飞行器在基于影响力函数的 Q 学习控制过程中, 每个学习时刻对应的学习窗口长度变化情况。窗口长度并非固定不变, 而是呈现出动态变化的特征。在学习初期, 大约前 5 次学习时, 窗口长度在 70 到 95 之间波动; 在第 5 次学习附近, 窗口长度降至约 50, 随后又快速上升。在第 20 次学习左右, 窗口长度更是出现了从约 25 急剧跃升至 130 左右的显著变化。

这种随学习进程和数据特性而变化的窗口长度设置, 使得自适应 Q 学习窗口鲁棒控制算法能够根据不同的数据情况灵活调整, 相较于无模型有限时间鲁棒控制, 能更有效地筛选和利用输入输出数据, 显著提高了数据的利用率, 进而提升了算法的整体性能和对复杂飞行工况的适应性。

图 5-2 x_1 状态轨迹




图 5-3 x_2 状态轨迹

图 5-2 和图 5-3 分别展示了固定翼飞行器的 x_1 状态轨迹和 x_2 状态轨迹。其中, x_1 和 x_2 可分别对应状态变量攻角和俯仰角速度。在图 5-2 中, 两种算法的初始时刻, x_1 值均约为 5。在随后的变化中, 自适应 Q 学习窗口鲁棒控制算法的曲线下降更为迅速, 大约在 6 秒时就趋近于稳定值 3 左右; 而无模型有限时间鲁棒控制的曲线下降相对缓慢, 且在下降过程中出现了一定的波动, 直到约 10 秒后才逐渐稳定到相近数值。

再看图 5-3, 对于 x_2 状态轨迹, 两种算法初始值都约为 2。自适应 Q 学习窗口鲁棒控制算法的曲线快速下滑, 在约 5 秒时就接近稳定值 0; 无模型有限时间鲁棒控制的曲线虽然也在下降, 但速度较慢, 且在接近稳定值的过程中波动较大, 直到约 8 秒才趋近于 0。

对比这两张图中两种算法的曲线走势可以明显看出, 无论是状态变量攻角 x_1 还是俯仰角速度 x_2 , 自适应 Q 学习窗口鲁棒控制算法都能使相应状态变量更快地收敛到稳定值, 展现出比无模型有限时间鲁棒控制更优的动态响应性能。这有力地证明了自适应 Q 学习窗口鲁棒控制算法在固定翼飞行器控制中的有效性。


图 5-4 K_1 的控制增益的趋势

图 5-5 K_2 的控制增益的趋势

当固定翼飞行器闭环系统的参数已知时，其控制增益的最优值为 $K_{opt} = [-0.5924 \quad 0.4311]$ 。观察图 5-4 中控制增益 K_1 随时间的变化曲线，初始值约为 1.2，在学习过程中迅速下降，在约 1500 步时就趋近稳定值约 -0.55；而蓝色曲线对应的第四章所提的无模型有限时间鲁棒控制方法，初始值约为 1.0，下降过程相对缓慢，直到约 3000 步后才趋近稳定，且稳定值略大于基于影响力函数的方法。

再看图 5-5 中控制增益 K_2 的变化情况，基于影响力函数的无模型有限时间鲁棒控制方法初始值约为 1.05，快速下降后在约 2000 步时趋于稳定，稳定值约为 0.42；第四章所提的无模型有限时间鲁棒控制方法初始值约为 0.98，下降速度较慢，在约 3500 步才稳定，稳定值略微高于基于影响力函数的方法。

综合这两张图可知，无论是控制增益 K_1 还是 K_2 ，基于影响力函数的无模型有限时间鲁棒控制方法均能更快地收敛到接近最优值，明显优于第四章所提的无模型有限时间鲁棒控制方法，体现出该方法在优化控制增益的有效性。

图 5-6 H_∞ 性能的趋势

在固定翼飞行器系统参数已知的前提下，其闭环系统的 H_∞ 干扰抑制水平最优值为 $\gamma_{opt} = 1.7964$ ，这是衡量 H_∞ 性能的关键指标。从图 5-6 展示的 H_∞ 性能随时间的变化趋势来看，在学习过程中，该算法下的 γ 值迅速下降，在约 1000 步时就趋近于稳定值 1.8134，与最优值 1.7964 极为接近。无模型有限时间鲁棒控制方法下降过程相对缓慢，直到约 3000 步后才趋于稳定，稳定值略高于自适应 Q 学习窗口鲁棒控制算法。

由此可见，自适应 Q 学习窗口鲁棒控制算法不仅在最终的 γ 值上更接近最优值，实现了 H_∞ 性能的小幅度提升，而且在收敛速度上明显快于第四章所提的无模型有限时间鲁棒控制方法，能够更快速有效地达到接近最优的 H_∞ 干扰抑制水平，展现出该算法在提升固定翼飞行器 H_∞ 性能方面的优势。

5.6 本章小结

本章专注于面向固定翼飞行器的自适应学习窗口鲁棒控制研究，旨在突破传统强化学习控制中存在的瓶颈问题。本章通过构建飞行数据与策略更新之间的定量关系，设计出数据选择的窗口长度自适应策略。该策略能够根据飞行实际情况，自适应地动态调整学习窗口的长度，从而实现对动态数据的高效筛选与利用。

对固定翼 F-18 飞行器的仿真实验结果有力地验证了本研究的有效性。仿真清晰表明，自适应学习窗口鲁棒控制算法显著提高了对测量所得的输入输出数据的利用率，过动态数据筛选与窗口长度优化，解决了在线学习效率低的问题。

第六章 主要结论与展望

6.1 主要结论

全文以固定翼飞行器在复杂环境下的鲁棒控制为核心,针对模型参数未知、短时强扰动及数据冗余三大瓶颈问题展开研究,提出了融合 Q 学习、动态约束与自适应优化的创新控制框架,并通过多维度实验验证了算法的有效性与工程实用性。本研究的内容概述如下:

(1) 考虑到固定翼飞行器模型参数未知且气动特性复杂多变的难题,提出基于滚动优化的 Q 学习鲁棒控制算法。该算法仅依靠飞行器的飞行状态数据和舵面偏转数据,动态逼近系统模型参数,摆脱了传统鲁棒控制方法对风洞试验数据的先验性依赖。具体而言,采用策略迭代解算法对固定翼飞行器的系统参数模型进行近似处理,并在基于 Q 学习的鲁棒控制中引入滚动优化策略,以提高系统在干扰变化下的鲁棒性。根据对固定翼 F-18 飞行器的仿真验证,所提出的算法可以在系统参数未知的情况下,学习到干扰抑制水平和控制增益的最优值。该方法显著消除模型失配现象对控制性能造成的负面影响,为飞行器在复杂环境下的精确控制提供了新的思路和方法。

(2) 当固定翼飞行器面临短时强约束工况时,传统基于渐近稳定性理论的控制方法暴露出暂态性能不足的弊端,难以满足实际运行需求。提出了一种有限时间有界性控制算法。该算法通过构建动态正定矩阵,精确描述状态约束边界,将有限时间安全需求转化为可求解的矩阵不等式约束形式。克服传统渐近稳定理论局限性的同时,实现对飞行器攻角和角速率的严格限制。所提算法直接从测量所得的输入输出数据中学习最优控制策略,确保了飞行器在突发扰动下的安全飞行。通过对固定翼 F-18 飞行器的仿真证明了算法的有效性。该方法增强了固定翼飞行器在短时强约束复杂工况下的暂态控制性能。

(3) 针对 Q 学习控制过程中固定翼飞行器的预设固定学习周期引发的动态效率低的问题,本研究提出了一种基于影响力函数的学习窗口动态调整算法。通过影响力函数构建固定翼飞行数据与策略更新之间的定量关系,设计出数据选择的窗口长度自适应策略。该策略能够根据实际情况,自适应地动态调整学习窗口的长度,保证在每个学习时刻都能充分利用数据。通过对固定翼 F-18 飞行器的进行仿真,证明了该策略有效避免低质量数据对学习结果的干扰,提高了有限时间鲁棒控制算法的学习效率,为固定翼飞行器在复杂环境下实现稳定控制提供了更为坚实可靠的保障。

综上所述,本研究在固定翼飞行器的鲁棒控制方面取得了多方面的创新成果,为复杂飞行环境下的自主控制提供了新的方法论基础。这些成果不仅在理论上具有重要的学术价值,而且在实际应用中具有广泛的前景,为固定翼飞行器的控制技术发展做出了积极的贡献。

6.2 展望

针对固定翼飞行器飞行气动参数的动态变化难以被线性化模型准确描述,风洞试验周期长、成本昂贵的问题,以及飞行器控制鲁棒性的问题。提出基于滚动优化的模型参

数未知系统鲁棒控制、短时强约束的无模型系统有限时间鲁棒控制和基于自适应窗口的无模型系统有限时间鲁棒控制的算法，虽然仿真结果表明了该算法的有效性以及在学习效率上的提升。但仍有以下几点不足需要进一步探讨：

（1）未来研究可拓展至多飞行器协同任务，设计分布式鲁棒控制策略，使各飞行器在通信受限且模型参数未知的情况下，仅利用本地测量数据和有限信息交互，实现协同飞行。需解决多飞行器系统在复杂环境下的稳定性与性能优化问题，开发高效分布式算法，以适应大规模飞行器协同控制的需求。

（2）针对固定翼飞行器在极端条件下的非线性特性，可开展更精确的非线性动力学建模，并在此基础上设计先进的非线性控制策略。重点研究如何在模型参数未知和存在强非线性扰动的情況下，实现精确的飞行器轨迹跟踪和姿态控制，进一步提升飞行器在复杂环境下的飞行性能和稳定性。

（3）为了进一步验证所提控制策略的有效性和可靠性，未来研究应通过构建真实的硬件在环测试平台，将控制算法与实际飞行器系统相结合，进行更全面和真实的性能测试。同时，开展实际飞行测试，收集真实飞行数据，为控制策略的优化和完善提供依据，推动研究成果从理论向实际应用的转化。

尽管在固定翼飞行器控制研究上已取得一定进展，但未来仍有广阔的研究空间与应用前景，通过持续探索与创新，有望推动飞行器控制技术迈向新的高度。

参考文献

- [1] Seo J, Kim Y, Kim S, et al. Collision avoidance strategies for unmanned aerial vehicles in formation flight[J]. IEEE Transactions on aerospace and electronic systems, 2017, 53(6): 2718-2734.
- [2] 胡琼. 无人驾驶航空飞行器飞行控制方法研究[D]:[博士学位论文]. 北京 北京理工大学, 2015.
- [3] Tian Z, Danino M, Bar-Shalom Y, et al. Missile threat detection and evasion maneuvers with countermeasures for a low-altitude aircraft[J]. IEEE Transactions on Aerospace and Electronic Systems, 2023, 59(6): 7352-7362.
- [4] Adams R J, Buffington J M, Sparks A G, et al. Robust multivariable flight control[M]. Springer Science & Business Media, 2012.
- [5] Kazim M, Azar A T, Koubaa A, et al. Disturbance-rejection-based optimized robust adaptive controllers for UAVs[J]. IEEE Systems Journal, 2021, 15(2): 3097-3108.
- [6] Xue Y, Chen W. Multi-agent deep reinforcement learning for UAVs navigation in unknown complex environment[J]. IEEE Transactions on Intelligent Vehicles, 2023, 9(1): 2290-2303.
- [7] Leman T, Xargay E, Dullerud G, et al. L1 adaptive control augmentation system for the X-48B aircraft[C]//AIAA guidance, navigation, and control conference. 2009: 5619.
- [8] 宁雷. 固定翼飞机飞行动力学及振动特性仿真研究[D]: [硕士学位论文]. 哈尔滨. 哈尔滨工程大学, 2016.
- [9] 秦荀, 李三军. F-35 战斗机的状态预测与健康管理系统[J]. 航空维修与工程, 2017 (4): 33-37.
- [10] Khan I A, Rahman S. Detailed modeling and investigation of impact of transient loading on electrical power system of military aircraft F-35[C]//2022 IEEE Transportation Electrification Conference & Expo (ITEC). IEEE, 2022: 837-842.
- [11] 沈磊. 民用飞机电传飞控作动系统设计与工程运用[D]: [硕士学位论文]. 上海. 上海交通大学, 2012.
- [12] Yeh Y C. Design considerations in Boeing 777 fly-by-wire computers[C]//Proceedings Third IEEE International High-Assurance Systems Engineering Symposium (Cat. No. 98EX231). IEEE, 1998: 64-72.
- [13] 离子鱼. 歼-20 战斗机的技术分析[J]. 舰载武器, 2011 (2): 27-37.
- [14] Stephan J, Pfeifle O, Notter S, et al. Precise tracking of extended three-dimensional dubins paths for fixed-wing aircraft[J]. Journal of Guidance, Control, and Dynamics, 2020, 43(12): 2399-2405.
- [15] Omlor S, Radunz M. Structures and Trends in Design of Flight Control Systems for Modern Fighter Aircraft[J]. IFAC Proceedings Volumes, 1988, 21(18): 133-138.
- [16] Zhi Y, Liu L, Guan B, et al. Distributed robust adaptive formation control of fixed-wing UAVs with unknown uncertainties and disturbances[J]. Aerospace Science and Technology, 2022, 126: 107600.
- [17] Wang X, Kong W, Zhang D, et al. Active disturbance rejection controller for small fixed-wing UAVs with model uncertainty[C]//2015 IEEE International Conference on Information and Automation. IEEE, 2015: 2299-2304.
- [18] Zogopoulos-Papaliakos G, Karras G C, Kyriakopoulos K J. A fault-tolerant control scheme for fixed-wing UAVs with flight envelope awareness[J]. Journal of Intelligent & Robotic Systems, 2021, 102(2): 46.
- [19] Brelje B J, Martins J R R A. Electric, hybrid, and turboelectric fixed-wing aircraft: A review of concepts, models, and design approaches[J]. Progress in Aerospace Sciences, 2019, 104: 1-19.
- [20] Mobarez E N, Sarhan A, Ashry M M. Robust PID flight controller for ultrastick-25e UAV[C]//2019 15th International Computer Engineering Conference (ICENCO). IEEE, 2019: 150-156.
- [21] Wang W, Zhang J, Jiao R. Optimized fractional-order type-2 fuzzy PID attitude controller for fixed-wing aircraft[J]. Journal of Optimization Theory and Applications, 2024: 1-25.

- [22] 郑光廷, 王琦, 陈龙胜, 等. 基于遗传算法整定 PID 的倾转翼飞机过渡段定高控制[J]. 航空兵器, 2020, 27(6): 85-90.
- [23] Ghiglino P, Forshaw J L, Lappas V J. Online PID self-tuning using an evolutionary swarm algorithm with experimental quadrotor flight results[C]//AIAA Guidance, Navigation, and Control (GNC) Conference. 2013: 5098.
- [24] WENDEL T, BOLAND J, HAHNE D. High angle of attack control law development for a free-flight wind tunnel model using direct eigenstructure assignment[C]//Navigation and Control Conference. 1991: 2627.
- [25] Melkou L, Hamerlain M, Rezoug A. Fixed-wing UAV attitude and altitude control via adaptive second-order sliding mode[J]. Arabian Journal for Science and Engineering, 2018, 43: 6837-6848.
- [26] Pan Y, Li N, Zou W, et al. An augmented sliding mode control for fixed-wing uavs with external disturbances and model uncertainties[J]. Drones, 2023, 7(7): 440.
- [27] Reinhardt D, Johansen T A. Control of fixed-wing uav attitude and speed based on embedded nonlinear model predictive control[J]. IFAC-Papers On Line, 2021, 54(6): 91-98.
- [28] Zhang P, Zhou J, Tian D, et al. Distributed robust UAVs formation control based on semidefinite programming[J]. Tsinghua Science and Technology, 2024, 29(5): 1341-1354.
- [29] Qiao H Y, Meng H, Wang M J, et al. Adaptive control for hypersonic vehicle with input saturation and state constraints[J]. Aerospace Science and Technology, 2019, 84: 107-119.
- [30] Sariyildiz E, Oboe R, Ohnishi K. Disturbance observer-based robust control and its applications: 35th anniversary overview[J]. IEEE Transactions on Industrial Electronics, 2019, 67(3): 2042-2053.
- [31] Chen M, Shi P, Lim C C. Robust constrained control for MIMO nonlinear systems based on disturbance observer[J]. IEEE Transactions on Automatic Control, 2015, 60(12): 3281-3286.
- [32] Cao Y Y, Lam J. Stochastic stabilizability and H_∞ control for discrete-time jump linear systems with time delay[J]. Journal of the Franklin Institute, 1999, 336(8): 1263-1281.
- [33] Zhang H, Wang J, Shi Y. Robust H_∞ sliding-mode control for Markovian jump systems subject to intermittent observations and partially known transition probabilities[J]. Systems & Control Letters, 2013, 62(12): 1114-1124.
- [34] Nami C, Oka K, Sato M, et al. H_∞ control-based robust CAS design for QTW-UAV via the multiple-model approach with particle swarm optimization[J]. International Journal of Aerospace Engineering, 2019, 2019(1): 9267059.
- [35] Uyulan C, Yavuz M T. Robust H_∞ control applied on a fixed wing unmanned aerial vehicle[J]. Advances in aircraft and spacecraft science, 2019, 6(5): 371-389.
- [36] Zhang Y, Lim C C, Liu F. Robust mixed H_2/H_∞ model predictive control for Markov jump systems with partially uncertain transition probabilities[J]. Journal of the Franklin Institute, 2018, 355(8): 3423-3437.
- [37] Song Y, Wang Z, Ding D, et al. Robust H_2/H_∞ model predictive control for linear systems with polytopic uncertainties under weighted MEF-TOD protocol[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2017, 49(7): 1470-1481.
- [38] Hughes H D, Wu F. LPV H_∞ control for flexible hypersonic vehicle[J]. Control of Linear Parameter Varying Systems with Applications, 2012: 413-444.
- [39] Akyurek S, Kaynak U, Kasnakoglu C. Altitude control for small fixed-wing aircraft using H_∞ loop-shaping method[J]. IFAC-Papers On Line, 2016, 49(9): 111-116.
- [40] Moulay E, Léchappé V, Bernuau E, et al. Robust fixed-time stability: Application to sliding-mode control[J]. IEEE Transactions on Automatic Control, 2021, 67(2): 1061-1066.
- [41] Yao D, Li H, Shi Y. Adaptive event-triggered sliding-mode control for consensus tracking of nonlinear multiagent systems with unknown perturbations[J]. IEEE Transactions on Cybernetics, 2022, 53(4): 2672-2684.

- [42] Utkin V. Discussion aspects of high-order sliding mode control[J]. IEEE Transactions on Automatic Control, 2015, 61(3): 829-833.
- [43] Castañeda H, Salas-Peña O S, de León-Morales J. Extended observer based on adaptive second order sliding mode control for a fixed wing UAV[J]. ISA transactions, 2017, 66: 226-232.
- [44] Espinoza T, Dzul A E, Lozano R, et al. Backstepping-sliding mode controllers applied to a fixed-wing UAV[J]. Journal of Intelligent & Robotic Systems, 2014, 73: 67-79.
- [45] Yu Z, Zhang Y, Jiang B, et al. Distributed adaptive fault-tolerant close formation flight control of multiple trailing fixed-wing UAVs[J]. ISA transactions, 2020, 106: 181-199.
- [46] 王涛波, 黄宝军. 基于改进卡尔曼滤波的四维飞行航迹预测模型[J]. 计算机应用, 2014, 34(6): 1812-1815.
- [47] 谭伟, 陆百川, 黄美灵. 神经网络结合遗传算法用于航迹预测[J]. 重庆交通大学学报 (自然科学版), 2010.
- [48] 耿宏, 任道先, 杜鹏. 基于 NARX 神经网络航空发动机参数动态辨识模型[J]. 计算机工程与应用, 2017, 53(12): 241-248.
- [49] Nian R, Liu J, Huang B. A review on reinforcement learning: Introduction and applications in industrial process control[J]. Computers & Chemical Engineering, 2020, 139: 106886.
- [50] Xiong H, Diao X. Safety robustness of reinforcement learning policies: A view from robust control[J]. Neurocomputing, 2021, 422: 12-21.
- [51] Arulkumaran K, Deisenroth M P, Brundage M, et al. Deep reinforcement learning: A brief survey[J]. IEEE Signal Processing Magazine, 2017, 34(6): 26-38.
- [52] Wang C, Wang J, Ma Z, et al. Integrated learning-based framework for autonomous quadrotor UAV landing on a collaborative moving UGV[J]. IEEE Transactions on Vehicular Technology, 2024.
- [53] Hung S M, Givigi S N. A Q-learning approach to flocking with UAVs in a stochastic environment[J]. IEEE transactions on cybernetics, 2016, 47(1): 186-197.
- [54] Wada D, Araujo-Estrada S A, Windsor S. Unmanned aerial vehicle pitch control under delay using deep reinforcement learning with continuous action in wind tunnel test[J]. Aerospace, 2021, 8(9): 258.
- [55] Wang W, Wang L, Wu J, et al. Oracle-guided deep reinforcement learning for large-scale multi-UAVs flocking and navigation[J]. IEEE Transactions on Vehicular Technology, 2022, 71(10): 10280-10292.
- [56] Yan C, Wang C, Xiang X, et al. Deep reinforcement learning of collision-free flocking policies for multiple fixed-wing UAVs using local situation maps[J]. IEEE Transactions on Industrial Informatics, 2021, 18(2): 1260-1270.
- [57] Devaraju S, Ihler A, Kumar S. A deep q-learning based, base-station connectivity-aware, decentralized pheromone mobility model for autonomous UAV networks[J]. IEEE Transactions on Aerospace and Electronic Systems, 2024.
- [58] Hu S, Yue D. Event-based H_∞ filtering for networked system with communication delay[J]. Signal Processing, 2012, 92(9): 2029-2039.
- [59] Zhang X M, Han Q L. Event-based H_∞ filtering for sampled-data systems[J]. Automatica, 2015, 51: 55-69.
- [60] Cohen G, Sapiro G, Giryes R. Detecting adversarial samples using influence functions and nearest neighbors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 14453-14462.
- [61] Yedavalli R K. Flight Dynamics and Control of Aero and Space Vehicles[M]. John Wiley & Sons, 2020.
- [62] Roskam J. Airplane flight dynamics and automatic flight controls[M]. DARcorporation, 1998.
- [63] Kamalapurkar R, Walters P, Rosenfeld J, et al. Reinforcement learning for optimal feedback control[M]. Berlin: Springer International Publishing, 2018.
- [64] Lian J, Li C, Xia B. Sampled-data control of switched linear systems with application to an F-18 aircraft[J]. IEEE Transactions on Industrial Electronics, 2016, 64(2): 1332-1340.

- [65] 王德进, 自动化系统 H_2 和 H_∞ 优化控制理论[M]. 哈尔滨工业大学出版社, 2001.
- [66] Jang B, Kim M, Harerimana G, et al. Q-learning algorithms: A comprehensive classification and applications[J]. IEEE access, 2019, 7: 133653-133667.
- [67] Beard R W, Saridis G N, Wen J T. Galerkin approximations of the generalized Hamilton-Jacobi-Bellman equation[J]. Automatica, 1997, 33(12): 2159-2177.
- [68] Zhang X, Liu J, Xu X, et al. Robust learning-based predictive control for discrete-time nonlinear systems with unknown dynamics and state constraints[J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2022, 52(12): 7314-7327.
- [69] Huang H, Li D, Xi Y. Design and input-to-state practically stable analysis of the mixed H_2/H_∞ feedback robust model predictive control[J]. IET control theory & applications, 2012, 6(4): 498-505.
- [70] Al-Tamimi A, Lewis F L, Abu-Khalaf M. Model-free Q-learning designs for linear discrete-time zero-sum games with application to H-infinity control[J]. Automatica, 2007, 43(3): 473-481.
- [71] 俞立. 鲁棒控制: 线性矩阵不等式处理方法[M]. 清华大学出版社, 2002.
- [72] Yaz E E. Linear matrix inequalities in system and control theory[J]. Proceedings of the IEEE, 1998, 86(12): 2473-2474.
- [73] Kim J H, Lewis F L. Model-free H_∞ control design for unknown linear discrete-time systems via Q-learning with LMI[J]. Automatica, 2010, 46(8): 1320-1326.
- [74] Stevens B L, Lewis F L, Johnson E N. Aircraft control and simulation: dynamics, controls design, and autonomous systems[M]. John Wiley & Sons, 2015.
- [75] Zhang Y, Liu C, Sun H. Robust finite-time H_∞ control for uncertain discrete jump systems with time delay[J]. Applied Mathematics and Computation, 2012, 219(5): 2465-2477.
- [76] Weisberg S, Cook R D. Residuals and influence in regression[J]. 1982.