

基于深度强化学习的固定翼无人机编队控制算法

化晨昊¹, 谭泰¹, 江泰民¹, 李辉^{1,2}, 张建伟^{1,2*}

(1. 四川大学计算机学院, 成都 610065;

2. 四川大学视觉合成图形图像技术国防重点学科实验室, 成都 610065)

摘要: 在民用和军用领域, 无人机 (Unmanned Aerial Vehicle, UAV) 编队的应用日益广泛; 然而, 对于复杂度较高的六自由度固定翼无人机模型, 现有的编队控制研究相对有限。针对上述挑战, 提出了分层近端策略优化算法 (Hierarchical Guidance and Control Proximal Policy Optimization, HGC-PPO)。HGC-PPO 基于分层架构, 将编队控制分为制导层和控制层。HGC-PPO 的无人机控制层采用了一种基于强化学习的多输入多输出架构, 在编队制导层, 基于课程学习策略以构建奖励函数, 平滑了学习过程中的难度曲线。这种方法确保了训练的有效收敛, 同时提高了样本利用率和训练效率。实验结果表明, HGC-PPO 算法能够在保持高效的同时, 实现稳定且精确的固定翼无人机编队控制。综上所述, HGC-PPO 算法为六自由度固定翼无人机编队控制提供了一种有效的解决方案。

关键词: 分层强化学习; 深度强化学习; 奖励塑造; 近端策略优化算法; 课程学习; 六自由度固定翼无人机; 编队飞行

中图分类号: V279

文献标识码: A

文章编号: 1009-1300(2025)03-0083-12

DOI: 10.16358/j.issn.1009-1300.20240200

Fixed wings UAV formation control algorithm based on deep reinforcement learning

Hua Chenhao¹, Tan Tai¹, Jiang Taimin¹, Li Hui^{1,2}, Zhang Jianwei^{1,2*}

(1. College of Computer Science, Sichuan University, Chengdu 610065, China;

2. National Key Laboratory of Fundamental Science on Synthetic Vision, Sichuan University, Chengdu 610065, China)

Abstract: Unmanned Aerial Vehicles (UAVs) are extensively utilized in civilian and military domains. Existing formation control research is found to be limited for high-complexity six-degree-of-freedom fixed-wing UAV models. To address this challenge, a hierarchical proximal policy optimization algorithm (i. e. Hierarchical Guidance and Control Proximal Policy Optimization, HGC-PPO), is proposed. In HGC-PPO,

收稿日期: 2024-12-29; 修回日期: 2025-03-25

基金项目: 国家自然科学基金联合基金项目 (U20A20161)

作者简介: 化晨昊, 硕士研究生。

通信作者: 张建伟, 研究员。

引用格式: 化晨昊, 谭泰, 江泰民, 等. 基于深度强化学习的固定翼无人机编队控制算法[J]. 战术导弹技术, 2025 (3): 83-94.

(Hua Chenhao, Tan Tai, Jiang Taimin, et al. Fixed wings UAV formation control algorithm based on deep reinforcement learning[J]. Tactical Missile Technology, 2025 (3): 83-94.)

formation control is divided into a guidance layer and a control layer based on a hierarchical architecture. In the control layer, a reinforcement learning-based multi-input multi-output architecture is adopted. In the guidance layer, a curriculum learning strategy is employed to construct the reward function, which smooths the difficulty curve during training. By this method, it can ensure the effective convergence of training while improving the sample efficiency and training performance. Experimental results show that it can achieve stable and accurate fixed-wing UAV formation control while maintaining high efficiency by the HGC-PPO algorithm, which can provide an effective solution for the formation control problem of six-degree-of-freedom fixed-wing UAVs.

Key words: hierarchical reinforcement learning; deep reinforcement learning; reward shaping; proximal policy optimization algorithm; curriculum learning; 6-DoF fixed-wing UAV; formation flying

1 引言

无人机以其高性能、低成本及强大的环境适应性而著称,广泛应用于辅助通信^[1]、空战^[2]、集群飞行^[3]、避障飞行^[4]等场景。特别是固定翼无人机,由于其卓越的适应性和较大的装载能力,在复杂环境下的任务执行中表现出色,常被用于编队飞行任务。编队飞行是一种常见的多机协同方法^[5]。传统的编队方法有领导者-跟随者^[6]方法,人工势场方法^[7],虚拟领导者方法^[8]和基于行为方法^[9]。

在无人机编队控制领域,当前主要采用两类控制方法:一是基于精确数学模型的传统控制技术,二是利用深度强化学习实现的智能控制方法。前者依赖于对系统的详细建模,后者则通过机器学习算法使无人机能够在不确定环境中自主学习优化飞行策略。

传统的控制方法主要包括模糊逻辑控制方法,模型预测控制方法,滑模控制方法。但是模糊集合的调整优化较为困难,并且以上这些方法都对无人机运动建模和环境建模有较高的要求。

随着神经网络方法的发展,深度强化学习方法有了很多应用,如电子游戏领域^[10-11]、大模型领域^[12]、控制领域^[13-14],战场智能决策^[15-16]。在固定翼无人机编队场景中,强化学习方法可以通过试错学习控制策略,是一种高效、适应性强的方法。近年来,有一些学者使用强化学习方法进行无人机编队控制:

(1) 基于四旋翼无人机模型:文献[17]在

给定编队轨迹上有不错的性能,但是训练轨迹过少,策略与轨迹相关性较大。文献[18]使用多智能体强化学习算法实现编队避障,但是无人机运动仅由速度和方向表示。

(2) 带约束的固定翼无人机模型:文献[19]和文献[20],使用了多种强化学习算法进行无人机编队控制。但是文中使用离散的动作、状态空间,假设无人机有相同的恒定速度。文献[21]实现了编队路径规划控制,但是其无人机模型输入为加速度和角速度,运动过程中保持高度不变。文献[22]和文献[23]基于三自由度模型,并将运动约束在二维平面上。文献[24]在四自由度固定无人机模型上实现集群飞行,其高度受限并且模型难以控制编队队形。文献[25]使用多智能体算法实现编队避障,该模型是二维平面上的圆,且以平面力作为输入。这种模型过于简化,缺少对算法实践的优化。

综上,当前对基于无约束的六自由度固定翼无人机模型的编队问题研究较少。

六自由度固定翼无人机模型可以更准确地描述无人机的运动状态,可以更好地适应动态环境,并且更具备工程实践价值。但是复杂的模型和编队控制场景增加了强化学习算法中的状态维度,基础的强化学习方法在这种场景中学习效率差,甚至难以收敛。

针对无人机编队控制中的复杂挑战,本文提出了三项关键创新:

(1) 提出了一种基于分层深度强化学习的算法 HGC-PPO。HGC-PPO 算法包含编队制导层和

无人机控制层两层。分层框架通过清晰划分模块边界并缩减单个模块的状态空间,有效解决了普通强化学习方法在无人机编队场景中的收敛性问题。

(2) HGC-PPO 使用多输入多输出 (Multiple-Input Multiple-Output, MIMO) 的控制层。优化了传统 PID 算法在固定翼无人机控制场景中调参困难和难以适应多变量耦合系统的问题。

(3) 在 HGC-PPO 的编队制导层中,使用了基于课程学习的奖励模型。这种模型可以保证智能体的学习由易到难,平滑智能体的学习曲线,提高训练效率。

2 固定翼无人机飞行动力学建模

本研究使用基于 JSBSim^[26] 的六自由度固定翼无人机模型。该模型假设无人机为刚体,在运动中不发生形变。模型有在机体坐标系中围绕质心的三个旋转自由度和三个平动自由度。

六自由度固定翼无人机可以进行绕三个坐标轴的转动,所以无人机的机体坐标系 $O_b x_b y_b z_b$ 与地面坐标系 $O_g x_g y_g z_g$ 不重合。无人机的欧拉角是通过无人机机体坐标系与地面坐标系之间的关系确定的。俯仰角 θ 表示机体纵轴与地面的夹角。偏航角 ψ 表示机体纵轴在水平面上的投影与地面坐标系 x 轴的夹角。滚转角 ϕ 表示机体竖轴与铅垂面的夹角。地面坐标系与无人机机体坐标系中的物理量可以通过欧拉旋转矩阵进行转换。

地面坐标系,机体坐标系,欧拉角之间的关系示意图如图1所示。




图1 固定翼无人机姿态图

Fig. 1 Attitude of fixed-wing UAV

当无人机进行旋转运动时,沿着机体坐标系三个轴产生的角速度 p 、 q 、 r 与欧拉姿态角的关系为

$$\begin{cases} p = \dot{\phi} - \dot{\psi} \sin \theta \\ q = \dot{\theta} \cos \phi + \dot{\psi} \cos \theta \sin \phi \\ r = -\dot{\theta} \sin \phi + \dot{\psi} \cos \theta \cos \phi \end{cases} \quad (1)$$

在六自由度固定翼无人机模型中,无人机的速度在机体轴上的分量为

$$\begin{cases} u = |V| \cos \alpha \cos \beta \\ v = |V| \sin \beta \\ w = |V| \sin \alpha \cos \beta \end{cases} \quad (2)$$

式中,迎角 α 是飞行速度矢量在机身平面上的投影与无人机朝向的夹角; V 为速度矢量;侧滑角 β 是无人机速度矢量与无人机对称平面上的夹角。

六自由度固定翼无人机的输入为 $\{\delta_a, \delta_e, \delta_r, \delta_i\}$, 表示四个控制杆的位移。

3 主要方法

3.1 问题描述

无人机编队控制的目标是通过协调多个无人机的行为,使其能够以特定的几何构型和动态特性完成任务。本研究中使用领导者-跟随者方法对无人机编队进行控制。以数学公式形式描述无人机编队控制的最优化目标 J 为

$$J = \text{MIN} \left(\sum_{i=1}^T \sum_{i=1}^N (\|p_i - p_i^{\text{des}}\|^2) \right) \quad (3)$$

式中, p_i 表示跟随者 i 无人机在领导者机体坐标系中的方位向量, p_i^{des} 表示对应的期望位置向量。式(3)构建了编队控制的系统优化目标,其核心在于实现全局误差范数的聚合优化,从而确保编队拓扑结构在动态任务中的时空一致性。

本研究中的无人机编队控制步骤如下:

(1) 根据领导者-跟随者模型计算期望速度向量与期望位置向量。

(2) 使用 HGC-PPO 算法分别控制每个跟随者达到期望位置。

HGC-PPO 算法将编队期望位置生成与强化学习控制两个部分解耦。HGC-PPO 算法聚焦于具有普适性的动态轨迹跟踪问题,而无需依赖特定编

队拓扑的先验知识,从而支持异构编队构型与动态间距调整任务的快速迁移。为聚焦核心问题验证,研究设定以下理想化条件:

(1) 无人机的运动不受外界条件干扰。

(2) 无人机编队间的通信不受干扰并且忽略时间延迟,确保全局信息同步。

3.2 基于分层策略的HGC-PPO算法框架

HGC-PPO算法基于JSBSim固定翼无人机模型。该模型能够高精度复现无人机在真实飞行中的动力学特性,基于此类高保真模型的算法设计更具有通用性。

HGC-PPO算法采用分层架构,将无人机编队控制解耦为无人机控制与编队制导两个子模块,使用飞控指令中间状态作为模块交互接口,将复杂问题分解为两个子问题。分层架构增强了算法的通用性。图2中对比了HGC-PPO算法和近端策略优化算法(Proximal Policy Optimization, PPO)。

HGC-PPO算法基于PPO算法^[27],PPO算法的核心思想在于通过Actor-Critic架构实现策略优化。

固定翼无人机的动作控制需要四维控制量的协同工作。传统PID控制器依赖多个单输入单输出(Single-Input Single-Output, SISO)系统的组合,这不仅使得参数调整复杂化,而且难以有效处理多变量间的耦合效应。HGC-PPO算法的控制层采用神经网络生成所有必要的控制量,构成一个多输入多输出(Multiple-Input Multiple-Output, MIMO)系统。这种方法减少了对先验知识的依赖,简化了参数调整过程,可以实现多变量协同控制。在固定翼无人机系统中,调整任何一个运动参数都需要多个控制舵面的协同操作。例如,飞行器的俯仰-高度耦合现象:调整飞机的俯仰角

会改变升力方向,从而影响飞行高度和空速,进一步作用于飞行器的稳定性。因此,在调整飞行高度时,需协调控制俯仰角与油门两个控制舵。通过强化学习方法,HGC-PPO能够更好地实现协同控制,提供更为精准和平滑的控制效果。

HGC-PPO编队制导层需要解决对四维轨迹 $f(x, y, z, t)$ 的动态跟踪制导问题,这种动态制导任务较为复杂。面对这种高维度和动态变化的任务,如果奖励函数设计不当,会导致算法学习效率低下甚至无法收敛。基于课程学习^[28]的奖励函数可以逐步增加任务难度的方式训练模型,让智能体从简单到复杂逐渐学习,从而加速训练过程、提高优化效果,并增强泛化能力。这种方法可以有效减少梯度波动,使模型更好地适应复杂数据。

3.3 基于强化学习的无人机控制层

控制层的状态空间主要包括本机的基本运动状态和上层的制导运动指令。因为无人机的输入状态包含了多种不同单位的物理量,在输入神经网络前,无人机输入状态归一化至 $[-1, 1]$,角度用正弦和余弦处理。考虑控制误差和基本运动信息,状态空间设计为 $[u, v, w, v_c, \Delta z, \Delta v_c, \Delta \phi, \phi]$ 。其中, (u, v, w) 为三维空间内的速度分量, $(\Delta z, \Delta v_c, \Delta \phi)$ 由上层编队制导模块输出 $(z_t, v_{c,t}, \phi_t)$ 和实际状态 (z, v_c, ϕ) 计算得到。

固定翼无人机的输入控制为 $\{\delta_a, \delta_e, \delta_r, \delta_t\}$ 。其中,副翼控制 δ_a ,升降舵控制 δ_e ,方向舵控制 δ_r 的范围都是 $[-1, 1]$ 。油门控制 δ_t 的范围被设定为 $[0.2, 1]$,油门控制最低值设置可以防止无人机失速,提高稳定性。

控制层的奖励函数主要考虑控制误差和稳定




图2 算法框架对比图

Fig. 2 Comparison of algorithm framework

性两个方面。所以奖励函数为

$$r = r_{\text{error}} + r_{\text{stable}} \quad (4)$$

式中, r_{error} 为误差奖励, r_{stable} 为稳定奖励。单个控制误差由式(5)统一计算。这样的计算方法可以加速误差在0附近的收敛速度, 系数 k_i 用来平衡各个误差项的量纲。误差奖励为单个误差奖励的几何平均值。在MIMO系统中, 使用几何平均值作为误差的衡量方式, 能够更有效地捕捉多个控制变量之间的相对变化关系, 从而提供更均衡的性能反馈。误差计算公式为

$$r_{\text{error}} = \sqrt[n]{\prod_{i=1}^n e^{(\text{target} - \text{value})^2 \cdot k_i}} \quad (5)$$

控制成本奖励是为了使智能体尽量输出稳定的动作, 使用尽可能少的操作达到目标状态。控制成本奖励公式为

$$r_{\text{stable}} = \sqrt[n]{\prod_{i=1}^n e^{\Delta \text{in}^2 \cdot k_i}} \quad (6)$$

式中, Δin 表示 $\delta_a, \delta_e, \delta_r, \delta_i$ 四个控制值的变化量, 系数 k_i 用来平衡各项控制量对稳定性的影响。

最后本研究基于以下几点原则设置终结条件:

(1) 任务目标约束原则。当前任务为无人机控制任务, 当控制误差过大时判断当前任务失败, 减少偏离任务的无效探索。当无人机的期望滚转角与当前滚转角差值大于 45° , 或者期望速度与当前速度差值大于 80 m/s , 或者期望高度与当前高度大于 1500 m 时终结训练, $r = -5$ 。

(2) 安全性原则。防止智能体输入危险动作, 导致无人机失控或处于失控边缘。根据JSBSim模型参数, 当无人机的法向加速度绝对值大于 $2.5g$ 时或者切向加速度大于 $0.5g$ 时, 终结训练, $r = -5$ 。

(3) 防止过度优化原则。限制无人机角速度范围, 防止极端情况下智能体过度优化导致动作失稳。当无人机滚转角速度大于 $40 (^\circ)/\text{s}$ 、俯仰角速度大于 $5 (^\circ)/\text{s}$ 、偏航角速度大于 $4 (^\circ)/\text{s}$ 时, 终结训练, $r = -5$ 。

(4) 防止单局训练时间过长。单局训练时间过长时, 神经网络对价值函数的估值方差会变大, 不利于网络收敛。当训练时间大于 200 s 时终结训

练, $r = 5$ 。

3.4 基于强化学习和课程学习的编队制导层

编队制导层基于领导者-跟随者^[6]模型进行编队制导目标计算, 并依据制导目标与被控无人机的实时状态生成相应的控制动作。制导层基于相对状态构建奖励函数, 避免依赖全局坐标系或预设轨迹。训练过程中引入的随机化初始状态与随机动作选择, 进一步增强了策略的泛化鲁棒性。

在编队制导层实验中, HGC-PPO算法的核心任务是通过解析动态制导目标(长机)与跟随者无人机的实时状态信息, 生成鲁棒性控制策略以最小化编队间距误差。

编队制导层状态向量如式(7)所示:

$$[\Delta x, \Delta y, \Delta z, \rho, \Delta v_c, \eta, \dot{\psi}, \dot{\psi}_i, \Delta \psi, u, v, w, \phi, \psi, \theta] \quad (7)$$

式中, $(\Delta x, \Delta y, \Delta z)$ 表示三维空间内制导目标位置和本机位置的差值; ρ 表示在二维水平面上制导目标位置和本机位置的差值; Δv_c 表示制导目标速度和本机速度的差值; η 表示速度方向和二维空间距离误差向量的夹角; $(\dot{\psi}, \dot{\psi}_i, \Delta \psi)$ 依次表示: 期望朝向角和实际朝向角度差, 朝向角度变化率, 期望朝向角度变化率; (u, v, w) 表示机体坐标系的速度分量; (ϕ, ψ, θ) 依次表示无人机的滚转角, 朝向角和俯仰角。

在动作空间的设计上, 本节使用3.3节中的控制层接口进行动作转换。三维驾驶编队制导动作为 $[v_i, \phi_i, z_i]$ 。其中, v_i 表示期望速度, 取值范围是 $[80, 200] \text{ m/s}$ 。 ϕ_i 表示期望滚转角, 取值范围是 $[-72, 72] (^\circ)$; z_i 表示期望高度, 取值范围是 $[1500, 9000] \text{ m}$ 。

编队制导层需要考虑三维空间中的编队制导误差, 还应综合考虑无人机自身的运动状态, 以实现有效的协同控制。因此, 奖励函数应同时反映无人机的运动状态和编队制导误差, 以指导系统在任务执行过程中的协调与优化。总奖励函数为各个项的加权和, 奖励函数设计公式为

$$r_t = k(r)r_{t, \text{dis}} + \lambda_1 r_{t, z} + \lambda_2 r_{t, \phi} + \lambda_3 r_{t, v} \quad (8)$$

式中, $r_{t, \text{dis}}$ 表示二维平面上的距离误差奖励; $r_{t, z}$ 表示高度误差奖励; $r_{t, \phi}$ 和 $r_{t, v}$ 表示运动状态奖励。

式(8)中的系数 $k(r)$ 为课程权重, $\lambda_1, \lambda_2, \lambda_3$ 为固定权重。

奖励函数权重项的设计基于以下三点原则:

(1) 量纲平衡原则。基于不同物理量的奖励项具有显著差异的数值尺度。通过引入归一化权重因子, 可将各奖励项映射至同一数量级空间, 从而规避因量纲差异导致的多奖励项退化为单一奖励主导的情况。

(2) 梯度均衡原则。不同奖励项对应的物理量具有显著差异的时变特性, 因此需要权重项避免奖励梯度偏置。

(3) 课程学习原则。通过动态权重构建渐进式目标空间, 实现训练过程的多阶段优化导向。

课程权重机制通过动态调节学习目标优化训练过程, 初期编队制导层基于先验知识构建基础运动策略, 待策略稳定后, 逐步降低先验约束权重, 引导智能体在既有策略上进行精细化调优。这种分阶段训练模式实现了从知识引导到自主探索的平滑过渡。式(8)只使用一项课程权重, 可以使不同课程的分布尽可能相似, 平滑不同课程之间的梯度, 提高训练稳定性。

课程权重的计算方法如式(9)所示。缓存池用于存储平均奖励值 $\overline{r_{\text{epi}}}$ 。缓冲池中的平均奖励可以反映智能体对当前课程的掌握情况。当缓存池满后, 根据 $\overline{r_{\text{epi}}}$ 奖励统计值, 迭代课程权重。只有缓存池满后才会迭代, 保证一定时间内课程的稳定性。图3为课程权重迭代示意图。课程权重迭代计算公式为

$$k(r) = \sum_{i=1}^n \frac{1}{1 + e^{a_i \cdot r + b}} \quad (9)$$

式中, n 表示课程数量; r 表示奖励值; a_i 和 b 为系数参数。求和项的形式确保在一定的窗口内, 课程权重相近, 提高了课程奖励模型的稳定性。



图3 课程权重迭代方法

Fig. 3 Course weight iteration method

在实验中, 设置课程数量 $n = 4$, $k_1 = 0.2$, $k_2 = 2$, $k_3 = 1$ 。

式(8)中每一项奖励的计算均采用与式(10)相同的形式。式(10)为本文中的奖励计算通用公式, 计算方法在变量 x 接近目标target的时候会产生更大的梯度。

$$f(x_{\text{target}}, x, b) = \log_2 \left(\frac{1}{2} + |x_{\text{target}} - x| \right) + \max \left[\log_2 \left(\frac{1}{2} + |x_{\text{target}} - x| \right) - b, 0 \right] \quad (10)$$

在式(8)中, 求和项 $r_{t, \text{dis}}$ 和 $r_{t, z}$ 的作用是引导智能体最小化三维空间内的编队制导距离误差。所以计算过程中: $\text{dis}_{\text{target}} = 0$, $z_{\text{target}} = z_0$ 。

式(8)中, $r_{t, \phi}$ 的作用是引导滚转控制学习。其核心设计包含双目标优化: 抑制制导目标与本机的距离误差及姿态角偏差。如式(11)所示, 理想滚转角由三项加权合成: 第一项通过最小化朝向与距离向量角度差抑制距离误差; 第二、三项联合抑制目标与本机状态偏差及其动作误差, 实现运动策略的渐进优化。

$$\phi_{\text{target}} = (\eta_{\text{dis}} - \psi) - 1.5(\psi_t - \psi) + 3(\dot{\psi}_t - \dot{\psi}) \quad (11)$$

式(8)中, $r_{t, v}$ 的主要功能是引导智能体减小距离误差, 如式(12)和式(13)。 v_{dis} 表示当前速度向量与水平距离向量的夹角, 用于判定加速与减速。 v_{target} 由夹角 v_{dis} , 距离 dis , 跟随者速度 v_f 共同决定。

$$v_{\text{dis}} = \arccos \left(\frac{\text{dis} \cdot v}{(|\text{dis}| \cdot |v|)} \right) \quad (12)$$

$$v_{\text{target}} = v_f + \text{sgn}(v_{\text{dis}}) \cdot \frac{\text{dis}}{k} \quad (13)$$

最后, 本节同样基于3.2节中的终结条件设置原则, 设计如下终结条件:

(1) 任务目标约束。当编队水平距离误差大于5000 m或者高度误差大于2000 m时结束训练, $r = -15$ 。

(2) 防止单局训练时间过长。训练时间达到300 s, 结束训练, $r = -10$ 。

(3) 安全性原则。速度小于60 m/s时结束训练, $r = -10$ 。

HGC-PPO算法的伪代码如算法1所示。

算法 1: HGC-PPO

输入 两个模块的参数:每局步数 n_{step} ,每次更新回合数 n_{episode} ,算法超参数:学习率、激活函数、交叉熵权重

输出 编队飞行控制策略 π_{θ}

1. 无人机控制层训练阶段

2. 初始化仿真环境,初始化控制器神经网络参数 θ

3. **For** episode=1 to n_{episode} **do**

4. 初始化环境,随机化初始状态

5. **For** step=1 to n_{step} **do**

6. 根据当前策略输出控制动作与环境交互。

7. 将交互信息存入 buffer

8. 更新网络参数并清空 buffer

9. **End For**

10. **End For**

11. 编队制导层训练阶段

12. 初始化仿真环境,初始化编队制导神经网络参数 θ

13. **For** episode=1 to n_{episode} **do**

14. 初始化环境,随机化初始状态

15. **For** step=1 to n_{step} **do**

16. 根据当前策略输出编队制导动作

17. 使用控制器将编队制导动作转化并与环境交互。

18. 将交互信息存入 buffer

19. 更新网络参数并清空 buffer

20. **IF** 适应性权重缓冲池满

21. 更新权重,并清空缓冲池

22. **End IF**

23. **End For**

24. **End For**

25. 结束训练,得到编队飞行控制策略

4 无人机控制层实验

4.1 无人机控制层实验设计

在 HGC-PPO 算法的控制层训练中,采用了广泛的随机化策略,包括初始状态的随机化以及目标切换的随机化。这种设计旨在使编队制导层学习更加通用和稳健的策略。通过环境层面的随机化增强了算法的探索性,并有效增加了训练样本的多样性,从而减轻了模型的过拟合风险。

控制层的目标是在各种状态下,都能使实际运动状态逼近目标状态。每回合开始时,随机化初始速度、滚转角、高度($v_{\text{init}}, \phi_{\text{init}}, z_{\text{init}}$);随机化目标速度、滚转角、高度(v_t, ϕ_t, z_t)。速度的范围是 $[70, 350]$ m/s, 滚转角的范围是 $[-70, 70]$ ($^{\circ}$), 高度的范围是 $[3000, 8000]$ m。训练过程中,每

150 步随机改变目标状态增量($\Delta v_t, \Delta \phi_t, \Delta z_t$)。目标速度增量、目标滚转角增量,目标高度增量的范围依次为 $[-40, 40]$ m/s, $[-45, 45]$ ($^{\circ}$), $[-1500, 1500]$ m。使用目标状态增量并且设置增量范围可以有效提高控制的稳定性和可行性。

无人机控制实验的评价指标主要涵盖两方面:一是控制项的稳态误差,即无人机实际运动状态稳定值与目标值的偏差程度,它反映了控制的精准度;二是控制的响应速度,体现为无人机对指令的响应快慢。这两个关键指标均可通过无人机实际运动状态随时间的响应图进行直观观测与分析。控制实验的超参数如表 1 所示。

表 1 训练超参数

Table 1 Hyper parameters of training

参数	值
折扣因子	0.99
优化器	Adam
学习率	0.002
批处理回合数	15
交叉熵权重	0.01
PPO 裁剪边界	0.2
优势估计参数 λ	0.98
仿真步长/s	0.2
仿真最大步数	1 000
激活函数	Tanh
Actor 神经元数量	[256,256,256]
Critic 神经元数量	[256,256,256]

4.2 无人机控制层实验结果

在本节中,使用 PID 控制算法作为基线算法。图 4 中包含控制层的实验结果,图 4 (a) 表示控制层训练过程中的奖励值,在 300 次更新后,控制算法已经收敛,达到稳定状态。图 4 (b) ~ (d) 表示 HGC-PPO 控制器和 PID 算法的对比结果。实验通过多次切换目标值来测试控制器的控制性能和响应速度。

(1) 高度控制实验。图 4 (b) 表示高度控制实验结果。在高度调整过程中, HGC-PPO 算法控制层有更快的响应速度,可以在 30 步左右完成高度调整,并且在目标高度附近波动小,控制更加稳定。

(2) 速度控制实验。图 4 (c) 表示速度控制

实验。目标速度发生较大改变时, HGC-PPO 控制层的性能和 PID 控制算法相近, 二者都可以在 150 步内响应并且有较小的控制误差。

(3) 滚转控制实验。图 4 (d) 表示滚转控制实验。HGC-PPO 算法控制层在滚转角控制实验中, 可以在快速响应的同时, 保持稳定的、波动较小的控制。而 PID 算法控制误差较大。原因是滚转控制中, 需要方向舵和副翼的联合控制。并且, 相同的副翼控制量在运动速度不同时有不同的效果。HGC-PPO 算法控制层属于 MIMO 系统, 在随机场景中, 可以有效学习耦合系统中的控制方法。这种特点使得 HGC-PPO 控制层算法比人工调整参数的 PID 算法有更好的适应性。

5 编队制导层实验

在编队制导层训练中, 采用长机轨迹作为动态跟踪基准, 聚焦于控制策略对时变目标的自适应能力, 暂不考虑避碰约束以降低策略探索维度。

算法收敛后进入编队飞行验证阶段, 基于领导者-跟随者架构构建僚机的期望位置生成模型, 并通过动态轨迹追踪实现多机协同运动控制, 同时通过设定编队间距阈值 (大于算法最大跟踪误差的 1.3 倍) 引入被动避撞机制, 确保在未显式嵌入避碰逻辑条件下满足编队飞行安全性需求。

5.1 编队制导层实验设计

在编队制导层实验中, 也使用与控制层相似的随机化策略以提高泛化性。在每局训练开始时, 随机初始化智能体与动态制导目标的三维相对距离 $(\Delta x, \Delta y, \Delta z)$, $\Delta x, \Delta y$ 范围为 $[-3000, 3000]$ m, Δz 范围为 $[-1500, 1500]$ m; 相对速度 Δv_c 的范围为 $[-50, 50]$ m/s; 相对朝向角度 $\Delta\psi$ 的范围 $[0, 360]$ ($^\circ$)。随机初始化可让智能体学会从各类初始位置出发完成对动态目标的制导; 另一方面, 在编队飞行遭遇智能体制导失误而脱离目标的情况时, 随机初始化赋予的经验可使其快速恢复, 增强了整体系统的鲁棒性和适应性。此外,




图4 HGC-PPO控制层实验结果

Fig. 4 Experimental results of the HGC-PPO controller module

动态制导目标随机化初始速度、滚转角、高度 (v_i, ϕ_i, z_i) 。训练过程中每300步随机改变状态增量 $(\Delta v_i, \Delta \phi_i, \Delta z_i)$ 。具体随机化参数与控制层实验相同。

最后,本节训练参数中的仿真最大步数设置为1500步,主要是因为编队制导的响应周期相较于无人机控制更长。其余参数与控制实验中相同。

本节设置了两个指标来说明算法的控制优化效果:

(1) 平均编队制导误差 $\bar{d}$ 。平均编队制导误差是编队控制算法在任务周期内的误差均值,反映算法在常态工况下的综合控制精度,可作为无人机编队控制场景的性能基准参考值。在式(14)中, d_i^t 表示在 t 时刻无人机 i 的编队距离误差。分母项通过编队规模 n 与任务周期时间步总量 N_t 构建全局归一化因子,该指标以全域时空均值形式量化编队系统的平均跟踪精度,综合表征算法的稳态控制精度与一致性表现。

$$\bar{d} = \frac{\sum_{i=1}^n \sum_{t=1}^{N_t} d_i^t}{nN_t} \quad (14)$$

(2) 最大编队制导误差 $d_{\max}$ 。最大编队制导误差表征算法在多种复杂机动下的误差峰值,体现控制系统的鲁棒性边界,为编队安全间距设计、容错控制阈值划定等安全性分析提供关键量化依据。在式(15)中, $d_{(i,t)}$ 表示跟随者 i 在 t 时刻的编队距离误差, $\text{MAX}()$ 运算通过跨时域峰值提取,捕获所有跟随者在任务全周期内的最大误差极值。

$$d_{\max} = \text{MAX}(d_{(i,t)}) \quad (15)$$

5.2 编队制导层实验结果

图5为编队制导层的奖励图。在实验中, HGC-PPO算法是本文中提出的新算法。PPO算法是本文中的基线算法, PPO算法使用单层架构, PPO算法的奖励是制导层奖励函数和控制层奖励函数的总和。PID-PPO算法也是分层的算法, 制导层设计与HGC-PPO算法相同, 控制层使用PID算法。图5中的评估奖励与制导层奖励函数相同, 为了平衡评估奖励中的项, 评估奖励中各项系数固定为1。




图5 算法奖励图

Fig. 5 Diagram of algorithm reward

从图5可以看到, 尽管PPO算法与HGC-PPO算法奖励函数相同, 但是单个模块无法将复杂问题解耦, 复杂的状态空间导致智能体的探索学习效率低下, 算法无法收敛。PID-PPO算法也采取分层架构, 所以整体上可以学到有效的控制策略。但是单输入单输出的PID控制层的控制能力相比HGC-PPO控制层较差, 具有更快响应速度和更小稳定误差的HGC-PPO控制层可以有效优化整体控制效果。PID-PPO算法的评估奖励稍差于HGC-PPO算法。

除此之外, 还采用图5中的三种算法分别进行100次随机化测试, 用于对比三种算法的性能。随机化测试的设计与随机化训练相同; 测试得到的指标数据如表2所示。其中, HGC-PPO有最小的编队制导误差。

表2 算法性能对比表

Table 2 Comparison of training method performance

算法	平均编队制导误差/m	最大编队制导误差/m
HGC-PPO	39.57	58.09
PID-PPO	60.26	244.76
PPO	2563.7	3257.4

在图6中进一步可视化了HGC-PPO算法的制导轨迹, 包括了高度调整、S形转弯、连续转弯场景。图6中的 x 轴、 y 轴、 z 轴分别为北向距离、东向距离和高度, 单位为m。图6的三个场景的平均控制误差分别为29.26 m, 33.01 m, 35.33 m。不同场景中的控制误差较为接近, 证明了制导算法具有良好的泛化性和稳定性。

5.3 无人机编队实验结果

本节设计了多机编队实验以验证编队算法的有效性。实验中使用HGC-PPO算法进行五架飞机编队控制，无人机的相对距离设置为80 m以保持飞行安全，控制效果图如图7所示。图7中包含四种场景：转弯，直线飞行，S型转弯以及螺旋飞行。

在图8中，进一步描述了算法在图7的四种场景中的控制误差。图8的纵坐标轴采用编队距离误差与无人机宽度的无量纲比值（即归一化编队

误差），其计算如式（16）所示，通过将编队位置偏差量 d 与无人机横向特征尺寸 w 相除，构建可跨机型、跨尺度的标准化性能评价参数。本实验中 $w = 10\text{ m}$ 。

$$y = \frac{d}{w} \quad (16)$$

在图7的全部四种编队运动场景下，所有跟随者均能以极高的效率与领导者完成编队构建。当领导者执行不同的机动策略时，跟随者不但能够精准地追随领导者的机动状态，而且始终维持领导者-跟随者模型中预先设定的队形。




图6 编队制导轨迹对比图

Fig. 6 Comparison of formation guidance trajectory




图7 HGC-PPO算法编队控制图

Fig. 7 Formation control diagram with HGC-PPO algorithm




图8 HGC-PPO算法编队控制误差

Fig. 8 HGC-PPO algorithm formation control error

6 结 论

综上,本文提出了一种基于深度强化学习的HGC-PPO算法。该算法主要使用了分层框架对复杂问题进行拆解;其中的控制层基于强化学习,相较于传统控制器更高效;制导层使用了基于课程学习的奖励模型,保证算法收敛的同时提高了收敛速度。本文得出以下主要结论:

(1) 基于分层架构的HGC-PPO算法有效解决了无人机编队控制中普通强化学习算法收敛性差的问题。

(2) HGC-PPO的无人机控制层有效地解决了传统控制算法调参困难和耦合变量控制困难的问题。

(3) HGC-PPO编队制导层中基于课程学习的奖励模型可以在保证收敛的同时提升算法训练速度。

[参 考 文 献]

- [1] Xu FM, Shi W, Feng T, et al. UAV assisted communication network uplink transmission technology based on joint beamforming[J]. Journal of Electronics & Information Technology, 2022, 44 (3): 871-880.
- [2] Fu L, Xie F, Wang D, et al. The overview for UAV air-combat decision method[C]. The 26th Chinese Control and Decision Conference (2014 CCDC). IEEE, Changsha, China, 2014: 3380-3384.
- [3] Cao Y, Ren W, Meng Z. Decentralized finite-time sliding mode estimators with applications to formation tracking[C]. Proceedings of the 2010 American Control Conference, Baltimore, MD, USA, 2010: 4610-4615.
- [4] Wang C, Wang J, Shen Y, et al. Autonomous navigation of UAVs in large-scale complex environments: A deep reinforcement learning approach[J]. IEEE Transactions on Vehicular Technology, 2019, 68 (3): 2124-2136.
- [5] Bieniawski S R, Rosenzweig S, Blake W B. Summary of flight testing and results for the formation flight for

- aerodynamic benefit program [C]. 52nd Aerospace Sciences Meeting, National Harbor, Maryland, USA, 2014.
- [6] Do K D, Pan J. Nonlinear formation control of unicycle-type mobile robots [J]. *Robotics and Autonomous Systems*, 2007, 55 (3): 191–204.
- [7] Dimarogonas D V, Loizou S G, Kyriakopoulos K J, et al. A feedback stabilization and collision avoidance scheme for multiple independent non-point agents [J]. *Automatica*, 2006, 42 (2): 229–243.
- [8] Ren W, Beard R W. Decentralized scheme for spacecraft formation flying via the virtual structure approach [J]. *Journal of Guidance, Control, and Dynamics*, 2004, 27 (1): 73–82.
- [9] Lawton J R T, Beard R W, Young B J. A decentralized approach to formation maneuvers [J]. *IEEE Trans. Robotics and Automation*, 2003, 19 (6): 933–941.
- [10] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning [J]. *Nature*, 2015, 518 (7540): 529–533.
- [11] Ye D, Liu Z, Sun M, et al. Mastering complex control in moba games with deep reinforcement learning [J]. *Proceedings of the AAAI Conference on Artificial Intelligence*, 2020, 34 (4): 6672–6679.
- [12] Zhang D, Chen L, Zhang S, et al. Large language models are semi-parametric reinforcement learning agents [J]. *Advances in Neural Information Processing Systems*, 2023, 36: 78227–78239.
- [13] Romero A, Song Y, Scaramuzza D. Actor-critic model predictive control [C]. 2024 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2024: 14777–14784.
- [14] Rudin N, Hoeller D, Reist P, et al. Learning to walk in minutes using massively parallel deep reinforcement learning [C]. *Conference on Robot Learning*. PMLR, Auckland, New Zealand, 2022: 91–100.
- [15] 唐文泉, 孙莹, 杨奇, 等. 一种面向2V2近距空战的强化学习算法[J]. *战术导弹技术*, 2022 (1): 120–130.
- [16] 郑成辰, 李辉, 陶伟, 等. 基于深度强化学习的导弹末端约束角制导律[J]. *战术导弹技术*, 2022 (6): 93–102+110.
- [17] 吴婷, 叶林奇, 杨君, 等. 基于强化学习的多无人机避障编队控制[J]. *飞控与探测*, 2025, 8 (2): 9–17.
- [18] 张宇宸, 段海滨, 魏晨. 基于深度强化学习的无人机集群数字孪生编队避障[J]. *工程科学学报*, 2024, 46 (7): 1187–1196.
- [19] Hung S M, Givigi S N, Noureldin A. A dyna-q (λ) approach to flocking with fixed-wing UAVs in a stochastic environment [C]. 2015 IEEE International Conference on Systems, Man, and Cybernetics. IEEE, Kowloon Tong, Hong Kong, 2015: 1918–1923.
- [20] Hung S M, Givigi S N. A Q-learning approach to flocking with UAVs in a stochastic environment [J]. *IEEE Transactions on Cybernetics*, 2016, 47 (1): 186–197.
- [21] 唐恒, 孙伟, 吕磊, 等. 融合动态奖励策略的无人机编队路径规划方法[J]. *系统工程与电子技术*, 2024, 46 (10): 3506–3518.
- [22] Li B, Yang Z, Chen D, et al. Maneuvering target tracking of UAV based on MN-DDPG and transfer learning [J]. *Defence Technology*, 2021, 17 (2): 457–466.
- [23] 唐恒. 无人机强化学习动态编队及路径规划研究[D]. 西安: 西安电子科技大学, 2023.
- [24] 相晓嘉, 闫超, 王菖, 等. 基于深度强化学习的固定翼无人机编队协调控制方法[J]. *航空学报*, 2021, 42 (4): 420–433.
- [25] 虞逸凡. 基于深度强化学习的多智能体编队避障控制研究[D]. 大连: 大连海洋大学, 2024.
- [26] Berndt J. JSBSim: An open source flight dynamics model in C++ [C]. AIAA Modeling and Simulation Technologies Conference and Exhibit. Providence, Rhode Island, 2004.
- [27] Schulman J, Wolski F, Dhariwal P, et al. Proximal Policy Optimization Algorithms [EB/OL]. 2017 [2025]. <https://arxiv.org/abs/1707.06347>
- [28] Bengio Y, Louradour J, Collobert R, et al. Curriculum learning [C]. *Proceedings of the 26th annual international conference on machine learning*. Montreal, Quebec, Canada, 2009: 41–48.