

单位代码：10610

学 号：2021223045140

四川大學

硕士研究生学位论文

(专业学位)

题目： 基于深度强化学习的视距内空战

机动决策算法研究

培养单位： 计算机学院

作者姓名： 田成滨

指导教师： 李辉 教授

学位类别： 工程硕士

领域名称： 计算机技术

论文答辩时间：二〇二四年五月

学位授予时间：二〇二四年六月

**Research on Maneuver Decision Algorithm for Air Combat
Within Visual Range Based on Deep Reinforcement Learning**

**A dissertation submitted to Sichuan University
in partial fulfillment of the requirements
for the degree of
Master of Engineering
in Computer Technology**

**By
Tian Chengbin
Supervisor: Prof. Li Hui**

Computer Science, Sichuan University, Chengdu, China

May 2024

摘 要

空战是未来战争中影响胜负的核心领域。借助人工智能等技术手段,实现自动化、智能化的空战目标,是目前航空航天、自动化、人工智能等学科研究领域的热点课题。基于深度强化学习的视距内空战机动决策算法,是一类应用机器学习技术解决空战决策问题的前沿算法,被视作当前智能化空战研究领域极具价值与潜力的研究方向。

本文从基于深度强化学习的视距内空战机动决策算法研究领域的研究现状出发,梳理综述了领域内相关研究中普遍存在的问题,针对各个问题分别设计并提出了具有对应优化效果的解决方案。本文的主要研究工作及取得的成效包括:

(1) 针对战场态势感知误差对基于深度强化学习的视距内空战机动决策算法训练和机动决策的干扰问题,提出一种基于门控循环单元提取态势特征的近端策略优化算法,在端到端的强化学习训练过程中,降低态势感知误差对训练和机动决策的影响。首先,依据态势时间序列模型,推导引入前序态势序列信息以降低态势感知误差所造成影响方案的可行性。随后,在近端策略优化算法的基础上,引入门控循环单元,融合前序态势信息,提取连续态势序列中的隐藏特征。接着,设置优势态势解算单元,压缩状态空间维度、降低训练难度。同时,设计一种量化优势的奖励塑造方法引导训练加速收敛。最后,通过设计和引入态势感知误差量,搭建具备态势感知误差的空战仿真环境,在不同感知误差强度和不同敌我初始态势等多个场景下进行仿真对比实验。实验结果表明,所提算法的训练速度和训练模型机动决策性能均显著优于基础强化学习算法,能够有效提高飞行器在面对战场态势感知误差时的空战机动决策能力。

(2) 针对基于深度强化学习的视距内空战机动决策算法应用中,普遍存在特定训练模型泛化性能弱的问题,提出一种基于自注意力机制与预训练模型的近端策略优化算法,在不显著降低机动决策性能的前提下,削弱训练模型对训练场景的拟合程度,提高训练效率和决策针对性,从而提高特定训练模型泛化性能。首先,推导在迁移学习和策略重用思想基础上,引入自注意力机制以提高训练效率和训练模型泛化性能的可行性。随后,在近端策略优化算法基础上,设计引入一种基于自注意力机制的实时奖励塑造方法,提高智能体在训练探索中的针对性。同时,设计并训练实现具备基础机动控制能力和终段追击能力的预训练决策模型,基于预训练模型进行强化学习训练,从而提高训练效率、降低训练模型对训练场景拟合程度、提高模型泛化能力。最后,设计进行一系列视距内空战场景下的泛化性能测试仿真实验。实验中,经所提算法训练得到的特定模型智能体决策成功率比基线算法提高 20% 以上,证明其能够有效提高特定训练模型在未知空战环境下的决策泛化性能。

(3) 针对基于深度强化学习的视距内空战机动决策研究领域内,缺乏统一标准的

飞行器模型与仿真验证支撑平台的研究现状,同时基于本文所提算法的训练和验证需要,设计并开发一种面向深度强化学习的空战训练仿真一体化平台,支撑不同飞行器模型与机动决策算法的仿真训练和验证。首先,分析平台系统设计需求,对平台进行架构设计与工作流程推演。随后,基于 Qt、OpenGL、PyTorch 库等技术栈,开发实现平台设计预期的各项功能,包括异构模型接入与管理、空战想定批量生成、多线程并行式仿真与训练算法框架等功能模块。最后,将平台应用在本文所提算法的训练和验证实验中,展示平台的应用效果,体现平台开发应用价值。

基于以上研究工作,本文对基于深度强化学习的视距内空战机动决策算法研究领域内存在的态势感知误差干扰、特定训练模型泛化性能弱、缺乏统一标准的模型与仿真平台等问题提供了解决思路与算法技术案例,具备一定的理论价值与工程应用参考价值。

关键词: 视距内空战; 空战机动决策; 深度强化学习; 感知误差; 泛化性能

Abstract

Air combat is identified as a core area influencing the outcome of future warfare. Leveraging artificial intelligence for automated and intelligent air combat is a key research area in the disciplines of aerospace, automation, and artificial intelligence. The maneuver decision algorithm for air combat within visual range based on deep reinforcement learning, represents a forefront algorithm that utilizes machine learning technologies to address decision-making problems in air combat, It is considered a highly valuable and potential research direction in the domain of intelligent air combat studies.

This dissertation reviews the current research in the field of maneuver decision algorithms for air combat within visual range based on deep reinforcement learning, systematically reviewing and identifying common issues, then proposing solutions to optimize them. The main research efforts and achievements of this dissertation include:

(1) Addressing interference from battlefield situational perception errors in deep reinforcement learning-based air combat decision algorithms, this dissertation proposes a proximal policy optimization algorithm based on gated recurrent unit to mitigate perception errors during training. Initially, introducing prior situational sequence information's feasibility to lessen perception errors' impact is derived from a situational time series model. Then, using proximal policy optimization, gated recurrent units are employed to assimilate prior information and extract hidden features in continuous sequences. An advantageous situation solving unit is developed to compact state space and simplify training. A reward shaping method quantifying advantage is designed for faster convergence. Finally, by introducing a situational perception error measure, an air combat simulation with perception errors is created for comparative experiments under varying error intensities and initial scenarios. Results show the algorithm significantly outperforms basic reinforcement learning in training speed and decision-making, effectively enhancing air combat maneuver decisions amidst situational perception errors.

(2) Addressing the issue of weak generalization in specific training models of air combat decision algorithms based on deep reinforcement learning, a proximal policy optimization algorithm based on self-attention mechanism and pretrained model is proposed. This method aims to mitigate overfitting to particular scenarios without sacrificing decision performance, thus improving training efficiency and decision specificity to boost generalization. Initially, it's shown that incorporating self-attention mechanisms, grounded in

transfer learning and policy reuse principles, can elevate training efficiency and generalization. Then, leveraging proximal policy optimization, a real-time reward shaping method inspired by self-attention mechanism is designed to sharpen the agent's focus during exploration. A pretrained decision model featuring basic maneuver controls and pursuit capabilities is also developed. Training with this model is intended to heighten efficiency, diminish scenario-specific overfitting, and improve generalization. Finally, a series of simulation experiments testing generalization performance in within-visual-range air combat scenarios were designed and conducted. In these experiments, agents trained with the proposed algorithm achieved a decision success rate more than 20% higher than that of the baseline algorithm, proving its effectiveness in enhancing the decision generalization capability of specific training models in unknown air combat environments.

(3) Addressing the current research gap of lacking unified standards for aircraft models and a simulation validation platform in the field of deep reinforcement learning-based maneuver decision-making for air combat within visual range, this dissertation designs and develops an integrated training and simulation platform for deep reinforcement learning oriented air combat. This platform facilitates the simulation training and validation of various aircraft models and maneuver decision algorithms, catering to the specific training and validation needs of the algorithm proposed. Firstly, the platform system design requirements are analyzed, followed by the architectural design and workflow deduction of the platform. Subsequently, the platform's anticipated functionalities are developed using a technology stack that includes Qt, OpenGL, and PyTorch libraries. These functionalities encompass modules for accessing and managing heterogeneous models, generating air combat scenarios in batches, and facilitating multi-threaded parallel simulations with training algorithm frameworks. Finally, the platform is applied to the training and validation experiments of the algorithm proposed in this paper, demonstrating its application effectiveness and highlighting the value of its development and use.

Based on these work, this dissertation offers solutions and algorithmic examples to issues in the field of maneuver decision algorithms for air combat within visual range based on deep reinforcement learning, such as interference from situational perception errors, weak generalization performance of specific training models, and the lack of unified standards for models and simulation platforms. It has significant theoretical and practical value.

Key words: air combat within visual range; air combat maneuver decision; deep reinforcement learning; perception error; generalization performance

目 录

摘 要.....	I
Abstract.....	IV
目 录.....	V
图目录.....	IX
表目录.....	XI
第 1 章 引言.....	1
1.1 选题背景与研究意义.....	1
1.1.1 选题背景.....	1
1.1.2 研究意义.....	3
1.2 国内外研究现状.....	3
1.2.1 深度强化学习研究现状.....	3
1.2.2 视距内空战机动决策算法研究现状.....	6
1.3 论文主要研究内容与组织结构.....	12
1.3.1 本文主要研究思路与研究内容.....	12
1.3.2 本文组织结构.....	13
第 2 章 相关理论基础.....	15
2.1 引言.....	15
2.2 视距内空战机动建模.....	15
2.2.1 坐标系.....	15
2.2.2 飞行器动力学模型.....	18
2.2.3 视距内空战相对态势模型.....	20
2.3 深度强化学习理论基础.....	21
2.3.1 马尔可夫决策过程.....	21
2.3.2 深度强化学习理论.....	21
2.3.3 近端策略优化算法.....	26
2.4 本章小结.....	28
第 3 章 基于深度强化学习的抗感知误差空战机动决策算法.....	29
3.1 引言.....	29
3.2 问题描述与方法动机.....	30

3.2.1 问题描述	30
3.2.2 方法动机	30
3.3 态势感知误差建模	31
3.4 基于 GRU 提取特征的近端策略优化算法	32
3.4.1 门控循环单元	32
3.4.2 状态序列空间	33
3.4.3 优势态势解算单元	33
3.4.4 GPPO 算法	34
3.4.5 奖励塑造	35
3.5 仿真实验	37
3.5.1 基础实验设计	37
3.5.2 基础实验结果分析	39
3.5.3 多场景泛化性能测试实验	43
3.6 本章小结	45
第 4 章 基于深度强化学习的泛化性增强空战机动决策算法	47
4.1 引言	47
4.2 问题描述与方法动机	48
4.3 基于自注意力机制与预训练模型的近端策略优化算法	49
4.3.1 基于 QKV 模型的自注意力机制	49
4.3.2 基于自注意力机制的实时奖励塑造方法	50
4.3.3 空战态势解算单元	52
4.3.4 预训练模型设计与实现	52
4.3.5 AMP3O 算法	55
4.4 泛化性能测试实验	56
4.4.1 视距内空战想定集预处理	56
4.4.2 实验设计	58
4.4.3 实验结果分析与泛化性能测试	59
4.5 本章小结	65
第 5 章 面向深度强化学习的空战训练仿真一体化平台系统设计与实现	67
5.1 引言	67
5.2 空战训练仿真一体化平台系统设计	67
5.2.1 需求分析	67
5.2.2 系统设计	68

5.2.3 平台工作流程	70
5.3 空战训练仿真一体化平台应用效果	71
5.3.1 异构模型管理模块	71
5.3.2 想定管理模块	72
5.3.3 多线程并行式仿真与训练	73
5.3.4 空战态势可视化工具	74
5.4 本章小结	75
第 6 章 总结与展望	75
6.1 工作总结	77
6.2 研究展望	78
参考文献	79
附录 A	85
攻读学位期间取得的研究成果	89
致 谢	91

图目录

图 1.1	基于深度强化学习的空战机动决策领域文献数量变化图	2
图 1.2	全文组织结构	13
图 2.1	地平面坐标系	16
图 2.2	机体轴坐标系	16
图 2.3	速度坐标系	17
图 2.4	飞行器动力学模型	19
图 2.5	视距内空战相对态势模型	20
图 2.6	强化学习基础框架	22
图 2.7	神经元结构图	23
图 2.8	神经网络结构示例	24
图 2.9	Actor-Critic 架构图	26
图 3.1	门控循环单元结构图	32
图 3.2	GPPO 算法运行架构	35
图 3.3	训练过程平均奖励变化图	40
图 3.4	单局测试中的关键态势量变化曲线	41
图 3.5	GPPO 智能体飞行轨迹视图	43
图 3.6	多场景实验训练过程平均奖励变化图	45
图 4.1	QKV 模型结构图	50
图 4.2	预训练模型训练过程平均奖励变化图	54
图 4.3	初始坐标变化实验训练过程平均奖励变化图	59
图 4.4	单局测试实验中注意力权重系数变化图	60
图 4.5	初始坐标与敌方策略变化实验训练过程平均奖励变化图	61
图 4.6	单局测试实验中注意力权重系数变化图	62
图 4.7	AMP3O 智能体飞行轨迹示例	64

图 5.1	空战训练仿真一体化平台系统架构图	69
图 5.2	空战训练仿真一体化平台工作流程图	70
图 5.3	空战训练仿真一体化平台初始界面	71
图 5.4	模型管理界面	72
图 5.4	想定管理界面	72
图 5.5	想定批量生成工具	73
图 5.6	视距内空战抗感知误差实验可视化验证界面	75
图 5.7	特定训练模型智能体泛化性能测试实验可视化验证界面	75

表目录

表 1.1	视距内空战机动决策算法分类与对比	11
表 2.1	动作空间变量变化范围及变化率	19
表 3.1	基础实验设计参数	38
表 3.2	神经网络主要参数	39
表 3.3	多场景实验设置	44
表 4.1	预训练模型训练设计参数	53
表 4.2	预训练模型神经网络主要参数	54
表 4.3	实验想定初始坐标集设计参数	57
表 4.4	神经网络主要参数	58
表 4.5	初始坐标变化实验各智能体决策性能	61
表 4.6	初始坐标与敌方策略变化实验各智能体决策性能	63

第1章 引言

1.1 选题背景与研究意义

1.1.1 选题背景

伴随着人类战争形态的演进，制空权对于战争胜负的影响力被不断放大^[1,2]。海湾战争中，美军开创了以空战为主体赢得战争的先例，颠覆了传统的战争模式，确立了现代战争中海陆空立体化对抗的战略格局；科索沃战争中，北约盟军凭借绝对的制空优势，成功地以付出极小伤亡代价的非接触式作战方式，快速迫使南联盟撤军；俄乌战争中，交战双方空中力量的拉锯对抗直接对地面战线的推进、僵持、反攻等局势走向产生了决定性影响^[3]。根据多场现代战争的经验足以判断，在未来的战争中，空中作战将是能够决定局部战场局势走向、深刻影响战争全盘胜负的关键核心领域。

视距内空战顾名思义，指的是发生在视距范围内的空中作战，作战载具间的欧氏距离通常不超过 10 千米^[4]。由于对战场态势变化的观察和做出相应决策的一系列过程都发生在极短时间内，视距内空战的决策过程显著符合约翰·博伊德在 20 世纪中期提出的经典“OODA”决策循环模型^[5]，该模型表现为观察（Observation）、定位（Orient）、决策（Decision）、行动（Action）四个典型步骤的循环，同时还具有对抗强度大、态势变化剧烈、交战方式灵活多变等特点。

视距内空战这一概念的产生，是随着预警机、中远距离空空导弹的出现后，超视距空战这一概念的诞生而相对定义的。20 世纪末以来，由于超视距空空导弹、机弹数据链、高精度雷达等先进武器装备的不断进化迭代，能够“决胜于千里之外”的超视距空战正在逐步成为载人战斗机之间的主流作战形式^[6]。然而，视距内空战并没有因此趋势而遭到忽视，反而在此背景下同样获得了突飞猛进的发展^[7,8]，并仍在当今空战领域占据有不可或缺的一席之地，主要原因包括：（1）空中电子战烈度不断提升，在电磁干扰作用下，中远距离空空导弹不能确保消灭目标，因而将被迫采用航炮等视距内空战打击手段^[9]；（2）随着材料学技术发展，各类飞行器的雷达散射截面呈指数级减小，乃至出现“隐形”战斗机，与敌相接时可能已是视距内空战范围；（3）用于预警、侦察、协助态势感知等作战任务的无人战斗机需要与敌机保持较近距离^[10]，以抵抗电磁干扰、完成战略任务；（4）视距内空战领域存在更典型的“OODA”决策循环模型，更适合搭载智能化决策算法以自主或协助飞行员完成空战决策^[11]；（5）存在护航、空中加油、舰载机进近着舰等典型非对抗式视距内空战场景等。因此，视距内空战仍是国内外现役飞行员的重要训练科目和当前空战研究领域的重点内容^[12]。

视距内空战战术目的达成与否主要取决于飞行器机动决策效果的优劣^[13]，藉由信

息化、自动化、智能化技术和算法实现的自主机动决策，能够减轻飞行员决策压力、提高决策效率和准确性、提升无人驾驶装备作战效能、实现有人/无人作战平台协同作战，甚至于最终突破现有认知瓶颈、拓展空战领域战术战法。在此背景下，视距内空战自主机动决策算法是国内外学者研究的热点，常见的研究方法包括：（1）基于博弈论的微分对策方法、矩阵对策方法等；（2）基于优化理论的遗传算法、动态规划算法等；（3）基于先验知识的专家系统、贝叶斯网络等；（4）基于深度强化学习的智能机动决策算法等。

其中，深度强化学习是人工智能领域机器学习技术的一个分支，其借助深度神经网络对环境态势特征进行精确感知，并使用强化学习方法探索和学习不同态势下的最优决策。基于深度强化学习的视距内空战机动决策算法针对复杂多变的战场态势具有更强的适应能力，不依赖复杂的先验知识和人为的事先设计，决策响应速度快、精度高、实时算力需求低，并且具有探索学习超前战术动作的巨大潜力^[14]。2020 年，DARPA 举办的 Alpha Dogfight 视距内空战对抗比赛中，使用深度强化学习算法训练出的智能体以巨大优势击败了资深人类飞行员^[15]，充分证明了深度强化学习方法解决视距内空战机动决策问题的能力与有效性，并引起了全球相关领域研究人员的关注。图 1.1 展示了在计算机和工程科学领域的几大主流文献检索平台中，以“深度强化学习”、“空战”、“机动决策”作为中英文关键词，检索得到的发表于近几年的学术文献数量。由相关研究数量反映出的研究热度从侧面表明，基于深度强化学习的机动决策算法已经掀起了全世界范围内的研究热潮，并被普遍认为是视距内空战机动决策领域最具前景的研究方向^[16]。




图 1.1 基于深度强化学习的空战机动决策领域文献数量变化图

Figure 1.1 Bibliographic quantity changes in the field of air combat maneuver decision based on deep reinforcement learning

1.1.2 研究意义

本文从我国国防军事工业信息化、现代化建设的国计方针总体目标出发,紧跟研究热点,在分类梳理和综述国内外空战机动决策算法相关领域研究现状的基础上,总结了基于深度强化学习的视距内空战机动决策算法的优越性,同时指出当前研究中普遍存在的问题,包括:战场态势感知误差对深度强化学习训练和机动决策的干扰问题、基于深度强化学习的机动决策算法特定训练模型泛化性能弱的问题、缺乏统一标准的飞行器模型与仿真验证支撑平台等。随后,本文针对各个问题分别开展一系列研究工作。针对算法研究问题,本文在充分的可行性分析与推导基础上,设计提出具有对应优化效果的深度强化学习算法,并进行严谨的验证实验。针对研究领域内飞行器模型与验证支撑平台差异性大的现状和所提算法训练验证的需要,本文设计开发了空战训练仿真一体化平台系统,并展示了该系统在基于深度强化学习的视距内空战机动决策算法研究实验中的支撑应用效果。

本文研究所针对的问题,在当前基于深度强化学习的视距内空战机动决策研究领域内普遍存在。未来,随着该领域研究在真实空战环境中的进一步验证和落地应用,这些问题将愈加突出。因此,本文所做研究工作着眼于我国基于深度强化学习的视距内空战机动决策算法研究领域全局,有一定的前瞻性,可为该研究领域的未来发展提供具有普适价值的理论参考和实践应用的新思路,具备一定创新性与研究价值。

1.2 国内外研究现状

首先,本节的第一部分将介绍深度强化学习的发展历程、关键技术,以及近期取得的研究成果,进而论述深度强化学习相关研究方法在决策控制领域的独特优势与应用价值。随后,本节的第二部分将分类介绍视距内空战机动决策算法研究领域的国内外主流研究方法和研究现状。其中,将重点综述基于深度强化学习的视距内空战机动决策算法的应用发展情况,比较其与其他几类决策算法间的差异和优劣,并尝试总结现有研究中普遍存在的规律特点和有待进一步研究的方向,从而为本文后续的算法研究工作和系统设计工作提供依据。

1.2.1 深度强化学习研究现状

1.2.1.1 强化学习

强化学习是一种能够学习最优行为决策策略的机器学习技术,它通过算法构造智能体自主与环境交互,根据环境反馈习得经验,进而优化自身的决策策略。与机器学习领域更为典型和常见的有监督学习或无监督学习不同,强化学习方法的设计目的主要是为了解决序贯决策与动态交互优化类问题。在设计思路,强化学习方法参考了人类对动

物学习决策行为的理解，以人工智能算法思维结合最优控制理论和心理学发现^[17]，力求模仿人类观察学习环境并做出决策的方式。在学习过程中，强化学习智能体需要通过反复观察环境、试探做出决策、获取环境中的结果反馈，从而习得经验，并作为未来在相同或相似环境态势下做出决策的依据。其学习训练过程可被抽象为追求奖励函数最大化的探索过程，其学习探索能力和最终的决策能力具有极高的理论上限。

强化学习作为人工智能研究领域的独立分支，从上世纪中叶起，逐步得到国内外专家学者的关注和研究。1954年，人工智能领域未来的第一位图灵奖获得者——Marvin Minsky^[18]在他的博士论文中设计了一个基于神经模拟强化系统的机器人模型，该模型实现了对自身决策得到的环境反馈进行学习理解和复用，被视作强化学习理论的首次完整实践。1956年，动态规划理论的奠基人 Bellman^[19]在通过严谨的理论推导定义了强化学习问题的数学框架，并以迭代试错的方法在该框架内求解最优值函数策略。Howard^[20]在 Bellman 的研究基础上，详细阐明了动态规划理论，并系统完整地引入了马尔科夫决策过程模型，使得马尔科夫决策过程从此成为强化学习领域的核心概念和基础数学模型，同时标志着强化学习研究领域具备了系统性的研究架构。1972年，Klopf^[21]在根据神经科学领域的研究思想，提出了基于时间差分的试错学习理论，大幅提高了强化学习方法的试错规模和借助试错达成的学习效果。20世纪90年代前后，“强化学习教父”Sutton及其团队研究人员在多年的研究和教学基础上，系统全面地总结了强化学习领域的知识理论体系^[22]，并提出了预测时间差分方法^[23]、资格迹^[24]等具有开创性的强化学习技术，极大推动了强化学习领域的研究发展。1992年，Watkins^[25]等人历史性地提出了强化学习领域经典的Q学习算法，该算法作为一种离线策略学习（Off-policy Learning）、无模型（Model-Free）的强化学习算法，在棋牌、即时战略等类型的游戏、推荐系统、自动化控制、交易决策等极广泛的领域范围内得到了提升显著且稳定的应用效果。两年后，Rummery和Niranjan^[26]提出了在线学习（On-policy Learning）的Sarsa（State-Action-Reward-State-Action）算法，该算法在面对动态变化的环境时具有更强的适应能力。在上述一系列研究的推动下，自20世纪末期开始，强化学习在全世界有关人工智能的理论研究和应用研究领域均占据了一席之地，被普遍视作未来实现智能化控制与决策最具潜力的研究方向。

然而，随着强化学习算法被应用于解决越来越复杂的问题，不断增长的状态空间维度和愈发稀疏的环境奖励反馈，使得学习成本和习得最优策略的难度呈指数级上升，出现“维度爆炸”，即 Bellman^[27]在1960年研究动态规划问题时预言的“维度诅咒”（Curse of dimensionality）。“维度诅咒”的应验，曾一度严重限制了强化学习方法的应用范围，研究者们难以利用强化学习技术解决一些现实中的复杂问题。在经历了多年的研究探索后，深度强化学习成为了“维度诅咒”的破解之道。

1.2.1.2 深度强化学习

深度强化学习（Deep Reinforcement Learning, DRL）顾名思义，是两大主流机器学习方法——深度学习与强化学习的结合。深度学习借助高层数的神经网络，对高维度数据进行有效特征提取与表征。这恰好能够为面临维度诅咒的强化学习方法提供其最需要的，对高维状态空间的感知表征和学习理解能力。实现高维态势感知理解的同时，两者的结合在理论上具备许多优点，并使研究者们窥见了应用上的诸多灵活性，例如：使得研究者得以在一轮端到端的训练中，凭借对深度神经网络的针对性优化配合强化学习奖励函数的定义与塑造等手段，低成本地实现对具体应用场景或任务的特异性优化等。

2013年，来自DeepMind的Mnih^[28]等人提出了DQN算法（Deep Q-Network），该算法将深度神经网络与Q学习算法结合，使用深度卷积神经网络来学习高维态势直接映射到Q值的函数。通过在一系列游戏中进行的实验表明，该算法能取得与人类玩家相媲美，甚至是超越人类玩家的决策能力。DQN算法也因此被视为DRL领域的开创性算法，引起了全世界科研人员的关注，开启了DRL方向研究的全新时代。2015年，DeepMind的Hasselt^[29]等人在DQN算法的基础上进行了改良，提出了Double DQN算法，该算法通过设计两个深度Q网络，分别用于选择策略动作和计算目标Q值，得以针对性地解决DQN训练中可能存在的Q值的过度估计问题，并在游戏实验中取得了相较DQN算法更加优异的性能。同年，伯克利大学的Schulman^[30]等人提出了基于策略梯度方法的TRPO算法（Trust Region Policy Optimization），有效提高了DRL训练的稳定性，并推动了基于策略梯度方法的DRL算法研究的盛行。2016年，来自DeepMind的Lillicrap^[31]等人提出了DDPG算法（Deep Deterministic Policy Gradient），该算法同样基于策略梯度，高效地实现了连续动作空间上的DRL训练。同年，DeepMind的Silver^[32]等人将DRL神经网络与蒙特卡洛树搜索结合，训练出的AlphaGo智能体，在公开围棋比赛中击败了人类顶级棋手李世石。2017年，加入OpenAI的Schulman^[33]及其研究团队设计并提出了PPO算法（Proximal Policy Optimization），其网络设计简洁高效，并在极广的应用范围内均展现出优秀的决策性能和鲁棒性，快速成为了OpenAI等一众顶尖DRL研究团队在不同研究任务中的基线算法。2018年，多伦多大学的Fujimoto^[34]等人在DDPG算法中引入延迟更新策略和双Critic网络结构，提出了TD3算法（Twin Delayed DDPG），减小了DRL训练中的值函数逼近误差。

经过上述一系列探索，基于DRL的算法研究领域已取得了长足的进展，主流的高性能算法得到了广泛地推广和改良，同时，DRL方法在各类应用中也不断取得成功。除前文已经提到的AlphaGo智能体击败世界冠军外，ANYmal^[35]公司借助DRL算法控制的四足机器人已经实现能够自适应复杂地形，并自主导航和规划路径的野外自由行走；OpenAI^[36]团队通过DRL技术训练多关节机械手，使其能够根据目标任务需要，自主进行抓握、搬运、玩魔方等复杂且灵活多变的动作；南京大学与淘宝联合发表的文献^[37]

中，使用 DRL 算法实现的商品推荐系统，根据评估能够帮助淘宝在真实环境下额外获得 2% 的利润提升。

综上所述，DRL 领域研究既已产出了一系列高效稳定且通用性强的高性能算法，又通过多领域的应用研究证实了其在实际问题中的应用效果。在决策控制领域，相较于高度依赖先验知识的专家系统、计算复杂度过高的近似动态规划算法、缺乏自适应性的 PID 控制等^[38]决策控制领域的传统算法，基于 DRL 的方法在适用范围、灵活性、决策的适应性、鲁棒性和智能化程度上均已展现出独特的优势^[39]。此外，由于 DRL 方法面对多样化的环境和不同的应用场景均具备探索适应能力，随着新算法技术的不断产出和 DRL 方法被应用在更多更广泛的领域，在可以预见的未来里，基于 DRL 的算法还将产生巨大的应用价值^[40]。

1.2.2 视距内空战机动决策算法研究现状

视距内空战机动决策算法，即利用自动化、智能化的算法技术，实现在视距内空战场景下，基于当前态势和作战目标的实时机动决策输出算法。为降低战斗机驾驶员的决策负担、提高战斗机自动/辅助决策的效率与准确性、强化无人驾驶设备作战表现、实现有人/无人作战平台协同作战，同时寄希望于通过该领域研究，开拓全新的空战战术战法，20 世纪 90 年代以来，视距内空战机动决策算法日益成为国内外相关领域学者的研究热点。当前，常见的视距内空战机动决策算法根据所用的主体方法和算法运行框架可大致分为几个大类，本小节将分别综述几类方法的特点与研究现状，并在节末做出对比与分析。

1.2.2.1 基于博弈论的视距内空战机动决策算法

早在 20 世纪早期，空战博弈理论就开始受到关注^[1]。基于博弈理论，可以将空战抽象视作我方与敌方、友方等多方之间的博弈过程。在给定的博弈背景中，各方均试图通过采取策略以最大化自身的预期回报值，同时避免自身决策与他方决策交互得到低回报，因而产生各方之间的博弈。基于博弈论的视距内空战机动决策算法，旨在寻找能够使博弈达成平衡或优势的机动策略，根据对博弈问题的求解方式可以再细分为基于微分对策的方法、基于矩阵对策的方法、影响图博弈等。

基于微分对策的空战机动决策算法，以建立描述空战双方状态转移和控制规律的微分方程为基础，在动态博弈理论框架下求解机动策略^[17]。该类方法对方程的求解过程一般需要将微分对策问题转换为单双边优化问题，进而能够采用定性或定量的方法进行求解。Horie^[41]等人构建了追逃博弈框架对战机的追逃机动决策问题建模，借助微分对策法将该博弈问题求解转化为双边优化问题，使用半直接定量法求得数值解。Xu^[42]等人将空战中的相对态势要素建模为博弈支付函数，将最优策略求解转化为非线性规划问

题进行求解。基于微分对策的空战机动决策算法数学表达清晰，从建模到求解的过程直观明了、易于理解，能够实现动态博弈求解，但其计算量庞大，难以实现复杂模型下的空战机动决策问题实时求解。

基于矩阵对策的空战机动决策算法则属于静态博弈框架的范畴，被部分学者视为微分对策方法的离散形式，在决策时刻构建可用机动的支付矩阵，再根据 Min-max 原理对最优序列进行求解。Chen^[43]等人利用矩阵对策法对 2v2 空战进行零和博弈建模，进而分析求解。徐光达^[44]等人提出一种基于双矩阵对策的空战机动决策算法，避免了零和有限对策问题，并提高了决策速度。文献[45]通过矩阵对策方法求解最优决策的近似范围，再结合遗传算法确定决策输出。基于矩阵对策的空战机动决策算法运算过程中得到的支付矩阵易于利用，可与其他算法或理论结合，灵活性强，相较于微分对策方法，其计算量也较小。然而，该方法仍难以计算复杂模型问题。同时，其最终决策效果很大程度上取决于算法的态势评价函数，但针对空战问题，此函数还难以完备地定义。

影响图博弈方法将影响决策的随机变量进行拓扑排序，在不同层分别利用博弈理论框架求解，以构建层次决策能力。文献[46]借助非零和多阶段影响图博弈方法，为人类飞行员提供视距内空战场景下的辅助决策。文献[47]提出滚动时域法优化多级影响图博弈中的求解速度，并用于空战机动决策仿真场景。相较于其他基于博弈论的方法，影响图博弈的可解释性最高，具备结合其他决策方法的可拓展性，但却最难求得博弈问题精确的最优解^[48]。

1.2.2.2 基于优化理论的视距内空战机动决策算法

基于优化理论的视距内空战机动决策算法通常将空战机动决策问题抽象建模为多目标优化问题，并使用各种主流的数值优化算法进行求解，典型算法包括：遗传算法、近似动态规划算法、粒子群优化算法等。

遗传算法在优化算法研究领域发展得较为成熟，其设计参考了生物遗传进化的模式，将待求解问题的初始解视作遗传信息，并通过类似染色体遗传、选择、变异、淘汰等过程，求得最优解^[49]。文献[50]将空战态势感知到判断决策的过程抽象为分类器，使用遗传算法优化分类器性能，从而实现对空战态势的正确判断和机动决策。文献[51]对空战中的先敌攻击等优势态势进行分析建模，使用模糊遗传算法求解实现优势态势的对应决策。使用遗传算法进行目标优化的视距内空战机动决策算法对策略搜索空间约束少，鲁棒性强，能处理复杂模型问题，在某些空战问题中能取得较好的性能。然而，其算法参数的选择高度依赖先验知识设计，且每一决策时刻都需要在解空间内寻优，决策实时性存在不足^[14]。

近似动态规划算法相比起数学界经典的动态规划方法，避免了在每一离散状态下对目标优化函数值进行展开计算^[14]，转而凭借函数逼近器来近似计算未获得的总奖励值，

从而使其适用于大规模连续空间问题的优化学习,具备相对较短的优化时间。McGrew^[52]等人采用值迭代技术计算函数逼近,代表近似动态规划的解,并将此方法用于仿真测试环境中的无人机机动决策,取得了良好的决策效果。文献[53]基于函数拟合思想优化逼近近似值函数,对空战机动决策中的长期收益进行逼近优化,文中提出了一种惩罚因子,在近似动态规划过程中通过该因子的修正作用以避免决策碰撞问题。但是,以上应用普遍对空战模型进行了较大简化方才得以施行,近似优化算法难以在有限时间开销下实现对三维六自由度的复杂空战模型机动决策的优化演算。其次,该类方法进行策略提取时需要通过 Rollout 的方式进行前瞻预测,虽然提高了决策准确率,但带来了较大的计算量,制约了决策实时性的表现上限,且易发生过拟合、不利于决策算法的泛化性能^[54]。

粒子群优化算法是一种基于群体智能的优化算法,算法设计思路源自于鸟类或鱼类等动物群体中常见的协同行为,通过模拟个体作为群体内部粒子的行为,来搜索优化问题的最优解。Zhang^[55]等人对战斗机构建人工势场函数作为粒子群优化指标,提高了粒子群优化的全局搜索能力和计算效率,进而提高空战机动决策能力。文献[56]结合粒子群优化与矩阵对策方法,对空战中的攻防博弈机动做出优化决策。基于粒子群优化的空战机动决策方法虽然在不同的空战优化问题中表现出较好的适用性,但实际运用中通常只能对机动决策起辅助作用,且优化过程容易陷入局部最优,对复杂模型问题也缺乏实时有效求解的能力。

1.2.2.3 基于先验知识的视距内空战机动决策算法

基于先验知识的视距内空战机动决策算法将人类对空战领域的大量知识与经验构建为数字化的知识库或推理机,移植到计算机程序或系统里,并采用类似“if-else-then”的谓词逻辑制定产生式规则^[57],在机动过程中实时根据规则采取决策行为。此类算法明确回答了“什么情况下做出什么决策”的问题,具有易于工程化、完全可解释的优点,并且随着数字化的先验知识不断增加和进一步细化,该类算法在保持可解释性的前提下具备较高的决策能力上限,因而得到了较为广泛的应用和发展。该类方法中,具有代表性的有:专家系统、PID 控制、模糊决策树、贝叶斯网络等。

专家系统即记录了某一领域人类专家所具备的知识的计算机应用系统,被视作人工智能的初级形态。傅莉^[58]等人借助滚动时域法拆解空战过程,在每个时域内分别利用专家系统求解,实现了有效的空战机动决策。王炫^[59]等人建立了一种进化式专家系统树框架,通过将遗传算法和专家系统相结合进行机动决策控制,在仿真实验中成功操控劣势态势下的战斗机通过机动决策反败为胜。

PID 控制,即“Proportional-Integral-Derivative”,比例-积分-微分控制,其原理更接近基于反馈优化的控制方法,但其实际性能和稳定性高度依赖人为设定的系统数学模型和 PID 控制参数。算法运行过程中,通过不断地优化调整决策输出,使决策效果不

断趋近于参数计算得到的期望值。文献[60]中结合了 PID 控制方法与固定翼飞行特性，设计了飞行器的副翼杆控制器，帮助飞机在不同机动环境下保持既定航路。文献[61]针对空战中的导弹机动控制设计了鲁棒 PID 控制器，优化导弹机动性能。

模糊决策树是在基于先验知识建立决策树的基础上，在树中加入模糊规则，在决策过程中基于规则进行模糊判断的一种决策方式。贝叶斯网络则是在先验知识基础上，基于概率论和贝叶斯原理进行推理的方法。文献[62]中基于模糊决策树对机载传感器信息进行快速处理，进而协助机动决策。Geng^[63]等人在模糊决策树基础上引入了贝叶斯网络，构建了混合策略决策系统，提升了面对未知环境时的空战机动决策效果。

虽然基于先验知识的视距内空战机动决策算法具有可解释性较强、决策性能与鲁棒性均较好等优点，但其决策原理决定了它们将始终具有一大致命劣势，即由于其决策的依据为设计者提供的先验知识，故其决策能力必然存在上限，其行为表现难以超出设计者的认知经验与思维能力的极限^[48]。

1.2.2.4 基于深度强化学习的视距内空战机动决策算法

基于 DRL 的视距内空战机动决策算法需要对空战机动决策问题进行建模，确定状态空间、动作空间、奖励函数等 DRL 训练过程中需要的关键概念集合，随后构建 DRL 算法智能体，将智能体置于仿真环境中进行探索训练，最终将训练得到的算法智能体决策模型部署到空战机动平台，在平台机动过程中根据观测态势实时输出机动决策。相较于上述其他几类方法，基于 DRL 的视距内空战机动决策算法具有诸多独特的显著优势，如：不依赖先验知识、决策能力理论上可突破人类决策能力上限、适用范围广、灵活性强、决策的鲁棒性和智能化程度均较高、异构计算与协同自适应等。因此，自 2013 年 DQN 算法问世以来，基于 DRL 的视距内空战机动决策算法已经在航空航天、军事兵工领域引起了研究人员的广泛关注。2020 年，DARPA 举办了举世瞩目的 Alpha Dogfight 视距内空战对抗比赛，苍鹭系统公司使用 DRL 算法训练出的智能体，在比赛中以巨大优势击败了资深人类飞行员^[15]，充分证明了 DRL 方法解决视距内空战机动决策问题的强大能力，基于 DRL 的方法也随之在全世界范围内被广泛应用到视距内空战机动决策问题中。

目前，基于 DRL 的视距内空战机动决策算法可根据使用的 DRL 算法类型分为几类，主要包括：基于值函数的 DRL 算法、基于策略梯度的 DRL 算法、分层 DRL 方法等。

基于值函数的 DRL 算法以 DQN、Double DQN 等算法为代表，该类算法的核心思路是对训练中各个状态下的长期奖励期望进行估值，通过学习该值的函数，实现对各个状态下最优决策动作的选择，作为典型的 DRL 方法，具有训练样本效率高、收敛性好等优势。孔维仁^[64]等人在 DQN 算法基础上通过参数共享和虚拟自我对局提高了算法学习效率，并在 1v1 视距内空战机动决策场景下取得了较好的决策表现。Li^[65]等人在

DDQN 算法基础上设计了多步奖励学习机制，缩短了算法训练时间，并在无人机跟踪目标场景中进行了验证。此类算法属于 DRL 算法的较早期形态，算法设计之初主要针对的是离散动作空间下的决策问题，为解决连续动作空间内的复杂模型空战机动决策，必须对算法作较大幅度的适应性调整，因而制约了此类算法的机动决策能力上限。

基于策略梯度 (Policy Gradient, PG) 的 DRL 算法以 PPO、DDPG 等为代表，此类算法在训练过程中将持续计算当前策略下的总奖励期望值基于当前策略参数 θ 的梯度，并沿梯度方向更新 θ ，从而指导智能体最终收敛于最优策略^[66]。文献[67]提出了一种基于 PPO 的无人机空战机动决策方法，使用情景奖励塑造对环境奖励进行重塑，并针对使用贪心算法调整机动策略的敌机进行了训练，训练出的智能体在对抗实验中取得了 62% 的胜率和 27% 的平局率。Yang^[68]等人在 DDPG 算法中加入优化动作作为初始样本，在保留算法探索多样性的前提下，过滤了一部分无效的探索，文章在实验中将所提方法运用于仿真环境下的无人机机动决策，实现了对简单运动的目标敌机进行追踪。基于 PG 的 DRL 算法作为当前 DRL 研究领域较为前沿的主流算法，能够针对复杂的连续动作空间问题进行训练和决策，相比起基于值函数的方法，其在端到端的训练过程中能够更高效直接地在策略空间里搜索最优策略，因而普遍具有更广的适用范围，在视距内空战决策领域研究中也普遍展现出更优秀的性能与训练决策效果，吸引了大量研究团队参与相关研究。

分层 DRL 方法是近两年来引起视距内空战机动决策领域的专家学者们较多关注的一类 DRL 方法，在 Alpha Dogfight 视距内空战对抗比赛中取得第二名的队伍所使用的智能体就借鉴了分层 DRL 方法进行训练^[69]。所谓的分层主要有两种形式^[70]，分别是基于选项的分层 DRL 和基于子目标的分层 DRL。分层 DRL 方法的主要设计目的是为了解决 DRL 训练中的奖励稀疏问题，通过将训练目标分层抽象、逐层训练，能够一定程度上克服奖励稀疏环境下的 DRL 训练难、训练后模型决策效果差等问题，同时分层思想能够一定程度上增加 DRL 方法的可解释性。然而，分层抽象技术本身也引入了一些额外的问题，如分层结构参数复杂、分层依据难以界定、不同层级决策间难以解耦合带来的性能损失等。国内外多个研究团队在近年里使用基于分层 DRL 的视距内空战机动决策算法进行了一系列相关研究，主要在编队机动^[71]等空战问题上实现了机动决策性能的优化。相较于基于策略梯度的方法取得的进展，使用分层 DRL 的视距内空战机动决策算法在适用范围和决策性能上存在差距，相关研究目前主要针对对抗性较小的机动决策问题，尚处在研究的早期阶段^[72]。

表 1.1 中梳理和记录了上文综述的几类方法分别具有的特点，以及各类方法对应的优劣势评述。

表 1.1 视距内空战机动决策算法分类与对比

Table 1.1 Classification and comparison of maneuver decision algorithm for air combat within visual range

类别	具体方法	主要优势	主要缺陷
基于博弈论的 视距内 空战机动 决策算法	微分对策	数学表达清晰、可实现动态 博弈求解	计算量大、决策实时性差
	矩阵对策	可拓展性强、适用范围广、 计算量相对较小	难以计算复杂模型问题、 决策质量不高
	影响图博弈	可解释性强、具备可拓展性	求解精度低、计算量大
基于优化理论 的视距内 空战机动 决策算法	遗传算法	理论研究成熟、鲁棒性强、 适用范围广	实时性不足、依赖先验知识设计
	近似动态 规划	适用于大规模连续性问题、 实时性较强	难以优化复杂模型空战问题、 存在过拟合风险
	粒子群优化	决策适应性强、易实现	难以直接实现机动决策输出、 适用范围受限、易陷入局部最优
基于先验知识 的视距内 空战机动 决策算法	专家系统		
	PID 控制	可解释性强、鲁棒性强、 决策性能较好	决策能力存在认知上限、 行为表现受限于设计者知识范围
	模糊决策树		
	贝叶斯网络		
基于 DRL 的 视距内 空战机动 决策算法	基于值函数 的 DRL 算法	训练样本效率高、收敛性强	难以处理连续动作空间问题， 需付出额外开销
	基于策略梯度 的 DRL 算法	适用范围广、鲁棒性强、 决策性能优异	训练样本效率相对较低
	分层 DRL	降低训练难度、克服奖励 稀疏问题、增强可解释性	分层设计难度较大、 不同层级间存在性能损失

根据前文综述，在当前的国内外研究中，相较于其他类别的视距内空战机动决策算法，基于 DRL 的算法在各类仿真实验中能够表现出极高的决策准确度，响应速度快、实时算力需求低、泛化适应能力和鲁棒性均较强，具有探索学习超前战术动作的巨大潜力，并已在实践中取得了巨大突破和成就。因此，基于 DRL 的视距内空战机动决策算法已被普遍认为是视距内空战机动决策领域最具前景的研究方向^[16]。

然而，当前基于 DRL 的视距内空战机动决策算法研究中，还有一些较为深层且普遍存在的问题，例如：（1）忽略态势感知误差等真实战场环境因素：当前研究主要使用空战仿真环境进行训练和模拟实验，空战仿真环境相较于真实世界环境做出了较大程度的简化，因而导致绝大多数研究者忽视了真实世界中必然存在的态势感知误差等环境

因素，忽视其可能对算法训练和决策性能造成的影响；（2）特定训练模型泛化性能弱：基于 DRL 的视距内空战机动决策算法依赖训练过程中的经验学习决策，训练得到的某一特定模型，在面对未知环境时的机动决策性能将出现一定程度的损失；（3）缺乏统一标准的飞行器模型与仿真决策验证支撑平台，研究成果难以横向对比，缺乏说服力与可信度等。

在先前的研究中，这些问题或因不属于空战机动决策的核心环节而遭到忽视，或是被暂时搁置，但在未来，随着领域内的研究进一步深入、随着新的研究成果被应用于仿真程度更高的环境甚至是现实空战中，上述问题将是相关领域研究人员难以回避、必须予以解决的。

1.3 论文主要研究内容与组织结构

1.3.1 本文主要研究思路与研究内容

根据上一小节所作的总结梳理与分析，本文认为当前基于 DRL 的视距内空战机动决策算法研究领域内的现有研究成果中普遍存在一些具有普遍性的问题。本文将以上述问题为依据和研究出发点，旨在针对各个问题分别提出合理有效的分析推导与对应的算法解决方案，并通过全面的对比实验验证所提方法的可行性，力求为我国基于 DRL 的视距内空战机动决策算法相关研究提供理论参考价值和实践应用方面的新思路。主要研究思路及研究内容包含以下几个方面：

（1）针对战场态势感知误差对 DRL 训练和机动决策的干扰问题，首先分析态势感知误差的来源和必然性。接着，根据真实战场环境特点，对态势感知误差量进行仿真建模，搭建具备态势感知误差的视距内空战仿真环境。随后，提出一种基于门控循环单元提取态势特征的近端策略优化算法，对算法内部各组成元件的功能进行推导阐述。最后，在不同感知误差强度及不同敌我初始态势等多种视距内空战机动场景下，进行仿真对比实验，分析方法性能和应用前景。

（2）针对基于 DRL 的视距内空战机动决策算法特定训练模型泛化性不足的问题，首先分析和推导模型在未知环境泛化性能下降的原因，进而得出解决方法动机。在此基础上，提出一种基于自注意力机制与预训练模型的近端策略优化算法，引入基于预训练模型的策略重用方法和基于自注意力机制的奖励塑造方法，以提高算法训练模型的泛化性能。最后，在标准的视距内空战仿真场景下，设计进行一系列训练模型泛化性能测试实验，测试和验证所提算法的性能和对特定训练模型泛化性能的提升效果。

（3）以改进当前基于 DRL 的视距内空战机动决策研究领域内，缺乏统一标准的飞行器模型与仿真决策验证支撑平台的研究现状为出发点，同时基于所提算法的训练和验证需要，设计并提出面向深度强化学习的空战训练仿真一体化平台。首先，分析平台的

系统设计需求，继而对平台架构进行设计细化，并对平台工作流程进行推演。随后，开发并实现平台设计预期的各项功能。最后，在实现平台预期功能的基础上，借助平台对本文所提算法进行验证实验，展示平台的应用效果。

1.3.2 本文组织结构

本文正文部分分为六章，全文组织结构如图 1.2 所示。




图 1.2 全文组织结构

Figure 1.2 Organization structure of full text

第 1 章为引言。该章节首先介绍了本文的选题背景，引申讨论了本文所选研究方向的研究意义。接着，该章节梳理和综述了本文研究领域国内外研究现状，分析现有研究中存在的普遍问题并进行总结。最后，以该章节的综述为依据，介绍了本文的主要研究

内容和研究方法，并对全文的组织结构做出描述。

第2章为相关理论基础。该章节首先对视距内空战机动场景进行建模，对本文后续实验中的飞行器仿真控制模型和视距内空战优势机动进行描述和定义。随后，该章节介绍了深度强化学习领域的基础概念和理论，并介绍和推导了当前深度强化学习领域的主流框架与算法。

第3章为基于深度强化学习的抗感知误差空战机动决策算法。该章节针对战场态势感知误差对DRL训练和机动决策的干扰问题，首先描述了空战态势感知误差的成因，并对章节所提方法的动机做出推导。接着，根据战场态势感知误差来源与特点，设计了态势感知误差量，搭建具备态势感知误差的空战仿真环境。随后，提出一种基于门控循环单元提取态势特征的近端策略优化算法，设计和定义了优势态势解算单元、算法运行架构、一种量化优势的奖励塑造方法等模块。最后，在具备态势感知误差的空战仿真环境下进行多项试验，证明了所提方法在态势感知存在误差的空战环境下具有良好的机动决策能力。

第4章为基于深度强化学习的泛化性增强空战机动决策算法。该章节针对基于DRL的视距内空战机动决策算法特定训练模型泛化性不足的问题，首先分析并推导了基于深度强化学习的特定训练模型在未知环境中，泛化性能下降的原因和优化解决思路。随后，提出一种基于自注意力机制与预训练模型的近端策略优化算法，分别介绍了算法中基于自注意力机制的奖励塑造方法、基于预训练模型的策略重用方法与预训练模型的设计实现。最后，定义了一种想定集划分与随机抽样方法，对视距内空战机动决策问题的MDP模型进行划分，并对划分后的想定集进行随机抽样，用于训练和测试。通过一系列对比测试实验，证明使用所提算法得到的特定训练模型具备较强泛化能力。

第5章为面向深度强化学习的空战训练仿真一体化平台系统设计与实现。该章节首先根据研究领域现状及本文所提算法的训练验证需要，对平台设计需求做出分析，在此基础上，设计了平台系统架构，推演了平台工作流程。随后，对平台设计预期的各项功能进行开发，分析介绍并展示各项功能开发效果。最后，在实现平台预期功能的基础上，以本文所提算法的训练验证实验为例，演示了平台的应用效果。

第6章为总结与展望。该章节中梳理和总结了本文主要的研究工作和结论成果，对本文的学术价值和应用价值做出主观的预测与评价。随后，规划展望了未来在本研究方向上可以进行的研究工作。

第2章 相关理论基础

2.1 引言

为科学严谨地研究视距内空战机动决策问题,需要对视距内空战场景中的环境坐标系、飞行器机动模型、飞行器间的相对态势模型等概念做出定义或建模,从而为后续实验中飞行器机动状态的仿真和视距内空战机动决策算法的演算提供依据,保证仿真实验的精度与可信度。同时,为研究和基于 DRL 的视距内空战机动决策算法,需要对 DRL 领域的基本理论和概念进行阐释和界定,为本文后续提出算法的动机阐述和推导过程做出铺垫。基于上述目的,本章首先描述后续实验中,对视距内空战机动问题所进行的数学建模,随后将阐述 DRL 算法研究领域的基础理论概念和知识,并介绍和分析推导本文后续涉及的主要 DRL 算法及其原理。

2.2 视距内空战机动建模

视距内空战场景下,各飞行器间的欧氏距离通常不超过 10 千米^[4],敌我飞行器作战空域环境区别较小,且视距内空战机动对抗通常在较短时间内就将分出胜负,作战持续时间较短的情况下可忽视燃油质量等飞行器自身变化。同时,本文所做的基于 DRL 的视距内空战机动决策算法研究,主要关注 DRL 方法在感知误差条件下的决策效果、使用特定训练模型的决策泛化能力等,侧重于算法性能特点对机动决策效果的影响。

因此,本文将敌我飞行器均视为对称且质量分布均匀的理想刚体模型,使用简化的三自由度飞行控制及仿真模型对飞行器运动方式进行控制、解算与仿真,假设飞行器速度方向与机体轴正朝向相同,以降低飞行器机体控制方面的决策难度。本文假设实验全程所处空域的重力加速度、空气密度和飞行器自身质量始终保持不变,同时,不考虑地球自转、曲率等因素对飞行器运动的影响。

2.2.1 坐标系

为精确描述飞行器在视距内空战场景中的三维空间位置、朝向、机体姿态等信息,需建立统一、标准化的参考坐标系,作为下文推导或实验中获取和描述飞行器信息的基本依据。

首先,在不考虑地球自转、曲率等因素的情况下,以交战空域海平面为参考系,建立最直观常用的三维笛卡尔惯性系——地平面坐标系 $(O_g x_g y_g z_g)$,其中 O_g 为指定原点,在本文实验中设为作战空域地平面或海平面中心点, $O_g x_g$ 取正北航向, $O_g y_g$ 取正东航向, $O_g z_g$ 铅垂向下^[60],构成右手坐标系。该坐标系与地平面固连,示意图如图 2.1 所示。




图 2.1 地平面坐标系

Figure 2.1 Horizontal coordinate system

在地平面坐标系的基础上,为更精确地描述飞行器的滚转、俯仰等运动姿态,通常以我方操控飞行器的质心 O_b 为原点,建立与飞行器机体固连的机体坐标系,即体轴系 $(O_b x_b y_b z_b)$,其中 $O_b x_b$ 取飞行器对称平面内,与飞行器设计轴线平行,从质心指向飞行器几何前方的射线, $O_b y_b$ 取垂直于飞行器对称平面,从质心指向飞行器右侧的射线, $O_b z_b$ 取飞行器对称平面内,垂直于 $O_b x_b$ 指向机身下方的射线^[73],示意图如图 2.2 所示。




图 2.2 机体轴坐标系

Figure 2.2 Aircraft body axis coordinate system

为精确描述我方飞行器的位移、速度和航迹变化,通常建立速度坐标系 $(O_v x_v y_v z_v)$,也称气流坐标系^[73],坐标系原点 O_v 位于飞行器质心, $O_v x_v$ 轴方向与飞行器当前速度矢量 V 重合, $O_v z_v$ 取飞行器对称平面内,垂直于 $O_v x_v$ 指向机身下方的射线, $O_v y_v$ 则取垂直于 $x_v O_v z_v$ 平面,指向飞行器右侧的射线^[73]。依据此描述,建立速度坐标系,如图 2.3 所示。其中, α 为速度向量在飞行器对称面的投影与机体轴的夹角,称为迎角, δ 为速度向量 V 与飞行器对称面的夹角,称为侧滑角。




图 2.3 速度坐标系

Figure 2.3 Velocity coordinate system

三维坐标系中同一坐标在不同坐标系下进行的坐标转换,可以视作坐标向量乘以两坐标系间的基元变换矩阵^[73]。标准三维笛卡尔坐标系下,三轴旋转弧度分别为 ζ 、 η 、 ξ 时,向标准坐标系进行坐标转换的基元变换矩阵表示如下:

$$\begin{cases} L_x(\zeta) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \zeta & \sin \zeta \\ 0 & -\sin \zeta & \cos \zeta \end{bmatrix} \\ L_y(\eta) = \begin{bmatrix} \cos \eta & 0 & -\sin \eta \\ 0 & 1 & 0 \\ \sin \eta & 0 & \cos \eta \end{bmatrix} \\ L_z(\xi) = \begin{bmatrix} \cos \xi & \sin \xi & 0 \\ -\sin \xi & \cos \xi & 0 \\ 0 & 0 & 1 \end{bmatrix} \end{cases} \quad (2-1)$$

其中,机体轴坐标系和地面坐标系之间的关系可通过航向角 ψ 、俯仰角 β 以及滚转角 μ 三个角度进行描述。航向角 ψ 为飞行器机体设计轴线与正北方向的夹角;俯仰角 β 为飞行器机体设计轴线与其在水平面上的投影间的夹角;滚转角 μ 也被称作倾斜角,定义为飞行器对称面与地面坐标系铅垂平面间的夹角。各角度精确定义及范围将在下一小节结合飞行器动力学模型进行叙述。根据上述定义,可以得出机体轴坐标系向地面坐标系进行坐标转换的基元变换矩阵:

$$\begin{aligned}
 L_{bg} &= L_x(\psi)L_y(\beta)L_z(\mu) \\
 &= \begin{bmatrix} \cos\beta\cos\mu & \cos\beta\sin\mu & -\sin\beta \\ \sin\psi\sin\beta\cos\mu - \cos\psi\sin\mu & \cos\psi\cos\mu + \sin\psi\sin\beta\sin\mu & \sin\psi\cos\beta \\ \sin\psi\sin\mu + \cos\psi\sin\beta\cos\mu & \cos\psi\sin\beta\sin\mu - \sin\psi\cos\mu & \cos\psi\cos\beta \end{bmatrix} \quad (2-2) \\
 &= L_{gb}^{-1}
 \end{aligned}$$

同理, 由于机体轴坐标系与速度坐标系间的相对关系可通过迎角 α 与侧滑角 δ 进行描述, 根据速度坐标系定义, 可得速度坐标系向机体轴坐标系进行坐标转换的基元变换矩阵:

$$\begin{aligned}
 L_{vb} &= L_x(\delta)L_y(\delta)L_z(\alpha) \\
 &= \begin{bmatrix} \cos\delta\cos\alpha & \cos\delta\sin\alpha & -\sin\delta \\ \sin^2\delta\cos\alpha - \cos\delta\sin\alpha & \cos\delta\cos\alpha + \sin^2\delta\sin\alpha & \sin\delta\cos\delta \\ \sin\delta\sin\alpha + \cos\delta\sin\delta\cos\alpha & \cos\delta\sin\delta\sin\alpha - \sin\delta\cos\alpha & \cos^2\delta \end{bmatrix} \quad (2-3) \\
 &= L_{bv}^{-1}
 \end{aligned}$$


若将飞行器控制与仿真模型简化至三自由度, 则需假设飞行器速度方向与机体轴正朝向相同, 即 $O_b x_b$ 与 $O_v x_v$ 重合, 从而推出体轴系 $(O_b x_b y_b z_b)$ 与速度坐标系 $(O_v x_v y_v z_v)$ 的三轴重合, 则 L_{vb} 简化为单位矩阵, 同时有:

$$L_{vg} = L_{vb} \cdot L_{bg} = E \cdot L_{bg} = L_{bg} \quad (2-4)$$

2.2.2 飞行器动力学模型


本文实验中使用简化的三自由度飞行控制及仿真模型对飞行器运动方式进行控制、解算与仿真, 对飞行器的动力学建模如图 2.4 所示。

图 (a) 中, ψ 表示速度在水平面的投影与正北方向的夹角, 即航向角, 取值范围为 $[0, 2\pi]$; 方位向量 $(x_{pos}, y_{pos}, z_{pos})$ 基于预设原点表示了飞行器当前的空间方位。图 (b) 中, $\mathbf{v}$ 代表飞行器当前速度向量, 速度大小表示为 v , 单位为 m/s , 变化范围为 $[100, 350]$; $\mathbf{G}$ 为飞行器自身重力; 将飞行器刚体模型所受除重力外的空气阻力、机翼升力、发动机推力等一切内外力视为统一合力, 并沿速度方向及垂直速度方向进行分解, 得到垂直



(a) 飞行器垂直面动力学模型

(a) Aircraft vertical dynamic model



(b) 飞行器水平面动力学模型

(b) Aircraft horizontal dynamic model

图 2.4 飞行器动力学模型

Figure 2.4 Aircraft dynamic model

速度方向的分力 N_x 和沿速度方向的分力 N_y ，即飞行器切向与法向所承受的过载； β 表示飞行器机身纵轴与其在水平面上的投影间的夹角，即俯仰角，取值范围为 $[-\pi/2, \pi/2]$ ； μ 表示飞行器机身滚转角，取值范围为 $[-\pi, \pi]$ 。公式 (2-5) 中列出了飞行器三自由度仿真模型下，各主要状态量之间的关系方程：

$$\begin{cases} \Delta v = g(N_x - \sin \beta) \\ \Delta \beta = \frac{g(N_y \cos \mu - \cos \beta)}{v} \\ \Delta \psi = -g \frac{N_y \sin \mu}{v \cos \beta} \\ \Delta x_{pos} = v \cos \beta \cos \psi \\ \Delta y_{pos} = v \sin \beta \\ \Delta z_{pos} = -v \cos \beta \sin \psi \end{cases} \quad (2-5)$$

式中， g 为标准重力加速度； N_x 、 N_y 与 μ 可作为飞行器模型的三维动作输入，模拟实现对飞行器机动的有效操控。为使模型控制更贴近真实空战，本文实验中采用连续动作空间，各动作量变化范围及每秒限定最大变化率如表 2.1 所示：

表 2.1 动作空间变量变化范围及变化率

Table 2.1 Range and rate of variables in action space

变量名	矢量符号	变化范围	最大变化率 (s ⁻¹)
切向过载	N_x	$[-G, 8G]$	3G
法向过载	N_y	$[-3G, 8G]$	3G
滚转角	μ	$[-\pi, \pi]$	$\pi/2$

注：1) 滚转角取值 $-\pi$ 与 π 含义相同，并已作连续性处理。

2.2.3 视距内空战相对态势模型

本文侧重于机动决策算法性能研究,故选择以基础的一对一视距内空战想定作为视距内空战场景样例。面向真实世界三维环境中的视距内空战场景,针对我方飞行器与目标敌方飞行器的相对态势关系,建立三维几何模型如图 2.5 所示。任一敌我飞行器坐标、朝向等初始信息均确定的视距内空战相对态势模型,可称作一个视距内空战想定。




图 2.5 视距内空战相对态势模型

Figure 2.5 Relative situation model of air combat within visual range

图中, $O_g x_g y_g z_g$ 为地平面坐标系, 根据本文 2.4 中所描述模型, 可将敌我飞行器视作三维空间中的质点, 并以 (x_U, y_U, z_U) 表示我方飞行器位置坐标, 以 (x_T, y_T, z_T) 表示敌方飞行器位置坐标。 $\mathbf{D}$ 为敌机相对我机的位置矢量, 其模长记为 d , 方向由我机位置指向敌机位置。 ψ_U 为我机航向角, ψ_T 为敌机航向角, 图中未标注的敌我俯仰角分别用 β_U 和 β_T 表示。 $\mathbf{v}_U$ 代表我机的速度矢量, $\mathbf{v}_T$ 代表敌机的速度矢量。我机速度矢量与 $\mathbf{D}$ 的夹角 θ_C 称为追击角, 也被称作天线偏转角^[74], 敌机速度矢量与 $\mathbf{D}$ 的夹角 θ_E 为逃逸角, 亦称作视界角。敌我速度矢量间的夹角为 η , 称作航向交叉角。公式 (2-6) 为上述角与向量间的数值运算关系方程:

$$\begin{cases} \eta = \arccos \left(\frac{\mathbf{v}_U \cdot \mathbf{v}_T}{\|\mathbf{v}_U\| \|\mathbf{v}_T\|} \right) \\ \mathbf{D} = (x_T - x_U, y_T - y_U, z_T - z_U) \\ d = \sqrt{(x_T - x_U)^2 + (y_T - y_U)^2 + (z_T - z_U)^2} \\ \theta_C = \arccos \left(\frac{\mathbf{D} \cdot \mathbf{v}_U}{\|\mathbf{D}\| \|\mathbf{v}_U\|} \right) \\ \theta_E = \arccos \left(\frac{\mathbf{D} \cdot \mathbf{v}_T}{\|\mathbf{D}\| \|\mathbf{v}_T\|} \right) \end{cases} \quad (2-6)$$

起源于早期机炮空战时代的角度准则, 至今仍是世界范围内认可度最高的空战规则。角度准则提出: 视距内空战成功取得胜利的关键是通过采取一系列机动, 取得更有利的

空间占位^[75]。这是由于视距内空战中的常规武器系统、侦查预警系统通常瞄向机头前方，并随着机载武器装备的发展而具备一定角度的离轴瞄准能力，但通常难以直接瞄准飞行器侧翼或后方。因此，通过机动获得有利占位，俗称对敌“咬尾”的一方，能够更轻易地使用机载武器或雷达系统完成战术打击和侦察预警目的，而处在劣势占位、难以瞄准敌机的另一方则难以实现有效的反击。

由上述角度位置关系及视距内空战相对态势模型可知，当 θ_c 越小时，我方飞行器越容易瞄准敌机，当 θ_e 越小时，我方飞行器越不容易被敌机瞄准。因此，对飞行器在视距内空战中做出优势机动，完成追击、预警、侦察等作战任务的条件定义如下：

条件（1） 追击角 θ_c 小于指定优势范围，本文实验中指定范围为 $\pi/6$ ；

条件（2） 逃逸角 θ_e 小于指定优势范围，本文实验中指定范围为 $\pi/2$ ；

条件（3） 与敌机的距离 d 、距离向量沿OZ方向分量，即两机海拔高度差，均小于指定范围，在本文实验中， d 需小于1500m，两机海拔高度差需小于300m。

满足以上三个条件，即认为我方飞行器已做出优势机动，完成预定任务，定义为实现视距内空战优势机动决策。

2.3 深度强化学习理论基础

2.3.1 马尔可夫决策过程

马尔可夫决策过程(Markov Decision Process, MDP)是强化学习理论的基础，关于MDP的定义是，当某一决策过程中，未来环境状态的条件概率分布仅依赖于当前环境状态^[76]，则称该过程具备马尔可夫性，可被视作马尔可夫决策过程。空战机动决策过程具备马尔可夫性，因此可视为马尔可夫决策过程。MDP通常被定义和建模为四元组 $\{\mathbf{S}, \mathbf{A}, \mathbf{R}, \mathbf{P}\}$ 。其中， $\mathbf{S}$ 表示环境下所有状态的集合，被称作状态空间； $\mathbf{A}$ 表示决策主体在环境中的不同状态下可以采取的动作集合，称为动作空间； $\mathbf{R}$ 为不同状态下的不同决策带来的回报奖励集合； $\mathbf{P}$ 为状态转移函数，即在状态 s_t 下采取动作 a_t 后，状态转移至 s'_{t+1} 的概率。

2.3.2 深度强化学习理论

2.3.2.1 强化学习基础理论

如前文所述，强化学习是一种通过算法构造智能体，通过智能体与环境自主交互并学习最优行为决策策略的机器学习方法^[17]，而这种交互正是建立在MDP的基础之上。在强化学习理论中，将能够进行学习与决策输出的控制算法部分称作智能体，环境则包括了智能体之外的其他部分。强化学习的目标就是在给定的MDP中，通过训练智能体

探索环境，不断“试错”，最终学习得到不同状态下的期望最优策略

$\pi(a|s) = P[A_t = a | S_t = s]$ 。强化学习的基础框架表示如图 2.6 所示，即在连续的决策过程中，智能体在每一时刻 s_t 向环境输出一个动作 a_t ，并得到环境反馈的奖励回报值 r_t ，继而观测得到执行了动作 a_t 后下一时刻的环境状态 s_{t+1} 。




图 2.6 基础强化学习框架

Figure 2.6 Basic framework of reinforcement learning

依据上述框架的描述，强化学习过程中的状态转移过程不仅依赖于状态本身，也同时取决于智能体所采取的动作，但与过去时刻的状态无关，满足马尔可夫假设。表达为数学形式为：

$$p(s', r' | s, a) = P[S_t = s', R_t = r' | S_{t-1} = s, A_{t-1} = a] \quad (2-7)$$

MDP 中将 t 时刻环境反馈的奖励回报值的期望表示为 R_t 。当需要将强化学习从简单决策问题引入到决策时域较长或时域无限的情况时，自环境反馈中得到的累积奖励值也将无限增长，从而导致智能体难以基于长期奖励回报进行有效的学习和决策。因此，普遍采取引入奖励折扣系数的方式将长期奖励无限的问题转换为奖励有限问题，奖励折扣系数表示为 $\gamma \in (0, 1]$ ，从而将 MDP 拓展为 $\{S, A, R, P, \gamma\}$ 。当前时刻 t 对未来时刻 k 的奖励期望为 k 时刻奖励期望 r_k 乘上 γ^{k-t} ，从而 t 时刻起对未来的奖励期望可表示为：

$$R_{total}(t) = R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \dots + \gamma^{k-t} R_k = \sum_{k=t}^{\infty} \gamma^{k-t} R_k \quad (2-8)$$

通过强化学习方法学习寻找期望最优策略 $\pi(a|s)$ 的过程，可以被抽象为寻找状态-动作值函数最优解的过程。首先可定义状态值函数为：

$$V_{\pi}(s_t) = E_{\pi}[R_{total}(t)] \quad (2-9)$$

即表征智能体处于状态 s_t 的长期价值期望。

同理，在状态下采取动作的价值可通过采取动作后跳转状态的状态值进行评估，从而定义状态-动作值函数：

$$q_{\pi}(s_t, a_t) = E_{\pi}[R_{total}(t+1) | S_t = s_t, A_t = a_t] \quad (2-10)$$

当存在有一个或多个决策策略的决策效果不差于其他所有策略,即可称该策略为最优策略。通常使用 π^* 来表示最优策略,且根据定义可知最优策略对应状态值函数的最优解 $V^*(s)$, 即:

$$V^*(s) = \max_{\pi} V_{\pi}(s_t) \quad (2-11)$$

同理, 最优策略同样对应状态-动作值函数的最优解 $q^*(s, a)$, 即:

$$q^*(s, a) = \max_{\pi} q_{\pi}(s_t, a_t) \quad (2-12)$$

2.3.2.2 深度学习基础理论

深度学习是一种借助使用具有一定深度的神经网络, 对高维度数据进行特征识别、提取与表征的机器学习方法, 具备对复杂非线性数据的分析处理能力。深度学习的基础结构设计参考了自然界生物的神经系统中, 信息传递的基本单元——神经元, 在大量的神经元基础上构成了具有深度的神经网络。单个神经元的基本组成结构包括连接权重、偏置函数、激活函数, 典型结构如图 2.7 所示:




图 2.7 神经元结构图

Figure 2.7 Neuron structure

图中, j 用于标识当前神经网络所处层级, x_i 表示来自前一层神经网络层中各个神经元的输出, 对应的 w_{ij} 则为当前神经元与前序神经元的连接权重, 通过调整偏置函数 $Bias$ 可调节神经元的激活输出阈值等基本功能, $f(x_j)$ 为当前神经元采用的激活函数, $a(x_j)$ 为当前神经元的最终输出, 输出公式通常表示为:

$$a(x_j) = f\left(\sum_{j=1}^n w_{ij}x_j + Bias\right) \quad (2-13)$$

即对每个输入 x_i 与权重 w_{ij} 进行相乘后的结果与偏置函数 $Bias$ 进行叠加, 继而使用激活函数 $f(x_j)$ 求解最终输出^[77]。

深度神经网络中, 使用了大量神经元结构, 分层次进行排列, 同一层次的多个神经元共同组成一个网络层, 各层再依据本层功能而分类。其中, 输入层用于接收样本的特征向量, 输出层用于生成所需的输出, 而隐藏层则包括对输入层的信息进行处理的所有

有效单元^[78]。不同层之间的数据传输包含权重与偏置激活过程，而神经网络的训练过程目的就是对这些权重参数进行调整，以优化网络的特征提取性能。典型的神经网络结构如图 2.8 所示。




图 2.8 神经网络结构示例

Figure 2.8 Example of neural network structure

神经网络中的每一层的各个神经元在前序计算中的输入均为上一层神经元的输出，即除去输入输出层外，隐藏层的各层级中的任一神经元，均需要与上一层和下一层的所有神经元相连^[77]。因而可将神经元输出公式推广至第 j 层的第 k 个神经元，表示为：

$$a^k(x_j) = f\left(\sum_{i=1}^n w_{ij}^k a_{j-1}^k(x_i) + Bias^k\right) \quad (2-14)$$

其中， n 等于所在神经网络中的上一层神经元个数。

2.3.2.3 深度强化学习基础理论

深度强化学习在强化学习的基础上，为解决维度诅咒，即目标状态空间维度爆炸问题，而引入了能够表征理解高维状态空间的深度神经网络，直接在端到端的训练学习过程中对观测状态进行处理。2013 年，DeepMind 的 Mnih^[28]等人提出了 DQN 算法，首次将深度神经网络与强化学习算法结合。该算法作为 DRL 领域的经典算法，采用基于目标值函数的优化方法进行训练，即通过梯度下降等手段持续学习调整网络模型参数，使得智能体所采取的策略不断逼近最优动作-状态值函数 $q^*(s, a)$ 。DQN 算法的训练过程通过伪代码表示如算法 2.1 所示。

然而，由于基于目标值函数的 DRL 方法最终学习得到的值函数固定，所以对于给

算法 2.1 DQN 算法

```

1:  初始化 Q 网络, 随机初始化权重参数  $\theta$ , 初始化目标网络参数  $\theta' = \theta$ 
2:  初始化经验池
3:  for episode = 1 to max do
4:      重置并初始化环境状态
5:      for  $t = 1$  to  $t = T_{\max}$  do
6:          观察  $s_t$ , 并根据  $\varepsilon - greedy$  策略选择动作  $a_t$ 
7:          执行动作  $a_t$ , 观察奖励  $r_t$  和下一状态  $s_{t+1}$ 
8:          将  $\{s_t, a_t, r_t, s_{t+1}\}$  存储到经验池
9:          从 D 中随机抽样一批数据  $\{s_j, a_j, r_j, s_{j+1}\}$ 
10:         If  $s_{j+1}$  是终止状态:
11:              $target = r_j$ 
12:         else:
13:              $target = r_j + \gamma * \max_{\pi} [q_{\pi}(s_{j+1}, a_j : \theta')]$ 
14:              $Loss = [target - q_{\pi}(s_j, a_j : \theta)]^2$ 
15:             执行梯度下降步骤以最小化  $Loss$ 
16:         If  $t \bmod C == 0$ :
17:             更新目标网络的权重  $\theta' = \theta$ 
18:         End for
19:     End for
20: 结束

```

定观测状态所得出的最优策略选择也是固定的。这样的特性导致此类 DRL 方法在推广到更广泛的应用场景时受到限制^[39], 例如: 现实中有大量问题的最优策略具有离散分布, 或者服从某一概率密度函数, 此时基于目标值函数的 DRL 方法难以学习到长期最优策略; 基于目标值函数的 DRL 方法难以精确处理连续动作空间下的学习任务; $\varepsilon - greedy$ 策略存在过估计问题; 样本效率较低等。

因此, 在对以 DQN 算法基于目标值函数的 DRL 方法不断进行改进的同时, 基于策略梯度 (Policy Gradient, PG) 的 DRL 算法被提出, 并逐渐得到了更广泛的应用。基于 PG 的 DRL 算法将目标策略预设并表示为不同状态下选取最优动作的概率密度函数, 不断计算当前策略下的总奖励期望值基于当前策略参数 θ 的梯度, 进而沿梯度方向更新 θ , 从而指导智能体最终收敛于最优策略 $\pi(a|s)$ ^[66], 其损失函数可表示为:

$$Loss_{PG}(\theta) = E_{(s_t, a_t) \sim \pi_{\theta}} [A_{\theta}(s_t, a_t) \log \pi_{\theta}(a_t | s_t)] \quad (2-15)$$

式中, θ 为可优化参数; $E_{(s_t, a_t) \sim \pi_{\theta}}$ 表示基于采样经验对状态 s_t 下采取动作 a_t 的策略

期望; $A_{\theta}(s_t, a_t)$ 表示状态 s_t 下采取动作 a_t 的优势函数; $\pi_{\theta}(a_t | s_t)$ 表示状态 s_t 下采取动作 a_t 的概率密度函数。

相较基于目标函数进行优化, 基于 PG 的优化效果直接作用于目标策略, 带来了更高的采样利用效率, 加快了训练过程, 且应用范围更广, 在更普遍的问题中均能收敛到最优策略。在过去几年的研究中, 基于 PG 陆续产出了 PPO、DDPG 等具有优异性能和稳定性的 DRL 算法, 在不同的研究方向上取得了出色的决策效果。

2.3.3 近端策略优化算法

2.3.3.1 Actor-Critic 架构

在机器学习方法中, 历来存在一个核心问题, 即平衡模型预测值的偏差与方差。由于基于 PG 的 DRL 算法根据训练样本, 直接对优化目标动作的概率密度函数进行优化, 则易受样本噪声和样本随机性等因素影响, 产生相对较大的方差。为减少基于 PG 的 DRL 算法的方差, 当前主流研究与算法中普遍采用了 Actor-Critic 架构。

Actor-Critic 架构通常可简称为 A-C 架构, 其中的 Actor 网络也被称作策略网络, Critic 网络被称作价值网络。其通过设置一个额外且独立的 Critic 网络评估策略的长期收益, 减少了直接对复杂样本进行梯度估计产生的方差^[77]。同时, 由于 Actor 网络与 Critic 网络能够共享一部分特征表示, 加上 A-C 架构通常配合使用优先经验回放等样本重用策略, 使得训练过程更加地稳定, 训练效率也得到有效提高, 并且降低了算法收敛到局部最优的可能。A-C 架构的典型结构如图 2.9 所示。




图 2.9 Actor-Critic 架构图

Figure 2.9 Actor-Critic architecture

2.3.3.2 近端策略优化算法

近端策略优化 (Proximal Policy Optimization, PPO) 算法是一种建立在 A-C 框架基

础上的基于 PG 的 DRL 算法。其首先使用重要性采样方法，建立经验回放缓冲区，使行为策略获取的数据能够用于更新目标策略，提高了数据利用率并加快训练学习速度；随后，借助以 KL 散度为基线的裁剪项 $Clip$ 约束两个网络间的采样分布差异，确保了两次网络更新的差距幅度不会过大，从而提高算法运行效率^[78]。PPO 算法的损失函数可表示为：

$$\begin{cases} L_{PPO}^{\theta^k}(\theta) \approx \sum_{s_t, a_t} \min \left(\left[\frac{\pi_{\theta}(a_t, s_t)}{\pi_{\theta^k}(a_t, s_t)} A_{\theta^k}(s_t, a_t) \right], Clip \right) \\ Clip = \left(\frac{\pi_{\theta}(a_t, s_t)}{\pi_{\theta^k}(a_t, s_t)}, 1 - \epsilon, 1 + \epsilon \right) A_{\theta^k}(s_t, a_t) \end{cases} \quad (2-16)$$

式中， ϵ 代表 PPO 网络的裁剪系数； θ^k 代表 k 次迭代后的网络参数。

PPO 算法的训练过程通过伪代码表示如算法 2.2 所示。

算法 2.2 近端策略优化算法 (PPO)

- 1: 使用初始化参数 θ 对策略网络 $\pi(a|s)$ 进行初始化
 - 2: 使用初始化参数 ϕ 对价值网络 $V_{\phi}(s)$ 进行初始化
 - 3: **for** iteration = 1 **to** N **do**
 - 4: **for** $t = 1$ **to** $t = T_{\max}$ **do**
 - 5: 观察环境态势 s_t
 - 6: 使用策略网络 $\pi(a|s)$ 生成动作 a_t
 - 7: 执行动作 a_t ，观察奖励 r_t 和下一状态 s_{t+1}
 - 8: 存储经验样本 $\{s_t, a_t, r_t, s_{t+1}\}$
 - 9: **End for**
 - 10: 计算优势函数 $\hat{A}(s, a) = q_{\pi}(s, a) - V_{\phi}(s)$
 - 11: **#更新策略网络:**
 - 12: **for** $K_epochs = 1$ **to** K **do**
 - 13: 计算当前策略 $\pi(a|s)$ 下的动作概率和对数概率
 - 14: 通过优势函数 $\hat{A}(s, a)$ 计算当前动作的优势比率和经 $Clip$ 裁剪后的优势比率
 - 15: 计算策略损失函数 $L_{PPO}^{\theta^k}(\theta)$
 - 16: 计算策略网络的梯度并更新参数 θ
 - 17: **End for**
 - 18: **#更新价值网络:**
 - 19: 使用均方误差损失函数更新价值网络参数 ϕ
 - 20: **End for**
 - 21: **结束**
-

PPO 算法由于其广泛的适用性、鲁棒性和优秀的性能，已成为了 OpenAI 等顶尖 DRL 研究团队在不同应用场景和决策问题中普遍优先采用的基线算法。因此，本文后续实验将主要以 PPO 算法为基础，针对视距内空战机动决策场景下的具体问题进行对应优化和改进，研究并产出适用于具体视距内空战机动问题的 DRL 方法。

2.4 本章小结

本章内容主要涉及了深度强化学习与视距内空战机动问题的相关理论和基础知识，是本文后续进行算法推导与研究论述内容的前序铺垫。本章首先推导了对视距内空战机动场景的建模过程，具体内容包括：

首先，对空战中常用坐标系进行描述，推导了不同坐标系内坐标转换的基元变换矩阵；对本文实验中使用的飞行器仿真控制模型进行了动力学建模和运动方程分析；对典型的一对一视距内空战场景进行相对态势建模，定义视距内空战优势机动。这部分工作为本文后续实验中，飞行器机动状态的仿真演算、视距内空战机动决策算法与奖励塑造方法的设计和执行提供了依据。

随后，本章介绍了深度强化学习领域的基础概念和理论。分别从基础的强化学习、深度学习概念出发，进而阐述了典型的基于值函数的深度强化学习算法，并举例推导其关键函数。本章最后部分，介绍了当前基于策略梯度的深度强化学习算法中，通常使用的 Actor-Critic 框架，并推导和介绍了性能优异的近端策略优化算法主要流程，为本文后续章节中的算法设计和研究提供了理论基础。

第3章 基于深度强化学习的抗感知误差空战机动决策算法

3.1 引言

在真实空战环境中,以光电传感器和雷达为代表的机载态势感知设备^[79]极易受气象因素、电磁干扰、设备精度等因素影响,产生读数误差。因此,视距内空战机动决策场景中,飞行器对环境态势感知的误差应广泛存在。基于深度强化学习的机动决策算法在视距内空战机动决策领域虽已取得了重要进展,但现有方法普遍未考虑空战中的态势感知误差对 DRL 决策的影响。由于状态空间是连续且高维的,基于 DRL 的决策智能体只有在正确认知环境态势的前提下才能探索学习到正确的决策,因此可以预见,态势感知误差的存在将显著影响 DRL 智能体对环境状态估计的精度和准确性,进而显著影响基于 DRL 的视距内空战机动决策算法在真实环境中的训练及最终决策效果。

针对基于 DRL 的视距内空战机动决策算法研究中,态势感知误差对算法训练和决策效果的影响问题,本章首先分析了在端到端的强化学习训练过程中,降低态势感知误差影响的理论依据与方法动机,进而提出一种基于门控循环单元(Gated Recurrent Unit, GRU)提取态势特征的近端策略优化算法。随后,搭建了具备态势感知误差的空战仿真环境,并在不同感知误差强度及不同敌我初始态势等多种场景下进行了仿真对比实验,以验证本章所提算法性能。本章具体工作包括以下部分:

(1) 分析态势感知误差对 DRL 训练和决策产生干扰的原理,提出并推导了在端到端的强化学习训练过程中,通过引入前序态势序列态势信息,以提高神经网络对感知误差下真实态势特征的学习能力、降低态势感知误差所造成影响的可行方案,为后续算法的设计提供方案动机和理论基础。

(2) 在本文第二章对视距内空战典型相对态势的建模基础上,通过分析真实战场环境中态势感知误差的由来和特点,设计并向空战相对态势模型中引入了态势感知误差量,搭建了具备态势感知误差的空战仿真环境。

(3) 设计并提出一种基于 GRU 提取态势特征的近端策略优化算法,该算法在 PPO 算法的基础上引入了门控循环单元,融合前序态势信息,提取连续态势序列之间的隐藏特征。同时,算法设置了优势态势解算单元,以压缩状态空间维度,实现降低训练难度。最后,设计了一种量化优势的奖励塑造方法,引导算法训练加速收敛。

(4) 在具备态势感知误差的空战仿真环境中,针对典型视距内空战相对态势想定,对所提算法与常用基线 DRL 算法进行了对比实验,随后,在不同感知误差强度及不同敌我初始态势等多种场景下进行了泛化性实验。通过多项实验,充分验证了所提算法在态势感知存在误差环境下的视距内空战机动决策能力。

3.2 问题描述与方法动机

3.2.1 问题描述

真实空战环境里,以光电传感器和机载侦测雷达为代表的现代飞行器主流机载感知设备^[79],是实现敌对与对环境态势感知的主要手段。但是,以此二者为代表的主流机载感知设备在敌方电磁干扰、气象环境干扰、读数误差等因素影响下,均易发生观测失准^[80]。例如,通过使用空战中常用的箔条干扰弹、红外辐射弹等干扰武器,可以对机载雷达发射的电磁信号产生散射,或是对光电传感器带来错误成像,从而致使我方飞行器接收到的反馈信号失准;云层中自然出现的放电现象与电离效应也会对雷达辐射信号造成干扰;雷达和光电传感器等感知设备自身的探测误差和读数误差也会带来态势感知的失准。因此,可以预见,随着空中电子战烈度的不断增加^[8],在未来的真实空中战场环境里,飞行器的态势感知误差将长期普遍存在。

根据空战过程的马尔可夫性,可将空战中的环境态势抽象视作多元平稳时间序列 $U(t)$,为便于举例,将受不确定随机误差影响的某一维度环境态势观测值,抽象表示为一阶动态自回归时间序列模型 (Autoregressive Time Series Model),表示为^[81]:

$$\begin{aligned} AR(1): X'_t &= \varphi X_{t-1} + a_t \\ &\neq X_t \end{aligned} \quad (3-1)$$

其中, X'_t 为 t 时刻态势观测值, φ 表示真实态势值 X_t 对 X_{t-1} 的依赖,根据马尔可夫性可知这种依赖关系受限于真实物理环境、飞行器动力学模型演算性质,以及动作空间变量的最大变化率,即此类态势通常不在短时间内发生大幅度突变; a_t 表示由态势感知误差量抽象成的随机扰动,称为态势感知误差偏移量。在误差随机的情况下,当 $X_i \neq X_j$ 且 $X_{i-1} \neq X_{j-1}$ 时,有概率出现:

$$\begin{aligned} X'_i &= \varphi X_{i-1} + a_i \\ &= \varphi X_{j-1} + a_j \\ &= X'_j \end{aligned} \quad (3-2)$$

抽象而言,基于 DRL 的决策智能体进行训练学习的原理为:依据某一态势 X_k 下做出决策后得到的反馈奖励等信息,对当前的决策选择做出优劣评判,从而习得再次遭遇相同态势 $X_i = X_k$ 时,应该调整采取怎样的决策策略。而当智能体对态势观测失准时,针对不同态势 $X_i \neq X_j$,有概率出现相同观测结果 $X'_i = X'_j$,使得智能体难以区分,错将不同的真实态势观测理解为相同的态势值,在错误观测的基础上进行状态估计与学习,从而无法习得正确的决策策略。

3.2.2 方法动机

针对观测值包含态势感知误差条件下,难以区分真实态势值的问题,在数学上可采

用一种简单方法增加对真实态势值的判断准确率,即:由于环境与敌我飞行器态势变化受限于物理环境、飞行器动力学模型演算性质、动作空间变量的最大变化率等条件,在较短时间内具有一定的依赖关系或周期性模式,据此,可通过引入当前时刻 t 之前 k 步时间片的观测值 $X'_{t-1}, X'_{t-2}, \dots, X'_{t-k}$,建立 k 阶自回归模型:

$$AR(k): X''_t = \varphi_1 X'_{t-1} + \varphi_2 X'_{t-2} + \dots + \varphi_k X'_{t-k} + a_t \quad (3-3)$$

其中, $\varphi_1, \dots, \varphi_k$ 表示前序值关于当前时刻 t 的回归依赖系数。通过增加 k ,即引入了更多的自回归项,引入了更多的历史信息,能够更全面地包含时间序列数据的动态特征和变化趋势,提高观测值与真实值的相关性。

同理,对于DRL训练,同样也可以通过引入前序一小段时间片内的观测信息,增加智能体对于当前态势真实情况的状态估计准确率。并且,由于DRL方法在训练和决策中的端到端特性,提高对态势真实情况的状态估计准确率即可直接提升智能体的学习和决策效果。因此,本章提出以下思路以解决基于DRL的视距内空战机动决策中的感知误差问题:训练中的任意 t 时刻,在智能体的观测态势中同时引入前序一段时间片内的态势数据,以高效的循环神经网络进行特征提取和状态估计,同时辅以奖励塑造等技术手段,实现在端到端的DRL训练中,提高智能体对态势感知误差的抵抗效能。

3.3 态势感知误差建模

通过对产生态势感知误差的主要原因进行分析,可假定态势感知误差偏移量为分布不均匀的随机概率分布,相同条件下产生绝对值较小的态势感知误差偏移量的概率相对较低;同时,敌我飞行器间的几何距离外的其他条件一致时,产生绝对值较小的态势感知误差偏移量的概率与距离呈负相关。根据上述前提,为模拟更真实的空战环境,本章设计并向本章现有的视距内空战相对态势模型中引入了态势感知误差量,对态势感知不准确的现象做出仿真表征。

首先,构建感知误差强度系数,通过该系数表征态势感知误差强度与敌我飞行器间的几何距离的负相关关系:

$$\gamma = \begin{cases} 1 & d \geq d_{\max} \\ \cos \left[\frac{\pi(d - d_{\min})}{2(d_{\max} - d_{\min})} \right] & d_{\min} < d < d_{\max} \\ 0 & d \leq d_{\min} \end{cases} \quad (3-4)$$

式中, d 为我机与敌机的欧氏距离;在本章实验中 $d_{\max}$ 设为10km,超出此距离范围发生的空战通常可被视作超视距空战;本章实验中的 $d_{\min}$ 设为1500m,即达成视距内空战优势机动决策所需的最大敌我距离。

为表征误差的随机性,设计随机误差系数:

$$\tau = rand(e^{-\gamma}, 1) \quad (3-5)$$

通过该系数控制态势感知误差量的产生随机性,确保态势感知误差在不同相对态势下的存在与随机分布。在此基础上,得到环境对态势感知数据产生的误差偏移量:

$$\varphi_{Dis} = \varphi_{real} \times k(\tau + \gamma) \quad (3-6)$$

式中, φ_{real} 代表视距内空战场景下,我方飞行器智能体感知得到的环境与敌我态势等各项态势数据的真实态势值; k 为仿真误差强度系数,在本章基础实验中设为 0.15,即令态势感知误差偏移量最大不超过真实态势值的 30%。

我方飞行器智能体最终得到的态势感知数据计算公式为:

$$\varphi_{final} = \varphi_{real} \pm \varphi_{Dis} \quad (3-7)$$

即,对各项真实态势数据随机加上或减去态势感知误差偏移量。通过对我方飞行器智能体所获得的所有态势感知数据中引入以上态势感知误差量,实现了在视距内空战相对态势模型中加入态势感知误差,提高了仿真程度。

3.4 基于 GRU 提取特征的近端策略优化算法

3.4.1 门控循环单元

门控循环单元^[82]是一种高效的循环神经网络 (Recurrent Neural Network, RNN), 其结构如图 3 所示。




图 3.1 门控循环单元结构图

Figure 3.1 Gated recurrent unit architecture

GRU 中引入了重置门和更新门的概念,均设定为激活函数为 Sigmoid 函数的全连接层,重置门用于筛除与未来无关的历史信息,更新门则用于控制隐藏特征的更新;随后计算候选隐藏特征 $\tilde{H}_t$ 来修正输出的结果。这样的门控设置使得 GRU 在具备融合过往

态势的前瞻能力和训练性能的同时，相比起长短期记忆神经网络（Long Short Term Memory, LSTM）节约了计算成本^[83]，从而具备了更快的计算速度，更适合应用在决策实时性要求较高的空战机动决策中。此外，由于 GRU 具有更少的迭代参数，记忆单元数量比起 LSTM 也更少，在需要快速迭代的 DRL 训练场景中，GRU 更容易实现良好的泛化性能。

3.4.2 状态序列空间

根据本文第二章中描述的飞行器动力学模型和视距内空战相对态势模型，为帮助 DRL 智能体实现对视距内空战环境态势的认知和理解，现定义我方飞行器在任一时刻的交战状态空间均包含以下基本信息：

（1）我方飞行器机动状态信息：位置坐标、速度、航向角、俯仰角、滚转角、切向过载、法向过载、重力；

（2）感知得到的敌方飞行器机动态势信息：位置坐标、速度、航向角、俯仰角、滚转角；

（3）视距内空战相对态势信息：距离、追击角、逃逸角、航向交叉角。

将上述信息表达为数学形式可写作：

$$s_t = \{x_U, y_U, z_U, v_U, \dots, d, \theta_C, \theta_E, \eta\} \quad (3-8)$$

由于态势感知误差量的存在，深度强化学习智能体对单一时刻的状态进行学习理解，可能出现较大误差；根据前文论述的方法动机，由于原始真实数据的确定性与连续性，相邻时刻的感知数据在环境误差下仍具有一定的相关性。基于此，对当前时刻及前序一段时间内的状态序列进行学习理解，能够帮助神经网络学习到状态序列中隐含的真实数据特征信息，从而使强化学习智能体正确理解战场态势，实现自主学习与自主决策。因此，定义视距内空战状态序列：

$$s_n(t) = \{s_{t-n+1}, s_{t-n+2}, \dots, s_{t-1}, s_t\} \quad (3-9)$$

即使用状态序列空间替代单一时刻状态空间，供算法智能体进行理解与学习。

3.4.3 优势态势解算单元

高维度的状态序列空间将给深度强化学习算法训练带来一定的难度，影响训练效率和最终决策性能。为压缩状态空间维度，同时保留状态序列空间内的隐藏特征信息，本章设计了优势态势解算单元，其解算过程如下：

步骤1 根据敌我机动态势数据，计算出敌机相对于我机的相对态势数据，包含相对位置 $(\Delta x, \Delta y, \Delta z)$ 、相对速度大小 Δv ，以及相对航向角 $\Delta \psi$ ，其计算公式如下：

$$\begin{cases} \Delta x = x_T - x_U \\ \Delta y = y_T - y_U \\ \Delta z = z_T - z_U \\ \Delta v = v_T - v_U \\ \Delta \psi = \psi_T - \psi_U \end{cases} \quad (3-10)$$

步骤 2 舍弃用于动作输入的我机切向过载、法向过载、滚转角三个维度数据，舍弃不包含空战态势特征的重力数据，舍弃与相对航向角带有相近信息的航向交叉角，舍弃相对位置信息中已包含的距离信息；

步骤 3 根据敌我当前俯仰角及高度差计算俯仰优势值，定量体现敌我俯仰角度差的同时，定性地反映出我机俯仰角的优势方向：

$$E_\beta = (\beta_U - \beta_T) \cdot \frac{\Delta z}{|\Delta z|} \quad (3-11)$$

步骤 4 为消除不同态势数据间的量纲差异带来的影响，对其做出如下归一化处理：

$$\begin{cases} \Delta x' = 2 \Delta x / d_{\max} \\ \Delta y' = 2 \Delta y / d_{\max} \\ \Delta z' = 2 \Delta z / d_{\max} \\ v' = \Delta v / v_{\max} \\ \psi' = \Delta \psi / \pi \\ E_\beta' = E_\beta / \pi \\ \theta_C' = \theta_C / \pi \\ \theta_E' = \theta_E / \pi \end{cases} \quad (3-12)$$

经优势态势解算单元处理完毕后的单一时刻态势数据可表示为：

$$s_t = \{\Delta x', \Delta y', \Delta z', v', \psi', E_\beta', \theta_C', \theta_E'\} \quad (3-13)$$

3.4.4 GPPO 算法

PPO 算法在连续动作空间任务上具有较高的稳定性和普遍适用性，探索环境时的样本复杂性较高，适合寻找视距内空战机动决策问题的最优解。根据上一小节中的描述，采用状态序列空间替代单一时刻状态空间，以求深度强化学习智能体能够学习理解到环境误差下的真实空战态势特征，而 GRU 所具有的融合过往态势的前瞻能力，对于提取状态序列空间中的隐藏特征具有独到优势^[84]。综上所述，本章提出一种基于 GRU 提取特征的近端策略优化算法——GPPO（Proximal Policy Optimization based on GRU）。

GPPO 算法中，GRU 融合状态序列并提取隐藏特征的过程如下：

步骤 1 算法启动时，初始化隐藏特征矩阵 H_0 ，填充为零。

步骤 2 算法运行时，将前一时刻隐藏特征 H_{t-1} 与当前状态序列中未融合的首帧状态 s_{t-t} 输入 GRU，经以下计算得到重置门神经元向量 r_t ，更新门神经元向量 z_t ，以及候

选隐藏特征 $\tilde{H}_t$:

$$\begin{cases} z_t = \sigma(\omega_z \cdot [H_{t-1}, s_{t-i}]) \\ r_t = \sigma(\omega_r \cdot [H_{t-1}, s_{t-i}]) \\ \tilde{H}_t = \tanh(\omega_{\tilde{H}} \cdot [r_t \cdot H_{t-1}, s_{t-i}]) \end{cases} \quad (3-14)$$

其中, ω_z 、 ω_r 和 $\omega_{\tilde{H}}$ 分别为更新门、重置门与候选隐藏特征计算的可学习参数, σ 为 Sigmoid 函数。

步骤3 根据更新门神经元向量 z_t 对前序隐藏特征 H_{t-1} 和候选隐藏特征 $\tilde{H}_t$ 进行融合, 更新当前隐藏特征:

$$H_t = (1 - z_t) \cdot H_{t-1} + z_t \cdot \tilde{H}_t \quad (3-15)$$

步骤4 如状态序列中还有未进行特征融合的状态, 返回步骤2, 以与状态序列进行部分融合的当前隐藏特征 H_t 和 s_{t-i+1} 作为输入。

步骤5 得到融合状态序列的隐藏特征 H_t 作为 GRU 的特征输出。

在 GPPO 的动作选择阶段, 使用 GRU 输出的隐藏特征 H_t 作为 Actor 神经网络的输入, 进行动作选择, 并在反向传播过程中将神经网络误差值梯度用于更新 ω_z 、 ω_r 和 $\omega_{\tilde{H}}$, 同时更新 Actor 和 Critic 网络。GPPO 的总体架构与流程和基础 PPO 相近, 其运行架构图如图 3.2 所示:




图 3.2 GPPO 算法运行架构

Figure 3.2 GPPO algorithm running architecture

3.4.5 奖励塑造

奖励塑造 (Reward Shaping, RS) 是通过向智能体提供根据先验知识设计和定义的

额外奖励函数，引导智能体向训练目标方向探索的一种技术。因奖励值由环境反馈，故本文全文的奖励计算中涉及的态势值均为真实态势数据，即奖励值由无感知误差态势数据计算得出。

为引导训练向胜利方向进行，在训练过程中设置单步奖励是一种通用的基础 RS 方法，其设计基本原则为：若智能体上一帧所采取的机动动作使得飞行器更接近于获胜条件，则可获得正奖励，反之则获得负奖励或无奖励。根据这一基本原则，考虑优势机动定义，设定基础单步奖励函数如下：

$$R_{step} = \lambda (R_d + R_H + R_{\theta_c} + R_{\theta_e}) \quad (3-16)$$

式中， λ 为单步奖励系数，在基础单步奖励中设置为 0.01； R_d 、 R_H 、 R_{θ_c} 和 R_{θ_e} 分别表示由敌我距离、高度差、追击角和逃逸角变化带来的单步奖励值，以 R_d 为例，其计算方式如下：

$$R_d = \begin{cases} 1 & d_t < d_{t-1} \\ 0 & d_t = d_{t-1} \\ -1 & d_t > d_{t-1} \end{cases} \quad (3-17)$$

即当敌我距离较前一帧减小时，获得正奖励，值为 1，当敌我距离较前一帧增大时，获得值为 1 的负奖励，距离不变时无奖励。 R_H 、 R_{θ_c} 和 R_{θ_e} 采用相同的计算方式。

然而，这种简单的 RS 方法存在一个明显的问题：不同的动作可能带来相同的奖励值，使得智能体无法在多个具有相同奖励的动作中区分出最优动作，影响学习效率。

为优化上述问题，同时根据视距内空战特点，引导智能体采取最优动作，本章提出一种量化优势的视距内空战 RS 方法，定义其基本规则如下：

规则 1 智能体采取的动作使得飞行器更接近于获胜条件，则可获得正奖励，反之则获得负奖励或无奖励；

规则 2 根据视距内空战先验知识，适当的加减速、保持航迹平滑等有助于飞行器接近获胜条件的机动动作，可以获得正奖励；

规则 3 采取最优动作应较采取次优动作获得更大的奖励值。

根据以上规则，设计单步奖励函数如下：

$$R'_{step} = \lambda_d R'_d + \lambda_H R'_H + \lambda_{\theta_c} R'_{\theta_c} + \lambda_{\theta_e} R'_{\theta_e} + \lambda_v R'_v + \lambda_m R'_m \quad (3-18)$$

其中包含了量化后的距离奖励 R'_d 、高度奖励 R'_H 、追击角奖励 R'_{θ_c} 和逃逸角奖励 R'_{θ_e} ，增加了速度奖励 R'_v 和航迹保持奖励 R'_m 。式中对各部分奖励设置独立的奖励系数 λ ， λ_d 为 0.15，其余基准值为 0.1，并根据训练场景作微调，从而优先实现对敌机的跟随，并免增速和保持航迹平滑带来的正奖励盖过不合理机动带来的惩罚。

为实现规则 3，应使奖励值量化反映态势变化程度，由此设计各部分奖励计算方式如公式 3-19 所示。

$$\begin{cases}
R'_d = \sin\left(\frac{\pi}{2} \cdot \frac{d_{t-1} - d_t}{v_{\max} \cdot T_{\text{step}}}\right) \\
R'_H = \sin\left(\frac{\pi}{2} \cdot \frac{z_{t-1} - z_t}{v_{\max} \cdot T_{\text{step}}}\right) \\
R'_{\theta_C} = \begin{cases} \frac{R_{\theta_C}}{2} & \theta_C \geq \pi/12 \\ \frac{R_{\theta_C}}{10} & \theta_C < \pi/12 \end{cases} \\
R'_{\theta_E} = \begin{cases} \frac{R_{\theta_E}}{2} & \theta_E \geq \pi/12 \\ \frac{R_{\theta_E}}{10} & \theta_E < \pi/12 \end{cases} \\
R_m = \begin{cases} 1 & \text{if } a_t = a_{t-1} \\ 0 & \text{if } a_t \neq a_{t-1} \end{cases} \\
R_v = \begin{cases} -1 & v_U < v_T \\ \sin\left(\frac{\pi}{2} \cdot \frac{v_U - v_T}{v_E - v_T}\right) & v_U \geq v_T \end{cases}
\end{cases} \quad (3-19)$$

式中, T_{step} 表示实验的仿真步长, 速度奖励 R_v 的计算中, v_E 表示当前感知态势下的期望速度, 其计算方式如下:

$$v_E = \begin{cases} v_T & d_t \leq d_{\min} \\ v_T + \frac{d_t - d_{\min}}{50} & d_{\min} < d_t \\ v_{\max} & v_T + \frac{d_t - d_{\min}}{50} \geq v_{\max} \end{cases} \quad (3-20)$$

即, 我机速度小于敌机速度感知量时, 获得负奖励, 否则获得正奖励, 奖励值的大小与我机速度向期望速度的趋近程度正相关。

3.5 仿真实验

3.5.1 基础实验设计

为验证 GPPO 算法在态势感知不稳定的条件下解决视距内空战机动决策问题的有效性, 本章首先设计了针对具有简单机动策略对手的基础对抗仿真对比实验。

实验中设有红蓝双方, 分别操控一架飞行器, 飞行器机动模型如本文第二章所述。蓝色方飞行器在固定位置生成, 由 GPPO 算法和基础 PPO 等对比算法控制的红色方飞行器, 在固定生成区域内的随机位置生成。蓝色方采取简单的匀速直线运动策略机动,

并将在红机抵近至本机 3km 以内，且本机相对于红机的逃逸角绝对值小于 $\pi/2$ 时，调整径向过载为 3，加速摆脱红方飞机；红色方则由深度强化学习算法控制机动。实验设计参数如表 3.1 所示。

表 3.1 基础实验设计参数

Table 3.1 Design parameters of basic experiment

参数	取值
对战空域大小(m)	50000*50000
对战空域海拔范围(m)	[1000,10000]
蓝方初始坐标(m)	(0,-10000,5000)
蓝方初始朝向角	0
蓝方初始速度(m/s)	150
红方初始 x 坐标范围(m)	[2000,5000]
红方初始 y 坐标范围(m)	[-12000,-15000]
红方初始 z 坐标范围(m)	[3500,7000]
红方初始朝向角	$3\pi/2$
红方初始速度(m/s)	150
仿真误差强度系数	0.15
仿真步长(s)	0.01666
决策步长(s)	0.1

单局仿真实验的终止仅有以下三种情况：

情况 1 一方飞行器通过优势机动完成作战任务，则判定该方获胜，完成优势机动的定义见本文 2.2 章节，用于胜负判定的数据为真实态势数据；

情况 2 一方飞行器离开对战空域，则判定该方失败；

情况 3 仿真时间超过 180 s，未产生胜负结果，判定红方飞行器机动决策超时，红方失败。

满足以上任一情况，单局仿真实验结束。

根据实验设置的对局终止情况，设置对局终止奖励如下：

$$R_{end} = \begin{cases} 25 & \text{if victory} \\ -25 & \text{if defeat or out-of-range} \\ -15 & \text{if overtime} \end{cases} \quad (3-21)$$

该实验中，GPPO 算法控制的红色方飞行器，需在有限时间内完成态势感知不准确前提下的态势感知与理解，同时进行正确地转向、调整高度，并适当加速以抵近蓝方飞行器后方，方能取得胜利，足以检验机动决策算法的性能。

为确保对比实验的严谨准确，真实反映算法性能，本章实验中对 DRL 算法神经网络的主要参数设置保持不变，具体数值如表 3.2 中所示。实验中，针对 GPPO 算法设置和量化优势的视距内空战 RS 方法设计消融实验，同时，引入同样使用 Actor-Critic 架构的 SAC^[85]、DDPG^[31]算法，与所提算法进行对比实验。


表 3.2 神经网络主要参数

Table 3.2 Main parameters of neural networks

参数名	参数值
神经网络层数	5
隐藏层神经单元数	256
行动者学习率	0.0003
评论家学习率	0.0005
折扣系数	0.99
网络更新步长	25
裁减系数	0.15
K_epoch	50
每轮训练局数	10000


3.5.2 基础实验结果分析

算法训练过程中，记录每一局的单局总奖励，以最近 10 局的平均总奖励作为纵坐标绘制实线，并根据平均总奖励的标准差绘制阴影。为使图线易于观察，对实线与阴影部分均做了平滑模糊处理，最终得到训练过程平均奖励变化曲线如图 3.3 所示：



(a) 基础 PPO 在有/无感知误差条件下的训练奖励变化

(a) Average reward changes of basic PPO with/without perception errors during training



(b) 不同方法在相同感知误差强度下的训练奖励变化

(b) Average reward changes of several methods with same perception errors during training


图 3.3 训练过程平均奖励变化图

Figure 3.3 Graph of average reward changes during training

图 3.3 的(a)分图展示了基础 PPO 算法在有感知误差和无感知误差条件下，分别进行一万局训练过程中的平均奖励变化。可见，在无态势感知误差的情况下，基础 PPO 算法只需要不到两千局便迅速收敛到了最优，且波动不断减小；而受态势感知误差影响的基础 PPO，经三千局训练探索后方能有效提升单局奖励，并很快陷入了一个较差的局部最优，难以继续提升，这反映出态势感知误差对强化学习智能体训练的显著影响。


图 3.3 的(b)分图展示了在相同强度的感知误差影响下，不同方法在训练过程中的平均奖励变化。可以看出，基础 PPO、SAC、DDPG 算法的表现均较差，难以有效提升训练奖励；经本章提出的 RS 方法引导的 PPO，通过短暂的训练便能一定程度地提升对局奖励，在经过七千局探索学习后，平均奖励值进一步有了显著提升的趋势；使用 GPPO 算法和基础奖励函数的智能体，在一万局的训练过程中平均奖励值呈稳定上升趋势，并最终趋近于最优奖励；同时使用 GPPO 算法及量化优势的视距内空战 RS 方法的智能体，在两千局训练后便将单局奖励提升到了接近最优水平，并在后续训练中逐渐收敛至稳定，其训练速度、训练结果均显著优于受态势感知误差影响的其他算法智能体。

图 3.4 展示了经不同方法训练后得到的智能体控制下，飞行器在初始位置相同的单局测试实验中的关键的敌我相对态势量的变化情况。由于各局仿真作战时间不同，为便于观察，图中相对态势数据截取至单局实验结束或决策步数达 270 步。




(a) 敌我相对高度变化曲线

(a) Changing curves of relative altitude




(b) 敌我距离变化曲线

(b) Changing curves of relative distance




(c) 敌我相对朝向角变化曲线

(c) Changing curves of relative orientation angle




(d) 敌我相对速度变化曲线

(d) Changing curves of relative velocity



(e) 追击角变化曲线

(e) Changing curves of attack angle



(f) 逃逸角变化曲线

(f) Changing curves of escape angle


图 3.4 单局测试中的关键态势量变化曲线

Figure 3.4 Changing curves of key situation quantity in single-game testing

从图 3.4 的(a)、(b)图中可以看出,同时使用 GPPO 及量化优势的视距内空战 RS 方法训练的智能体,在对局开始后控制飞行器最快地进行机动决策,调整高度与敌机持平,并快速接近敌机;使用基础奖励函数的 GPPO 智能体则稍慢,但最终同样达成较好的机

动决策效果；而使用 SAC、DDPG 或基础 PPO 训练的智能体均未能在短时间内拉近与敌机的距离，且使用基础奖励函数的 PPO 有失控下坠趋势；从(c)图中可以看出，使用 GPPO 算法训练的智能体通过机动决策缩小与敌机的相对朝向角，量化优势的 RS 方法帮助这一机动过程更加平滑，反观使用 SAC、DDPG 或基础 PPO 训练的智能体，则在短时间内未能缩小相对朝向角；(d)图中反映出 GPPO 智能体为达成追敌目标，能通过机动决策快速提高自身速度进行追敌，而基础 PPO 训练的智能体则加速较慢，量化优势的 RS 方法加快了飞行器的加速决策过程；图 3.4 的(e)、(f)图反映出 GPPO 算法训练的智能体操控飞行器通过机动决策，快速调整追击角与逃逸角至优势水平，量化优势的 RS 方法使得飞行器态势变化更加平滑，最终机动效果也更接近优势态势。

图 3.5 展示了两局红方初始坐标位置不同的单局测试实验中，经 GPPO 算法训练后的智能体控制的飞行器，在态势感知存在误差的视距内空战仿真环境中的交战飞行轨迹三视图。






图 3.5 GPPO 智能体飞行轨迹视图

Figure 3.5 Views of GPPO agent's flight trajectory

从图 3.5 中的红方飞行轨迹可以看出，经 GPPO 算法及量化优势的视距内空战 RS 方法训练的智能体，控制红方飞行器在作战开始后即根据敌机位置，快速调整了机身高度、朝向角，并在短时间内完成了较长距离的机动，迅速逼近敌机尾部，完成优势机动决策，达成了仿真作战任务目标，未出现低效或无意义的转向、摇摆，其机动轨迹较为平滑，仅能在高度控制上观察到较小的波动。据此可以判断，该智能体有效克服了态势感知误差对机动决策的影响，并且展现出了较高水平的机动决策性能。

综上所述，可见使用 GPPO 算法及量化优势的空战 RS 方法训练的智能体，在态势感知存在误差的条件下，仍具备较好的机动决策性能，且在决策速度、航迹平滑程度上优于使用 GPPO 算法和基础奖励函数训练的智能体；而使用 SAC、DDPG 或基础 PPO 算法和基础奖励函数训练的智能体则难以在态势感知误差下做出优势机动决策。

3.5.3 多场景泛化性能测试实验

为进一步验证 GPPO 算法抵抗态势感知误差、解决视距内空战机动决策问题的有效性，避免实验偶然性，本章设置了多个不同场景下的仿真对抗实验，以测试所提方法的泛化性能。主要实验设置如表 3.3 所示，其中，蓝方飞行器初始生成位置等未列出项与基础实验相同，各实验中做出的特殊调整在表格中用粗体标明。

表 3.3 多场景实验设置

Table 3.3 Multi-scenario experimental setup


序号	实验设置		
1	红方初始 X	红方初始 Y	红方初始 Z
	[2000, 5000]	[-12000, -15000]	[3500, 7000]
	敌我相对朝向	误差强度系数	蓝方机动策略
	$\pi/2$	0.3	直线加速摆脱
2	红方初始 X	红方初始 Y	红方初始 Z
	[-5000, 5000]	[-12000, -15000]	[3500, 7000]
	敌我相对朝向	误差强度系数	蓝方机动策略
	π	0.15	直线加速摆脱
3	红方初始 X	红方初始 Y	红方初始 Z
	[2000, 5000]	[-12000, -15000]	[3500, 7000]
	敌我相对朝向	误差强度系数	蓝方机动策略
	$\pi/2$	0.15	左转加速摆脱

其中，实验 1 在基础实验设置上加大了感知误差强度，检验 GPPO 算法面对高度失真的感知态势时的机动决策能力；实验 2 调整敌我初始相对朝向呈迎头相向态势，同时增大了初始位置变化范围，红方飞行器需要在调整速度、高度的同时，进行 180°转向至敌机后方，方能实现胜利目标；实验 3 则略微增加了蓝方机动策略的复杂度。以上实验设置，均加大了 GPPO 算法智能体做出优势机动决策、赢得任务胜利的难度。

图 3.6 展示了各实验训练过程中的平均奖励变化曲线。其中，实验 1 反映出：在更强烈的态势感知误差下，基础 PPO 算法结合基础奖励函数在两千局探索后就陷入了极差的局部最优，且难以继续提升；而使用 GPPO 算法及量化优势的视距内空战 RS 方法的智能体在强烈的态势感知误差下仍然能够缓慢但稳定地探索提升平均奖励，至一万局训练结束仍未明显陷入收敛，具有进一步提升的趋势。


实验 2 和实验 3 中，在增大机动难度和改变敌机策略的情况下，使用 GPPO 算法及本章设计 RS 方法的智能体均能在 4000 局以内将平均奖励提升至接近最优水平，并通过后续的训练使之趋于收敛；而使用基础 PPO 算法训练的智能体仍只能在一段时间的训练后，较小程度地提升平均奖励，并收敛至一个较差的局部最优。

此部分实验进一步证明，使用 GPPO 算法及量化优势的空战 RS 方法训练的智能体在态势感知存在误差的条件下，在不同的想定场景里均具备较好的性能。




(a)实验1（加大感知误差）训练过程平均奖励变化

(a) Average reward changes of experiment NO.1 during training



(b)实验2（增大机动难度）训练过程平均奖励变化

(b) Average reward changes of experiment NO.2 during training



(c)实验3（改变敌机策略）训练过程平均奖励变化

(c) Average reward changes of experiment NO.3 during training

图 3.6 多场景实验训练过程平均奖励变化图

Figure 3.6 Graph of average reward changes during training in multi-scenario experiments

3.6 本章小结

本章基于对真实空战环境的合理分析与研究推断，针对态势感知误差对基于 DRL 的视距内空战机动决策算法干扰问题，提出了一种基于门控循环单元提取态势特征的近

端策略优化算法,通过使用门控循环单元融合前序态势特征,降低态势感知误差对 DRL 方法的训练决策影响,并搭建了具备态势观测干扰量的视距内空战仿真环境,进行了一系列仿真对比实验,得到以下结论:

(1) 面对高仿真度的战场环境和客观存在的态势感知误差,使用 PPO、SAC 等 DRL 算法进行的视距内空战机动决策受到显著影响,算法机动决策性能相较于无感知误差环境出现明显下降。

(2) 本章提出的基于 GRU 提取态势特征的近端策略优化算法和对应的奖励塑造方法,在面对空战仿真环境中的态势感知误差时,能够较大程度地克服感知误差带来的影响,快速、有效地进行 DRL 训练。训练得到的算法智能体决策模型能够控制飞行器在态势感知存在误差的环境下,快速做出优势机动决策。同时,该算法在不同的实验场景和不同强度的态势感知误差下,均表现出优于基础 PPO 的性能,且在不同的视距内空战场景下均具有一定的泛化适用能力。

综上所述,本章通过研究与实验,证明了空战中态势感知误差对基于 DRL 的空战机动决策算法决策效果具有重大影响,而本章所研究提出的方法则能有效提高飞行器在面对态势感知误差时的空战机动决策能力,具有一定的工程应用参考价值。

然而,GPPO 算法虽然能够在端到端的训练中,抵抗态势感知误差带来的影响、理解态势隐藏特征并学习到正确的优势机动决策,但此学习过程完全依据训练中积累的经验数据。这将导致经训练得到的某一特定训练模型在接触到陌生未知的环境态势时,难以做出准确的认知和判断、决策性能下降,表现为特定训练模型在未知环境下的泛化性能弱。因此,本文的下一章将就此问题展开研究。

第4章 基于深度强化学习的泛化性增强空战机动决策算法

4.1 引言

本文上一章中,针对真实战场中普遍存在的态势感知误差对基于 DRL 的视距内空战机动决策算法的训练决策影响问题做出了研究。根据前文所述,态势感知误差之所以会对基于 DRL 的空战机动决策算法产生显著影响,是由于 DRL 方法需要通过在环境中进行训练,得到经验数据,进而对经验数据进行学习,然而态势感知误差直接降低了经验数据的准确性和有效性,从而显著降低了基于 DRL 的空战机动决策算法的训练决策效果。类似地,由于 DRL 方法需要通过训练经验进行学习这一特性,导致基于 DRL 的空战机动决策算法普遍存在另一短板,即特定训练模型的泛化性能不强。

基于 DRL 方法的空战机动决策智能体,在训练阶段往往能较高程度地拟合于训练数据,却不一定能真正理解空战任务的本质。在现实世界的空战场景中,作战环境通常是高维且复杂,并且时刻动态变化的,而基于 DRL 方法训练得到的空战机动决策智能体只能根据训练时所接触到的有限数据进行学习,试图在训练中覆盖所有战场情况并不现实。因此,经训练得到的智能体决策模型虽然能在训练环境中取得较强决策能力,具备较高性能水平,但在面对未知环境时,其仅能依据已有经验做出模糊判断,导致决策性能水平下降,表现为在未知场景下的模型泛化能力不强,无法满足视距内空战机动决策的需要。

针对基于 DRL 的视距内空战机动决策算法研究中,普遍存在特定训练模型泛化性能弱的问题,本章首先分析探讨了特定训练模型针对未知空战场景泛化性能弱的原因,在此基础上推导出本章所选方法的理论依据,从而提出一种基于自注意力机制与预训练模型的近端策略优化算法。随后,设计并进行了完整的泛化性能测试实验,以验证本章所提算法的性能。本章具体工作包括以下部分:

(1) 分析基于 DRL 的视距内空战机动决策方法训练得到的特定模型,在未知环境下泛化性能弱的原因,进而推理得出增强模型泛化性能的可行方案,为本章后续算法的设计提供方案动机和理论基础。

(2) 设计并提出一种基于自注意力机制与预训练模型的近端策略优化算法,该算法首先设计和训练了具备基础机动控制能力和终段追击能力的预训练模型。随后,根据策略重用思想,在预训练模型基础上进行新模型训练,减少新模型训练时的探索支出,降低最终训练模型对训练任务的拟合程度。同时,引入自注意力机制,在新模型训练过程中设计了一种基于自注意力机制的实时奖励塑造方法进行奖励塑造,提高新模型训练时的效率和探索针对性,并对最终训练模型的泛化性能起到提升作用。

(3) 在空战仿真环境中,定义视距内空战想定初始坐标集和敌机机动策略集。随后,定义一种想定集划分与随机抽样方法,对想定初始坐标集和敌机机动策略集进行划分和随机抽样,在此基础上进行交叉对比仿真实验,推断算法训练模型的泛化性能。通过多组实验与指标测算,证明所提算法训练得到的特定训练模型在视距内空战机动决策中具备较好的泛化性能。

4.2 问题描述与方法动机

根据本文 2.3 节所介绍的基础理论,可将视距内空战机动决策问题视作一个分支庞大的 MDP 模型 $\{\mathbf{S}, \mathbf{A}, \mathbf{R}, \mathbf{P}, \gamma\}$, 具体的任一视距内空战机动决策任务可视作该 MDP 模型的子集 $\{\mathbf{S}', \mathbf{A}', \mathbf{R}', \mathbf{P}', \gamma\}$, 基于 DRL 的视距内空战机动决策算法进行智能体训练的过程可视作对训练任务子集的探索学习过程。理想状态下,训练得到的空战机动决策智能体学习到了训练任务子集下的状态-动作值函数最优解 $q^*(s, a)$ 。

然而,在现实世界的空战场景中,作战环境通常是高维且复杂,并且时刻动态变化的。使用基于 DRL 的方法进行训练得到的空战机动决策智能体,通常只能根据训练任务抽象成的 MDP 模型 $\{\mathbf{S}', \mathbf{A}', \mathbf{R}', \mathbf{P}', \gamma\}$ 中包含的有限数据进行学习。若试图通过训练任务覆盖所有战场情况,训练中探索和学习所需的算力过大,在实际操作中并不现实。因此,当训练得到的智能体在决策中遇到训练任务中未出现过的空战态势 s , 只能通过深度神经网络进行模式识别与基于概率的模糊归类,对该态势下的最优策略进行不精确的模糊判断,据此做出的机动决策准确性也随之降低。类似地,当决策中战场环境发生改变,或是敌方飞行器采取于训练任务中不同的机动策略,即改变了不同时刻的动作-状态转移函数 $\mathbf{P}(s_{t+1} | s_t, a_t)$, 同样使得智能体无法基于训练所得模型做出准确判断,进而降低了智能体的机动决策性能。总而言之,由于实际决策任务与训练任务可分别视作视距内空战机动决策 MDP 的不完全重合子集,基于训练任务子集学习得到的 DRL 智能体在实际决策任务中面对未接触过的视距内空战场景,将出现一定程度的决策性能下降,表现为特定训练模型泛化性能不强。

特定训练模型泛化性问题在 DRL 理论研究领域已引起较广泛的关注,但在基于 DRL 的视距内空战机动决策研究领域内,国内外的相关研究工作仍主要集中在提高决策智能体在空战具体问题中的机动决策性能这一方向上。针对基于 DRL 方法的特定模型泛化性问题,文献[77]提出了基于预训练和基于目的地姿态预测的两种策略重用方法,分别提高了有人机和无人机在飞行器引导问题上的泛化能力;文献[86]采用任务间映射的策略重用等迁移学习技术,针对二维空域内的三对三空战起到了泛化性能改进效果。文献[87]中,作者设计了一种基于课程学习思想的递进式训练策略,提升了无人机追逃对抗决策模型的泛化性。上述研究中,均体现出使用迁移学习和策略重用的思想,通过预训练和递进式训练等方式降低特定训练模型对训练任务 MDP 的拟合程度,增强特定

训练模型泛化性。

受上述相关研究思想启发,针对基于 DRL 的视距内空战机动决策算法研究中,普遍存在的特定训练模型泛化性能弱的问题,本章设计提出以下思路进行解决:将视距内空战机动决策问题 MDP 模型 $M = \{S, A, R, P, \gamma\}$ 拆分为两部分,分别对应视距内空战优势机动决策中,飞行抵近敌机段 $M_1 = \{S_1, A_1, R_1, P_1, \gamma\}$ 和近距离“咬尾”追击段 $M_2 = \{S_2, A_2, R_2, P_2, \gamma\}$,有:

$$M = M_1 \cup M_2 \text{ 且 } M_1 \cap M_2 = \emptyset \quad (4-1)$$

通过将 M_2 段拆分为较小范围,使用低学习率和大批量训练的 DRL 方法,存在对该段空战机动决策进行全面探索的覆盖式学习可能。由此设计并针对 M_2 段进行覆盖式预训练,能够得到具备基础机动控制能力和终段追击能力的预训练决策模型。在该预训练模型基础上,基于迁移学习和策略重用思想,针对 M 的训练任务子集进行新模型训练,将有效减少训练中的探索支出,并且由于预训练模型具备的终段追击决策能力,避免了新模型过度拟合于训练任务,从而增强泛化性能;同时,引入一种基于 QKV (Query-Key- Value) 模型的自注意力机制,在新模型训练中进行实时奖励塑造。通过自注意力机制,有意识地提高决策智能体在视距内空战优势机动决策过程中,身处优势机动的不同阶段时,探索和决策的目的性与针对性,从而提高训练效率,并使得任意时刻存在多种决策能够奖励最优,进一步避免模型过度拟合于训练任务。

4.3 基于自注意力机制与预训练模型的近端策略优化算法

4.3.1 基于 QKV 模型的自注意力机制

注意力机制是一种用于增强神经网络模型对输入数据的关注度或调整数据权重配比的技术,起源于对人脑注意力分配,尤其是视觉注意力分配的仿生思想^[88]。通过引入注意力机制,神经网络模型可以在处理输入数据时更加灵活和精确地执行目标任务意图,从而在应用层面上提高模型的性能表现和泛化性能。自注意力机制(Self-Attention Mechanism)是一类用于处理序列数据的注意力机制,能够在不引入额外的循环结构或卷积操作的情况下,实现对序列的全局依赖关系的建模,对于处理长序列和大规模数据表现出良好性能,因而在自然语言处理、强化学习等领域取得了广泛应用^[89]。

QKV 模型是构成自注意力机制的典型模型,由 Query (查询)、Key (键) 和 Value (值) 三组向量运算组成,用于计算注意力权重并输出。QKV 模型能够高效处理长序列依赖问题,且对其执行过程的控制和对其输出结果的调用均十分灵活。QKV 模型基础结构如图 4.1 所示。




图 4.1 QKV 模型结构图

Figure 4.1 Architecture of QKV model

图中， W_q 、 W_k 、 W_v 分别是对应 Q 、 K 、 V 三组向量的权重参数矩阵。QKV 模型首先根据各向量的权重参数矩阵，对输入数据 X 进行全连接线性变换，得到 Q 、 K 、 V 三组向量， D_k 代表输入数据序列中单个元素维度。随后，针对每个查询向量和键向量计算注意力分数，并通过softmax函数进行归一化，得到注意力权重：

$$\text{softmax}(k_n, q) = \frac{k_n^T \cdot q}{\sqrt{D}} \quad (4-2)$$

表示为：

$$\text{Attention_Weights}(Q, K) = \text{softmax}\left(\frac{K^T Q}{\sqrt{D_k}}\right) \quad (4-3)$$

在注意力权重基础上，通过与值向量相乘后进行加权求和运算得到输出，其输出可理解为基于查询向量和注意力权重对输入数据的变换表达，输出向量计算方式如下：

$$\begin{aligned} y_n &= \text{att}[(K, V), q_n] \\ &= \sum_{i=1}^n \text{softmax}[s(k_i, q_n)] \cdot v_i \end{aligned} \quad (4-4)$$

表示为：

$$\text{Output}(Q, K, V) = \text{Attention_Weights}(Q, K) \cdot V \quad (4-5)$$

4.3.2 基于自注意力机制的实时奖励塑造方法

本文 3.4.5 节中介绍了奖励塑造（RS）技术的定义与原理，并通过设计提出一种量化优势的视距内空战 RS 方法，帮助智能体高效准确地识别出当前训练任务 $\text{MDP}\{\mathbf{S}', \mathbf{A}', \mathbf{R}', \mathbf{P}', \gamma\}$ 下的状态-动作值函数最优解 $q_{M'}^*(s, a)$ ，提高了智能体的训练学习效率。然而，该方法赋予了唯一的最优决策动作大于任何其他动作的奖励值，即最优决

策动作与最大奖励值存在唯一映射关系 $a_{best} \rightarrow R_{max}$ ，从而使智能体难以区分构成最大奖励值的各维度态势奖励与各维度态势变化间的对应关系，同时也降低了探索 and 选择其他次优策略的概率和趋向，使得训练得到的智能体决策模型更高程度地拟合于训练任务 MDP。因此，该 RS 方法对于特定训练模型的泛化性能将起降低作用。

在本章研究中，为提升基于 DRL 的视距内空战机动决策算法得到的特定训练模型泛化性能，提出一种基于自注意力机制的实时 RS 方法。该方法在 DRL 算法原有神经网络的基础上，引入并维护一个基于 QKV 模型的子模块，该模块与算法网络的输入层相连，接收实时态势输入并计算注意力权重。在 DRL 算法网络训练过程中，该模块与算法网络同步更新，根据算法策略损失梯度更新 Q 、 K 、 V 向量对应权重参数。

在奖励函数设置上，本章与第三章相同，首先根据视距内空战优势机动定义，设定基础单步奖励函数如下：

$$R_{step} = \lambda (R_d + R_H + R_{\theta_c} + R_{\theta_E}) \quad (4-6)$$

其中，单步奖励系数 λ 值的设定、 R_d 等针对不同态势的单步奖励值计算方式，均与第三章保持一致。在基础单步奖励函数之上，为提高特定训练模型泛化性，对基于自注意力机制的实时 RS 方法定义基本规则如下：

规则 1 智能体采取的动作使得飞行器更接近于获胜条件，则可获得正奖励，反之则获得负奖励或无奖励；

规则 2 在智能体训练过程中，基于 QKV 模型学习视距内空战优势机动的各阶段特征，对各维度的态势变化所带来的奖励分配不同的注意力权重，凸显高权重的态势变化对奖励值变化的对应影响，以便于智能体学习理解阶段性机动决策目标。

根据以上规则，设计基于自注意力机制的实时 RS 方法的单步奖励函数如下：

$$R'_{step} = \lambda (\omega_d R_d + \omega_H R_H + \omega_{\theta_c} R_{\theta_c} + \omega_{\theta_E} R_{\theta_E}) \quad (4-7)$$

其中， λ 值设定为基础单步奖励的 4 倍，以保持量纲对齐， R_d 等针对不同态势的单步奖励值计算方式，均与基础单步奖励函数保持一致， ω_d 、 ω_H 、 ω_{θ_c} 、 ω_{θ_E} 分别为使用 QKV 模型针对当前态势特征，对敌我距离、敌我高度差、追击角、逃逸角这四部分奖励分配和输出的注意力权重系数，由于 QKV 模型中的注意力权重系数由 softmax 函数归一化，故时刻有：

$$\omega_d + \omega_H + \omega_{\theta_c} + \omega_{\theta_E} = 1 \quad (4-8)$$

基于上述规则，使得算法训练过程中，获取单步最优奖励的决策动作将不只有一种，加大了智能体探索倾向。同时，通过注意力权重的分配，帮助智能体对次优奖励对应的态势和动作做出评判与取舍，易于学习到当前态势下最优奖励和最优动作所对应状态变化的潜在趋势，帮助智能体理解空战决策任务的本质。

基于自注意力机制的实时奖励权重系数分配算法的伪代码如算法 4.1 所示。

算法 4.1 基于自注意力机制的实时奖励权重系数分配

```

1:  初始化 QKV 模型, 定义注意力参数矩阵  $W_q$ 、 $W_k$ 、 $W_v$ 
2:  初始化目标注意力权重系数  $\omega_d$ 、 $\omega_H$ 、 $\omega_{\theta_C}$ 、 $\omega_{\theta_E}$ 
3:  for iteration = 1 to N do
4:      for  $t = 1$  to  $t = T_{\max}$  do
5:          观察当前环境态势  $s_t$ 
6:          根据注意力参数矩阵  $W_q$ 、 $W_k$ 、 $W_v$  对当前态势  $s_t$  执行线性变换, 计算  $Q$ 、 $K$ 、 $V$  三组向量
7:          基于  $Q$ 、 $K$  向量关联, 计算注意力分数
8:          通过 softmax 函数进行归一化, 计算注意力权重  $Attention\_Weights(Q, K)$ , 计算并实时输出目标注意力权重系数  $\omega_d$ 、 $\omega_H$ 、 $\omega_{\theta_C}$ 、 $\omega_{\theta_E}$ 
9:          使用注意力权重对值向量  $V$  加权求和
10:     End for
11:     #更新注意力参数:
12:     根据任务目标计算损失函数, 更新注意力参数矩阵  $W_q$ 、 $W_k$ 、 $W_v$ 
13: End for
14: 结束
    
```

4.3.3 空战态势解算单元

根据本文第二章中描述的飞行器动力学模型和视距内空战相对态势模型, 为帮助 DRL 智能体实现对视距内空战环境态势的认知和理解, 设置空战态势解算单元对观测到的空战态势信息进行处理。首先, 定义我方飞行器的交战状态空间内容与本文 3.4.2 相同。随后, 采取与本文 3.4.3 优势态势解算单元相同的解算过程, 在保留交战状态空间内的主要特征信息的同时, 统一量纲、降低状态空间维度, 经空战态势解算单元处理完毕后的特定时刻态势数据表示为:

$$s_t = \{\Delta x', \Delta y', \Delta z', v', \psi', E_{\beta}', \theta_C', \theta_E'\} \quad (4-9)$$

4.3.4 预训练模型设计与实现

基于本章 4.2 节所述的方法动机, 需要将视距内空战机动决策问题的 MDP 模型 $M = \{S, A, R, P, \gamma\}$ 拆分为两部分, 其中, 应将近距离“咬尾”追击段 $M_2 = \{S_2, A_2, R_2, P_2, \gamma\}$ 拆分为较小模型, 从而在恰当的算力条件下, 实现覆盖式全面探索的预训练。

根据该设计目标, 为得到具备基础机动控制能力和终段追击能力的预训练决策模型, 首先在预训练实验中设红蓝双方, 分别操控一架飞行器, 飞行器机动模型如本文第二章

所述。每一局仿真对抗中，蓝色方飞行器在固定位置生成，DRL 算法控制的红色方飞行器在设定的生成区域内的随机位置生成。蓝色方采取简单的匀速直线运动策略机动，以便于智能体学习“咬尾”追击策略。预训练阶段训练设计参数如下：

表 4.1 预训练模型训练设计参数

Table 4.1 Design parameters of pretrained model training

参数	取值
对战空域大小(m)	50000*50000
对战空域海拔范围(m)	[1000,10000]
蓝方初始坐标(m)	(0,-10000,5000)
蓝方初始朝向角	0
蓝方初始速度(m/s)	150
红方初始 x 坐标范围(m)	$[-2500,-1500] \cup [1500,2500]$
红方初始 y 坐标范围(m)	$[-12500,-11500] \cup [-8500,-7500]$
红方初始 z 坐标范围(m)	$[4500,4700] \cup [5300,5500]$
红方初始朝向角	$[0,2\pi)$
红方初始速度(m/s)	250
仿真步长(s)	0.01666
决策步长(s)	0.1
单局最大仿真时间(s)	90

与本文第三章类似，在本章实验中，单局仿真实验的终止同样有以下三种情况：

情况 1 一方飞行器通过优势机动完成作战任务，则判定该方获胜，完成优势机动的定义见本文 2.2 章节，用于胜负判定的数据为真实态势数据；

情况 2 一方飞行器离开对战空域，则判定该方失败；

情况 3 超过单局最大仿真时间，未产生胜负结果，判定红方飞行器机动决策超时，红方失败。

满足以上任一情况，单局仿真实验结束。根据实验设置的对局终止情况，设置对局终止奖励如下：

$$R_{end} = \begin{cases} 25 & \text{if victory} \\ -25 & \text{if defeat or out-of-range} \\ -15 & \text{if overtime} \end{cases} \quad (4-10)$$

为确保在大批量训练后，预训练模型能够按预期效果实现对 M_2 段 MDP 模型的全面探索和学习，本章通过多轮实验，尝试以降低模型学习率、调整策略网络更新步长、调整动作采样中正态分布采样的最小标准差等手段提升预训练效果和预训练模型决策性能。最终选定的预训练模型神经网络主要训练参数设置如表 4.2 所示。

表 4.2 预训练模型神经网络主要参数

Table 4.2 Main parameters of pretrained model neural networks

参数名	参数值
神经网络层数	5
隐藏层神经单元数	256
行动者学习率	0.0001
评论家学习率	0.0003
折扣系数	0.99
网络更新步长	50
动作采样初始标准差	0.8
动作采样最小标准差	0.2
裁减系数	0.15
K_epoch	50
一轮训练最大局数	100000

训练该模型过程中，记录每一局的单局总奖励，以最近 50 局的平均总奖励作为纵坐标绘制实线，根据平均总奖励的标准差分布绘制阴影，同时对实线与阴影部分均做平滑模糊处理，得到的训练过程平均奖励变化曲线如图 4.2 所示：




图 4.2 预训练模型训练过程平均奖励变化图

Figure 4.2 Graph of average reward changes during pretrained model training

由图中所示的平均奖励值变化情况可知，该预训练模型在大批量训练中的平均奖励持续稳步增长，最终趋近收敛到较高水平。据此得出推论，该模型已具备实现近距离“咬尾”追击的机动决策能力，基本达到预训练模型设计和训练目标。

4.3.5 AMP3O 算法

针对基于 DRL 的视距内空战机动决策算法的特定训练模型泛化性问题, 依据本章方法动机, 提出一种基于自注意力机制与预训练模型的近端策略优化算法, 简称为 AMP3O (Proximal Policy Optimization based on Self-Attention Mechanism and Pretrained model), 算法训练过程的伪代码表示如下:

算法 4.2 基于自注意力机制与预训练模型的近端策略优化算法 (AMP3O)

```

1:  If 加载预训练模型不成功:
2:      #进入预训练模式
3:      使用初始化参数  $\theta$  对策略网络  $\pi(a|s)$  进行初始化
4:      使用初始化参数  $\phi$  对价值网络  $V_\phi(s)$  进行初始化
5:  else:
6:      加载预训练模型参数  $\theta$ 、 $\phi$  与策略价值网络
7:  for iteration = 1 to N do
8:      for  $t = 1$  to  $t = T_{\max}$  do
9:          通过空战态势解算单元解算环境状态  $s_t$ 
10:         使用策略网络  $\pi(a|s)$  生成动作  $a_t$ 
11:         通过基于自注意力机制的实时 RS 方法, 输出注意力权重系数  $\omega_d$ 、 $\omega_H$ 、 $\omega_{\theta_C}$ 、 $\omega_{\theta_E}$ 
12:         执行动作  $a_t$ , 根据目标注意力权重系数计算奖励  $r_t$ , 观察下一状态  $s_{t+1}$ 
13:         存储经验样本  $\{s_t, a_t, r_t, s_{t+1}\}$ 
14:     End for
15:     计算优势函数  $\hat{A}(s, a) = q_\pi(s, a) - V_\phi(s)$ 
16:     #更新策略网络:
17:     for  $K\_epochs = 1$  to  $K$  do
18:         计算当前策略  $\pi(a|s)$  下的动作概率和对数概率
19:         通过优势函数  $\hat{A}(s, a)$  计算当前动作的优势比率和经 Clip 裁剪后的优势比率
20:         计算策略损失函数  $L_{PPO}^k(\theta)$ 
21:         计算策略网络的梯度并更新参数  $\theta$ 
22:     End for
23:     #更新价值网络:
24:     使用均方误差损失函数更新价值网络参数  $\phi$ 
25: End for
26: 结束

```

算法中, 结合了本章 4.3.2 节提出的基于自注意力机制的实时奖励塑造方法, 加载了 4.3.4 中经预训练得到的具备基础机动控制能力和终段追击能力的预训练决策模型,

基于以上方法进行视距内空战机动决策智能体训练,从而使得训练得到的特定训练模型具备更强的泛化性能。

4.4 泛化性能测试实验

4.4.1 视距内空战想定集预处理

为验证在视距内空战场景下,经本章所提算法训练得到的特定模型泛化性,本节拟设计和定义一种想定集划分与随机抽样方法。该方法首先将视距内空战机动决策问题的 MDP 模型抽样划分为 n 个想定子集。在此基础上,随机抽取 k 个想定子集作为本轮实验中用于测试的想定集。同时,分别使用不同 DRL 算法控制的智能体,在其余 $n-k$ 个想定子集上进行训练。随后,使用经训练得到的智能体决策模型在测试用的想定集上进行机动决策,记录决策表现情况。依据上述方法重复进行多次实验,根据实验结果推定各 DRL 算法的泛化性能。

4.4.1.1 视距内空战想定集划分规则

依据本章对基于 DRL 的视距内空战机动决策算法特定训练模型泛化性问题的描述,可知影响模型泛化性能的原因主要来自训练任务中未出现过的空战态势 s ,以及由于敌方飞行器策略改变等原因,带来的动作-状态转移函数 $P(s_{t+1}|s_t, a_t)$ 变化。因此,可通过在视距内空战机动决策问题 MDP 模型内,设计和划分出具有普适性和代表性的视距内空战想定初始坐标集和敌方飞行器机动策略集,将此二者交叉组合,即可得到所需的视距内空战想定集划分。

首先,对视距内空战空域进行等距离分段,以各段包含的坐标集合作为我方飞行器的初始坐标候选集。令该集合足够大,则即使在敌方飞行器的初始坐标保持不变的情况下,得到的空战想定初始坐标集中仍包含了视距内空战机动决策问题 MDP 模型中的全部敌我相对坐标情况。实验中,视距内空战想定初始坐标集设置如表 4.3 所示。

通过表中划分,将视距内空战想定初始坐标集划分为了 64 个子集,可供后续实验中随机抽样选择和使用。随后,还需针对敌方飞行器机动策略,划分出典型的机动策略集。可根据美国航空航天局划分和定义的 7 个基本空战机动动作^[90]进行划分,套用于三自由度飞行控制及仿真模型,即分为匀速直飞、最大过载左转、最大过载右转、最大径向过载加速、最大径向过载减速、最大切向过载爬升、最大切向过载俯冲共 7 种动作。其中,由于在真实空战中,飞行器通常不会长时间保持后几种机动动作,因此,在实验中作如下设置:以最大过载左转或右转导致朝向角变化 90° 后,切换转向方向;以最大径向过载加速至飞行器最大速度后,将切换为最大径向过载减速;同理,以最大径向过载减速至飞行器最小速度后,也将切换至最大径向过载加速;类似地,通过最大切向

表 4.3 实验想定初始坐标集设计参数

Table 4.3 Design parameters of initial coordinate set

参数	取值
对战空域大小(m)	100000*100000
对战空域海拔范围(m)	[1000,10000]
蓝方初始坐标(m)	(0,-10000,5000)
蓝方初始朝向角	90
蓝方初始速度(m/s)	250
红方初始 x 坐标范围(m)	$[-5000,-2000] \cup [2000,5000]$
对 x 坐标分段间距(m)	1500
红方初始 y 坐标范围(m)	$[-15000,-12000] \cup [-8000,-5000]$
对 y 坐标分段间距(m)	1500
红方初始 z 坐标范围(m)	$[1000,4000] \cup [6000,9000]$
对 z 坐标分段间距(m)	1500
红方初始朝向角	$[0,2\pi)$
红方初始速度(m/s)	250
仿真步长(s)	0.01666
决策步长(s)	0.1
单局最大仿真时间(s)	300

过载爬升至一定高度后，将切换至最大切向过载俯冲，以避免脱离战场空域范围，反之同理。至此，将视距内空战敌方飞行器机动策略集也划分为了若干子集，供后续实验中进行抽样选择使用。

4.4.1.2 视距内空战想定集抽样规则

基于上述划分，将视距内空战中的想定初始坐标集和敌方飞行器机动策略集划分为了若干子集，随后，可采取抽样方法在该样本集合中抽样选取用于测试的想定集和用于训练的想定集。本节实验目的在于：检验经本章所提算法训练得到的特定模型泛化性。为此，针对上述样本集合定义一种特殊的随机抽样，该抽样方法须使得用于训练的想定集与用于测试的想定集保持一定程度的差异，以检验经本章所提算法训练得到的决策智能体模型在未曾接触的空战环境下的决策性能，从而推知特定模型泛化性。该随机抽样方法的抽样策略表述为如下规则：

规则 1 在视距内空战想定初始坐标集中，随机抽取 4 个互不相邻的子集，作为实验中用于测试的想定集的想定初始坐标范围。

规则 2 在视距内空战想定初始坐标集中，剔除前一步所抽取的想定初始坐标子集，同时剔除与其直接相邻的所有坐标子集。以剩余的坐标子集为本节实验中用于训练的想定集的想定初始坐标范围。

规则 3 根据实验设置，在改变敌方飞行器机动策略的实验里，从视距内空战敌方飞行器机动策略集中随机抽取一种策略，作为训练过程中敌方飞行器的机动策略；在测

试想定生成时,在剩余策略中抽取一种与训练策略差异明显的机动策略,作为测试中敌方飞行器的机动策略。

规则 4 根据交叉实验原则,在每一组交叉实验中,从未按规则 1 抽取过的剩余想定初始坐标集中,随机抽取 4 个互不相邻的子集,以此类推,重复执行规则 1 到规则 3,得到各组交叉实验中用于训练和用于测试的想定集。

4.4.2 实验设计

为检验经本章提出的 AMP3O 算法训练得到的特定训练模型,在视距内空战机动决策问题中的泛化性能表现,本节基于前述想定集划分与抽样方法设计了两部分实验,分别为想定初始坐标变化实验和想定初始坐标与敌方策略均变化的实验。

想定初始坐标变化实验中,由不同 DRL 算法控制的我方飞行器和敌方飞行器,在每一局训练中均按抽样得到的训练想定初始坐标集进行生成。经一万局训练后,再分别将各算法训练得到的智能体决策模型投放到测试想定初始坐标集上,测试智能体决策模型在未知空战场景下的决策性能。如此重复进行 5 组交叉实验,根据实验结果推知各算法的特定训练模型泛化性能。在该实验的训练与测试中,敌方飞行器保持匀速直线机动。

想定初始坐标与敌方策略变化实验中,由不同 DRL 算法控制的我方飞行器和敌方飞行器,在每一局训练中同样按抽样得到的训练想定初始坐标集进行生成,并在测试想定初始坐标集上进行测试。与此同时,在训练和测试过程中,依据上一节所提想定集抽样规则三,分别令敌方飞行器采取不同的机动策略,同样重复进行 5 组交叉实验。

为确保对比实验严谨准确,能够真实反映算法性能,本文所述实验中神经网络的主要参数保持不变,具体数值如表 4.4 中所示。实验中,单局仿真实验的终止条件与本章 4.3.4 节中预训练阶段实验的终止条件均相同,仅单局最大仿真时间修改为 300s,以便

表 4.4 神经网络主要参数

Table 4.4 Main parameters of neural networks

参数名	参数值
神经网络层数	5
隐藏层神经单元数	256
行动者学习率	0.0001
评论家学习率	0.0003
折扣系数	0.99
网络更新步长	25
动作采样初始标准差	0.6
动作采样最小标准差	0.1
裁减系数	0.15
K_epoch	50
一轮训练最大局数	10000

智能体在训练阶段实现更充分的探索。实验中，针对 AMP3O 算法设置的预训练模块和 RS 模块设计了消融实验，同时，引入使用 Actor-Critic 架构的 SAC^[85]、DDPG^[31]算法，与 AMP3O 算法进行对比实验。

4.4.3 实验结果分析与泛化性能测试

4.4.2.1 想定初始坐标变化实验

根据实验设计，以第一组交叉实验为例，在想定初始坐标变化实验里各算法训练过程中，记录每一局的单局总奖励，以最近 10 局的平均总奖励作为纵坐标绘制实线，并根据平均总奖励的标准差绘制阴影。为使图线易于观察，对实线与阴影部分均做了平滑模糊处理，得到第一组交叉实验中各算法训练过程平均奖励变化曲线，如图 4.3 所示：




图 4.3 初始坐标变化实验训练过程平均奖励变化图

Figure 4.3 Graph of average reward changes during training in the coordinate change experiment

从图中展示的训练过程平均奖励变化曲线中可以看出，在该组实验中，由于想定初始坐标分布范围广，基础 SAC、DDPG 算法的训练表现较差，经万局训练后平均奖励收敛到-5 左右；而基础 PPO 算法和使用了本章所提 RS 方法的 PPO 算法，则相对能更有效地进行探索、提高训练过程奖励值，使用 RS 方法的 PPO 仅在探索训练速度上相较于基础 PPO 具备一定优势，但两者最终的训练平均奖励均只收敛至 8；使用 AMP3O 算法，但不使用 RS 模块的智能体，在万局训练过程中平均奖励值稳定上升，最终收敛至 15 左右的较高水平；完整的 AMP3O 算法学习探索表现最佳，经万局训练后的平均奖励水平达到了 20 以上，且训练速度相较于不使用 RS 方法的 AMP3O 具有显著优势。

在使用完整的 AMP3O 所训练智能体决策模型进行的测试实验中，挑选成功完成优势机动的某一单局实验，记录每一决策步中，基于自注意力机制的实时 RS 方法根据实时态势输出的注意力权重系数 ω_d 、 ω_H 、 ω_{θ_c} 、 ω_{θ_e} ，绘制为折线图如图 4.4 所示。




图 4.4 单局测试实验中注意力权重系数变化图

Figure 4.4 Graph of attention weight changes in a single test experiment

在测试实验中，注意力权重实际已不再对机动决策产生影响，智能体直接基于训练模型，针对当前观测态势实时输出端到端的机动决策，但图 4.4 仍能反映出基于自注意力机制的实时 RS 方法在先前的训练过程中发挥的作用。如图可见，在一局仿真对战中，基于自注意力机制的实时 RS 方法首先控制高度和追击角奖励权重增大，使得飞行器在仿真初始阶段更倾向于优先调整高度和朝向，使其朝靠近敌方飞行器的方向移动；而在仿真对战末段，该 RS 方法则控制距离、追击角、高度奖励权重均处在较高水平，这将引导飞行器调整机动姿态，争取逼近敌方飞行器的同时形成“咬尾”态势。

根据实验设计，将各组交叉实验中，不同算法训练得到的智能体决策模型加载至测试想定集中，进行 500 局随机生成和仿真，测试智能体决策模型在未知空战场景下的决策性能。经记录，各组交叉实验测试中，不同算法智能体的优势机动决策成功率与单局平均仿真时间 (s) 如表 4.5 所示。由于正文篇幅有限，完整数据记录见本文附录 A-1。

根据表中实验数据可以看出，经 AMP3O 算法训练得到的智能体决策模型，在未知的空战态势场景下具备较高的决策成功率，平均决策时间最短；根据消融实验设计，在 AMP3O 算法中消去不同模块并进行实验，仍能得到优于基础 PPO 算法的实验结果；除此之外，其余算法训练得到的智能体决策模型，在未知空战场景下的决策性能则显著弱于 AMP3O 算法，且平均决策时间大幅增加。据此可以推断，AMP3O 算法训练得到的智能体决策模型在未知空战场景下具备较强的决策性能，即算法得到的特定训练模型具备了较强的泛化能力，且算法各模块均对特定训练模型的泛化性能起到了提升作用。

表 4.5 初始坐标变化实验各智能体决策性能

Table 4.5 Decision performance of each agent in the coordinate change experiment

	第一组交叉测试		第二组交叉测试			全组测试平均结果	
	成功率	平均时间	成功率	平均时间		平均成功率	平均时间
AMP3O	81.2%	87.22	80.8%	89.93		81.16%	88.72
AMP3O without RS	77.0%	93.27	76.4%	95.38		76.8%	95.97
PPO with RS	54.8%	151.78	52.8%	163.38		55.24%	154.82
PPO	54.2%	158.67	54.4%	162.68		55.68%	159.78
SAC	19.4%	252.0	21.8%	243.52		19.88%	245.22
DDPG	25.2%	226.32	19.4%	250.18		23.6%	234.60

4.4.2.2 想定初始坐标与敌方策略变化实验

同样以本部分实验中的第一组交叉实验为例，在该组实验中，依据本章设计的随机抽样方法，随机抽取最大过载爬升机动策略作为训练中敌方飞行器的初始机动策略。经记录训练过程奖励、对图线进行平滑模糊处理后，得到该组实验训练过程中各算法的平均奖励变化曲线如图 4.5 所示：




图 4.5 初始坐标与敌方策略变化实验训练过程平均奖励变化图

Figure 4.5 Graph of average reward changes during training in the coordinate & enemy maneuver change experiment

从图中展示的训练过程平均奖励变化曲线中可以看出,在该组实验中,由于想定初始坐标分布范围广、敌方机动策略复杂度增加,基础 SAC、DDPG、PPO 算法的训练表现均较差,经万局训练后平均奖励仍为负值;而使用了本章所提 RS 方法的 PPO 算法,则能够相对更有效地进行探索、提高训练过程奖励值,经万局训练后的平均奖励约达到 5;使用 AMP3O 算法,但不使用 RS 部分的智能体,在万局训练过程中平均奖励值呈稳定上升趋势,最终收敛至约为 10;而使用了完整的 AMP3O 算法的智能体则实现了最有效的学习和探索,经万局训练后的平均奖励水平达到了 20 左右,且其训练速度相较于不使用 RS 方法的 AMP3O 也具有显著优势。

与上一部分实验做法相同,在使用完整的 AMP3O 所训练智能体决策模型进行的测试实验中,挑选某单局实验,并记录每一决策步中,本章所提 RS 方法实时输出的注意力权重系数,绘制为折线图如图 4.6 所示。




图 4.6 单局测试实验中注意力权重系数变化图

Figure 4.6 Graph of attention weight changes in a single test experiment

如图可见,在单局仿真对战中,基于自注意力机制的实时 RS 方法同样先控制高度和追击角奖励权重增大,帮助飞行器在仿真初始阶段优先调整高度和朝向,使其在宏观范围上朝更靠近敌方飞行器的方向移动;在仿真对战末段,该 RS 方法则控制距离、追击角奖励权重均处在较高水平,降低了对高度、逃逸角的重视程度,这将引导飞行器调整机动姿态,在逼近敌方飞行器的同时形成“咬尾”态势。将图中奖励权重折线与想定初始坐标变化实验中的奖励权重折线对比,反映出基于自注意力机制的实时 RS 方法在不同空战场景下具备自适应性。

随后,根据实验设计,将各组交叉实验中,不同算法训练得到的智能体决策模型加载至用于测试的想定集,进行 500 局随机生成和仿真。测试中的每一局想定生成时,将敌方飞行器初始机动策略随机设定为除最大过载爬升外的其余几种基础策略之一。经记录,各组交叉实验测试中,不同算法智能体的优势机动决策成功率与平均单局仿真决策

表 4.6 初始坐标与敌方策略变化实验各智能体决策性能

Table 4.6 Decision performance of each agent in the coordinate & enemy maneuver change experiment


	第一组交叉测试		第二组交叉测试		……	全组测试平均结果	
	成功率	平均时间	成功率	平均时间	……	平均成功率	平均时间
AMP3O	61.4%	143.70	67.6%	139.23	……	63.84%	139.97
AMP3O without RS	45.0%	183.02	58.4%	163.97	……	47.52%	188.98
PPO with RS	40.0%	201.78	40.8%	203.38	……	40.28%	204.82
PPO	29.8%	241.78	33.8%	233.38	……	27.24%	244.82
SAC	8.2%	282.83	14.6%	273.90	……	11.60%	277.58
DDPG	9.6%	279.30	17.4%	264.77	……	13.32%	274.03

时间（s）如表 4.6 所示。由于正文篇幅有限，完整数据记录见本文附录 A-2。

根据表中实验数据可以看出，在想定初始坐标与敌方策略均发生变化的实验中，由于敌方机动策略复杂度增加，各算法训练得到的智能体决策模型，在未知的空战想定中的机动决策表现均出现明显下降，同时由于敌机机动策略的变化，不同组交叉测试实验中的性能表现出现较大幅度的波动，符合预期情况。相较于其他算法，AMP3O 算法训练得到的智能体决策模型，在未知的空战相对态势场景下仍具备最高的机动决策成功率、最短的平均决策时间，即 AMP3O 算法训练得到的模型仍表现出了相对最强的泛化能力。同时，在 AMP3O 算法中移除基于自注意力机制的实时 RS 方法得到的模型，和使用基于自注意力机制的实时 RS 方法、但不进行预训练的基础 PPO 算法得到的模型，在机动决策性能上均由于基础 PPO 和其他基线算法得到的决策模型。此实验结果再一次证明了，本章提出的 AMP3O 算法对特定训练模型泛化性能起到提升作用。


为展示 AMP3O 算法得到的智能体决策模型机动决策效果，图 4.7 以第一组交叉测试实验为例，展示了该组实验中，使用 AMP3O 算法训练得到的智能体决策模型控制飞行器成功完成优势机动决策时的飞行轨迹。

如图可见，由 AMP3O 算法智能体控制的飞行器，在差异较大的两个初始生成位置下，面对未在训练中接触过的敌方飞行器机动策略时，最终均完成了优势机动决策，达成了仿真作战任务目标。其机动轨迹中，可以观察到少量无效或不够完美的机动痕迹和少许波动，但总体显得较为平滑，展现出了良好的机动决策性能，基本满足空战优势机动要求。



(a) AMP3O 智能体飞行轨迹 1

(a) AMP3O agent's flight trajectory 1



(b) AMP3O 智能体飞行轨迹 2

(b) AMP3O agent's flight trajectory 2

图 4.7 AMP3O 智能体飞行轨迹示例

Figure 4.7 Example of AMP3O agent's flight trajectory

根据上述一系列实验结果可见，AMP3O 算法相较于其他基线 DRL 算法，能够在训练中更高效地实现学习和探索，在视距内空战机动决策中实现良好的机动决策性能。

与此同时,经其训练得到的特定训练模型,在未知的空战相对态势场景下实现了较高的优势机动决策成功率,表现出了显著优于其他算法所得模型的泛化能力。

4.5 本章小结

本章针对基于 DRL 的视距内空战机动决策算法研究中,特定训练模型普遍存在泛化性能较弱的问题展开研究。在对问题的成因和解决方法动机进行充分推导的基础上,本章提出了一种基于自注意力机制与预训练模型的近端策略优化算法,并随后设计了较为严谨的泛化性能测试实验以测试和验证所提算法的性能。基于上述工作,本章得到以下结论:

(1) 基于 DRL 的视距内空战机动决策算法,在训练过程中无法遍历探索完整的视距内空战 MDP 模型,且敌方飞行器的机动策略改变等因素难以预知。因此,基于 DRL 方法和有限探索训练得到的特定训练模型,在面对未知态势时普遍出现决策准确性下降,表现为特定训练模型泛化性能弱。

(2) 经消融实验与对比实验证明,本章提出的基于自注意力机制与预训练模型的近端策略优化算法,其主体包含基于预训练模型的策略重用和基于自注意力机制的奖励塑造两个部分,均对算法特定训练模型的泛化性能起到有效提升作用;该方法具备相对高效的训练探索速度;通过该方法训练得到的智能体决策模型,能够在面对未经探索的空战环境或未曾接触的敌方飞行器机动策略时,保持优于基础 PPO、DDPG、SAC 等基线 DRL 算法所得模型的机动决策能力,表现出良好的模型泛化性能。

综上所述,本章研究论述了基于 DRL 的视距内空战机动决策算法的特定模型泛化性能弱问题的成因,并通过实验验证,具有一定的理论研究参考价值。本章所研究提出的方法则能够有效提高训练得到的特定模型智能体在不同空战环境下的泛化性能,具备工程应用参考价值。

本章与第三章所进行的空战仿真实验中,需要根据实验设置,随机生成大批量的视距内空战想定、进行长时间的 DRL 仿真训练,并且在实验过程中追求训练速度和实验效率。为此,本文在第五章针对本文实验需求,同时针对研究领域内缺乏统一标准的飞行器模型与仿真决策验证支撑平台,导致所提算法难以横向对比的研究现状,设计提出并开发了面向深度强化学习的空战训练仿真一体化平台。

第5章 面向深度强化学习的空战训练仿真一体化平台系统设计与实现

5.1 引言

本文第一章中,综合论述了关于空中作战、基于 DRL 的视距内空战机动决策算法等研究领域对我国国防军事工业信息化、现代化建设具有的重要意义。而由于真实空战训练的对抗强度高、对装备和资源损耗大、飞行员面临高压与危险,所以,通过空战仿真平台来仿真模拟真实空战、对装备和战术战法进行性能验证,是成本低、风险小、应用前景广泛的必然之选,具有极高的应用价值。

然而,当前国内外空战研究领域内,缺乏被广泛应用且具有权威性的空战仿真平台。尤其是基于 DRL 的视距内空战机动决策算法相关研究领域,虽然近年来研究成果频出,但绝大多数研究与算法均是在自研的飞行器模型和仿真平台上进行验证和实验,不同研究间的对抗环境设计和飞行器仿真模型差异较大^[91],导致研究间横向对比困难,使得部分研究缺乏说服力与可信度。

针对当前基于 DRL 的视距内空战机动决策研究领域内,缺乏统一标准的飞行器模型与仿真决策验证支撑平台的研究现状,同时基于本文第三、四章所提算法的训练和验证需求,本章提出了面向深度强化学习的空战训练仿真一体化平台。平台开发实现异构模型接入与管理模块、定义标准化接口,支持不同飞行器模型或 DRL 算法的同平台仿真交互与验证;同时,通过开发实现空战想定批量生成工具,设计实现面向 DRL 的多线程并行式仿真与训练框架、开发和应用态势可视化工具,共同支撑本文第三、四章所提算法和实验的高效训练、仿真、验证。

本章的主要内容包括:首先,针对平台应用目标,对相关需求做出分析。随后,针对需求,对平台进行系统架构设计与工作流程推演。接着,基于在专业学位实践单位参与开发的 RASim 仿真引擎及基本可视化构件,使用 Qt、OpenGL、Python 编程语言等专业技术栈,开发实现了异构模型接入与管理、想定批量生成、多线程并行仿真与训练算法框架等平台设计预期的各项功能。最后,在实现预期功能的基础上,以本文第三、第四章所提算法的训练验证为例,演示了平台的应用效果,体现了平台的应用价值。

5.2 空战训练仿真一体化平台系统设计

5.2.1 需求分析

本章针对当前基于 DRL 的视距内空战机动决策研究领域内,缺乏统一标准的飞行

器模型与仿真决策验证支撑平台的研究现状,同时考虑本文第三、第四章所提算法的训练和验证需要,分析得出面向深度强化学习的空战训练仿真一体化平台设计应主要满足以下几个方面需求:

(1) 仿真引擎、算法智能体、可视化三端分离:将空战仿真引擎、决策算法智能体以及空战态势可视化工具,三个核心组件设计为相互独立的模块,模块间通过明确定义的标准通信接口进行交互,提高系统功能的灵活性、扩展性和可维护性,避免模块间出现意外耦合,影响训练或仿真的独立性。

(2) 异构模型兼容式仿真演算:针对主流与自研飞行器模型,分别提供标准化模型与自定义模型接入的接口,在仿真引擎中支持对不同的飞行器模型实体进行兼容仿真演算,在算法控制端支持不同模型的控制方式,在兼顾平台适用范围的前提下,确保各模型控制和仿真演算兼具精度与可信度。

(3) 环境态势反馈可控:针对本文第三章研究所需的具备态势感知误差的仿真空战环境描述,面向 DRL 算法智能体端抽象提供环境态势反馈截留与控制接口,支持决策算法的控制者根据研究需要,自主设计和控制环境态势反馈中的感知误差、不完备信息等条件。

(4) 想定批量生成与管理:针对本文第四章研究所需的视距内空战想定批量生成和应用需求,设计并提供空战想定批量生成与管理工具,支持平台的使用者根据研究需要,自主设计和批量生成空战想定。

(5) 多线程并行式仿真:为提高空战训练仿真效率、提高实验设备算力利用率、缩短基于 DRL 的视距内空战机动决策算法研究验证周期,设计并提供多线程并行式仿真交互接口,和对应利用多线程仿真数据进行 DRL 算法智能体网络更新与训练的算法框架。

(6) 可视化回放与验证:面向空战训练仿真中的可视化验证需求,提供实时可视化、对局回放与态势数据可视化验证等功能,供用户验证算法机动决策效果。

(7) 训练权限控制:针对本文第三、四章实验中的单局胜负判定、终局判定等应用需求,设计平台权限控制接口。根据研究需要,通过口令授权以开放仿真胜负判定、环境态势反馈截留等权限,提高平台应用的灵活性,保障仿真实验的真实性、可靠性。

5.2.2 系统设计

以上述需求分析为根据,本章对面向深度强化学习的空战训练仿真一体化平台做出对应的系统架构设计,其宏观系统架构图如图 5.1 所示。




图 5.1 空战训练仿真一体化平台系统架构图

Figure 5.1 System architecture of integrated training and simulation platform for air combat

由图中可见,空战训练仿真一体化平台系统架构分为三个相互独立的主要模块,分别是空战仿真引擎、DRL 算法决策控制端、空战态势可视化工具。模块间通过明确定义的标准化接口进行交互,一方面能够提高全平台功能的灵活性、扩展性和可维护性,避免模块间出现意外耦合,影响训练或仿真的独立性、影响仿真结果真实度。另一方面使得端与端之间实现分布式部署,在大规模演算中最大化利用硬件算力。

空战仿真引擎模块的设计分为仿真核心和外围构件工具两部分。仿真核心处为空战仿真演算引擎,采用在专业学位实践单位参与开发的 RASim 仿真引擎,包含多线程演算调度、异构模型多实例演算、多核并行式演算调度等功能模块,仿真输入输出均采用标准化 json 字符串接口,通过将各异构飞行器模型输入输出规范化、插件化,实现对异构模型兼容式仿真演算。外围构件工具包含想定生成与管理、异构模型接入与管理、态势指令收发模块,分别对应系统设计需求进行开发。其中,态势指令收发模块包含权限控制接口,以识别控制端授权口令,赋予仿真控制权限。

DRL 算法决策控制端在基于 DRL 的决策智能体算法核心基础上,抽象出三层外围框架。首先是对多线程训练的调度阻塞和经验学习机制,在训练时,基于当前 DRL 智

能体模型分别向多个线程输出决策动作，并将各线程反馈态势、奖励、输出动作等经验内容一并存入经验回放缓冲区，待需要更新神经网络时，阻塞等待各线程当前局仿真结束，使用经验回放缓冲区中经验更新网络并清空缓冲区，网络更新完毕后继续训练。其次是环境态势反馈截留模块，将仿真引擎传回的所有信息抽象为环境反馈并进行预解析，在此基础上可进行奖励重塑，也可将态势信息提取并按规则加入态势感知误差，或部分删除以模拟不完备信息空战。最上层是态势指令收发标准化接口，将控制端的动作输出按接口标准进行规范化，同时将仿真引擎传回的信息进行解析。

空战态势可视化工具包含三维立体可视化界面、态势数据可视化工具、对局记录与回访管理三部分实用工具，通过与仿真引擎进行标准化端口通信，既可在训练仿真的同时对仿真态势实时可视化，也可暂停或存储对局记录以进行数据测算或回放。

5.2.3 平台工作流程

实际应用中，以基于 DRL 的视距内空战机动决策智能体训练过程为例，面向深度强化学习的空战训练仿真一体化平台的主要工作流程如图 5.2 所示。




图 5.2 空战训练仿真一体化平台工作流程图

Figure 5.2 Workflow of integrated training and simulation platform for air combat

首先，需要在训练准备阶段完成以下工作：对训练中所需使用的飞行器仿真模型的标准导入；训练想定编辑或批量生成，并在训练开始前进行对应实例化；配置训练参数、并行线程数、配置决策端控制权限、完成决策智能体网络参数设置与初始化；初始化训练与仿真环境。随后，平台与决策端通过标准通信接口发起通信握手，握手成功后，训练开始。训练过程中，智能体控制端与平台进行实时交互仿真，根据权限可对环境反

馈态势进行截留,实现添加态势感知误差量等操作。训练过程中,存储经验用于 DRL 算法的更新,与此同时,用户可选择将实时仿真数据传输至可视化工具模块,实现态势实时可视化。训练结束后,算法控制端即得到训练完成的智能体网络模型,该模型可由控制端随时调用,用于视距内空战机动决策。训练结束后,用户也可选择将仿真过程数据存储至可视化工具模块,实现态势可视化回放。

5.3 空战训练仿真一体化平台应用效果

面向深度强化学习的空战训练仿真一体化平台,以前文所作需求分析和系统架构设计为出发点和参照,使用作者在专业学位实践单位参与开发的 RASim 仿真引擎及基础可视化元件为基本构件,引入了多线程间 Socket 交互通信和并行式仿真技术,使用了 OpenGL 和 Qt GUI 等可视化技术,借助 C++编程语言开发平台工具,借助 Python 编程语言和 PyTorch 库开发面向 DRL 算法的多线程并行式仿真与训练算法框架。经开发实现,平台初始化后的主界面如图 5.3 所示。



图 5.3 空战训练仿真一体化平台初始界面

Figure 5.3 Initial interface of integrated training and simulation platform for air combat

5.3.1 异构模型管理模块

根据平台系统设计需求,开发实现异构模型接入与管理模块。平台用户可将自研飞行器模型的仿真输入输出根据平台标准化接口规范进行便捷的重定义,实现接入平台并参与空战仿真演算引擎的异构模型兼容式仿真演算。通过打开平台内的模型管理界面,可对已接入平台的飞行器模型进行管理、参数、三维贴图调整。平台的模型管理界面如图 5.4 所示。




图 5.4 模型管理界面

Figure 5.4 Model management interface

5.3.2 想定管理模块

根据平台系统设计需求，开发实现想定管理模块与视距内空战想定批量生成工具。平台用户可根据实验设计需要，自主新建空战想定、进行想定编辑与管理、对任意想定生成仿真实例并进行仿真实验等。平台想定管理界面如图 5.5 所示。针对本文第四章研究所需的视距内空战想定批量生成和应用需求，平台提供空战想定批量生成与管理工具，支持平台用户根据研究需要，自主设计和批量生成空战想定。平台想定批量生成工具如图 5.6 所示。



图 5.5 想定管理界面

Figure 5.5 Scenario management interface



图 5.6 想定批量生成工具

Figure 5.6 Scenario batch generation tool

5.3.3 多线程并行式仿真与训练

根据平台系统设计，结合基于 DRL 的视距内空战机动决策算法研究中，提高仿真效率、提高硬件算力利用率、缩短机动决策算法研究验证周期等需求，基于 PyTorch 库开发和实现了面向 DRL 的多线程并行式仿真与训练算法框架，算法内核使用 PPO 算法为例，算法框架的伪代码如代码 5.1 所示。

实践中，平台基于 RASim 空战仿真演算引擎进行多线程并行式演算部署，生成并初始化多线程仿真实例，实现多线程并行式演算调度、异构模型多实例演算、多核并行式演算调度等核心功能。平台用户则可通过仿真控制接口或后台配置文件，对并行训练参数实现配置和调整，包括根据训练需要，更改并行线程数、仿真步长、决策接收步长、仿真实定执行顺序等配置或参数。在算法决策控制端，使用面向 DRL 的多线程并行式仿真与训练算法框架，实现了多线程训练中的调度阻塞、经验学习等机制，确保了算法智能体能够在多线程仿真条件下流畅地进行仿真，充分汇总和利用仿真数据更新智能体神经网络，准确、高效地执行仿真与训练。

算法 5.1 多线程并行式仿真训练算法框架（以 PPO 为例）

- 1: 使用初始化参数 θ 对共享策略网络 $\pi(a|s)$ 进行初始化
- 2: 使用初始化参数 ϕ 对共享价值网络 $V_\phi(s)$ 进行初始化
- 3: 在仿真引擎内部初始化各仿真线程实例
- 4: **for iteration = 1 to N do**
- 5: **# 多线程并行训练并收集经验数据:**

```

6:      for each thread do
7:          for  $t = 1$  to  $t = T_{\max}$  do
8:              与对应仿真线程交互，观察环境态势  $s_t$ 
9:              使用共享策略网络  $\pi(a|s)$  生成动作  $a_t$ 
10:             与对应仿真线程交互，执行动作  $a_t$ ，观察奖励  $r_t$  和下一状态  $s_{t+1}$ 
11:             存储经验样本  $\{s_t, a_t, r_t, s_{t+1}\}$  至共享经验回放缓冲区
12:         End for
13:         阻塞，等待其他线程完成单局仿真
14:     End for
15:     汇总各线程单局经验数据
16:     计算优势函数  $\hat{A}(s, a) = q_{\pi}(s, a) - V_{\phi}(s)$ 
17:     # 更新策略网络:
18:     for  $K\_epochs = 1$  to  $K$  do
19:         for each sample in summarized data do
20:             计算当前共享策略  $\pi(a|s)$  下的动作概率和对数概率
21:             计算当前动作的优势比率和经 Clip 裁剪后的优势比率
22:             计算策略损失函数  $L_{PPO}^{\theta^k}(\theta)$ 
23:         End for
24:         汇总策略损失，计算策略网络梯度，并更新共享策略网络参数  $\theta$ 
25:     End for
26:     # 更新价值网络:
27:     for  $K\_epochs = 1$  to  $M$  do
28:         for each sample in summarized data do
29:             使用目标价值和共享价值网络估计的价值间的均方误差计算价值损失
30:         End for
31:         汇总价值损失，计算价值网络梯度，更新共享价值网络参数  $\phi$ 
32:     End for
33: End for

```

5.3.4 空战态势可视化工具

根据平台系统设计，为支撑基于 DRL 算法的视距内空战训练仿真中的可视化验证需求，开发实现了可视化回放与验证模块。平台用户可在仿真训练过程中选择实时刷新可视化界面，获知算法智能体当前决策效果，也可关闭实时可视化，提高设备运转性能，并将对局数据存储记录以备复盘查看。图 5.7 和图 5.8 中，展示了使用空战态势可视化

工具,对本文第三章中的视距内空战抗感知误差实验和本文第四章中的特定训练模型智能体泛化性能测试实验进行可视化验证的界面。




图 5.7 视距内空战抗感知误差实验可视化验证界面

Figure 5.7 Visual verification interface for perception error-resistant experiment of air combat within visual range




图 5.8 特定训练模型智能体泛化性能测试实验可视化验证界面

Figure 5.8 Visual verification interface for test experiment on generalization performance of a specific training model agent

5.4 本章小结

本章从当前基于 DRL 的视距内空战机动决策研究领域内, 缺乏统一标准的飞行器

模型与仿真决策验证支撑平台的研究现状出发,同时针对本文第三、第四章所提算法的训练和验证需求,设计并开发了面向深度强化学习的空战训练仿真一体化平台。本章首先根据平台设计研发和应用目标,分析了具体的系统架构设计与功能需求。随后,针对所梳理需求,对平台系统架构及主要构件组成做出设计,对主要技术栈进行拆解分析,推演了平台工作流程。接着,基于 RASim 仿真引擎及基本可视化构件、使用 Qt、OpenGL、Python 编程语言等专业技术栈,开发了异构模型管理模块、想定管理模块、面向 DRL 的多线程并行式仿真与训练算法框架等平台组件,实现了平台设计预期的各项主要功能。最后,本章展示了面向深度强化学习的空战训练仿真一体化平台的开发应用效果,以及支撑和验证本文前序章节实验的使用案例。

第6章 总结与展望

6.1 工作总结

未来战争中,空中作战将是关键核心领域,基于DRL的视距内空战机动决策算法研究符合未来空战数字化、智能化的发展趋势,对我国国防军事工业信息化、现代化建设具有重要意义。本文对基于DRL的视距内空战机动决策算法研究领域的研究现状做出了梳理分析,针对研究领域内当前普遍存在的战场态势感知误差对DRL训练和机动决策的干扰问题、基于DRL的机动决策算法特定训练模型泛化性能弱问题、相关研究模型与验证支撑平台差异性大等方面问题进行了研究。本文的主要研究工作及取得的进展成效包括:

(1) 针对战场态势感知误差对基于DRL的视距内空战机动决策算法训练和机动决策的干扰问题,提出了一种基于门控循环单元提取态势特征的近端策略优化算法,旨在通过引入前序态势信息等手段,在端到端的强化学习训练过程中,降低态势感知误差对训练和机动决策的影响。首先,结合动态自回归时间序列数学模型,推导了通过引入前序态势序列态势信息,以降低态势感知误差所造成影响的可行方案。接着,基于真实战场中态势感知误差的来源和特点,对态势感知误差进行建模,向空战相对态势模型中引入了态势感知误差量,搭建了具备态势感知误差的空战仿真环境。随后,设计并提出一种基于门控循环单元提取态势特征的近端策略优化算法,通过门控循环单元融合前序态势信息,提取连续态势序列之间的隐藏特征,同时设置了优势态势解算单元,压缩视距内空战状态空间维度、降低训练难度,此外,还设计了一种量化优势的奖励塑造方法来引导训练加速收敛。最后,在具备态势感知误差的视距内空战场景内,进行仿真对比实验和多场景泛化测试实验。实验结果表明,所提算法能够有效提高飞行器在面对态势感知误差时的空战机动决策能力,具有一定的理论参考价值和工程应用价值。

(2) 针对基于DRL的视距内空战机动决策算法研究中,普遍存在特定训练模型泛化性能弱的问题,提出了一种基于自注意力机制与预训练模型的近端策略优化算法,旨在通过策略重用思想和注意力机制手段,降低训练模型对训练场景MDP模型的拟合程度,提高训练效率和决策针对性,从而提高特定训练模型泛化性能。首先,根据基于DRL的视距内空战机动决策算法训练决策原理,分析了特定训练模型在未知场景中决策性能下降、表现出弱泛化性能的原因,并论述通过迁移学习和策略重用思想,以及通过自注意力机制,提高训练效率,提高训练模型泛化能力的可行性。随后,设计提出一种基于自注意力机制与预训练模型的近端策略优化算法,算法引入基于自注意力机制的实时奖励塑造方法,设计实现具备基础机动控制能力和终段追击能力的预训练决策模型,

并基于预训练模型进行强化学习训练,从而提高智能体在训练探索中的针对性、提高训练效率、降低训练模型对训练场景拟合程度,最终实现对模型泛化性能的增强。通过设计进行视距内空战场景下的仿真实验和泛化性能测试实验,证明所提算法能够有效提高训练得到的特定模型智能体在不同空战环境下的泛化性能,具有一定工程应用价值。

(3) 针对基于 DRL 的视距内空战机动决策研究领域内,缺乏统一标准的飞行器模型与仿真决策验证支撑平台的研究现状,同时针对本文所提算法的训练和验证需要,设计并提出面向深度强化学习的空战训练仿真一体化平台。首先,分析了平台系统设计需求,在厘清需求的基础上对平台进行架构设计细化,并对平台工作流程进行推演。随后,在仿真引擎端实现作战想定批量生成、不同飞行器模型的标准化接入、部署与仿真;在算法控制端搭建并实现面向 DRL 的多线程并行式仿真与训练算法框架;采用多线程间 Socket 交互通信和并行式仿真技术实现高倍速并行交互和训练;采用 OpenGL 和 Qt GUI 等技术实现空战仿真态势的实时可视化。最后,在实现平台基本功能的基础上,对本文所提算法进行验证实验,展示平台的应用效果,表明了平台开发研究的应用价值。

6.2 研究展望

本文作为一篇工程硕士专业学位论文,对基于 DRL 的视距内空战机动决策算法研究领域内部分具有普遍性的问题开展了研究,通过一系列分析推导、算法设计和工程技术手段,对所梳理问题提出了解决思路与算法和技术案例。然而,由于研究时间和算力等条件限制,仍有部分问题值得加以完善,仍有一些研究工作有待进一步开展,包括:

(1) 本文所进行的算法研究仍有进一步改进和完善的空间,例如:基于门控循环单元提取态势特征的近端策略优化算法需融合前序状态序列,算法神经网络实际处理的状态空间维度较高,因而在面对更复杂的空战环境或者具有更复杂机动策略的敌人,训练难度可能显著增大;基于自注意力机制与预训练模型的近端策略优化算法对于训练模型泛化性能的提升还有机会进一步增强,可通过尝试加入数据增强、正则化、早停法等手段继续加强训练模型泛化性能,同时,应避免因过度追求训练模型泛化性能而导致模型决策质量降低,可针对两者之间的平衡问题开展研究。

(2) 本文所做研究主要针对单架飞行器机动场景,随着研究的进一步深入,需要考虑多飞行器机动场景与对应的多智能体相关算法研究。包括研究多智能体间的有效协同与通信,研究多异构飞行器间的非平稳性、信用分配等问题,以及研究将 DRL 算法与人类飞行员决策相配合,实现人机交互和协同。

(3) 未来还需加强基于 DRL 的机动决策算法可解释性研究。基于 DRL 的视距内空战机动决策算法应用于造价昂贵的飞行器,且未来可能投入国防、战争等重要领域,安全性和风险防范至关重要,其决策风险与决策可行性必须经过反复考验和论证,方可用于实战。因此,有必要进一步加强算法的可解释性研究。

参考文献

- [1] Dought G. The Command of Air[M]. LI Z, translated. Beijing: PLA Publishing House, 2014.
- [2] Davis D . Modern Air Combat[J]. PC Pilot, 2019(119):40-43.
- [3] 赵本东,胡星志,赖剑奇,等.俄乌冲突空天攻防作战应用分析与启示[J].战术导弹技术, 2022, (04): 17-22+202.
- [4] 牛绿伟,高晓光,张坤,等. 划分超视距、近距的多机协同作战战术决策[J]. 西北工业大学学报, 2011, 29(6):971-977.
- [5] Boyd J R . The Essence of Winning and Losing[DB/OL]. (1995-05-28)[2024-03-01]. <https://danford.net/boyd/>.
- [6] Ardi P S P , Sasongko R A .Air Combat Analysis Using NADM Computation in WVR Case[C]// 2017 5th International Conference on Instrumentation, Communications, Information Technology, and Biomedical Engineering (ICICI-BME), Bandung, Indonesia:IEEE. 2017: 45-50,.
- [7] Nichols S O. 21st century air-to-air short range weapon requirements[R]. Alabama: Maxwell Air Force Base, 1998.
- [8] 孙聪. 从空战制胜机理演变看未来战斗机发展趋势[J]. 航空学报,2021, 42(8):1-13.
- [9] Smith R E ,B.A. Dike, Mehra R K .Classifier systems in combat: two-sided learning of maneuvers for advanced fighter aircraft[J].Computer Methods in Applied Mechanics & Engineering, 2000, 186(2/4):421-437.
- [10] 樊会涛,闫俊.空战体系的演变及发展趋势[J].航空学报,2022,43(10):296-305.
- [11] Mcgrew J S .Real-time maneuvering decisions for autonomous air combat[D]. Boston, USA: Massachusetts Institute of Technology, 2009.
- [12] 朱星宇,艾剑良.多对多无人机空战的智能决策研究[J].复旦学报(自然科学版),2021,60(04): 410-419.
- [13] Dong Y , Ai J , Liu J .Guidance and control for own aircraft in the autonomous air combat: A historical review and future prospects[J]. Proceedings of the Institution of Mechanical Engineers, 2019, 233(16):5943-5991.
- [14] 董一群,艾剑良.自主空战技术中的机动决策: 进展与展望[J].航空学报,2020,41(S2):4-12.
- [15] Steve T. DARPA Selects Five Teams For Alpha Dogfight Trials Follow-Up[J]. Aerospace Daily & Defense Report,2020,274(30):1-2.
- [16] Yang Q , Zhu Y , Zhang J ,et al.UAV Air Combat Autonomous Maneuver Decision Based on DDPG Algorithm[C]//2019 IEEE 15th International Conference on Control and Automation (ICCA), Edinburgh, UK:IEEE, 2019:37-42,.
- [17] 何康馨. 基于深度强化学习的非完备信息博弈纳什均衡策略研究[D]. 成都:四川大学,2022.
- [18] Minsky M .Theory of neural-analog reinforcement systems and its application to the brain-model problem[D]. New Jersey, USA: Princeton University, 1954.
- [19] Bellman R .The Theory of Dynamic Programming[J]. Bulletin of the American Mathematical Society, 1954, 60(6): 503-516.
- [20] Howard R A .Dynamic Programming and Markov Processes[J]. Mathematical Gazette, 1960, 3(358): 120-130.
- [21] Klopff A H .Brain Function and Adaptive Systems: A Heterostatic Theory[J].brain function & adaptive

- systems a heterostatic theory, 1972, 72-164.
- [22] Sutton R , Barto A .Reinforcement Learning:An Introduction[M].Boston: MIT Press,1998.
- [23] Sutton, Richard S .Learning to Predict the Methods of Temporal Differences[J]. Machine Learning, 1988, 3(1), 103-135.
- [24] Watkins C J C H .Learning from delayed rewards[D].Cambridge, UK: Cambridge University, 1989.
- [25] Watkins C J C H , Dayan P .Q-learning[J].Machine Learning, 1992, 8(3-4):279-292.
- [26] Rummery G A , Niranjan M .On-Line Q-Learning Using Connectionist Systems[J]. Technical Report, 1994,2(37),5-6.
- [27] Bellman R , Kalaba R .Dynamic programming and adaptive processes: Mathematical foundation[J]. IRE Transactions on Automatic Control, 1960, AC- 5(1):5-10.
- [28] Mnih V, Kavukcuoglu K, Silver D, et al. Playing atari with deep reinforcement learning[C] // NIPS Deep Learning Workshop, Nevada, 2013:1-31.
- [29] Van Hasselt H, Guez A, Silver D. Deep reinforcement learning with double q-learning[C]// Proceedings of the AAAI conference on artificial intelligence. 2016, 30(1),1-22.
- [30] Schulman J, Levine S, Abbeel P, et al. Trust region policy optimization[C]// International conference on machine learning. PMLR, 2015: 1889-1897.
- [31] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning[J]. Computer Science, 2016, 8(6): A187.
- [32] Silver D, Huang A, Maddison C J, et al. Mastering the game of Go with deep neural networks and tree search[J]. Nature, 2016, 529(7587): 484-489.
- [33] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[DB/J]. (2017-08-28) [2024-03-01]. <https://arxiv.org/pdf/1707.06347.pdf>.
- [34] Fujimoto S , Van Hoof H , Meger D .Addressing Function Approximation Error in Actor-Critic Methods[C]// Proceedings of the 35th International Conference on Machine Learning. Stockholm: ICML, 2018. 1582-1591.
- [35] Miki T , Lee J , Hwangbo J ,et al.Learning robust perceptive locomotion for quadrupedal robots in the wild[J]. Science robotics, 2022, 7(62), 22-28.
- [36] Andrychowicz O M , Baker B , Chociej M ,et al.Learning dexterous in-hand manipulation:[J].The International Journal of Robotics Research, 2020, 39(1):3-20.
- [37] Shi J C , Yu Y , Da Q ,et al.Virtual-Taobao: Virtualizing Real-world Online Retail Environment for Reinforcement Learning[C]//National Conference on Artificial Intelligence.Association for the Advancement of Artificial Intelligence (AAAI), Hawaii, USA.2019: 4902-4909.
- [38] 张立华,刘全,黄志刚,等. 逆向强化学习研究综述[J]. 软件学报,2023,34(10): 4772-4803.
- [39] 曾俊杰,秦龙,徐浩添,等. 基于内在动机的深度强化学习探索方法综述[J]. 计算机研究与发展, 2023, 60(10):2359-2382.
- [40] Li C, Zheng P, Yin Y, et al. Deep reinforcement learning in smart manufacturing: A review and prospects[J]. CIRP Journal of Manufacturing Science and Technology, 2023, 40: 75-101.
- [41] Horie K , Conway B A .Optimal Fighter Pursuit-Evasion Maneuvers Found Via Two-Sided Optimization[J]. Journal of Guidance Control & Dynamics, 2006, 29(1): 105-112.
- [42] Xu G , Liu Q , Zhang H .The application of situation function in differential game problem of the air combat[C]//2018 Chinese Automation Congress (CAC), Xi'an, China, 2018: 1190-1195.
- [43] Xia C, Zhao M. The decision method research on air combat game based on uncertain interval information[C]//2012 Fifth International Symposium on Computational Intelligence and Design [第

- 五届计算智能与设计国际会议 ISCID 2012]论文集. 2012:456-459.
- [44] 徐光达,吕超,王光辉,等. 基于双矩阵对策的 UCAV 空战自主机动决策研究[J]. 舰船电子工程,2017,37(11):24-28+39.
- [45] 邓可,彭宣洪,周德云.基于矩阵对策与遗传算法的无人机空战决策[J].火力与指挥控制,2019,44(12):61-66+71.
- [46] Virtanen K , Karelahti J , Raivio T .Modeling Air Combat by a Moving Horizon Influence Diagram Game[J].American Institute of Aeronautics and Astronautics, AIAA, 2006(5),1080-1091.
- [47] Cruz J B J , Simaan M A , Gacic A ,et al.Moving horizon Nash strategies for a military air operation[J]. IEEE Transactions on Aerospace & Electronic Systems, 2002, 38(3):989-999.
- [48] 孙智孝,杨晟琦,朴海音等.未来智能空战发展综述[J].航空学报,2021,42(08): 35-49.
- [49] 湛文静,李泳科.基于改进遗传算法的路径规划问题相关研究综述[J].计算机与数字工程,2023,51(07):1544-1550.
- [50] 谢建峰,杨啟明,戴树岭等.基于强化遗传算法的无人机空战机动决策研究[J].西北工业大学学报,2020,38(06):1330-1338.
- [51] 徐超,王玉惠,吴庆宪等.基于模糊遗传算法的先进战机协同攻防决策[J].火力与指挥控制,2020,45(03):14-21.
- [52] McGrew J S. Real-time maneuvering decisions for autonomous air combat[D]. Boston, USA: Massachusetts Institute of Technology, 2008.
- [53] 姜龙亭,寇雅楠,王栋等.改进近似动态规划法的攻击占位决策[J].火力与指挥控制,2019,44(07):135-141.
- [54] McGrew J S, et al. Air-Combat Strategy Using Approximate Dynamic Programming[J]. Journal of Guidance Control & Dynamics, 2010(5):33-39.
- [55] Zhang T , Yu L , Zhou Z L ,et al. Decision-making for air combat maneuvering based on hybrid algorithm[J]. Systems Engineering & Electronics, 2013, 35(7): 1445-1450.
- [56] 陈侠,刘敏,胡永新.基于不确定信息的无人机攻防博弈策略研究[J].兵工学报,2012,33(12):1510-1515.
- [57] Burgin G H , Sidor L B .Rule-based air combat simulation[J]. NASA Contractor Report 4160, 1988, 4160, 1-138.
- [58] 傅莉,谢福怀,孟光磊等.基于滚动时域的无人机空战决策专家系统[J].北京航空航天大学学报,2015,41(11):1994-1999.
- [59] 王炫,王维嘉,宋科璞等.基于进化式专家系统树的无人机空战决策技术[J].兵工自动化,2019,38(01):42-47.
- [60] 邵佳梁. 基于分层控制的固定翼飞机空战对抗策略仿真研究[D]. 成都:电子科技大学,2023.
- [61] 马珍珍. 基于群智能优化的空空导弹鲁棒 PID 控制器设计[D]. 南京:南京航空航天大学,2019.
- [62] 张堃,周德云,王谦等.基于模糊决策树的机载多传感器智能管理方法[J].计算机应用,2011,31(12):3255-3257.
- [63] Geng W, Kong F, Ma D. Study on Tactical Decision of UAV Medium-Range Air Combat[C]. //第 26 届中国控制与决策会议(2014 CCDC)论文集. 2014:135-139.
- [64] 孔维仁,周德云,赵艺阳等.基于深度强化学习与自学习的多无人机近距空战机动策略生成算法[J].控制理论与应用,2022,39(02):352-362.
- [65] Li Y, Shi J, Jiang W, et al. Autonomous maneuver decision-making for a UCAV in short-range aerial combat based on an MS-DDQN algorithm[J]. Defence Technology, 2022, 18(9): 1697-1714.
- [66] 吴昭欣.基于深度强化学习的飞行器自主机动决策方法研究[D]. 成都:四川大学, 2021.

- [67] Yang K, Dong W, Cai M, et al. UCAV air combat maneuver decisions based on a proximal policy optimization algorithm with situation reward shaping[J]. Electronics, 2022, 11(16): 2602.
- [68] Yang Q, Zhu Y, Zhang J, et al. UAV air combat autonomous maneuver decision based on DDPG algorithm[C]//2019 IEEE 15th international conference on control and automation (ICCA). IEEE, 2019: 37-42.
- [69] Pope A P, Ide J S, Mićović D, et al. Hierarchical reinforcement learning for air-to-air combat[C]//2021 international conference on unmanned aircraft systems (ICUAS). IEEE, 2021: 275-284.
- [70] 黄志刚,刘全,张立华等.深度分层强化学习研究与发展[J].软件学报,2023, 34(02):733-760.
- [71] Kong W, Zhou D, Zhou Y, et al. Hierarchical reinforcement learning from competitive self-play for dual-aircraft formation air combat[J]. Journal of Computational Design and Engineering, 2023, 10(2): 830-859.
- [72] 杨晟琦,田明俊,司迎利等.基于分层强化学习的无人机机动决策[J].火力与指挥控制,2023,48(08):48-52+59.
- [73] 吴文海.飞行综合控制系统(第2版)[M].西安交通大学出版社,2018.
- [74] 唐文泉,孙莹,杨奇,李辉,王壮,何立.一种面向2V2近距空战的强化学习算法[J].战术导弹技术, 2022(01): 120-130.
- [75] 刘志敏.歼击机空战效能研究与计算机仿真[D].西安:西北工业大学,2003.
- [76] Li J, Song R L, Zhang H P. Dynamic Aircraft Conflict Alert Based on the Markov Decision Process and Simulation of Actual Flight Data [J]. Journal of Physics: Conference Series,2021,1813(1), 183-202.
- [77] 王壮.近距空战飞行器智能机动决策生成研究[D].成都:四川大学,2021.
- [78] Zhao W W, Cehu H R, Miao X K, et al. Research on the Multiagent Joint Proximal Policy Optimization Algorithm Controlling Cooperative Fixed-Wing UAV Obstacle Avoidance[J]. Sensors, 2020, 20(16),45-46.
- [79] Wang J Q, Chen Y F. Performance analysis of communications systems with radar interference and hardware impairment[J]. IET Communications, 2022, 16(19),39-48.
- [80] 吴建萍,邵昭晖,徐阳.激光对导弹光电传感器作战效果的定量评估方法[J].舰船电子工程, 2019, 39(10): 189-191.
- [81] 王振龙,胡永宏.应用时间序列分析[M].科学出版社,2007.
- [82] Kyunghyun C, Bart V M, Caglar G, et al. Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation[C]. //Conference on empirical methods in natural language processing, vol. 3: Conference on empirical methods in natural language processing (EMNLP 2014), 25-29 October 2014, Doha, Qatar.:Association for Computational Linguistics, 2014:1724-1734.
- [83] 刘建伟,宋志妍.循环神经网络研究综述[J].控制与决策, 2022, 37(11): 2753-2768.
- [84] 吴冯国,陶伟,李辉等.基于深度强化学习算法的无人机智能规避决策[J].系统工程与电子技术,2023,45(06):1702-1711.
- [85] Haarnoja T , Zhou A , Abbeel P ,et al. Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor[DB/OL]. (2018-08-08) [2024-03-01]. <https://arxiv.org/abs/1801.01290>.
- [86] 何立.基于策略重用的飞行器空战自主机动决策算法研究[D].成都:四川大学,2022
- [87] 符小卫,徐哲,王辉.基于DDPG的无人机追捕任务泛化策略设计[J].西北工业大学学报,2022,40(1):47-55.

- [88] Sun C , Li C , Lin X , et al.Attention-based graph neural networks: a survey[J]. Artificial Intelligence Review,2023,56(Suppl 2):2263-2310.
- [89] Vaswani A , Shazeer N , Parmar N ,et al.Attention Is All You Need[J].Advances in neural information processing systems, 2017, 30, 5998-6008.
- [90] Breitner M H , Pesch H J , Grimm W .Complex differential games of pursuit-evasion type with state constraints, part 2: Numerical computation of optimal open-loop strategies[J].Journal of Optimization Theory and Applications, 1993, 78(3):443-463.
- [91] 陈浩,黄健,刘权等.自主空战机动决策技术研究进展与展望[J].控制理论与应用,2023, 40(12): 2104-2129.

附录 A

附录 A-1 第四章 初始坐标变化实验数据记录表

AMP3O	第一组交叉测试					第二组交叉测试				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
	406	94	0	0	87.22	404	96	0	0	89.93
	第三组交叉测试					第四组交叉测试				
成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	
393	107	0	0	91.55	410	88	2	0	88.78	
	第五组交叉测试					全组测试结果				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功次数	平均成功率	平均 时间(s)		
	416	104	0	0	86.12	2029	81.16%	88.72		
AMP3O without RS	第一组交叉测试					第二组交叉测试				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
	385	115	0	0	93.27	382	96	0	0	95.38
	第三组交叉测试					第四组交叉测试				
成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	
382	118	0	0	98.73	386	114	0	0	98.45	
	第五组交叉测试					全组测试结果				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功次数	平均成功率	平均 时间(s)		
	385	115	0	0	94.02	1920	76.8%	95.97		
PPO with RS	第一组交叉测试					第二组交叉测试				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
	274	203	23	0	151.78	264	232	4	0	163.38
	第三组交叉测试					第四组交叉测试				
成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	
243	247	10	0	169.22	299	170	31	0	145.49	
	第五组交叉测试					全组测试结果				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功次数	平均成功率	平均 时间(s)		
	301	191	8	0	144.23	1381	55.24%	154.82		

(续表)

PPO	第一组交叉测试					第二组交叉测试				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
	271	211	18	0	158.67	272	220	8	0	162.68
	第三组交叉测试					第四组交叉测试				
SAC	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
	246	238	16	0	165.57	299	182	19	0	154.95
	第五组交叉测试					全组测试结果				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功次数	平均成功率	平均 时间(s)		
304	190	6	0	157.03	1392	55.68%	159.78			
DDPG	第一组交叉测试					第二组交叉测试				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
	97	396	7	0	252.0	109	380	11	0	243.52
	第三组交叉测试					第四组交叉测试				
SAC	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
	46	420	34	0	277.03	105	369	26	0	239.2
	第五组交叉测试					全组测试结果				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功次数	平均成功率	平均 时间(s)		
140	356	4	0	214.35	497	19.88%	245.22			
DDPG	第一组交叉测试					第二组交叉测试				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
	126	364	10	0	226.32	97	390	13	0	250.18
	第三组交叉测试					第四组交叉测试				
DDPG	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
	70	411	19	0	260.47	135	349	16	0	224.55
	第五组交叉测试					全组测试结果				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功次数	平均成功率	平均 时间(s)		
162	333	5	0	211.48	590	23.6%	234.60			

附录 A-2 第四章 初始坐标与敌方策略变化实验数据记录表

AMP3O	第一组交叉测试					第二组交叉测试				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
	307	190	3	0	143.70	338	161	1	0	139.23
	第三组交叉测试					第四组交叉测试				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
318	151	31	0	120.73	293	188	18	1	150.12	
第五组交叉测试					全组测试结果					
成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功次数	平均成功率	平均 时间(s)			
340	160	0	0	146.07	1596	63.84%	139.97			
AMP3O without RS	第一组交叉测试					第二组交叉测试				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
	225	269	6	0	183.02	292	203	5	0	163.97
	第三组交叉测试					第四组交叉测试				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
204	289	7	0	208.38	211	280	8	1	200.11	
第五组交叉测试					全组测试结果					
成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功次数	平均成功率	平均 时间(s)			
256	244	0	0	189.42	1188	47.52%	188.98			
PPO with RS	第一组交叉测试					第二组交叉测试				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
	200	278	22	0	201.78	204	284	12	0	203.38
	第三组交叉测试					第四组交叉测试				
	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)
177	299	24	0	214.82	203	251	44	2	204.15	
第五组交叉测试					全组测试结果					
成功 次数	超时 次数	越界 次数	失败 次数	平均 时间(s)	成功次数	平均成功率	平均 时间(s)			
223	271	4	2	199.97	1007	40.28%	204.82			

(附表)

PPO	第一组交叉测试					第二组交叉测试					
	成功 次数 149	超时 次数 324	越界 次数 27	失败 次数 0	平均 时间(s) 241.78	成功 次数 169	超时 次数 311	越界 次数 20	失败 次数 0	平均 时间(s) 233.38	
	第三组交叉测试					第四组交叉测试					
	成功 次数 99	超时 次数 381	越界 次数 20	失败 次数 0	平均 时间(s) 251.17	成功 次数 126	超时 次数 358	越界 次数 15	失败 次数 1	平均 时间(s) 247.55	
	第五组交叉测试					全组测试结果					
	成功 次数 138	超时 次数 339	越界 次数 22	失败 次数 1	平均 时间(s) 250.22	成功次数 681	平均成功率 27.24%	平均 时间(s) 244.82			
	SAC	第一组交叉测试					第二组交叉测试				
		成功 次数 41	超时 次数 453	越界 次数 6	失败 次数 0	平均 时间(s) 282.83	成功 次数 73	超时 次数 424	越界 次数 3	失败 次数 0	平均 时间(s) 273.90
		第三组交叉测试					第四组交叉测试				
		成功 次数 30	超时 次数 469	越界 次数 1	失败 次数 0	平均 时间(s) 292.95	成功 次数 61	超时 次数 423	越界 次数 13	失败 次数 3	平均 时间(s) 281.0
第五组交叉测试					全组测试结果						
成功 次数 85		超时 次数 401	越界 次数 14	失败 次数 0	平均 时间(s) 257.22	成功次数 290	平均成功率 11.60%	平均 时间(s) 277.58			
DDPG		第一组交叉测试					第二组交叉测试				
		成功 次数 48	超时 次数 446	越界 次数 8	失败 次数 0	平均 时间(s) 279.30	成功 次数 87	超时 次数 407	越界 次数 6	失败 次数 0	平均 时间(s) 264.77
		第三组交叉测试					第四组交叉测试				
		成功 次数 29	超时 次数 466	越界 次数 5	失败 次数 0	平均 时间(s) 290.55	成功 次数 83	超时 次数 410	越界 次数 7	失败 次数 0	平均 时间(s) 268.92
	第五组交叉测试					全组测试结果					
	成功 次数 86	超时 次数 401	越界 次数 13	失败 次数 0	平均 时间(s) 266.62	成功次数 333	平均成功率 13.32%	平均 时间(s) 274.03			