

硕士学位论文

强化学习驱动的无人机对抗决策方法研究

Research on Reinforcement Learning Driven UAV Adversarial Decision-Making Methods

作者姓名：王博艺

学号：32109165

指导教师：林恺/尹震宇（企业导师）

学科、专业：计算机技术

答辩日期：2024年5月24日

大连理工大学

Dalian University of Technology

学位论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经指明引用的内容外，学位论文不含任何其他个人、法人或者非法人组织已经发表或尚未发表的作品，且学位论文中已经指明作者姓名或者名称、作品名称的内容，不影响该作品的正常使用，也不存在不合理地损害相关权利人的合法权益的任何情形。对学位论文研究做出重要贡献的个人和法人或者非法人组织，均已在论文中以明确方式标明，且不存在任何著作权纠纷。

若因声明不实，本人愿意为此承担相应的法律责任。

学位论文题目：强化学习驱动的无人机对抗决策方法研究
作者签名：王博艺 日期：2024年5月29日

大连理工大学学位论文版权使用授权书

本人完全了解大连理工大学有关学位论文知识产权的规定，在校攻读学位期间论文工作的知识产权属于大连理工大学，允许论文被查阅和借阅。学校有权保留论文并向国家有关部门或机构送交论文的复印件和电子版，可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印、或扫描等复制手段保存和汇编本学位论文。

学位论文题目：强化学习驱动的无人机对抗决策方法研究
作者签名：王博艺 日期：2024年5月29日
导师签名：孙悦 尹震宇 日期：2024年5月29日

摘 要

近年来,随着无人机技术的不断迭代发展和强化学习在各个领域内的成功应用,基于无人机对抗的强化学习研究变得流行起来。强化学习驱动的无人机对抗决策方法能够为空战对抗研究提供更广阔的视角,在智能化战争背景下具备强大的应用价值。然而,现代战争环境日益复杂,无人机作战频率和规模持续上升,对抗手段也更加多样化,这导致无人机训练决策成本增加,无人机之间的配合协调互助能力下降、决策效果不良甚至较差。因此,本文结合近端策略优化理念和策略互助理论来充分利用无人机数据信息,对无人机对抗算法进行研究,主要研究工作如下:

首先,提出了最优传输支撑下的行为策略优化算法,用于解决无人机对抗中强化学习面临的数据成本高昂和分布外延等问题。该算法引入最优传输定理,对未标注奖励的对抗数据进行奖励标签的自动化分配,通过构建专家演示轨迹与未标注轨迹之间的最优传输映射,将专家的策略信息传递给未标注数据,实现对数据集的充分利用。针对分布外延问题,引入性能差异定理来评估离线数据集对当前策略进行改进的效果,并将策略改进约束在一定比率范围内,提升了策略优化的稳定性。此外,设计了一种混合损失函数,结合策略比率约束和数据过滤机制,有效降低了过拟合风险,增强了策略的泛化能力和鲁棒性。通过在仿真环境上进行的大量实验,验证了所提出算法的决策表现。

其次,提出了惊喜最小化驱动的协作策略优化算法,解决了无人机群的合作互助和有效探索等问题。该算法采用图注意网络和专家知识结合的方法,将关键关系推理为抽象关系图,简化了无人机群对抗的复杂态势关系,摆脱了大量细节而专注于关键关系,降低了策略学习难度。此外,将个体探索与团队协作有机结合,通过个体的自主试错和经验积累来驱动整个团队朝着更优协同策略的方向收敛。团队策略则持续地从个体的探索经验中汲取和融合有益信息,实现策略的迭代更新和完善。同时,采用基于惊喜最小化的自适应探索机制,将智能体在某一状态下的惊喜程度定义为该状态分布的熵值。通过将惊喜最小化作为探索的额外奖励,鼓励智能体寻找环境中较为确定和可预测的状态,减少对抗过程中的不确定性,同时平衡探索和利用。实验结果证明了该算法的性能以及各模块的有效性。

最后,对本文提出的两种模型进行了归纳总结,明确了它们各自的优点以及不足,并对该领域未来的发展方向进行了展望。

关键词: 无人机对抗; 机动决策; 强化学习; 深度强化学习; 多智能体强化学习

ABSTRACT

In recent years, with the continuous iterative development of UAV technology and the successful application of reinforcement learning within various fields, reinforcement learning research based on UAV confrontation has become popular. Reinforcement learning-driven decision-making methods for UAV confrontation can provide a broader perspective for air combat confrontation research, and have strong application value in the context of intelligent warfare. However, the modern war environment has become increasingly complex, the frequency and scale of UAV combat continue to rise, and the means of confrontation have become more diversified, which leads to an increase in the cost of UAV training and decision-making, a decrease in the ability of coordination and mutual assistance between UAVs, and poor or even poor decision-making effects. Therefore, this thesis combines the concept of proximal strategy optimization and strategy mutual aid theory to make full use of UAV data information, and conducts research on UAV confrontation algorithms, and the main research work is as follows:

First, a behavioral policy optimization algorithm under the support of optimal transmission is proposed for solving the problems of high data cost and distributional extents faced by reinforcement learning in UAV confrontation. The algorithm introduces the optimal transmission theorem to automate the allocation of reward labels for unlabeled rewarded adversarial data, and achieves the full utilization of the dataset by constructing the optimal transmission mapping between the expert's demonstration trajectory and the unlabeled trajectory to transfer the expert's strategy information to the unlabeled data. To address the distributional epistasis problem, a performance difference theorem is introduced to evaluate the effect of offline dataset to improve the current strategy, and the strategy improvement is constrained to be within a certain ratio, which enhances the stability of the strategy optimization. In addition, a hybrid loss function is designed to combine the strategy ratio constraint and data filtering mechanism, which effectively reduces the overfitting risk and enhances the generalization ability and robustness of the strategy. The decision-making performance of the proposed algorithm is verified through a large number of experiments conducted on the simulation environment.

Then, an individual teamwork strategy algorithm based on surprise minimization is proposed to solve the problems of cooperative mutual aid and effective exploration of UAV swarms. The algorithm adopts the method of combining graph attention network and expert knowledge, reasoning the key relationships into abstract relationship graphs, simplifying the complex situational relationships of UAV swarm confrontation, getting rid of a large number of details and focusing on the key relationships, and reducing the difficulty of strategy learning.

In addition, individual exploration and teamwork are organically combined to drive the whole team to converge towards a better synergistic strategy through the autonomous trial and error and experience accumulation of individuals. The team strategy, on the other hand, continuously draws and integrates useful information from individual exploration experience to realize iterative updating and improvement of the strategy. At the same time, the adaptive exploration mechanism based on surprise minimization is adopted, which defines the degree of surprise of an intelligent body in a certain state as the entropy value of the distribution of the state. By using surprise minimization as an additional reward for exploration, the intelligent body is encouraged to search for more certain and predictable states in the environment, reducing uncertainty in the confrontation process while balancing exploration and exploitation. Experimental results demonstrate the performance of the algorithm and the effectiveness of the modules.

Finally, the two models proposed in this thesis are summarized, their respective advantages as well as shortcomings are clarified, and the future development direction of this field is envisioned.

Key Words: UAV Combat; Motorized Decision-Making; Reinforcement Learning; Deep Reinforcement Learning; Multi-Agent Reinforcement Learning

目 录

摘 要	I
ABSTRACT	III
目 录	V
TABLE OF CONTENTS	VII
图目录	IX
表目录	XI
主要符号表	XIII
1 绪论	1
1.1 研究背景与意义	1
1.2 国内外相关研究工作进展	3
1.2.1 智能空战决策技术	3
1.2.2 深度强化学习方法	5
1.3 论文研究思路及目标	7
2 相关理论和概念基础	10
2.1 无人机空战环境研究	10
2.1.1 无人机运动控制模型	10
2.1.2 状态空间	11
2.1.3 无人机机动数据库	11
2.2 强化学习	12
2.2.1 马尔可夫决策过程	13
2.2.2 强化学习基本原理	13
2.2.3 离线强化学习	14
2.3 多智能体强化学习	15
2.4 本章小结	17
3 最优传输支撑下的无人机对抗行为策略优化方法	18
3.1 引言	18
3.2 模型结构	19
3.2.1 模型整体结构	19
3.2.2 无人机训练数据集奖励标注	21
3.2.3 行为策略的离线改进算法	22

3.2.4 针对复合动作的混合损失函数	24
3.3 实验结果与分析	25
3.3.1 仿真系统框架	26
3.3.2 实验环境及任务设计	26
3.3.3 实验结果与分析	27
3.3.4 不同模块的消融实验	33
3.4 本章小结	34
4 惊喜最小化驱动的无人机群对抗—协作策略优化方法	35
4.1 引言	35
4.2 模型结构	36
4.2.1 模型整体结构	36
4.2.2 空战态势的抽象图关系推理	37
4.2.3 基于个体团队策略互助的结合策略算法	40
4.2.4 基于惊喜最小化的多智能体合作探索方法	43
4.3 实验结果与分析	44
4.3.1 环境配置和任务设计	45
4.3.2 实验结果与分析	46
4.3.3 不同模块的消融实验	49
4.3.4 超参数分析	52
4.4 本章小结	53
5 结论与展望	54
5.1 结论	54
5.2 创新点	54
5.3 展望	55
参 考 文 献	57
攻读硕士学位期间科研项目及科研成果	61
致 谢	63

TABLE OF CONTENTS

1 Introduction	1
1.1 Research Background.....	1
1.2 Research Progress	3
1.2.1 Intelligent Air Warfare Decision Making Technology	3
1.2.2 Deep Reinforcement Learning Methods	5
1.3 Main Research Contents and Objectives.....	7
2 Relevant Theoretical and Conceptual Foundations.....	10
2.1 UAV Environment Study	10
2.1.1 UAV Motion Control Modeling.....	10
2.1.2 State Space	11
2.1.3 UAV Maneuvering Database	11
2.2 Reinforcement Learning.....	12
2.2.1 Markov Decision Process.....	13
2.2.2 Reinforcement Learning Fundamentals	13
2.2.3 Offline Reinforcement Learning	14
2.3 Multi-Agent Reinforcement Learning.....	15
2.4 The Chapter's Conclusion	17
3 UAV Adversarial Decision Making Method based on Optimal Transport Support Behavior Policy Optimization.....	18
3.1 Introduction	18
3.2 Model Structure.....	19
3.2.1 Overall Model Structure.....	19
3.2.2 UAV Training Dataset Reward Labeling.....	21
3.2.3 Offline Improvement Algorithm for Behavior Policy.....	22
3.2.4 Hybrid Loss Function for Composite Actions	24
3.3 Experimental Results and Analysis.....	25
3.3.1 Simulation System Framework	26
3.3.2 Experimental Environment and Task Design.....	26
3.3.3 Experimental Results and Analysis.....	27
3.3.4 Ablation Experiments with Different Modules	33
3.4 The Chapter's Conclusion	34
4 Multi-UAV Adversarial Approach based on Individual and Team Bonding Policy based on Surprise Minimization.....	35
4.1 Introduction	35

4.2 Model Structure.....	36
4.2.1 Overall Model Structure.....	36
4.2.2 Abstrat Graphical Relational Reasoning for Air Combat Postures.....	37
4.2.3 Combined Policy Algorithm based on Mutual Assistance of Individual Team Policy.....	40
4.2.4 Multi-Agent Cooperative Exploration Approach based on Surprise Minimization	43
4.3 Experimental Results and Analysis.....	44
4.3.1 Environment Configuration and Task Design.....	45
4.3.2 Experimental Results and Analysis.....	46
4.3.3 Ablation Experiments with Different Modules	49
4.3.4 Hyperparametric Analysis.....	52
4.4 The Chapter's Conclusion	53
5 Conclusions and Prospection	54
5.1 Conclusions	54
5.2 Highlights.....	54
5.3 Prospection	55
References	57
Achievements	61
Acknowledgements	63

图目录

图 1.1 无人机智能化作战基本框架	1
图 1.2 智能空战决策算法的发展	3
图 1.3 本文结构示意图	8
图 2.1 无人机三维空间状态描述	10
图 2.2 无人机基本战斗机动集合	12
图 2.3 强化学习系统模型	14
图 2.4 多智能体强化学习架构	16
图 3.1 最优传输支撑下的无人机对抗行为策略优化算法整体结构	19
图 3.2 最优传输法示意图	22
图 3.3 复合动作损失和子动作损失之间的差异	25
图 3.4 对抗直线飞行目标的算法胜率变化	28
图 3.5 对抗直线飞行目标的训练轨迹	28
图 3.6 基于 PPO 算法对抗胜率变化曲线	29
图 3.7 不同主流算法对抗 PPO 算法的胜率变化曲线	30
图 3.8 无人机导弹任务的胜率变化曲线	31
图 4.1 惊喜最小化驱动的无人机群对抗—协作策略优化算法整体结构	37
图 4.2 抽象关系图的几种关系	40
图 4.3 个体团队策略结合算法基本流程	41
图 4.4 场景描述	45
图 4.5 训练过程中不同方法的评价结果	47
图 4.6 不同多智能体强化学习方法的比较结果	48
图 4.7 与专家级机器人在不同场景下的比较结果	49
图 4.8 惊喜最小化模块的消融实验结果	51
图 4.9 不同 ω 值下 ITBP-SM 算法在不同任务场景的性能比较	52

表目录

表 2.1 基本机动动作指令	12
表 3.1 最优传输支撑下行为策略优化算法描述	20
表 3.2 三维环境对抗红蓝双方的初始态势	26
表 3.3 本章算法（红方）和其他算法（蓝方）对抗结果比较	31
表 3.4 不同主流算法对抗规则驱动方法的不同阶段的对抗结果比较	32
表 3.5 无最优传输和最优传输训练的消融实验	33
表 3.6 策略目标中价值函数估计的混合损失的消融实验	33
表 3.7 一般策略 vs 改进行为策略	33
表 4.1 惊喜最小化驱动的协作策略优化算法描述	38
表 4.2 实验参数设置	46
表 4.3 本章算法和其他算法在对抗场景上的性能比较	48
表 4.4 无抽象图关系推理和抽象图关系推理的消融实验	50
表 4.5 个体团队策略结合模块的消融实验	51

主要符号表

符 号	代表意义
英文字母	
$V(s)$	状态价值函数
$Q(s, a)$	状态-动作值函数
J	目标函数
H	熵
S	状态空间
A	动作空间
P	状态转移概率
R	奖励函数
希腊字母	
α	训练超参数
b	训练超参数
ω	训练超参数
g	重力加速度
r	奖励
缩写	
MDP	马尔可夫决策过程
OT	最优传输定理
KL 散度	Kullback-Leibler
JS 散度	Jensen-Shannon
MARL	多智能体强化学习

2003 年,法国宣布实施“地平线”计划,通过开发无人作战飞行演示器,确保在该领域的领先地位和国防需求^[4];2010 年,俄罗斯宣布实施“2011-2020 年国家武器计划”,依靠规划无人机系统和相关部队的发展,提升俄军现代化武器占比^[5];2016 年,美国国防部宣布了“小精灵”计划,旨在探索小型无人机集群的空中发射和回收、低成本飞机机身的设计和复杂数据飞行控制系统等技术^[6];2017 年,欧盟公布了未来空中作战系统计划,目的是为微型飞行器、无人机和机载武器开发一个相互关联和协同的系统集群^[7];2020 年,美国国防部宣布了空战进化计划,发展先进的人工智能空战算法,实现微型飞行器和无人机之间的协同作战^[8]。

纵观学术界研究历程,随着现代化作战技术和战略的发展,战场形势瞬息万变,交战双方想要迅速把握空战态势,做出准确决策变得愈发困难。传统的作战决策以战场态势感知作为前提和基础,将战场中兵力分布以及战场环境的当前状态和发展变化趋势作为评估依据,未考虑到人机协同新型现代战术行动等因素给作战决策带来的影响。由于未来战场的作战节奏明显加快,战场态势瞬息万变,能够克服时空不确定性建立环境感知与协同行动的关联模型,就能提高决策的速度以及准确性。因此,依据作战双方动态态势,迅速进行分析建模预测,精准产生高效智能的决策,成为当今无人机智能对抗领域的重要课题^[9]。

相较于单无人机对抗,多无人机对抗是一个更加复杂的问题^[10]。其面临环境高复杂性、博弈强对抗性、响应高实时性、信息低完整性、边界不确定性等一系列挑战,这使得传统方法很难达到多无人机对抗所需要的高实时性。同时,在严峻复杂的空战环境中,求解算法的鲁棒性要求更高。因而需要探寻一种更为有效的求解方法,将人工智能、武器系统、空战环境等作战要素整合成一套智能决策体系,从而在复杂空战场景中做出正确决策,助力我军在未来智能化空战对抗中获取优势地位。

强化学习普遍利用智能体和环境交互来获得奖励,无需先验知识来指导行为,在环境交互中通过不断地学习来达成回报最大化或者实现特殊目标。2016 年,美国 Psibernetix 公司开发的阿尔法 AI 多次成功击败了美军空间战术专家操纵的模拟战机,这证明了人工智能在空战决策领域所拥有的巨大潜力^[11]。随着现代化战争日益更新的先进技术装备,寻求一种能够在复杂多变、规模庞大的空战环境中实现精准性、实时性、稳定性的智能空战决策方法变得尤为重要。强化学习与复杂环境相互结合的应用,可以为军事行动提供更准确的方针指示,有效提高空战作战能力以及合理减少战斗损失。

综上所述,探索无人机如何在不同的任务背景下面对复杂的对抗环境进行智能决策,不仅有利于充分发挥无人机的个体自主性和群体互助性,同时还有着重要的理论意义以及应用价值。

1.2 国内外相关研究工作进展

现代战争自 1991 年的海湾战争起完成了机械化战场向信息化智能化战场的转变^[12]。无人机的智能化作战在未来多维战场上也将发挥越来越显著的作用，吸引了各国无数研究人员的青睐。以美国为首的西方国家在无人机领域的研究极大推动了相关技术的发展。下面将分别介绍智能空战决策技术、深度强化学习技术的研究现状。

1.2.1 智能空战决策技术

经过长时间的发展，目前主流的智能空战决策研究方法可以分为四个分支，基于博弈论的方法，基于启发式优化理论的方法，基于知识的方法和基于人工智能的方法^[13]。相关算法的出现时间见图 1.2。




图 1.2 智能空战决策算法的发展

Fig. 1.2 Development of intelligent air combat decision-making algorithms

博弈论是一种研究具有斗争或者竞争性质现象的数学理论，它提供了一种系统分析决策问题的方法，其中有多参与者追求各自的目标，博弈的结果就是参与者的收益值。通过博弈论，可以确定对抗对手的最佳策略^[14]。在该方法中，通常使用博弈矩阵法和纳什均衡策略来生成无人机的智能决策。算法实时执行决策过程来获得预测状态，然后比较预测得分并选择最佳策略。例如，Cruz 等人将摧毁敌方阵地作为无人机的目标，无人机采用非零和动态博弈论的方法对目标函数、控制变量和状态变量进行建模，实现了无人机的智能化决策^[15]。Austin 等人使用博弈矩阵法在丘陵地形的一对一空战中为低空飞行的无人机生成智能决策，提出的算法使得无人机在复杂环境的空战中战胜对手^[16]。Qian 等人针对不完全信息的近距离空战问题，提出了一种多机协同的智能决策方法，通过建立状态预测影响图模型解决了近距离空战中的决策问题^[17]。值得注意的是，虽然博弈论可以解决决策相关的问题，但是由于空战环境的复杂性和动态性，基于博弈论的数

学模型难以建立，其解的充分性和必要性也难以证明^[18]。

启发式优化算法是在问题复杂或者求解时间有限的情况下寻求优化问题的优质可行解的一种方法。它将空战问题合理转化为优化问题来寻求可行解，无人机与敌机之间的博弈过程可以通过价值函数来评估，最终得到最好的解决方案^[19]。例如，Yan 等人在多无人机目标分配模型中提出了一种匈牙利融合遗传算法。它使用匈牙利算法生成可行解作为遗传算法初始种群中的特殊个体，然后将分配模型中的目标函数作为拟合函数来优化结果。成功提升了多无人机任务分配的效率和准确性^[20]。Hu 等人提出了一种改进的蚁群算法，它集成了路径选择、信息素更新和信息素浓度间隔的改进，解决了传统蚁群算法的局部最优问题，实现复杂环境下多无人机的智能决策^[21]。Kaneshige 等人利用人工免疫算法使无人机能够掌握针对不同空战情况下的响应策略，通过建立包含任务成功和失败场景的数据库，使得无人机在面对相似场景可以快速反应。结果表明，人工免疫算法可以合理运用于空战决策中^[22]。然而，由于空战任务往往是一个高维连续的过程，大多数启发式优化算法无法实时执行并满足现实条件下的约束要求。

基于知识的方法则集成了大量数据，它采用关联规则的形式来描述数据之间的关联知识，并运用关联规则来得到相应条件下的最佳策略。例如，Huang 等人将空战博弈建模为马尔可夫决策过程，根据情节评估结果来自适应调整影响因素的权重，使得目标函数更加合理。通过近距离作战仿真，验证了本方法在空战问题的优越性^[23]。Huang 等人从大量飞行数据中获取知识来建立空战专家系统^[24]。通过重建空战经验缓冲区，成功增加了样本的多样性，提高了探索和利用效率。利用单架无人机仿真验证了该方法的有效性。由于人类的知识和经验目前仍难以概括为规则和数学描述，基于知识的方法还无法满足数据库之间的复杂映射。

基于人工智能的方法可以进一步细分为监督学习和深度强化学习两类。监督学习是利用已知类别的数据来预测结果的方法。Xi 等人提出了一种基于在线学习的半监督分类框架的空战目标机动识别模型，从提高样本标注效率的角度实现了空战目标机动的在线识别^[25]。Zhao 等人构建了一种新型决策树方法，将无人机和敌方信息作为决策树的输入，从不同方面对空战态势进行评估。与传统的贝叶斯网络相比，本方法有更好的性能^[26]。深度强化学习则是一种通过试错机制来学习策略的方法。You 等人在认知电子战框架中使用基于深度强化学习的导航决策框架，创建了一个目标跟踪模拟器，实现了无人机在不同环境下对目标的跟踪^[27]。Li 等人提出了一种并行自演训练的 SAC 算法来提高无人机控制决策的泛化性能，实现了多机作战环境下的策略共享并得到高质量的实时决策^[28]。考虑到上述方法在训练中需要大量样本，通过不断的试错来对模型进行改良，算法的求解速度和准确性仍面临严峻挑战。

无人机在三维空间中面临着巨大状态空间，这对固定结构神经网络的泛化能力提出了挑战^[29]。深度强化学习考虑即时奖励反馈和未来长期奖励反馈，使得无人机能够长期学习最优策略。深度强化学习目前在空战领域应用广泛，如弹道规划、目标跟踪、自主着陆、群体控制、目标分配等技术^{[30] [31] [32]}。

随着军事装备的发展，退役战斗机的无人改造、微型飞行器和无人机的联合作战、集群技术等新的无人机应用方式应运而生。无人机可以在不考虑飞行员限制的情况下进行更灵活的机动。在复杂空战态势下，具有高质量高稳定性机动决策能力的无人机能够快速掌握空战优势，充分利用其机动性能完成作战任务。目前，深度强化学习越来越广泛地应用于机动决策领域。虽然神经网络的训练需要大量的时间和计算资源，但强化学习特有的试错机制和算法强大的数据拟合能力，使得深度强化学习能够提供出更高质量的机动策略。

深度强化学习方法虽然需要大量样本进行训练试错，但其所具备的特点非常适用于解决高维度、动态的空战决策问题，因此本课题采用深度强化学习方法来求解无人机智能决策问题。下一小节介绍深度强化学习研究现状。

1.2.2 深度强化学习方法

深度强化学习是一种将强化学习和深度学习结合的通用范式。其主要目的是解决策略优化问题。在这种范式下，深度强化学习通过学习环境状态和动作之间的关系，决定在面对特定环境时执行哪种动作，以实现奖励最大化。近年来，深度强化学习技术在智能决策领域取得了广泛应用，其分析和应用也受到了学术界和工业界的广泛关注和认可。

在深度强化学习发展的早期阶段，主要用于各种二维电子游戏，如雅达利游戏^[33, 34]。随着 AlphaGo 使用深度神经网络和蒙特卡洛树搜索成功击败国际象棋世界冠军^[35]，人们对强化学习越来越感兴趣。2017 年 Deep Mind 发布新版 AlphaGo Zero，仅仅用了 3 天时间，就以 100% 的胜率战胜了 AlphaGo^[36]。将深度强化学习用于无人机智能空战决策是一种有效方法，无人机可以与环境互动不断进行试错，通过迭代获得不同环境下的最佳策略。

深度强化学习算法可以分为三大类，即基于值的方法、基于策略梯度的方法和基于函数的方法。

在基于值的强化学习中，智能体的目标是在一系列动作的长期运行中找到最大化价值函数的策略。常见的方法包括 Q-Learning、Sarsa 和 DQN 等。1992 年，Watkins 等人首先提出了 Q-Learning 方法^[37]，它是基于动态规划的思想，使用一个 Q 函数来评估每个状态动作对的回报，并给出最好策略。对于有限环境状态下的问题，Q-Learning 方法可以取得较好的效果。但当环境变得更加复杂以及状态样本数目增多（如空战决策问题）

时，很容易陷入计算过载以及局部最优解等问题中。

随着人工智能和神经网络的发展，人们自然想到将神经网络运用到强化学习的决策中，由此产生了深度强化学习算法。2013 年，Mnih 等人提出的 DQN 算法^[38]，是深度强化学习的典型代表。它使用卷积神经网络作为模型，并使用 Q-learning 方法的一种变体进行训练，同时将经验回放技术和随机小批量经验更新结合，来优化神经网络的训练过程。实验结果表明，DQN 在大多数雅达利游戏中超过了之前的算法并且与人类专家表现相当。从此，DQN 被广泛运用于离散动作环境下的决策。

自 DQN 成功之后，人们提出了大量的改进算法。Hasselt 等人提出了 Double DQN 算法^[39]。通过将最大 Q 值的运算解耦为对动作的选择和评估，降低了最大 Q 值的过高估计风险。Schaul 等人提出了基于经验重放机制的改进 Double DQN 算法，通过计算经验池中的每个样本的优先级，优先对高重要性样本进行采样^[40]。Hausknecht 等人通过用递归 LSTM 替换第一个后卷积连接层，研究了在 DQN 中添加递归的效果，更好的判断动作对当前状态造成的影响^[41]。

在基于策略梯度的强化学习中，智能体必须找到导致目标函数最优值的策略。与基于值的强化学习相比，基于策略梯度的强化学习不仅能够避免值函数误差导致的策略退化，而且更容易应用于连续动作空间的问题上。Actor-Critics 是一种广泛使用的策略梯度算法^[42]。Actor 是策略网络，用来控制智能体动作，Critic 是价值网络，用来给动作评分。Critic 对一步动作的评价使得算法可以单步更新，提高算法的学习和更新效率，然而策略网络和价值网络的相互依赖，会导致算法难以收敛。

2014 年，Silver 等人提出了确定性梯度策略算法(Deterministic Policy Gradient, DPG)^[43]，针对一个确定不变的状态，所选择的动作是确定的，这样就降低了所需的样本数目，它在一些基于高维动作空间的环境中所做的决策，明显优于同等条件下的随机策略梯度算法。在此基础上，Timothy 等人结合了 DPG 和 Actor-Critics 算法，同时采用了 DQN 的经验池机制，提出了深度确定性策略梯度算法^[44]，解决了 DQN 无法处理连续动作空间问题的缺点。

针对随机策略梯度方法选择动作的随机性，Schulamn 等人提出了置信域策略优化算法(Trust Region Policy Optimization, TRPO)^[45]，通过限制策略改变范围来避免每次迭代中策略参数变化过大的情况，其在控制领域有着很好的表现。然而该算法实现较为复杂，计算量也较大。针对这一情况，Schulamn 等人提出了近端策略优化算法^[46]，它是在 TRPO 算法基础上的改进，在实际使用中实现更加简单，计算量更小，成为了当时研究新问题的主流算法。

基于模型的强化学习则是提供环境模型，或者要求智能体学习环境模型，以便在特

定环境中执行任务。基于模型的强化学习由于模型的存在，智能体可以先从中学习对应动作的好坏，减少了智能体在真实环境中的探索次数，优化了智能体学习效率。

最传统的基于模型的强化学习方法一般是建立过度模式和奖励模式，而另一种创新方法是由 David 等人提出的价值等价模型，它构建了一个抽象的马尔可夫决策过程模型，从相同的真实状态出发，在抽象的马尔可夫决策过程中预演轨迹的累计奖励和真实环境中的轨迹累计奖励相匹配^[47]。目前比较先进的基于模型的方法是由 Schrittwieser 等人提出的 MuZero 算法，它能够学习一个隐式的环境模型，通过此模型预测未来的状态、奖励和终止情况，这使得其能够在不了解环境动力学的环境下进行有效的规划，实现了高效的强化学习^[48]。MuZero 算法在围棋、国际象棋、将棋以及雅达利游戏中表现出色，成为强化学习领域的重要突破。

1.3 论文研究思路及目标

空战战场环境复杂，设计出在复杂且瞬息万变的战场环境下的智能作战决策方法，深入理解竞争对手意图、增强战场态势理解，提高作战决策速度和准确性是空战博弈对抗研究的重点。现有的方法在准确性、鲁棒性以及抗噪能力等方面存在挑战，为解决这些问题，本文拟研究基于最优传输定理和性能差异定理的无人机近端策略优化算法，以提高作战决策的准确性和鲁棒性。同时，本文针对多机自主空战决策问题，提出一种基于强化学习的多无人机对抗决策算法，搭建无人机的对抗仿真环境，开展具体的无人机对抗仿真实验。本文的具体研究内容包括：

第一、传统无人机空战实时交互方法可能会导致成本高昂且进程缓慢等问题。为了解决这些问题。本文对常见的智能算法进行分析比较，基于离线强化学习方法对无人机进行智能决策，提出了可以克服无人机训练数据缺少标注的最优传输度量算法，在给定无人机对抗专家演示的情况下，使用最优传输定理对无人机训练数据进行特征关联表征并添加奖励标签。以确保标注后的数据可以被强化学习算法用于寻找良好策略，进而保证无人机智能决策的准确性和稳定性。

第二、传统离线强化学习方法由于过高估计分布外策略而表现不佳，本文基于性能差异定理构建了一种行为近端策略优化算法。算法通过限制学习策略和行为策略之间的比率在一定范围内，合理避免了常见的分布外延问题。此外，针对复合动作中整体动作和子动作之间的平衡维系问题，通过为每个子动作单独建立损失并引入一个由单独动作概率和联合动作概率结合的复合动作混合损失，来确保子动作和复合动作的整体性。

第三、针对无人机集群的对抗决策问题，本文提出了一种新颖的个体团队协同探索方法。通过图注意网络和专家知识将整体态势转化为简单的抽象关系图，摆脱大量细节

而专注于关键关系，降低策略的学习难度。随后将个体作为独立的探索单元，通过试错和采样来发现有效的行动模式。团队策略也不断从个体的探索经验中汲取知识，使得团队策略得以持续完善和进化。同时，为了平衡探索与利用，采用一种动态调整的强化学习探索目标。将个体的“惊喜程度”定义为其状态分布的熵值，通过追求低熵状态分布作为内在探索动机。在此驱动下，多智能体系统将通过分布式策略学习，使得整个系统朝着较为确定和可预测的状态空间方向收敛。




图 1.3 本文结构示意图

Fig. 1.3 Structure diagram of this thesis

本文共计包含五个章节，行文路线如图 1.3 所示，围绕上述提到的研究内容，具体章节安排如下：

第 1 章，绪论。详细介绍了现代战争下无人机智能对抗的研究背景和研究意义，以及人工智能技术在无人机自主决策研究中的应用和发展现状，具体分析了无人机智能空战决策技术、深度强化学习方法研究的国内外现状，并对本文的主要研究内容和组织架构进行了阐述。

第 2 章，相关理论和概念基础。首先介绍了无人机空战环境中所需要的运动控制模型、状态空间以及机动数据库。然后对马尔可夫决策过程进行了说明，由此引出了强化学习和离线强化学习的基本原理。最后，阐述了多智能体强化学习理论和马尔可夫博弈模型，详细分析了三种多智能体强化学习架构以及相关概念。

第 3 章，最优传输支撑下的行为策略优化的无人机对抗决策方法。本章详细阐述了算法的构建思路和技术特点。引入最优传输定理来标注缺乏奖励标签的离线数据集。使用性能差异定理对行为策略进行单调改进，限制学习策略和行为策略的比率，使得学习到的策略接近于行为策略。为了处理复合动作环境中存在的问题，提出了混合损失函数。最后，在不同任务中验证了所提出算法在无人机对抗任务中的有效性，同时进行消融实验证明所有模块的必要性和合理性。

第 4 章，基于惊喜最小化的个体团队策略结合算法的无人机群对抗方法。首先采用图注意网络和专家知识结合的方法，将关键关系联合推理成抽象关系图，降低了后续算法的收敛难度。随后引入个体团队协同探索框架，分别构建个体策略和团队策略，二者同时更新，并利用 KL 散度和裁剪操作控制个体团队策略之间的差异。最后引出基于惊喜最小化的合作探索方法，用于解决多智能体合作学习中出现的状态不确定性的具体挑战。实验部分，在四种不同场景上进行四对四无人机对抗实验，评估结果表明，所提出的方法提高了多智能体强化学习的探索效率和胜率，验证了本章算法的有效性。

第 5 章，结论。总结了本文所提出的方法对无人机决策对抗以及智能化战争领域的实际意义，探讨了研究方法存在的局限性并对该领域未来的发展进行了展望。

2 相关理论和概念基础

2.1 无人机空战环境研究

无人机空战是一个复杂的动态过程。随着无人机性能的不断提高，空战战术也随之发展。智能机动决策的核心是基于作战经验和实时态势生成和评估多个可能的作战机动序列^[49]。在实际作战中，无人机需要根据环境变化和态势变化，合理选择自己的动作，形成有效的作战方案。对无人机空战环境进行分析研究，为本文后续相关研究提供了理论基础。

2.1.1 无人机运动控制模型

无人机在飞行过程中有六个运动自由度。本文设计的算法主要关注运动控制，忽略了无人机的动力学模型，因此将其简化为三维空间中的质点模型。使用飞行速度、三维坐标和姿态角等物理量来描述无人机的态势。无人机的状态可以用图 2.1 表示。




图 2.1 无人机三维空间状态描述

Fig. 2.1 UAV state description in three-dimensional space

其中， $\{x, y, z\}$ 分别表示无人机在地面参照系下的三维坐标；单位矢量 v 表示无人机的速度； θ, ψ, ϕ 为姿态角，分别对应俯仰角、偏航角和滚转角。

通过分析无人机的运动特征，得到了简化的无人机动力学方程。方程中的每一项分别表示无人机的飞行速度、偏航角、俯仰角和三维空间坐标值的一阶微分方程。它们决定了无人机战斗过程中状态更新的计算方法。其中， $(\frac{dx}{dt}, \frac{dy}{dt}, \frac{dz}{dt})$ 表示速度在 3 个坐标轴上的分量。 g 表示重力加速度。 N_x 为切向加速度，是在速度方向的推力和自身重力的比值。它决定了加速、减速和匀速飞行等动作。 N_z 为法向加速度，是在垂直于机身平面向

上方向上受到的推力和自身重力的比值。它决定了平飞、拉升和俯冲等机动动作。在给定初始状态后，使用切向加速度、法向加速度和滚转角进行相应的运算，可以不断推算出后续状态的位置、速度和姿态等信息。该模型在现有研究中已经得到广泛应用^[50]。

$$\begin{cases} \frac{dv}{dt} = g(N_x - \sin \theta) \\ \frac{d\psi}{dt} = \frac{gN_z \sin \varphi}{v \cos \theta} \\ \frac{d\theta}{dt} = \frac{g}{v}(N_z \cos \varphi - \cos \theta) \\ \frac{dx}{dt} = v \cos \theta \cos \psi \\ \frac{dy}{dt} = v \cos \theta \sin \psi \\ \frac{dz}{dt} = v \sin \theta \end{cases} \quad (2.1)$$

2.1.2 状态空间

状态空间通常由问题本身决定，是一个预先定义的集合，表示系统或者智能体可能处于的所有状态。例如，在描述天气变化的状态空间中，可以定义为{晴天、多云、雨天、雾霾天}，其中每个状态代表一种自然天气情况。通过整合红蓝无人机的状态，结合相关任务情况，可以对空战态势进行评估。特别地，选择以下 12 维状态空间^[28]：

$$S = [v_r, x_r, y_r, z_r, \theta_r, \psi_r, v_b, x_b, y_b, z_b, \theta_b, \psi_b] \quad (2.2)$$

其中，下标为 r 和 b 的元素分别代表红方和蓝方的状态。在智能空战中，红蓝双方的实时态势都将分别作为奖励值的来源。使用 v_r 和 v_b 两个单位向量来表示双方的飞行方向。 d_r 和 d_b 表示双方的相对位置向量。相对态势信息可表示为：

$$\begin{cases} v_r = [\cos \psi_r \cos \theta_r, \sin \psi_r \cos \theta_r, \sin \theta_r] \\ v_b = [\cos \psi_b \cos \theta_b, \sin \psi_b \cos \theta_b, \sin \theta_b] \\ d_r = -d_b = [x_b - x_r, y_b - y_r, z_b - z_r] \end{cases} \quad (2.3)$$

相对态势信息和地面坐标系之间的关系可定义为：

$$\begin{cases} d = |d_r| \\ q_r = \cos^{-1} \frac{v_r d_r}{d} \\ q_b = \cos^{-1} \frac{v_b d_b}{d} \end{cases} \quad (2.4)$$

其中， d 表示双方的相对距离， q_r 和 q_b 表示速度和质心之间的夹角。

2.1.3 无人机机动数据库

机动数据库是无人机机动决策的基础，无人机的战术动作主要可以分为两类：第一

类是以经典战术飞行动作为基础设计的战术数据库，包含来自实战的复杂的战术动作，如筋斗、滚转、桶滚等；另一种是构成复杂机动动作的基本机动动作，即美国国家航空航天局学者提出的基本战斗机动数据库^[51]，包含 7 种基本动作（如图 2.2 所示）。这两种数据库已广泛应用于相关研究。




图 2.2 无人机基本战斗机动集合

Fig. 2.2 The basic fight maneuvering collection of the UAV

对于上述七种机动动作，使用切向加速度、法向加速度和滚转角进行控制。在模拟过程中，使用 $[N_x, N_z, \varphi]$ 三元组表示每个时刻的动作。七种不同的机动指令如表 2.1 所示。

表 2.1 基本机动动作指令

Tab. 2.1 The commands for the basic fight maneuvers

机动动作	切向加速度 N_x	法向加速度 N_z	滚转角 φ
定速	0	1	0
加速	-0.3	1	0
减速	0.3	1	0
右转	0	1.9	$\pi/3$
左转	0	1.9	$-\pi/3$
俯冲	0	-1.5	0
爬升	0	1.5	0

2.2 强化学习

近年来，强化学习技术的快速发展为无人机空战决策提供了一种高效的解决方法。强化学习算法无需历史数据和标注，可以主动学习环境，已成为人工智能领域的重要分支。相比传统的智能空战决策技术，强化学习可以将各部分合理串联起来，实现相互作

用和协同, 凭借少量的先验信息和专家知识完成复杂任务, 提高工作的稳定性和准确性。

2.2.1 马尔可夫决策过程

马尔可夫决策过程 (Markov Decision Process, MDP) 是求解序贯决策问题的经典方案^[52], 它是所有强化学习的基础理论。在强化学习中, MDP 所描述的环境通常是完全可观察的, 环境的马尔可夫性表示任何一个时刻对应的状态只和上一时刻的状态和动作有关, 与之前的任何时刻状态都无关。

马尔可夫决策过程通常用五元组 $M = \{S, A, P, R, \gamma\}$ 表示, 各元素的含义如下所示:

(1) S 代表状态空间。状态是对环境的描述, 在智能体做出动作后, 状态会发生变化, MDP 中所有可能出现的状态的集合是状态空间。

(2) A 代表动作空间。动作是对智能体行为的描述。MDP 中智能体所有可能的动作的集合是动作空间。

(3) P 代表状态转移概率。表示在 t 时刻智能体执行动作 a_t 后, 当前状态以某种概率转移到另一个状态。

(4) R 代表奖励函数。表示智能体做出动作后环境对智能体的反馈。

(5) γ 代表折扣因子。表示当前状态对后续所有状态的影响程度。

在 MDP 的框架下, 智能体的目标就是最大化每一个状态下的期望累计奖励。智能体将不断和环境进行交互, 从当前状态转移到下一状态时, 从环境中得到回报。价值函数是指基于策略 π 选择动作后与环境交互得到的预计长期回报。是当前状态下智能体如何采取行动的估计。值函数一般包括状态价值函数 $V(s)$ 和状态-动作值函数 $Q(s, a)$:

$$V(s) = E[R_t | s_t = s] \quad (2.5)$$

$$Q(s, a) = E[R_t | s_t = s, a_t = a] \quad (2.6)$$

当策略 π 确定时, 依据马尔可夫性质, 状态值函数满足贝尔曼方程, 可以描述出当前状态值函数和下一时刻状态值函数之间的转化关系:

$$V_\pi(s) = \sum_{a \in A} \pi(a|s) (r + \gamma \sum_{s' \in S} P(s'|s, a) V_\pi(s')) \quad (2.7)$$

同样, 也可以利用贝尔曼方程描述相邻两个时刻的状态-动作值函数的关系:

$$Q_\pi(s, a) = r + \gamma \sum_{s' \in S} P(s'|s, a) \sum_{a' \in A} \pi(a'|s') Q_\pi(s', a') \quad (2.8)$$

2.2.2 强化学习基本原理

强化学习的概念最早在 1954 年被提出。由于其自主学习能力和探索能力, 强化学习与监督学习和无监督学习并称为机器学习的三大技术。监督学习为每个样本提供具体标注, 而无监督学习不对数据做任何标注, 而是通过研究大量样本数据发现其分布规律。

强化学习不属于监督学习也不属于无监督学习，它是智能体和环境交互获取奖励的过程，解决的是序列决策优化问题。强化学习由五个关键要素组成：环境（Environment）、状态（State）、智能体（Agent）、动作（Action）和奖励（Reward）。智能体在环境中不断探索学习，尝试各种动作获得相应奖励。经过持续学习，最终学会一种可最大化预期奖励的优化策略。在强化学习中，状态和动作是核心的两个因素，强化学习的整体框架如图所示：




图 2.3 强化学习系统模型

Fig. 2.3 Reinforcement Learning system model

智能体：是人工设定出的实体，它是环境中动作的主题。

环境：智能体位于的场景，它是与智能体交互的对象。

状态：对智能体当前所处环境的整体概括。

在 t 时刻，智能体处于状态 s_t 下，执行动作 a_t 后，环境将从状态 s_t 转变为状态 s_{t+1} ，并生成相应的奖励 r_{t+1} ，智能体不断重复上述过程直到达到任务终止条件，状态动作对将生成一个序列集合 τ ：

$$\tau = \{s_1, a_1, s_2, a_2, \dots, s_T, a_T\} \quad (2.9)$$

在过程中，智能体通过不断与环境进行交互，利用获取到的奖励（正奖励和负奖励）来优化状态动作对之间的映射关系，最终得到能够获取累计最大奖励的最优策略。

2.2.3 离线强化学习

离线强化学习是一种数据驱动的强化学习范式，它从以前收集的离线数据集中学习离线策略。在数据收集成本高昂或者存在危险无法进行在线交互的环境中（如自动驾驶、医疗保健和空战对抗等），这种范式极具价值。

离线强化学习中，智能体不选择与环境实时交互，不收集交互产生的样本，而是利用未知的行为策略 π_B 所收集到的数据集进行训练，智能体依靠这些数据集学习新的改进

策略，而无需进一步和环境进行交互。这种数据驱动模式的前景令人鼓舞^[53]，人们对于解决强化学习实际应用寄予厚望。

目前离线强化学习还存在一些问题，离线强化学习完全依赖于离线数据集，由于它无法和环境互动，智能体无法通过探索找到一些数据集不存在的更高收益动作。从本质上讲，当使用学习到的模型或者策略来行动时，不可避免的会出现一些与训练过程所不同的状态，一旦智能体发现训练分布之外的状态，它可能会犯更大的错误。由于没有任何策略进行参考，这种错误会不断加剧，直到行为策略和训练时的学习策略完全背离，这种行为称作行为策略和学习策略之间存在的分布转移。

因此，定义了离线强化学习的分布转移概念，将贝尔曼方程应用到离线数据集中，得到以下损失函数：

$$J(\phi) = \mathbb{E}_{s,a,s' \sim D} [(r(s,a) + \gamma \mathbb{E}_{a' \sim \pi_{off}(\cdot|s)} [Q_\phi(s',a')] - Q_\phi(s,a))^2] \quad (2.10)$$

其中， ϕ 是上文提到的状态-动作值参数。 π_{off} 为目标策略。下一步的动作 a' 应该从当前评估的策略中产生，即为目标策略。而算法的样本则是依靠行为策略 π_b 生成的数据集产生，只有当 $\pi_{off} = \pi_b$ 时，才能准确估计状态-动作值函数。然而离线强化学习的最终目标是让学习到的目标策略超过行为策略，这就产生了矛盾。此外，即使目标策略能够准确评估训练数据上的目标，但由于采样或者函数近似的误差，状态分布仍然可能出现偏差，价值函数难以收敛导致最终学习失败。

2.3 多智能体强化学习

过去几年中，学术界一直致力于研究单智能体与环境的交互。但近年来，随着人工智能的发展，越来越多的学者开始研究多智能体在环境中的交互。在多智能体环境中，每个智能体不仅要考虑自身的最优决策，还需要考虑其他智能体的影响。多智能体环境通常分为混合、合作和对抗三种场景，本文的研究内容主要集中在合作场景中。随着智能体数量增多，环境的随机性和复杂性以及动作空间和状态空间的指数级增长，都增加了研究难度。

多智能体强化学习（Multi-Agent Reinforcement Learning, MARL）是通过多个智能体之间合作或者对抗来学习最优策略的算法，环境被建模为马尔可夫博弈模型^[54]，它由六元组 $M = \{N, S, A, P, R, \gamma\}$ 组成。其中， $N = \{1, \dots, N\}$ 表示智能体的集合， $S = S_1 \times \dots \times S_N$ 表示所有智能体可以观察到的状态空间， $A = A_1 \times \dots \times A_N$ 表示所有智能体的动作空间， $P = S \times A \rightarrow \Delta(S)$ 表示任何复合动作 $a \in A$ 从状态 $s \in S$ 到任何状态 $s' \in S$ 的转移概率， $R = S \times A \times S \rightarrow \mathbb{R}$ 表示所有智能体的奖励集合， γ 表示折扣因子，范围是从 0 到 1，代表了未来奖励的重要性。

MARL 过程是一个迭代过程，每个智能体按照约定顺序与环境互动。在每个时间步中，智能体读取当前状态并根据自己的策略选择一个动作。所有智能体的复合动作组成一个全局动作与环境互动，环境给予智能体奖励和新的状态。求解的过程就是计算出一个最佳策略使得联合奖励函数的值最优。

通过以上形式化的定义，可以借助强化学习算法来对模型进行处理。目前解决多智能体问题的强化学习架构主要有三种：完全分布式、完全集中式、集中式训练分布式执行。三种架构如图 2.4 所示，在此分别介绍几种方法。




图 2.4 多智能体强化学习架构

Fig. 2.4 Multi-Agent Reinforcement Learning frameworks

完全分布式是指分布式训练和分布式执行。每个智能体都有自己的奖励函数，不考虑其他智能体的状态，在自己的环境中独立地进行学习。每个智能体将其他智能体视为自身环境的一部分，通过输入自己的观测信息来输出动作，即每一个智能体都在进行单独的强化学习。这样做的优点是整个系统有着良好的扩展性，不会因为智能体数量的增加引起维度灾难导致系统无法继续训练。然而整个系统的环境是非稳态的，整体训练是否收敛不能保证。

完全集中式是指集中式训练和集中式执行。所有智能体作为一个整体进行合作，依

靠中央控制器接受所有智能体的消息，并为每个智能体选取合适的动作。这样做的好处是，由于中央控制器拥有所有智能体的状态和动作，因此对于这个系统来说，环境是稳态的，强化学习算法的收敛性可以得到保证。然而，如果智能体数量不断增加，所有智能体的信息不断堆叠拼凑，可能会导致维度爆炸问题，训练时间和复杂度会大幅提升。

为了克服上面两种方法的局限性，提出了集中式训练分布式执行这一方法^[55]。它意图通过集中式训练和分布式执行来优化每个智能体。在训练阶段，所有智能体通过中央控制器共享同一组参数，参数根据训练过程不断更新。这使得不同智能体可以从彼此之间相互学习，同时获得环境的所有观测信息，使得智能体团队之间有着良好的协同合作。在执行阶段，每个智能体根据自身需求布置网络，生成自己的策略，而不需要中央控制器的参与。在动态复杂的环境中，这种方式更具有稳定性和扩展性。

2.4 本章小结

本章主要围绕无人机空战环境研究、强化学习方法和多智能体强化学习方法进行了简单的介绍。首先介绍了无人机空战环境中所需的运动控制模型、状态空间和机动数据库。接着阐述了马尔可夫决策过程，并由此引出了强化学习和离线强化学习的基本原理。最后，介绍了多智能体强化学习理论和马尔可夫博弈模型，详细分析了三种多智能体强化学习架构以及相关概念。

3 最优传输支撑下的无人机对抗行为策略优化方法

3.1 引言

随着人工智能、通信技术和集成传感器技术的发展，各国对无人机对抗的需求日益增加，通过强化学习的方法对其进行分析，可以帮助科研人员更有针对性的开展相应领域技术的研究。此外，随着强化学习的快速发展，其强大的自主训练能力非常适用于无人机智能决策分析。因此，基于强化学习的无人机智能决策算法已经在各个领域被学者们广泛研究。

尽管现有基于强化学习的无人机决策算法在性能上相比传统机器学习方法和统计分析方法有所提升，但这些方法仍存在一定的局限性。传统强化学习需要智能体与环境实时交互来收集经验，但在一些现实场景中，这种实时交互成本高昂且进程缓慢。为了解决这种问题，近年来兴起了离线强化学习方法。本文在 2.2.3 小节中详细介绍了离线强化学习的基本原理，与传统方法不同，离线强化学习不需要实时交互，而是直接从数据集中学习，在自动驾驶和医疗保健等领域已有应用。这种方法已经在自动驾驶和医疗保健等领域得到应用，通过模拟现实场景，让计算机参考数据集自动学习如何做出最优决策。然而，离线强化学习也存在一些局限性。由于缺乏在线数据的收集和反馈，离线强化学习会严重高估数据集以外的轨迹，策略无法正确利用这些分布外的行为。因此，如何设计更加鲁棒和高效的离线强化学习算法，提高在数据集外的泛化能力，是一个值得进一步研究的重要问题。

同时，对于数据集中的数据，离线强化学习需要利用奖励来评估，这使得离线强化学习方法不适用于无法手工设计出合适奖励的应用场景。即使尝试使用人类偏好来标记这些数据，这种方法的成本也会非常昂贵。除了人工标记数据，另一种告知智能体系统人类偏好的方法是提供专家演示。在机器人技术领域，这种“从示范中学习”的方法已经得到广泛应用，并被证明在缺乏明确奖励函数的情况下，也能够帮助机器人系统学习到良好的行为策略。对于许多应用程序来说，与指定奖励函数相比，提供专家演示更为自然。目前有两种流行的提供专家演示的方法：行为克隆和逆强化学习。行为克隆的目的是通过一个离线监督学习问题来重现专家演示。如果演示是高质量的，并且被很详细的记录下来，那么行为克隆可以很好地起作用^[56]，然而行为克隆对新情况的泛化通常不起作用。逆强化学习则是通过从专家演示中捕捉意图，推断出智能体的奖励函数。目前的算法只需少量专家演示就能获得良好的性能。虽然逆强化学习不需要很多演示，但它侧重于在线强化学习，需要与环境进行大量交互，这一方法并不适合离线学习。综上

所述，使离线强化学习能够利用未标记数据集是一个具有重要实用价值的开放问题。

大多数离线强化学习算法采用在线交互来选择超参数。这是因为离线超参数选择一直是一个缺乏完美解决方案的问题。如果学习到的策略能够比行为策略拥有更好的性能，那么离线强化学习的交互风险将大大降低。因此考虑在保证单调性的情况下，利用离线数据集来改进行为策略。

本章针对以上问题，设计了最优传输支撑下的行为策略优化算法（Optimal Transport Support Behavior Policy Optimization, OTSBPO）。本章的工作提出了以下方案：首先，在给定专家演示的情况下，使用最优传输定理为离线数据集中未被标记的轨迹添加奖励标签，标注后的数据集可以被离线强化学习算法用于寻找良好策略。其次，引入性能差异定理来评判运用离线数据集改进行为策略的好坏，并将在线策略改进算法用在基于离线数据集的优化行为策略上，它限制了学习策略和行为策略之间的比率在一定范围内，这使得学习到的策略接近于行为策略。最后，提出一种新的混合损失方法，通过约束比率范围和删除由过大跨度策略生成的数据的方法来改进算法，更好地解决复合动作环境中存在的问题。在实验部分，基于上述模型框架，完成了不同场景下的无人机对抗任务，展现了所提出方法的优异性能。并与先进的离线强化学习方法进行对比实验，本章的方法在任务中取得了更好的性能。

3.2 模型结构

3.2.1 模型整体结构




图 3.1 最优传输支撑下的无人机对抗行为策略优化算法整体结构

Fig. 3.1 Overall structure of UAV adversarial decision model based on Optimal Transport Support Behavior Policy Optimization

本章提出的模型整体结构如图 3.1 所示。首先使用最优传输定理来处理无标记的离线数据集，为数据集内的轨迹分配奖励：未标记的离线数据集 D 和专家演示 D_e 作为输入。求解每条无标记轨迹的最优传输问题，得到成本矩阵和最佳对齐矩阵，然后将标记完成的轨迹进行组合，得到带有奖励标签的完整离线数据集 D_{label} 。此外，还将性能差异定理运用到离线数据集上来优化行为策略。经过一系列分析，得出推论：通过最大化 $E_{s \sim \rho_D(\cdot), a \sim \pi(\cdot|s)}[A_{\pi_k}(s, a)]$ 和最小化 $\max_s D_{TV}(\pi || \pi_k)[s]$ ，可以使离线数据集持续改进策略。为了将这一推论作为优化目标来操作，通过重要性采样处理得到比率 $\frac{\pi(a|s)}{\pi_k(a|s)}$ 。为了解决总变差散度的问题，进行了裁剪操作，并将其纳入需要最大化的部分中。最后，在复合行动环境设置中，建议每个子动作单独计算损失，同时引入复合行动混合损失，将单独概率和联合概率相互结合来解决这个问题。基于以上实现细节，表 3.1 展示了整个模型的伪代码部分。

表 3.1 最优传输支撑下行为策略优化算法描述

Tab. 3.1 Description of Optimal Transport Support Behavior Policy Optimization

算法 3.1 最优传输支撑下行为策略优化算法

输入： 无标记数据集 D^u ，专家演示数据集 D^e

```

1: 初始化 $D^{label}$ 
2: foreach  $\tau^{(m)}$  in  $D^u$  do
3:    $C^{(m)}, \mu^{*(m)} \leftarrow \text{SolveOT}(D^e, \tau^{(m)})$  //Wasserstein 距离
4:   for  $t = 1$  to  $T$  do
5:      $r_{ot}(s_t^{(m)}) \leftarrow -\sum_{t'=1}^{T'} C_{t,t'}^{(m)} \mu_{t,t'}^{*(m)}$  //Wasserstein 距离的推导公式
6:   end for
7:    $D^{label} \leftarrow D^{label} \cup (s_1^{(m)}, a_1^{(m)}, r_1^{OT}, \dots, s_T^{(m)})$ 
8: end for
9: 通过行为克隆估算行为策略 $\hat{\pi}_b$ 
10: 通过 SARSA 计算 Q 函数 $Q_{\pi_b}$ 
11: 通过拟合返回值计算函数 $V_{\pi_b}$ 
12: 初始化 $k = 0$ ，设置 $\pi_k \leftarrow \pi_b$  &  $Q_{\pi_k} = Q_{\pi_b}$ 
13: for  $i = 1$  to  $N$  do
14:    $A_{\pi_k} = Q_{\pi_k} - V_{\pi_b}$ 
15:   通过最大化 $L_k(\pi)$ 来更新策略 $\pi$ 
16:   if  $J_{\Delta}(\pi) > J_{\Delta}(\pi_k)$  then
17:     set  $k = k + 1$  &  $\pi_k \leftarrow \pi$ 
18:   end if
19: end for
    
```

3.2.2 无人机训练数据集奖励标注

传统空战对抗数据的特点是样本数少并且生成样本的成本高昂。因此本节考虑在预处理环节对大规模无标记空战训练数据进行奖励标记，随后建立强化学习模型。本章的模型是完全依赖离线数据集的算法。与标准的强化学习设置不同，这一类型的算法缺乏明确的奖励函数。将 $\tau = (s_1, a_1, s_2, a_2, \dots, s_T)$ 表示为每个时间步 $t = 1, 2, \dots, T-1$ 的行为策略与 MDP 交互的序列。同时不使用奖励函数，而是使用一个由专家策略 π_e 生成的专家演示数据集 $D^e = \{\tau_e^{(n)}\}_{n=1}^N$ ，以及由任意策略 π_b 生成的大规模无标记数据集 $D^u = \{\tau_b^{(m)}\}_{m=1}^M$ 。整体目标是学习一种最优的离线策略 π ，它可以在不与环境发生任何交互的情况下，整合专家演示和大规模无标记数据集来得到奖励。综上所述，本节考虑使用最优传输定理来解决这个问题。

最优传输定理 (Optimal Transport, OT) 是比较概率测度的原则性方法，也被称为 Wasserstein 距离^[57]。与常见散度度量方法 (如 KL 散度、JS 散度) 不同的是，它在衡量分布差异的时候考虑了对应关系和局部几何特征，并能够提供更加精确的度量结果。

令 $\hat{p}_e = \frac{1}{T'} \sum_{t=1}^{T'} \delta_{s_t^e}$ 和 $\hat{p}_\pi = \frac{1}{T} \sum_{t=1}^T \delta_{s_t^\pi}$ 分别表示专家策略 π_e 和行为策略 π 的经验状态分布。离线强化学习的 Wasserstein 距离 (二阶平方) 定义如下：

$$W^2(\hat{p}_\pi, \hat{p}_e) = \min_{\mu \in M} \sum_{t=1}^T \sum_{t'=1}^{T'} c(s_t^\pi, s_{t'}^e) \mu_{t,t'} \quad (3.1)$$

其中， M 表示耦合矩阵集， c 为价值函数， δ_x 代表 x 的狄拉克测度。该式可以用来评估专家策略和行为策略之间的距离。令 μ^* 表示该优化问题的最优耦合。随后，通过公式 (3.1)，得出奖励信号：

$$r_{OT}(s_t^\pi) = - \sum_{t'=1}^{T'} c(s_t^\pi, s_{t'}^e) \mu_{t,t'}^* \quad (3.2)$$

利用公式 (3.2) 中的奖励函数，为无标注数据集标注奖励信号。通过计算专家演示和离线数据集之间的匹配，可以为数据集中的每一条轨迹分配奖励。表 3.1 的前半部分概述了本节的方法，将无标记数据集 D 和专家演示 D^e 作为输入。为了解决每个无标记轨迹的最优传输问题，考虑使用 Sinkhorn 算法进行此计算，获得成本矩阵和最优耦合矩阵。同时使用公式 (3.2) 计算每个时间步的奖励标签。随后，合并所有完成标记的轨迹，生成一个完全的离线数据集 D^{label} 。

在对离线数据集进行奖励标注后，可以利用离线强化学习算法来学习策略。由于处于离线环境中，更倾向于采用一种能够最大程度减少分布偏移的离线强化学习算法。与之前专注于在线奖励计算的工作不同，本节的重点在于生成高质量的奖励标签。此外，

在进行离线强化学习训练之前，完全离线的计算出奖励标签，从而避免了修改离线强化学习算法的任何部分。图 3.2 描述了最优传输定理使用专家演示为无标记数据集标注奖励的整个流程。




图 3.2 最优传输法示意图

Fig. 3.2 Illustration of Optimal Transport

3.2.3 行为策略的离线改进算法

在强化学习中，值函数通常用来衡量某个策略的期望收益或者价值。给定一个策略 π ，其值函数记作 $J(\pi)$ ，表示在该策略下的期望收益。假设折扣后的非归一化访问频率为 $\rho_\pi(s) = \sum_{t=0}^T \gamma^t P(s_t = s | \pi)$ 。其中， $P(s_t = s | \pi)$ 表示策略 π 生成的轨迹中，第 t 个状态等于 s 的概率^[58]。对于任意两个策略 π 和 π' ，性能差异定理 $J_\Delta(\pi', \pi) \triangleq J(\pi') - J(\pi)$ 可以用优势函数来衡量：

$$J_\Delta(\pi', \pi) = E_{\tau \sim P_{\pi'}(\tau)} \left[\sum_{t=0}^T \gamma^t A_\pi(s_t, a_t) \right] = E_{s \sim \rho_{\pi'}(\cdot), a \sim \pi'(\cdot|s)} [A_\pi(s, a)] \quad (3.3)$$

可以通过最大化公式（3.3）来改进策略，将其用于离线数据集来改进行为策略。因此，利用性能差异定理对离线数据集改进行为策略进行理论分析，通过离线数据集 D 改进由行为克隆生成的 $\hat{\pi}_b$ ：

$$J_\Delta(\pi, \hat{\pi}_b) = E_{s \sim \rho_\pi(\cdot), a \sim \pi(\cdot|s)} [A_{\hat{\pi}_b}(s, a)] \quad (3.4)$$

通过最大化这个等式，可以得到一个优于行为策略 $\hat{\pi}_b$ 的策略。然而，由于期望值依赖于新策略的状态分布，因此有必要用旧策略的状态分布来替代新策略的状态分布，然后衡量这种替代所带来的误差。其过程是一个很难求解的方程。因此，使用从离线数据集中恢复的状态分布 $\rho_D(s)$ 来替换。其中， $\rho_D(s) = \sum_{t=0}^T \gamma^t P(s_t = s | D)$ 代表离线数据集中第 t 个状态等于 s 的概率。所以考虑用下式替代 $J_\Delta(\pi, \hat{\pi}_b)$ ：

$$\hat{J}_\Delta(\pi, \hat{\pi}_b) = E_{s \sim \rho_D(\cdot), a \sim \pi(\cdot|s)} [A_{\hat{\pi}_b}(s, a)] \quad (3.5)$$

为了区分两个公式之间的差异，引入了 $E_{s \sim \rho_{\hat{\pi}_b}(s), a \sim \pi(\cdot|s)} [A_{\hat{\pi}_b}(s, a)]$ ，其中 $\rho_{\hat{\pi}_b}(s)$ 代表状态分布。此外，利用总变差散度 $D_{TV}(\pi || \hat{\pi}_b)[s] = \frac{1}{2} E_a |\pi(a|s) - \hat{\pi}_b(a|s)|$ 来量化状态 s 下

策略 π 和 $\hat{\pi}_b$ 之间的差异。将离线数据集 D 视为确定性分布，总变差散度定义为：

$$D_{TV}(D||\hat{\pi}_b)[s_t] = \frac{1}{2}(1 - \hat{\pi}_b(a_t|s_t)) \quad (3.6)$$

由此，得到以下约束：

$$\begin{aligned} J_{\Delta}(\pi, \hat{\pi}_b) \geq & \hat{J}_{\Delta}(\pi, \hat{\pi}_b) - 4\gamma A_{\hat{\pi}_b} \cdot \max_s D_{TV}(\pi||\hat{\pi}_b)[s] \cdot \mathbb{E}_{s \sim \rho_{\hat{\pi}_b}(\cdot)} [D_{TV}(\pi||\hat{\pi}_b)[s]] \\ & - 2\gamma A_{\hat{\pi}_b} \cdot \max_s D_{TV}(\pi||\hat{\pi}_b)[s] \cdot \mathbb{E}_{s \sim \rho_D(\cdot)} [1 - \hat{\pi}_b(a|s)] \end{aligned} \quad (3.7)$$

上式的第二项与强化学习 TRPO 算法^[45]一致，而第三项是特定用于离线数据集中的，它用于捕捉离线数据集 D 和行为策略 $\hat{\pi}_b$ 不匹配所造成的差异。当策略 $\hat{\pi}_b$ 确定后，第三项就可以视为一个常数。如果想要使得 $J_{\Delta}(\pi, \hat{\pi}_b)$ 最大化，应当将 $\mathbb{E}_{s \sim \rho_D(\cdot), a \sim \pi(\cdot|s)} [A_{\hat{\pi}_b}(s, a)]$ 最大化的同时将 $\max_s D_{TV}(\pi||\hat{\pi}_b)[s]$ 最小化，这样才能保证离线数据集 D 不断改进进行为策略 $\hat{\pi}_b$ 。

假设成功运用离线数据集 D 改进进行为策略 $\hat{\pi}_b$ ，得到新策略 π_k 。虽然上述方法可以保证策略 π_k 一定优于策略 $\hat{\pi}_b$ ，但是却不能保证 π_k 的最优性。因此，从 π_k 出发，考虑离线数据集 D 能否进一步提升新策略 π_k ，进而将性能差异定理重新运用于策略 π_k 。使用本小节前半部分的类似处理方法，采用离线数据集 D 的状态分布来替换 ρ_{π_k} 。

$$\hat{J}_{\Delta}(\pi, \pi_k) = \mathbb{E}_{s \sim \rho_D(\cdot), a \sim \pi(\cdot|s)} [A_{\pi_k}(s, a)] \quad (3.8)$$

同样，得到以下约束：

$$\begin{aligned} J_{\Delta}(\pi, \pi_k) \geq & \hat{J}_{\Delta}(\pi, \pi_k) - 4\gamma A_{\pi_k} \cdot \max_s D_{TV}(\pi||\pi_k)[s] \cdot \mathbb{E}_{s \sim \rho_{\pi_k}(\cdot)} [D_{TV}(\pi||\pi_k)[s]] \\ & - 4\gamma A_{\pi_k} \cdot \max_s D_{TV}(\pi||\pi_k)[s] \cdot \mathbb{E}_{s \sim \rho_{\hat{\pi}_b}(\cdot)} [D_{TV}(\pi_k||\hat{\pi}_b)[s]] \\ & - 2\gamma A_{\pi_k} \cdot \max_s D_{TV}(\pi||\pi_k)[s] \cdot \mathbb{E}_{s \sim \rho_D(\cdot)} [1 - \hat{\pi}_b(a|s)] \end{aligned} \quad (3.9)$$

与公式（3.7）不同的是，引入的 $\mathbb{E}_{s \sim \rho_{\hat{\pi}_b}(\cdot)} [D_{TV}(\pi_k||\hat{\pi}_b)[s]]$ 与目标策略 π 无关，因此也可以被视为一个常数。特殊的是，如果令 $\pi_k = \pi_b$ ，那么公式（3.7）就是本式的特殊情况。基于此，因为 π_b 往往是第一个需要改进的策略，设定 $\pi_0 = \pi_b$ 。此外，将 $\mathbb{E}_{s \sim \rho_D(\cdot), a \sim \pi(\cdot|s)} [A_{\pi_k}(s, a)]$ 最大化的同时最小化 $\max_s D_{TV}(\pi||\pi_k)[s]$ 来确保离线数据集 D 可以继续改进策略 π_k 。

然而，最小化 π 和 π_k 之间的总变差散度可能会使 $\pi = \pi_k$ ，这种解可能不是需要的结果，因为算法希望通过优化过程来改进 π_k ，而不是使它保持一个恒定值。因此，更合适的优化目标是在限制总变差散度最小的同时最大化 $\mathbb{E}_{s \sim \rho_D(\cdot), a \sim \pi(\cdot|s)} [A_{\pi_k}(s, a)]$ ：

$$\begin{aligned} & \underset{\pi}{\text{Maximize}} \mathbb{E}_{s \sim \rho_D(\cdot), a \sim \pi(\cdot|s)} [A_{\pi_k}(s, a)] \\ & \text{s. t. } \max_s D_{TV}(\pi||\pi_k)[s] \leq \delta \end{aligned} \quad (3.10)$$

为了达到最大化,考虑采用重要性采样法来确保期望值是完全基于旧策略 π_k 的行为分布,而不是新策略的行动分布 π :

$$E_{s \sim \rho_D(\cdot), a \sim \pi(\cdot|s)}[A_{\pi_k}(s, a)] = E_{s \sim \rho_D(\cdot), a \sim \pi_k(\cdot|s)} \left[\frac{\pi(a|s)}{\pi_k(a|s)} A_{\pi_k}(s, a) \right] \quad (3.11)$$

通过这种方法,可以根据分布 $\rho_D(\cdot)$ 从离线数据集中采样状态 s ,然后使用策略 $a \sim \pi_k(\cdot|s)$ 来采样行动,并估计出该式。同时,对于总变差散度,做出如下变化:

$$\begin{aligned} \max_s D_{TV}(\pi || \pi_k)[s] &= \max_s \frac{1}{2} \int_a |\pi(a|s) - \pi_k(a|s)| da \\ &= \max_s \frac{1}{2} \int_a \pi_k(a|s) \left| \frac{\pi(a|s)}{\pi_k(a|s)} - 1 \right| da = \frac{1}{2} \max_s \mathbb{E}_{a \sim \pi_k(\cdot|s)} \left| \frac{\pi(a|s)}{\pi_k(a|s)} - 1 \right| \end{aligned} \quad (3.12)$$

这一操作的目的是为了确保持续性 $\frac{\pi(a|s)}{\pi_k(a|s)}$ 的一致性。然后将公式(3.12)与 clip 操作结合起来:

$$\begin{aligned} \max_{s \sim \rho_D(\cdot)} D_{TV}(\pi || \pi_k)[s] \leq \epsilon &\leftrightarrow \max_{s \sim \rho_D(\cdot)} \mathbb{E}_{a \sim \pi_k(\cdot|s)} \left| \frac{\pi(a|s)}{\pi_k(a|s)} - 1 \right| \leq 2\epsilon \\ &\leftrightarrow \max_{s \sim \rho_D(\cdot)} \mathbb{E}_{a \sim \pi_k(\cdot|s)} \text{clip} \left(\frac{\pi(a|s)}{\pi_k(a|s)}, 1 - 2\epsilon, 1 + 2\epsilon \right), \end{aligned} \quad (3.13)$$

$$\text{clip}(\alpha, \beta, \gamma) = \min(\max(\alpha, \beta), \gamma)$$

在这里,求解最大值运算是不切实际的,因此考虑使用 TRPO 算法,将求解最大值变为求解期望值,同时插入总变差散度^[59],得到最终的损失函数:

$$\begin{aligned} L_k(\pi) &= E_{s \sim \rho_D(\cdot), a \sim \pi_k(\cdot|s)} \left[\min \left(\frac{\pi(a|s)}{\pi_k(a|s)} A_{\pi_k}(s, a), \right. \right. \\ &\quad \left. \left. \text{clip} \left(\frac{\pi(a|s)}{\pi_k(a|s)}, 1 - 2\epsilon, 1 + 2\epsilon \right) A_{\pi_k}(s, a) \right) \right] \end{aligned} \quad (3.14)$$

其中,最小化操作使该目标成为公式(3.11)的下限。将学习策略和行为策略约束在一定范围内,解决了离线强化学习的问题。

3.2.4 针对复合动作的混合损失函数

在许多环境中,智能体的动作都是由多个子动作组成的复合动作。例如,在控制某些工业机器人时,与环境的交互通常涉及每个关节的单独动作。对于复合动作,常见的方法是将子动作的概率密度相乘,得到复合动作的概率密度^[46],如下式所示:

$$r_1 = \frac{\prod \pi_{new}^i(a_t^i | s_t)}{\prod \pi_{old}^i(a_t^i | s_t)} \quad (3.15)$$

然而,这种方法的一个缺点是,如果复合动作在某些子动作维度上没有满足要求,在裁剪操作时,会粗略地过滤掉整个复合动作,降低了数据样本的使用效率。因此,为了提高数据通过率,提出了另一种方法,即单独计算每个子动作的比率:

$$r_2^i = \frac{\pi_{new}^i(a_t^i | s_t^i)}{\pi_{old}^i(a_t^i | s_t^i)} \quad (3.16)$$

使用公式 (3.15) 的复合比率时, 算法的优化目标是优化整个复合动作。而使用公式 (3.16) 的子动作比率时, 算法将优化每个子动作, 如果每个子动作都能被优化, 那么整个复合动作也就得到了优化。然而, 单独考虑每个子动作的问题是, 它并没有考虑每个子动作之间的联系, 缺少整体性的考虑。图 3.3 展示了两种方法的差异。




图 3.3 复合动作损失和子动作损失之间的差异

Fig. 3.3 Difference between the compound action loss and the sub-action loss

因此, 本节提出了一种混合方法, 可以增强子动作之间的联系同时提高样本利用率。结合公式 (3.15) (3.16), 得到新的裁剪操作方法:

$$r_{MIX} = \omega r_1 + (1 - \omega) r_2 \quad (3.17)$$

$$L_{clip} = \min(r_{MIX} A, \text{clip}(r_{MIX}, 1 - \epsilon, 1 + \epsilon) A) \quad (3.18)$$

其中, ω 用于对两个比率进行加权。在本文的实验中, ω 设置成 0.4。将新的裁剪操作用于公式 (3.14) 中, 得到新的混合损失函数:

$$L_k(\pi) = E_{s \sim \rho_D(\cdot), a \sim \pi_k(\cdot | s)} [\min(r_{MIX} A_{\pi_k}(s, a), \text{clip}(r_{MIX}, 1 - \epsilon, 1 + \epsilon) A_{\pi_k}(s, a))] \quad (3.19)$$

3.3 实验结果与分析

在本部分, 利用 Python 语言环境, 在离线数据集上对所提出的方法进行了实证验证。针对各种任务环境下的无人机对抗任务, 参照了标准的强化学习训练和测试配置, 结合特定场景进行仿真建模。在相同的实验设置下, 将本文方法与其他学者提出的方法进行了对比, 多个指标显示, 本文方法的性能优于其他方法。同时, 为了证明所提出的

奖励标注方法的表征能力、行为策略优化的有效性以及混合损失函数的鲁棒性，对相关功能模块进行了分离，进行了多组消融实验。实验结果表明，在大多数情况下，相关理论均能达到较优或最优表现。

3.3.1 仿真系统框架

本实验使用的仿真平台配置为：Intel i5-12400@2.4GHz CPU，32GB 内存。软件环境为：Windows 系统，Pytorch 1.9.0，编程工具为 Python 3.8。将本章算法用于无人机对抗中，需要搭建的仿真系统由三个部分组成：服务器端、训练端和执行端。

服务器端具有无人机对抗演示功能，通过提供接口接受执行端传达的对抗数据并基于 TacView 进行可视化仿真。TacView 是国际通用的飞行数据分析工具软件，具有提供 3D 视角、数据记录、数据分析、态势演示和自定义集成等功能。训练端具有核心算法训练功能，包含 Pytorch、Pandas 等第三方库，接受离线数据集中的训练数据，基于不同的算法和策略进行训练。在训练完成后会生成强化学习模型。执行端具有加载算法模型的功能，可以基于训练完成的模型与服务器端进行交互，检测模型的性能和稳定性。

一次完整的训练过程如下：初始阶段，服务器端读取环境配置文件，创建初始环境和智能体。训练端从离线数据集获取数据后，算法模型进行迭代训练，训练过程中与服务器端没有任何交互，直到达到最大训练次数。训练完成后，将相关参数和模型传入执行端，执行端与服务器端进行交互仿真。

3.3.2 实验环境及任务设计

首先，规定红蓝双方的初始态势。本章所有实验均采用相同的初始态势，不考虑空气阻力、环境变化、燃油体积等外部因素对无人机对抗的影响。设置无人机的速度范围为 100m/s 至 500m/s，高度范围为 2000m 至 5000m，低于最低高度或高于最高高度均视为无人机出界。每轮实验采用 500 个时间步，当时间步耗尽后仍未结束对抗则视为平局。红蓝双方的其他设计均相同，这样能够以公平的方式比较强化学习的有效性。无人机 1v1 对抗的初始状态如表 3.2 所示。

表 3.2 三维环境对抗红蓝双方的初始态势

Tab. 3.2 Three-dimensional environment against the initial postures of Red and Blue

	初始坐标(m)	速率(m/s)	航向角(°)
红方	(0, 0, 4000)	300	随机
蓝方	(5000, 5000, 4000)	300	随机

其次，设计了单独作战环境。该环境适用于两个智能体 1v1 的对抗任务，本章提供了无武器任务和导弹任务两种设置。同时为每个任务提供了自我控制设置和对战基准设置。在模拟任务中，胜负判定主要依据三维空间角度和距离。当无人机占据明显角度优势且达到距离要求，可在瞬间击败敌机。当无人机占据角度优势但距离稍远，有 20% 的几率击败敌机。无武器任务要求无人机处于优势态势，这意味着无人机需要飞向对手尾部并保持适当距离。导弹任务则要求无人机学会击落对手，导弹引擎是基于比例制导的。

(1) 本章第一个对抗任务为“与直线飞行目标的无人机对抗”。实验中，红蓝双方各部署 1 架无人机，均采用导弹任务。红方采用不同的强化学习算法控制，蓝方采用直线机动策略。双方无人机的武器状态设置为自由开火（对非友方目标进行射击）。

(2) 本章第二个对抗任务为“不同算法之间的无人机对抗”。实验中，红蓝双方各部署 1 架无人机，分别在无武器和导弹任务场景下进行仿真。双方均采用不同的强化学习算法进行控制。

(3) 本章第三个对抗任务为“与仿真任务驱动目标的无人机对抗”。实验中，红蓝双方各部署 1 架无人机，蓝方采用机动规则驱动，分配攻击红方的任务，在红方进入攻击范围时发起攻击，同时为蓝方设置巡逻区域。红方采用不同的强化学习算法进行控制。

3.3.3 实验结果与分析

本文为离线强化学习提供专家演示，并通过人工演示和强化学习领域最常用的 PPO 算法^[46]收集离线数据集，其中人工演示生成的数据占比 30%，强化学习算法收集数据占比 70%，数据集中各种状态的轨迹分布较为均匀。收集到的离线数据集经过手工去除标签后，分为两类，一类是缺少奖励标签的无标签离线数据集，用于本章提出的算法；另一类是完整的离线数据集，用于与主流强化学习算法进行对比实验。实验中，每轮训练 500 次，共训练 5 轮取平均值以避免出现特殊情况。每个训练回合训练 1 万个时间步。

实验一：与直线飞行目标的无人机对抗

首先，着眼于旨在实现直线机动策略的作战任务。通过对比各种主流离线强化学习算法（包括 CQL、IQL、TD3-BC^[60]以及本文提出的最优传输支撑下的行为策略优化算法 OTSBPO）对性能的影响，记录胜率变化曲线，结果如图 3.4 所示。

图 3.4 的研究结果表明，在该环境中，几乎所有主流离线强化学习算法经过数个阶段的迭代后，都能达到大约 85% 的胜率，罕见的失败情况主要是由于我方或者敌方无人机超出边界，导致算法未能及时捕获敌方无人机。各种算法在准确性方面没有明显差异，但在迭代速度方面，本章算法稍显不足，略逊于目前的主流算法。对于这种简单任务，主流离线强化学习算法都能够轻松应对。




图 3.4 对抗直线飞行目标的算法胜率变化

Fig. 3.4 Comparison of algorithmic win rates against straight-line flying targets




图 3.5 对抗直线飞行目标的训练轨迹

Fig. 3.5 Training trajectory against straight flight targets

在 OTSBPO 算法的训练过程中,记录了每个回合红蓝双方无人机的动作状态信息。并使用 matplotlib 库将这些数据可视化为轨迹图。图 3.5 展示了几个特定回合的对抗路径。从图 3.5 a)和图 3.5 b)可以看出,在第 10 回合和第 50 回合时,红方无人机处于对环境的随机探索状态,根据算法的学习探索策略随机选择动作。此时,红方无人机无法根据蓝方的轨迹制定有效的应对策略,导致任务失败。而在第 300 回合时(如图 3.5 c)所示),红方无人机已经掌握有效对策,缩小了与蓝方的距离,并能调整到较好的位置,但在引导过程中,红方无人机选择了许多无效动作,导致轨迹不够平滑。图 3.5 d)展示了第 350 回合无人机的轨迹图。经过这番训练,红方无人机可以凭借自身特点,采用简单的机动策略,高效学习到最优对抗方案,这不仅提高了对抗成功率的稳定性,还改善了无人机飞行轨迹的质量,最终使红方无人机在对抗中取得胜利。

实验二：不同算法之间的无人机对抗

本部分旨在评估本章提出的离线强化学习算法在处理高维状态空间和动作空间方面的成效,并比较各种主流离线强化学习方法的相对对应优缺点。在对抗实验中,红蓝双方分别采用 PPO、CQL、TD3-BC、IQL 以及 OTSBPO 算法进行控制。对于上述主流强化学习方法,本实验的设置均来自其原始论文和公开代码。

首先红蓝双方均采用 PPO 算法进行无武器对抗训练,经过多轮迭代,结果呈现出一种动态平衡的态势。如图 3.6 所示,在整个训练过程中,双方获胜和失败概率交替波动,呈现出相持不下的局面。在大多数平局情况下,双方战机均未发现对方。由此可见,使用相同算法对于红蓝双方的胜率不会产生任何影响。




图 3.6 基于 PPO 算法对抗胜率变化曲线

Fig. 3.6 Based on the PPO algorithm against the change curve of the winning rate

在此基础上，红方无人机分别采用 CQL、TD3-BC、IQL 和 OTSBPO 算法，蓝方无人机采用 PPO 算法，双方进行无武器对抗任务。图 3.7 展示了双方在对抗过程中的胜率波动情况。与实验一中针对直线飞行目标对抗相比，几种算法的胜率均有所下降。从图中可以明显看出，OTSBPO 算法大约在 325 次训练后达到收敛，其收敛速度略逊于 CQL 算法和 TD3-BC 算法。然而，相较于 CQL 算法、TD3-BC 算法和 IQL 算法，OTSBPO 算法具有更高的胜率，最终胜率达到了 70% 左右。这表明在面对传统强化学习算法时，OTSBPO 算法在处理无人机对抗任务时表现出更优异的性能。




图 3.7 不同主流算法对抗 PPO 算法的胜率变化曲线

Fig. 3.7 Variation curve of the winning rate of different mainstream algorithms against PPO algorithms

在导弹任务中，本文探讨了 OTSBPO 算法是否能够胜任此任务。除了新增武器设置外，为简化仿真模型，将武器设置成自由开火模式。这使得双方进入开火范围时无需考虑弹药数量等问题，从而增加了击中和被击中的可能性。其他设置与上一小段相同。图 3.8 展示了双方对抗的胜率变化情况，可以明显的观察到，当无人机携带武器后，各算法的胜率均出现了下降趋势，但降幅存在一定差异。本文提出的方法在性能指标下降幅度上小于其他方法。根据对抗结果，发现即使处于导弹任务中，OTSBPO 算法也可以取得较高的胜率。经过大约 350 次迭代后，胜率稳定在 65% 左右。上述实验数据表明，无论采用哪种任务方式，OTSBPO 算法的引入明显提升了对抗传统强化学习方法的胜率。




图 3.8 无人机导弹任务的胜率变化曲线

Fig. 3.8 Win rate change curve for UAV missile missions

表 3.3 本章算法（红方）和其他算法（蓝方）对抗结果比较

Tab. 3.3 Comparison of confrontation results between OTSBPO (Red) and other algorithms (Blue)

任务	算法	胜利	失败	平局
无武器任务	CQL	3968	2845	1187
	TD3-BC	4372	2623	1005
	IQL	4213	2910	877
	PPO	5755	1341	904
导弹任务	CQL	3048	2829	2123
	TD3-BC	3342	3013	1645
	IQL	3544	2740	1716
	PPO	5156	1534	1310

最后,为进一步验证 OTSBPO 算法的优越性,使用该算法训练红方无人机,蓝方无人机分别采用 CQL、TD3-BC、IQL 和 PPO 算法。通过无人机空战仿真实验,真正意义上比较 OTSBPO 算法与其他算法之间的差异性。在实验中,对抗次数设置为 8000 次,其余参数保持不变。表 3.3 统计了训练过程中红蓝双方的胜负和平局次数。根据对抗结果,明显发现本文算法与 PPO 算法对抗中胜利次数最多,胜率分别达到了 71.9%和 64.5%。在和其他算法的对抗中,本文算法胜利次数总是大于失败次数。这表明 OTSBPO 算法在

与其他算法对抗时中表现出色，能够制定更优的机动策略，帮助无人机快速击落敌机。

实验三：与仿真任务驱动目标的无人机对抗

在本实验中，蓝方智能体采用机动规则驱动的模式，为其设置巡逻区域，并分配攻击红方的任务，允许其在区域内自由移动。红方智能体的实验参数设置与实验一相同，采用不同强化学习算法进行驱动。与实验一相比，本实验的不同之处在于实验场景任务复杂度增大，导致整体状态更为复杂，这对算法提出了更高的要求。在算法训练的前期、中期和后期，分别随机选取训练过程中 50 轮任务对抗的结果，统计获胜、失败和平局的次数。从表 3.4 可以看出，在训练初期，双方胜率基本相似，算法尚未很好地学会如何进攻。在训练中期，胜率开始逐渐上升，但平局的概率也有所增加，这表明智能体开始掌握如何取得相对位置优势，无意义的行为逐渐减少。到了训练后期，红方能够以较高的概率获胜，失败或平局的概率降至最低。通过对三个不同阶段的观察，OTSBPO 算法在大多数情况下都处于较优或者最优的位置。进一步表明其在无人机对抗任务中的表现更加均衡的性能，侧面证实了该方法在实际应用中的价值。

表 3.4 不同主流算法对抗规则驱动方法的不同阶段的对抗结果比较

Tab. 3.4 Comparison of confrontation results at different stages of different mainstream algorithms against rule-driven methods

训练阶段	算法	胜利	失败	平局
前期	CQL	20	13	17
	TD3-BC	24	15	11
	IQL	16	25	9
	OTSBPO(ours)	19	22	9
中期	CQL	23	10	17
	TD3-BC	21	9	20
	IQL	23	10	17
	OTSBPO(ours)	26	8	17
后期	CQL	35	5	10
	TD3-BC	33	1	16
	IQL	36	0	14
	OTSBPO(ours)	40	3	7

3.3.4 不同模块的消融实验

本小节评估了构成 OTSBPO 算法的不同模块的影响。本章已经详细介绍了 OTSBPO 算法，它由离线数据集改进行为策略衍生而来，包含了最优传输模块、行为策略优化模块和混合损失函数模块。为了深入探究这三个模块对算法的影响，本小节进行了消融实验。本文对算法进行解构，对比了以下变体模型：OTSBPO 算法以及不包括最优传输模块的 BPO 算法；OTSBPO 算法和不包括混合损失函数模块的 OTSBPO 算法；OTSBPO 算法和通用离线强化学习 CQL 算法并附加最优传输模块和混合损失函数模块。这些变体模型在三个实验任务中分别进行了评估，实验结果如表 3.5、表 3.6 和表 3.7 所示。

表 3.5 无最优传输和最优传输训练的消融实验

Tab. 3.5 Ablation experiment for training without and with Optimal Transport

环境	无最优传输胜率	包含最优传输胜率
实验一	75.7%	84.3%
实验二	58.9%	71.2%
实验三	64.3%	78.3%

表 3.6 策略目标中价值函数估计的混合损失的消融实验

Tab. 3.6 Ablation experiment for Mixing Loss of value function estimates in the policy objective

环境	无混合损失胜率	包含混合损失胜率
实验一	81.5%	84.3%
实验二	64.4%	71.2%
实验三	71.9%	78.3%

表 3.7 一般策略 vs 改进行为策略

Tab. 3.7 General policy vs Improving behavior policy

环境	一般策略	改进行为策略
实验一	85.3%	84.3%
实验二	66.7%	71.2%
实验三	70.1%	78.3%

第一组实验评估了引入最优传输模块的重要性。在算法中引入最优传输模块有三个优点。首先，该模块消除了单独训练奖励函数或者判别器的必要性，从而降低了性能开

销，并避免了对网络架构超参数调优的需求。其次，与传统方法相比，该模块避免处理与极值相关的优化问题所带来的挑战，使其免受强化学习训练不稳定性的影响。此外，该模块独立于离线强化学习，因为最优传输定理计算奖励的方法不受离线强化学习的影响。表 3.5 的实验结果表明，引入最优传输模块提高了算法的性能，并降低了算法的性能开销。

第二组实验比较了混合损失函数和原始损失函数（仅仅使用子动作损失）在不同任务上的性能差异。在大多数实验中，仅使用子动作损失产生的收益非常有限，这是因为子动作损失没有考虑整个动作序列的策略。混合损失包括子动作损失和复合动作损失，增强了优化的稳定性，在提高样本利用率的同时产生了优异的训练结果。实验结果表明，混合损失函数优于原始损失函数。在不同任务上进行的实验验证了所提出的混合损失函数的有效性。当需要从复合动作中学习时，使用混合损失对于获得良好的性能至关重要。

最后一组实验说明了通过离线数据集改进行为策略的重要性，以及确保最终学习策略和行为策略之间的紧密一致性。通过比较主流的离线强化学习 CQL 算法和 OTSBPO 算法在不同任务下的性能差异，明显看出后者表现出更优越的性能。这一结果有力地证明了本文提出的行为策略优化模块的有效性。

3.4 本章小结

本章通过引入最优传输定理对无人机训练数据进行奖励标注，基于性能差异定理评估离线策略的改进效果，并运用混合损失函数深入挖掘复合动作之间的复杂关联关系。首先，在给定专家演示的情况下，使用最优传输定理为离线数据集中未标记的轨迹添加奖励标签，离线强化学习算法可以利用标注后的数据集推导出良好的策略。其次，引入性能差异定理来评估利用离线数据集改进行为策略的效果，将学习策略和行为策略之间的比率限制在一定范围内，从而确保学习到的策略接近行为策略。此外，提出一种新颖的混合损失方法，通过限制比率范围和消除过大跨度策略，增强子动作之间的联系同时提高样本利用率，提高算法在复合动作环境的性能。在实验部分，通过在不同任务场景下执行无人机对抗任务，展示了 OTSBPO 算法的决策能力。与主流的离线强化学习算法的对比实验以及消融实验，进一步验证了本章算法的优越性能。

4 惊喜最小化驱动的无人机群对抗—协作策略优化方法

4.1 引言

随着混合智能、多智能体和大数据技术的发展,近年来以动态复杂环境指挥作战为背景的军事感知决策技术在各种任务中取得了关键性突破。特别是无人机群参与的立体协调作战,其决策响应速度和任务成功率已经达到或者超越当前作战体系下的决策水准。然而,与传统机械部队作战相比,动态联合作战环境中信息冗余度高,战场变量复杂,演变规律模糊,敌对信息缺乏并存在干扰因素。这导致作战决策耗时较长,同时难以保证可靠性。尤其是在空战集群场景中,现有的预先规划决策方法难以适应未来军事对抗中快速、高效、动态的决策需求,因此亟需引入基于多智能体强化学习的动态感知行动作战决策方法。面对瞬息万变的空战态势,实时感知环境并给予决策。鉴于以上问题,本章将重点研究多智能体强化学习方法在无人机群空战决策中的应用。

近年来,多智能体强化学习作为一种灵活高效的控制问题解决方法受到众多学者的青睐。现实生活中,许多控制问题需要智能体之间的相互合作。然而目前合作性多智能体任务通常只对团队目标给予奖励,多智能体系统中团队奖励的稀疏性仍然是多智能体强化学习算法面临的一大挑战。为了解决这一问题,可以考虑使用密集的个体奖励来帮助智能体完成任务。目前有两种主流的个体策略生成奖励方法。第一种是将所有智能体的个体奖励和团队奖励统一计算并平均分配,每个智能体获得相同的奖励。然而,引入个体奖励可能会改变智能体的目标,导致一些不合理的行为出现。例如,在空战中,如果引入过多鼓励无人机执行机动动作的奖励,智能体可能会倾向于执行这些动作,而忽略击落敌机以获得胜利。第二种方法则是将个体奖励直接加入团队奖励中。然而,这种方法简单的方法存在问题,简单的将个体奖励和团队奖励混合,在实际应用中可能需要对加权系数进行大量调整工作。此外,两种奖励的结合可能导致信用分配问题^[61],使智能体之间产生相互干扰。综上所述,如何考虑团队策略和个体策略之间的相互辅助作用,仍然是一个开放和具有挑战性的问题。

此外,由于无人机集群对抗的复杂性和动态性,每架无人机通常只能观测到所处位置的局部信息,对全局信息缺乏了解和探索。当前研究工作致力于解决如何有效探索未知环境并获取有利于学习最优策略的信息和经验这一挑战。例如,EITI方法^[62]通过建模一个智能体的行为对其他智能体行为的影响,来鼓励协调探索。与以往采用基于噪声的探索策略的方法相比,该方法能够更好地捕捉智能体间的相互作用,从而提高探索效率,获取更有利于学习最优策略的信息和经验。尽管这些探索策略在学习性能方面取得了不

错的效果，但是它们仍然存在一些问题：首先，多智能体的局部观察和非平稳性在探索中引入了额外的困难。每个智能体根据自身的局部观察采取策略行动，它们之间并不共享对环境的认识。此外，每个智能体的动作和状态也会受到其他智能体的影响，这在学习中会产生额外的随机性。最后，即使处于同步协调探索的状态，也可能存在局部信息和全局信息不一致的情况。尽管现有的多智能体强化学习探索策略在提高学习性能方面取得了进展，但在处理局部观察、环境非平稳性以及局部全局信息不一致等问题上仍然存在局限性。因此，如何在这种更复杂的环境中设计高效、鲁棒的探索机制，仍然是一个开放且具有挑战性的研究问题。

本章在第三章的基础上进行了拓展，将强化学习方法应用于多无人机对抗场景。这使得本文第三章和第四章形成了一个相对完善且系统的无人机对抗决策方法，覆盖了不同数量的无人机对抗场景。此外，本章针对强化学习在多智能体场景下的局限性进行了改进。从态势表示、策略改进和算法优化等方面对现有方法进行了增强，提高了决策的准确性和效率，使得强化学习模型能够更好地应用于无人机群的对抗场景。

基于上述几个问题，本章提出了一种新颖的多智能体强化学习算法：惊喜最小化驱动协作策略优化算法（Individual and Team Bonding Policy based on Surprise Minimization, ITBP-SM）。首先，针对无人机群的态势进行分析，使用图注意网络搭建拓扑图。有意识的利用无人机群对抗的稀疏性，并结合专家知识迅速提取出原始拓扑图中的关键信息，将其建模为更为简化的抽象图，在此基础上合理有效的应对无人机群对抗的态势复杂性。其次，该算法将个体视为独立的探索单元，通过试错和采样发现有效的行动模式。个体行动真正的目标是推动整个团队朝着协作的方向发展，实现奖励最大化。团队策略也不断从个体行动中汲取新的经验和知识，不断完善自身。最后，采用动态分配的强化学习探索目标，将个体的惊喜程度定义为状态分布的熵值。通过追求低熵状态分布，即惊喜最小化作为内在动机。多智能体系统将共同学习一种分布式的策略，使整个系统朝着较为确定和可预测的状态发展。在实验部分，基于上述方法完成了不同任务的仿真实验，并与现有的主流方法进行了大量的对比实验，展示了所提出方法的优异性能。

4.2 模型结构

4.2.1 模型整体结构

本文提出的算法整体结构如图 4.1 所示。首先，使用拓扑图构建整个无人机群的态势情况，并结合专家知识提取三种关键关系，将这些关键关系联合推理成抽象关系图，这种成功的简化为后续优化算法学习奠定了基础。其次，针对每个智能体，采用了两种独立的方法分别学习两种不同目标，避免了相互影响。同时，引入新的策略差异约束，

限制两种方法之间的差距,确保个体策略能够朝着提高整体团队奖励的方向发展,保持优化目标的一致性。在团队层面的学习过程中,从各智能体执行的策略所产生的轨迹数据中提取信息,最终目标是优化预期的累积团队奖励。最后,将个体惊喜程度定义为状态分布的熵值。通过追求低熵状态分布,即惊喜最小化作为内在动机。它持续跟踪当前状态分布估计值,并基于该估计值制定行动方案。每当执行一个动作后,状态分布估计就会相应更新,行动策略也随之调整,以适应新的态势。整个模型采用集中式训练分布式执行的框架。表 4.1 展示了整个模型的伪代码部分。




图 4.1 惊喜最小化驱动的无人机群对抗—协作策略优化算法整体结构

Fig. 4.1 Overall Structure of UAV Swarm Decision Model Based on Individual and Team Bonding Policy based on Surprise Minimization

4.2.2 空战态势的抽象图关系推理

在无人机群空战对抗场景中,首要任务是识别关键的战斗关系,并过滤掉无关信息。每架参与对抗的无人机必须首先确定哪个对手是自己的主要目标,哪个队友将辅助它完成对抗任务。在时空关系的启发下,考虑采用图神经网络来解决态势关系的传递问题。然而,由于态势关系的复杂性,现有方法在不进行任何简化的情况下就直接应用整个图,导致了性能的严重下降。在实际空战对抗中,并不是所有参与的无人机都具有很强的相关性。例如,某些无人机具有较强的攻击性,主要针对敌方目标。而另一些无人机则采取支援策略,需要同时考虑支持友方和攻击敌方。因此,在无人机群对抗中,拓扑图呈现出一种较强的局部相关性,而非整体相关性。受此启发,一旦有意识地利用无人机群对抗的稀疏性,就能迅速提取出原始拓扑图中的关键信息,并将其建模为更简化的抽象图,在此基础上合理有效的应对无人机群对抗的挑战。

表 4.1 惊喜最小化驱动的协作策略优化算法描述

Tab. 4.1 Description of Individual and Team Bonding Policy based on Surprise Minimization

算法 4.1 惊喜最小化驱动的协作策略优化算法

初始化参数: 对于每个智能体 i , 设置个体策略 π_i 的参数 θ_i , 设置团队策略 $\tilde{\pi}_i$ 的参数 $\tilde{\theta}_i$; 设置个体评价函数 V_i 的参数 ϕ_i , 设置团队评价函数 $\tilde{V}_i$ 的参数 $\tilde{\phi}_i$, 设置惊喜模块 S_i 的参数 φ_i

```

1: while step < 总步数 do
2:   set 数据缓冲区 $D = \{ \}$ 
3:   for  $a = 1$  to 批量大小 do
4:     初始化轨迹列表 $\tau$ 
5:     for  $t = 1$  to  $T$  do
6:       for  $i = 1$  to 所有智能体 do
7:         根据个体策略 $\pi_i$ 和参数 $\theta_i$ 采样动作概率 $p_i^t$ 
8:         根据动作概率 $p_i^t$ 采样动作 $a_i^t$ 
9:         计算个体评估值 $v_i^t = V_i(s_t; \phi_i)$ 
10:        据团队策略 $\tilde{\pi}_i$ 和参数 $\tilde{\theta}_i$ 采样动作概率 $\tilde{p}_i^t$ 
11:        计算团队评估值 $\tilde{v}_i^t = \tilde{V}_i(s_t; \tilde{\phi}_i)$ 
12:        计算惊喜最小化的奖励
13:      end for
14:      执行所有智能体的动作 $a$ , 观测即时奖励 $r$ 和下一状态
15:      将上述参数加入轨迹中
16:    end for
17:    根据轨迹使用 GAE 计算个体策略的优势估计 $A_i^t$ 
18:    根据轨迹使用 GAE 计算团队策略的优势估计 $\tilde{A}_i^t$ 
19:    将轨迹放入数据缓冲区 $D$ 
20:  end for
21:  for  $ax = 1$  to 训练批量大小 do
22:    从数据缓冲区 $D$ 采样数据
23:    对每个智能体 $i$ , 使用 Adam 更新值函数 $J(\theta_i)$ 和惊喜值的熵 $H(s_i)$ 
24:    对每个智能体 $i$ , 使用 Adam 更新值函数 $\tilde{J}(\tilde{\theta}_i)$ 
25:    对每个智能体 $i$ , 使用 Adam 更新评估函数 $L(\phi_i)$ 
26:    对每个智能体 $i$ , 使用 Adam 更新评估函数 $\tilde{L}(\tilde{\phi}_i)$ 
27:    对每个智能体 $i$ , 更新惊喜模块的损失函数 $S_{loss}(\varphi_i)$ 
28:  end for
29:  for  $e = 1$  to 评估回合 do
30:    评估每个智能体的团队策略
31:  end for
32: end while

```

在本研究中，利用图注意网络（Graph Attention Network, GAT），根据时空特征学习最重要的敌友关系。每个节点对应一个无人机，每条边对应相邻两个无人机之间的关系。首先，节点对 $(i, j)_{j \in N_f}$ 的注意力系数可以通过以下公式计算：

$$\alpha_{ij}^t = \frac{\exp(\text{LReLU}(a_f^T [W_f^Q v_i^t || W_f^V (v_j^t || e_{ij}^t)]))}{\sum_{k \in N_f} \exp(\text{LReLU}(a_f^T [W_f^Q v_i^t || W_f^V (v_k^t || e_{ik}^t)]))} \quad (4.1)$$

其中， $||$ 代表向量拼接操作， $(\cdot)^T$ 代表转置操作。 W_f^Q 和 W_f^V 分别代表训练模型权重， a_f^T 为 i 和 j 节点的注意力机制权重系数。 $\text{LReLU}(\cdot)$ 代表所使用的激活函数。 v_j^t 代表 t 时刻的 j 节点向量， e_{ij}^t 代表 t 时刻的两个节点之间的边向量。 N_f 代表节点取自友方， N_o 代表节点取自敌方。同样，节点对 $(i, j)_{j \in N_o}$ 的注意力系数也可以通过公式（4.1）计算，权重为 W_o^Q 、 W_o^V 和 a_o^T 。获得归一化的注意力系数后，汇总来自友方和敌方的特征。无人机的图注意层输出为：

$$h_{f_i}^t = \sigma(\sum_{j \in N_f} \alpha_{ij}^t W_f^V (v_j^t || e_{ij}^t)) \quad (4.2)$$

$$h_{o_i}^t = \sigma(\sum_{j \in N_o} \alpha_{ij}^t W_o^V (v_j^t || e_{ij}^t)) \quad (4.3)$$

其中， $h_{f_i}^t$ 和 $h_{o_i}^t$ 分别是无人机 i 与友方和敌方的空间特征， $\sigma(\cdot)$ 为非线性函数， W_f^V 和 W_o^V 分别为训练权重系数。

同时，针对不同时刻的态势进行评估也对整体的稳定性起着关键的作用。为了捕获时间特征，将 one-hot 编码直接嵌入到一个紧密的向量中，表明前一步的战斗关系。因此，用于学习无人机群空战中关系的时空特征定义为：

$$h_i^t = f(\text{OHE}(i) || v_i^t || h_{f_i}^t || h_{o_i}^t || h_{a_i}^t) \quad (4.4)$$

$$h_{a_i}^t = f(\text{OHE}(f_i^{t-1}) || \text{OHE}(o_i^{t-1})) \quad (4.5)$$

其中， $h_{a_i}^t$ 表示无人机 i 在 t 时刻的时间特征， $\text{OHE}(\cdot)$ 为 OneHotEncoder 函数， f_i^{t-1} 和 o_i^{t-1} 指的是在 $t-1$ 时刻识别到友方和敌方指数。 $f(\cdot)$ 是一个两层神经网络。

然后，将时空特征 h_i^t 分别输入两个不同的头，来识别最重要的友方 f_i^t 和敌方 o_i^t ：

$$f_i^t, o_i^t \leftarrow g(h_i^t) \quad (4.6)$$

其中， $g(\cdot)$ 是一个两头神经网络， f_i^t 和 o_i^t 分别从两种不同的输出中进行采样。

在识别出最重要的态势关系后，考虑利用专家知识进行关系推理，构建了一个新颖的抽象关系图。图中，无人机节点 i 的出度度数为 3，分别指向友方 f_i 、敌方 o_i 和友方的敌方 o_{f_i} 。当节点 i 指向节点 j 时，代表两个节点之间存在关系，无人机 i 对无人机 j 存在兴趣。图 4.2 展示了抽象关系图的几种关系。图 4.2 a) 展示了整体三种关系，剩下三幅图

分别展示了直接关系（实线，最重要的友方和敌方）、间接关系（蓝色虚线，最重要友方的最重要敌方）和被动关系（红色虚线，将中心节点视为重要友方的无人机）。




图 4.2 抽象关系图的几种关系

Fig. 4.2 Several relationships of Abstract Relationship Graph

在确定了朋友和对手后，通过专家知识推理出三种关系：

直接关系。在空战中，首先应当考虑最重要的友方和敌方。因此，当前节点 i 指向 f_i 和 o_i ，直接展示了最重要的作战关系。

间接关系。除了最重要的关系，同时考虑到有意义的间接关系。专家飞行员通常也会考虑友方所面对的最重要的敌方。因此让当前节点 i 指向最重要友方 f_i 的最重要敌方 o_{f_i} 。 o_{f_i} 通常依据专家知识进行判断得到。

被动关系。为了更好地完成任务，专家飞行员通常也会将场地中心的无人机视为重要的朋友。这种对飞机的关注往往是被动的，但是通常符合实际情况和实战经验。

抽象关系图是一种基于专家知识的可视化工具，通过简单的关系推理来提供直观表示。它分别指出了无人机的三种重要关系。与传统的态势拓扑图相比，抽象关系图极大简化了整体复杂的情况，通过摆脱大量细节而专注于关键关系，降低策略学习的难度。促进了团队之间的合作和决策制定。

4.2.3 基于个体团队策略互助的结合策略算法

个体奖励可以通过多种方法帮助学习团队策略，例如，多评论员（Multi-Critic）、多任务学习和奖励重塑等方法。这些方法能够更紧密地融合个体和团队奖励，但过于强烈的融合可能导致智能体学习到偏离团队合作的目标，因为个体奖励通常比团队奖励更为丰富。此外，现有方法都使用单一策略网络学习个体和团队两类奖励，策略网络在优

化过程中可能难以平衡这两类学习目标，最终学习到的策略可能无法有效促进团队合作。为了解决这些问题，提出了个体团队策略结合算法（ITBP）。与现有方法使用单一策略网络学习两类奖励不同，ITBP 算法采用两种独立的策略分别学习个体奖励和团队奖励，避免学习目标之间的相互干扰。同时，通过约束个体策略和团队策略之间的差异，使得个体策略的优化方向与团队策略保持一致。这一约束有效地引导个体策略朝着增加团队奖励的方向探索。克服了现有方法中两者难以平衡的问题。图 4.3 展示了 ITBP 算法的基本流程。




图 4.3 个体团队策略结合算法基本流程

Fig. 4.3 The basic flow of the ITBP algorithm

在算法中，每个智能体 i 学习个体策略 π_i ，以最大化预期折扣累计个体奖励 $J(\theta_i) = E[\sum_{t=0}^{\infty} \gamma_t r_i^t]$ ，同时学习团队策略 $\tilde{\pi}_i$ ，以最大化预期折扣累计团队奖励 $J(\tilde{\theta}_i) = E[\sum_{t=0}^{\infty} \gamma_t r_t]$ 。两种策略之间同时学习和相互制约。个体策略促使智能体优化自身表现，而团队策略鼓励合作以实现共同目标。通过同时根据各自的梯度信息更新 θ_i 和 $\tilde{\theta}_i$ ，每个智能体都能在个体奖励和团队奖励之间取得平衡，从而促进多智能体环境中合作行为的出现。接下来将分别介绍个体策略学习和团队策略学习的详细流程。

在多智能体强化学习中，每个智能体的个体策略都需要与团队策略协调一致，以实现整体奖励的最大化。个体策略在学习过程中，应该根据团队策略的指引来调整自身的决策。当个体策略与团队策略一致时，学习可以较快进行；而当两者出现较大冲突时，个体策略则应谨慎更新，以免偏离团队策略的优化方向。

参考主流多智能体强化学习 MAPPO 算法^[63]，考虑利用其中的目标函数：

$$J_{CLIP}(\theta_i) = E[\min(\mu_i^t(\theta_i)A_i^t, \text{clip}(\mu_i^t(\theta_i), 1 - \epsilon, 1 + \epsilon)A_i^t)]$$

$$\mu_i^t = \frac{\pi_{\theta_i}(a_i^t|\tau_i^t)}{\pi_{\theta_i^{old}}(a_i^t|\tau_i^t)} \quad (4.7)$$

其中, θ_i^{old} 是采样时单个策略的参数。

为了权衡个体策略和团队策略的一致性, 需要定量描述两个策略之间的相似程度。一种可行的方法是, 比较个体策略 π_i 和团队策略 $\tilde{\pi}_i$ 在轨迹动作对 (τ_i^t, a_i^t) 上的相似性。通过引入相似性度量, 个体策略更新时就能够兼顾自身探索和团队协作:

$$\sigma_i^t(\theta_i) = \frac{\pi_{\theta_i}(a_i^t|\tau_i^t)}{\tilde{\pi}_{\tilde{\theta}_i}(a_i^t|\tau_i^t)} \quad (4.8)$$

基于定义的相似性度量, 为个体策略提出了一个新的面向合作的目标函数:

$$J_{ITBP}(\theta_i) = E[\text{clip}(\sigma_i^t(\theta_i), 1 - \epsilon, 1 + \epsilon)A_i^t] \quad (4.9)$$

其中, ϵ 用于调节 σ_i^t 的更新幅度。较大的 ϵ 值意味着对两个策略相似性的约束较弱, 而较小的 ϵ 值则表示约束较为严格。 J_{ITBP} 的核心思想是将智能体策略 π_i 的更新限制在策略相似性 σ_i^t 范围内。如果 π_i 与 $\tilde{\pi}_i$ 的差异过大, 则意味着两个策略的优化方向存在较大偏差。

考虑如何利用 $J_{CLIP}(\theta_i)$ 和 $J_{ITBP}(\theta_i)$ 这两个目标函数来优化个体策略。多智能体合作的过程中, 个体策略的更新应当遵循以下总体原则: 当个体策略与团队策略整体保持一致时, 智能体可以相对大幅度地更新自身策略, 以快速适应环境变化和团队需求; 当个体策略与团队策略出现冲突时, 智能体应当小幅度地调整策略, 避免个体行为过度偏离团队的整体方向, 从而维护团队的稳定性和整体奖励。因此, 根据个体策略和团队策略的比值大小, 设计了两种目标函数:

$$J(\theta_i) = E[\mathbb{I}_{\sigma_i^t \leq 1} \max(J_{CLIP}(\theta_i), J_{ITBP}(\theta_i))] \quad (4.10)$$

$$J(\theta_i) = E[\mathbb{I}_{\sigma_i^t > 1} \min(J_{CLIP}(\theta_i), J_{ITBP}(\theta_i))] \quad (4.11)$$

其中, 当个体策略小于团队策略时, 采用公式 (4.10), 当个体策略大于团队策略时, 采用公式 (4.11)。由于个体策略 π_i 和团队策略 $\tilde{\pi}_i$ 都从 π_i 采样的轨迹中学习, 为了个体策略能够有效地学习团队策略, 个体策略应该采样具有高价值的团队奖励的轨迹。因此, 对于个体策略的学习目标, 采用 KL 散度作为正则化方法, 个体策略将提取团队策略学习的知识, 并倾向于团队奖励较高的部分。

综上所述, 个体策略的整体目标函数是:

$$J(\theta_i) = E[\mathbb{I}_{\sigma_i^t \leq 1} \max(J_{CLIP}(\theta_i), J_{ITBP}(\theta_i)) + E[\mathbb{I}_{\sigma_i^t > 1} \min(J_{CLIP}(\theta_i), J_{ITBP}(\theta_i))] - \alpha KL(\tilde{\pi}_i, \pi_i)] \quad (4.12)$$

同时, 团队策略 $\tilde{\pi}_i$ 是基于个体策略 π_i 采样得到的轨迹数据进行学习和训练的。然而, 由于 $\tilde{\pi}_i$ 的学习策略与采样策略不同, 会导致两者之间存在策略偏差。为了纠正这种偏差,

需要引入重要性采样技术，这种更新方式类似于 PPO 算法，对 $\tilde{\pi}_i$ 的更新进行修正：

$$\tilde{\sigma}_i^t(\tilde{\theta}_i) = \frac{\tilde{\pi}_{\tilde{\theta}_i}(a_i^t|\tau_i^t)}{\pi_{\theta_i^{old}}(a_i^t|\tau_i^t)} \quad (4.13)$$

在算法学习的前期阶段由于个体策略 π_i 和团队策略 $\tilde{\pi}_i$ 存在较大差异，如果直接根据 π_i 的梯度来更新 $\tilde{\pi}_i$ ，则会导致大部分梯度被 clip 函数裁剪掉，从而阻碍了团队策略的有效学习。为了解决这一问题，引入了具有递减系数 β 的 KL 散度，用于控制个体策略和团队策略之间的距离，确保团队策略能够有效更新。对于每个智能体 i ，团队策略的目标函数是：

$$\tilde{J}(\tilde{\theta}_i) = E[\min(\tilde{\sigma}_i^t(\tilde{\theta}_i)\tilde{A}_i^t, \text{clip}(\tilde{\sigma}_i^t(\tilde{\theta}_i), 1 - \epsilon, 1 + \epsilon)\tilde{A}_i^t) - \beta \text{KL}(\pi_i, \tilde{\pi}_i)] \quad (4.14)$$

4.2.4 基于惊喜最小化的多智能体合作探索方法

惊喜是指智能体在与环境交互时，实际状态与预期状态之间存在偏差的程度。现有研究主要集中在利用惊喜来驱动探索，即通过最大化惊喜来获取更丰富的信息。但这些方法在多智能体环境下存在采样效率低的问题。此外，智能体的行为会对环境的长期状态产生复杂的影响。一个智能体的状态变化不仅受其自身行为影响，也受其他智能体行为的影响。在规划策略时，需要考虑其他智能体的策略。但是，每个智能体都是相互独立的，无法预知其他智能体的下一步行动。因此，当智能体的行为出现意料之外的情况时，如随机探索，惊喜就会出现。这一系列原因导致的惊喜行为，使得智能体很难判断这些行为是否具有意义。

为了确保智能体行为的可预测性，降低惊喜的发生至关重要。由于整体的状态空间和动作空间规模庞大，将整体惊喜最小化作为一个集中的目标是极具挑战的。此外，这种方式也存在不合理之处，因为不同智能体对整体状态变化的影响程度存在差异。因此，本章提出了一种全新的基于惊喜最小化的多智能体强化学习合作探索方法。它将惊喜最小化作为个体的内在动机，通过追求低熵状态分布来实现，从而学习最小化惊喜的策略。

为了将惊喜最小化实例化，设计了一个强化学习智能体，同时设置额外奖励，当智能体经历更熟悉的状态会获得额外奖励。这转化为学习具有最低状态熵的策略。在一个完全观测的可控马尔可夫过程中，智能体学习到的策略为 π_θ 。惊喜最小化是为了使得状态分布的熵在事件的每个时间步 t 中保持最小。通过拟合每个时间步的状态边缘分布 $p^{\pi_\theta}(s_i^t)$ 的估计值 $p_{\theta_i}(s_i^t)$ 来拟合熵。由此，一条完整的轨迹状态分布 $\tau = \{s_1, s_2, \dots, s_T\}$ 的熵之和可以用下式来估计表示：

$$\begin{aligned} \sum_{t=0}^T H(s_i^t) &= - \sum_{t=0}^T E_{s_i^t \sim p^{\pi_i^0}(s_i^t)} [\log p^{\pi_i^0}(s_i^t)] \\ &\leq - \sum_{t=0}^T E_{s_i^t \sim p^{\pi_i^0}(s_i^t)} [\log p_{\theta_i}(s_i^t)] \end{aligned} \quad (4.15)$$

其中，当 $p_{\theta_i}(s_i^t)$ 准确拟合出 $p^{\pi_i^0}(s_i^t)$ 时，公式（4.15）中的不等式就变成了一个等式。将不等式的右侧最小化，则转化为一个新的最大化奖励的强化学习目标，将这个目标作为额外奖励。由此引出一个新的奖励函数：

$$\tilde{r}(s_i^t) = r(s_i^t) + \omega \log p_{\theta_i}(s_i^t) \quad (4.16)$$

其中，参数 ω 用于控制额外奖励的比例。使得两个奖励项处于同一个量级上。

为了将本节方法实例化到强化学习算法中，必须对公式（4.16）中 $p_{\theta_i}(s_i^t)$ 的充分统计量进行适当调整。考虑到状态边缘分布 $p^{\pi_i^0}(s_i^t)$ 会随着策略参数 π_i^0 变化，因此必须对 $p_{\theta_i}(s_i^t)$ 进行相应的调整。具体来说，在迭代的每一步中，所有智能体根据策略梯度算法获得新策略。智能体利用新策略和环境互动，同时将新观察到的状态轨迹更新到缓冲区 D 。在下一个时间步开始之前，针对每个独立智能体，使用最大似然状态密度估计过程 $\theta_i = \operatorname{argmax}_{\theta_i} \sum_D \log p_{\theta_i}(s_i)$ 对缓冲区 D 内的经验更新充分统计量参数 $\theta_i = \mathcal{U}(D)$ 。然后，智能体根据组合奖励调整其策略。原则上，基于惊喜最小化的合作探索方法可以根据实验环境选择任何合适的模型进行使用，来估计智能体的状态密度。对于一些相对简单的分布类，例如独立边缘概率的乘积，足以让本节方法在很多环境中运用。同时注意到， $p_{\theta_i}(s_i)$ 可以被建模为观察实验中每个维度的独立高斯分布。因此，奖励公式最终改写为：

$$\tilde{r}(s_i) = r(s_i^j) - \omega \sum_j (\log \sigma_j + \frac{(s_i^j - \mu_j)^2}{2\sigma_j^2}) \quad (4.17)$$

其中， σ_j 和 μ_j 分别为来自缓冲区的状态空间第 j 维度的标准差和样本均值。

4.3 实验结果与分析

本节旨在通过无人机群对抗任务实验，验证前文提出的惊喜最小化驱动的协作策略优化算法的有效性。首先对实验设置进行说明：基于 Python 语言，采用多智能体强化学习模型，构建不同的任务环境进行实验。与第三章实验设置类似，本节实验遵循主流的强化学习训练与测试配置，并计算各类评估指标。在相同实验配置下，将本章算法与现有的主流多智能体强化学习方法进行了对比。多个评估指标均表明本章算法明显优于其他方法。此外，通过消融实验切分和组合算法模块，进行了多组消融实验，证明本章算法在大多数情况都能取得良好效果。

4.3.1 环境配置和任务设计

本章实验在一台搭载 Intel i5-13400@2.5GHz CPU，32GB 内存的 PC 上运行。软件环境包括：Windows 操作系统，Pytorch 1.9.0，编程语言为 Python 3.8。将本章算法应用于无人机群对抗任务中，需要搭建的仿真系统由三个部分组成：服务器端、训练端和执行端。仿真系统配置与第三章完全相同。

实验在基于 Unity3D 开发的无人机空战模拟环境中进行。每架无人机由无人机飞行动力学、武器模块、传感器和专家知识库四个部分组成。具体来说，所有实验均在四种典型的 4v4 无人机对抗场景中进行了演示，包括围攻、突围、对抗和分散攻击。在所有场景中，红蓝双方在战场大小为（100km，70km，10km）的环境中进行初始化设置，红蓝双方的无人机群具有完全相同的机动参数，每架无人机的初始高度为 3-4km，初始速度为 300m/s，为了简化计算，假定燃料无限，每回合时间上限为 500 个时间步。图 4.4 分别展示了四种场景的不同设置，具体设置如下所示：




图 4.4 场景描述

Fig. 4.4 Scenario description

围攻场景：如图 4.4 a) 所示，红方无人机包围蓝方无人机。红方的 x 坐标和 y 坐标设置为 $2|x| + 3|y| \geq 100$ 。蓝方的 x 坐标和 y 坐标设置为 $2|x| + 3|y| \leq 50$ 。红方无人机朝向设置为面向环境中心，其余设置参数随机生成。

突围场景：如图 4.4 b) 所示，这种情况与围攻场景正好相反，红方处于劣势位置，被蓝方包围，具体设置和围攻场景完全相同。

对抗场景：如图 4.4 c) 所示，红蓝双方的初始相对位置为 50-60km，红方的 x 坐标设置为 $25 \leq x \leq 30$ ，蓝方的 x 坐标设置为 $-30 \leq x \leq -25$ 。双方的 y 坐标设置为 $|y| \leq 30$ 。双方无人机朝向设置为相对朝向，其余设置参数随机生成。

分散场景：如图 4.4 d) 所示，红蓝双方在 $80\text{km} \times 60\text{km}$ 的范围内随机初始化进行对

抗，无人机朝向也随机生成。

此外，还定义了相对胜率（Relative Winning Rate, RWR）和绝对胜率（Absolute Winning Rate, AWR）作为评估算法性能的指标。其中，相对胜率是指胜场局数占胜场与败场总局数的比例。而绝对胜率是指胜场局数占总局数（胜场、败场和平局构成）的比例。实验设置的具体模型参数如表 4.2 所示。

表 4.2 实验参数设置
Tab. 4.2 Experimental parameter setting

参数	数值设定	参数	数值设定
智能体数	8	回合数	10000
最大步长	500	折扣因子	0.99
批处理大小	256	数据缓冲区大小	1e6
滑动更新权重	5e-4	裁剪参数	0.2
模型更新频率	20	优化器	Adam
优化器参数	1e-5	策略学习率	0.0001
动作学习率	0.001	熵系数	0.01
激活函数	ReLU	输出函数	sigmoid

4.3.2 实验结果与分析

为了评估本章算法在学习能力和无人机对抗能力方面的表现，将其法与其他主流多智能体强化学习算法（其中包括 MADDPG^[55]、MAPPO、HAPPO^[65]和 MOSS^[66]）以及专家级机器人^[64]（基于人类知识的专家级人工规则，完全依赖于人类对多智能体空战的认知）进行比较。在本研究中，本章算法作为红方训练，其他算法作为蓝方训练。MADDPG、MAPPO、HAPPO 和 MOSS 的参数设置，如学习率、网络结构和裁剪率，均与原论文中或者开源代码中的设置保持一致，所有算法都在与 ITBP-SM 算法相同条件下进行训练的。本节共考虑了 4 种不同场景，即围攻、突围、对抗和分散攻击。所有实验设置 10000 次迭代，并进行 5 轮训练，取平均值以避免出现特殊情况。在每 50 次迭代中，当平均胜率的波动范围处于 0%-5%之间，可以确定算法收敛。接下来将分别分析不同场景下的实验结果。

为了展示 ITBP-SM 算法的学习性能，将其与四种主流的多智能体强化学习算法进行了比较。五种算法均通过自我对弈的方式在四个场景中进行训练，从图 4.5 中可以看出，ITBP-SM 算法在经过约 650 次迭代后实现收敛。从整体表现来看，随着训练的进行，

各种强化学习算法都取得了相对较高的分数，这表明所有算法都从自我对弈中学到了某种空战知识。其中，ITBP-SM 算法的最终收敛胜率高于其他四种方法。以图 4.5 c) 所示的对抗场景为例，经过约 650 次的迭代后，ITBP-SM 算法的胜率比其他主流方法高出约 10%。同时，ITBP-SM 算法的初始学习速度较慢，但在训练中后期逐渐加快。这主要是因为初期智能体需要随机探索多种不同状态，其中很多状态是无用的，导致平均胜率相较于其他算法略有下降，但随后胜率迅速上升。尽管 ITBP-SM 算法能带来更加优越的胜率，但是对于无人机群对抗而言，单一的胜率曲线并不能完全说明其策略的优劣，并且理论上可能存在一些非理性因素使得学习的策略变得不够稳定。




图 4.5 训练过程中不同方法的评价结果

Fig. 4.5 Evaluation results of different methods during training

因此，针对相对胜率和绝对胜率两个指标对 ITBP-SM 算法与其他四种算法在 4v4 对抗场景下的表现进行了比较。在实验中，ITBP-SM 算法训练红方，其余算法训练蓝方。在所有算法完全收敛后，让 ITBP-SM 算法训练的智能体分别与其他智能体进行 200 次对抗，共采样 5 轮取平均值避免出现特殊情况。图 4.6 显示了 ITBP-SM 算法与其他算法的对抗结果。可以看出，ITBP-SM 算法可以击败其他所有算法。其中，与 MADDPG 算

法的对抗过程中，在对抗任务下 TBP-SM 算法取得了 76.4%的相对胜率和 61.3%的绝对胜率。MADDPG、MAPPO、HAPPO 和 MOSS 等算法采用端到端的方式学习探索知识和环境，忽略了对初始环境探索到的关系简化。相比之下，ITBP-SM 算法有助于智能体模拟策略、加速收敛并采取最优保守行动，从而简化了战术学习过程。通过以上分析，可以确定 ITBP-SM 算法大幅度减少了态势信息和意图信息中的冗余交互，在无人机群空战中取得了先进的性能。




图 4.6 不同多智能体强化学习方法的比较结果

Fig. 4.6 Comparative results of different Multi-Agent Reinforcement Learning algorithms

表 4.3 本章算法和其他算法在对抗场景上的性能比较

Tab. 4.3 Performance comparison between ITBP-SM and other algorithms on adversarial scenarios

算法	相对胜率	绝对胜率	平均失败次数	p 值
MADDPG	76.4%	61.3%	18.9	9.95×10^{-4}
MAPPO	81.2%	53.7%	12.4	2.08×10^{-3}
HAPPO	59.4%	49.5%	33.8	3.97×10^{-3}
MOSS	57.1%	47.4%	35.5	6.25×10^{-5}

为了进一步确定 ITBP-SM 算法相对于其他主流算法的优越性，对它们之间的对战结果进行了统计假设检验。在这个二项式假设检验中，不考虑平局结果，以消除可能带来的不确定影响。设定的空白假设是“ITBP-SM 算法对其他算法的胜率不超过 50%”，备择假设则是“ITBP-SM 算法对其他算法的胜率超过 50%”，这与期望证明的“ITBP-

SM 算法可以击败其他所有算法”这一命题相对应。如表 4.3 所示，在 0.05 的显著水平下，所有返回的 p 值均小于临界值，因此拒绝空白假设，接受备择假设。统计假设检验的结果也证明了 ITBP-SM 算法相对于其他算法的优越性。

同时，为了评估 ITBP-SM 算法是否具备击败专家级机器人的能力，对其进行了全面的训练。训练包含四种典型的空战场景（包围、突围、对抗、分散），红蓝双方分别依靠 ITBP-SM 算法和专家级机器人提供策略。每 10 轮迭代一次，直至训练结束一共迭代 300 次。专家级机器人由基于规则的专家级演示无人机策略进行建模，该策略是由基于空战手册的飞行员知识进行提供，具有完整的机动技术，如锁定、射击和目标搜索等战术。由于专家级机器人的策略无法改变，因此 ITBP-SM 算法可以通过训练逐步获得更多胜利。图 4.7 展示了不同场景下的对比结果。数据表明，当训练结束后，ITBP-SM 算法以出色的胜率战胜了专家级机器人。值得注意的是，在包围场景中，ITBP-SM 算法利用各种天然优势取得了 95.6% 的相对胜率和 91.3% 绝对胜率。同时，ITBP-SM 算法在突围场景中也表现出色，相对胜率高达 86.1%，绝对胜率为 82.9%。这些实验结果证明了 ITBP-SM 算法战胜专家级机器人的能力。由于无人机群空战问题的固有复杂性，专家级机器人难以将战术策略转化为交战规则。而 ITBP-SM 算法突破了人类知识的桎梏，通过训练促进了专家级集群对抗战术的出现。综上所述，ITBP-SM 算法在相关场景中优于专家级机器人，从侧面证明了该方法具有实际应用价值。




图 4.7 与专家级机器人在不同场景下的比较结果

Fig. 4.7 Comparative results with expert robots in different scenarios

4.3.3 不同模块的消融实验

上一节的对照实验数据表明，本章提出的方法提升了多智能体强化学习算法在无人机群对抗任务中的表现，但无法证明各模块单独对无人机群对抗任务带来的提升作用。

在这一小节中，分别评估了构成该算法的不同模块对结果的影响。本章已经详细介绍了 ITBP-SM 算法，它包含了抽象图关系推理模块、惊喜最小化模块和个体团体策略结合模块，本小节的消融实验将侧重于检查这三个模块对算法性能的影响。

为了验证抽象图关系推理的有效性。在本实验中，同时使用包含抽象图关系推理模块和不包含抽象图关系推理模块（仅使用图注意网络）进行测试。所有算法均采用集中式训练分布式执行框架，每个智能体使用参与者网络在执行过程中根据局部轨迹做出决策，分别对抗由专家级机器人策略驱动的红方无人机。实验采用了 4v4 的四种场景作为训练场景。如表 4.4 所示，可以明显看出，在训练的前期和中期，抽象图关系推理模块的胜率大于或等于仅使用图注意网络模块的算法，而到了训练后期，两种模块的胜率基本趋于持平。抽象图关系推理模块通过模仿专业飞行员识别关键关系，简化了原始问题，使学习过程更加容易，优化了算法的更新收敛速度。因此，抽象图关系推理模块对对抗的有效性得到了证明。

表 4.4 无抽象图关系推理和抽象图关系推理的消融实验

Tab. 4.4 Ablation experiments in relational reasoning without abstract graphs and in relational reasoning with abstract graphs

训练阶段	场景	无抽象图关系推理胜率	抽象图关系推理胜率
前期	围攻	19.3%	21.7%
	突围	21.1%	20.0%
	对抗	17.4%	22.4%
	分散	22.4%	26.7%
中期	围攻	51.7%	60.3%
	突围	40.3%	58.1%
	对抗	50.4%	61.4%
	分散	47.0%	55.3%
后期	围攻	89.3%	91.3%
	突围	83.5%	82.9%
	对抗	80.1%	84.7%
	分散	82.9%	83.2%

为了验证个体团队策略结合模块的效果，分别对比了以下变体模型：仅仅包含个体策略的 IP-SM 算法和仅仅包含团队策略的 TP-SM 算法以及个体团队策略结合的 ITBP-

SM 算法。ITBP-SM 算法的不同部分被消减后的胜率对比如表 4.5 所示。可以看出，不论是仅仅使用个体策略还是团队策略，胜率都有不同程度的下降。ITBP-SM 算法为个体策略提供了合作导向的指导，使其能够根据策略相似性调整更新幅度，同时个体策略仍基于自身优势函数进行更新，继续学习个体奖励。随着训练的进行，算法逐渐侧重于学习团队策略并获得更高的团队奖励，同时使用 KL 散度控制个体策略和团队策略之间的差异，确保团队策略的有效更新。个体团队策略结合使智能体能够更有效地分享和协调信息，进一步验证了该模块的有效性。

表 4.5 个体团队策略结合模块的消融实验

Tab. 4.5 Individual team bonding policy modules for ablation experiments

场景	IP-SM 胜率	TP-SM 胜率	ITBP-SM 胜率
围攻	53.7%	61.7%	91.3%
突围	60.2%	53.3%	82.9%
对抗	59.4%	58.9%	84.7%
分散	67.1%	52.4%	83.2%




图 4.8 惊喜最小化模块的消融实验结果

Fig. 4.8 Results of ablation experiments with surprise minimization modules

针对惊喜最小化模块，设置了以下两种变体模型：包含惊喜最小化的个体团队策略结合算法（ITBP-SM），以及不包含惊喜最小化的个体团队策略结合算法（ITBP）。实验设置与前述部分保持一致。实验结果如图 4.8 所示，惊喜最小化模块能够在大多数情况下带来性能上的提升。在具备一定复杂度的 4v4 对抗任务中，态势空间巨大，惊喜最

小化有助于智能体更好地优化策略，降低系统出错或产生意外策略的风险，同时加快收敛速度，保持稳定的状态空间。实验结果有力地证明了惊喜最小化模块的有效性。

通过消融实验对框架进行模块划分，可以验证三种模块的有效性。比较消融前后算法的行为和性能，可以判断每个模块对整体功能的贡献程度以及模块之间的相互作用。这种方法有助于理解算法的内在机制，并为设计更加智能和灵活高效的多智能体算法提供指导和启示。

4.3.4 超参数分析

超参数是机器学习和深度学习模型中需要手动设置调整的参数，这些参数无法直接从训练数据中学习得到，而是需要通过实验来调整确定。超参数的选择对模型的性能和泛化能力有着重要的影响，因此对于每个具体的任务和数据集，都需要仔细地选择和调整超参数。

本章节的主要超参数是控制环境奖励和额外奖励之间的比例系数 ω 。 ω 通过调节额外奖励的大小，使所有奖励维持同一个量级，避免惊喜最小化方法失效或被过度使用。参数分析实验在相同 4v4 实验环境下，使用不同的超参数值进行对比，观察 ITBP-SM 算法对该超参数的敏感性，图 4.9 以折线图的形式展示了相关指标的平均值结果。

通过图 4.9 可以观察到，当 ω 为 0.1 时，ITBP-SM 算法在多个场景下取得最佳性能，随着 ω 的不断增大，性能呈现下降趋势，最终收敛到次优奖励，这表明过度的惊喜最小化反而会阻碍智能体的正常探索，降低模型的学习能力。




图 4.9 不同 ω 值下 ITBP-SM 算法在不同任务场景的性能比较

Fig. 4.9 Performance comparison of ITBP-SM in different task scenarios with different ω values

4.4 本章小结

本章提出了一种新的多智能体强化学习方法，该方法结合了个体团体策略互助的结合策略算法和基于惊喜最小化的多智能体合作探索方法，并使用抽象图关系推理进行关键关系的提取。首先，使用图注意网络提取拓扑图，并采用专家知识进行关键关系的简化提取，这种成功的简化为后续算法优化更新奠定了基础。其次，为每个智能体单独学习个体策略和团队策略，在智能体的公共信任区域不断更新迭代，同时对双方施加约束，促进策略的相互学习。最后，将惊喜最小化视为一种内在探索方法，为此构建了经验的状态分布，并将每个状态的概率视为额外奖励，这种额外奖励使得智能体能够保持稳定的态势，并合理有效地探索周围环境。在此基础上，多智能体系统通过共同学习分布式策略，使得整个系统朝着稳定可预测的状态发展。在实验部分，本章通过在四种主流无人机群对抗场景下进行实验，验证了所提出的多智能体强化学习方法的有效性。与现有方法进行了大量对比实验，展现了所提出方法的优异性能。此外针对不同模块进行消融实验，验证了各模块的必要性和合理性。综上所述，ITBP-SM 算法在不同场景下均表现出更优秀的任务执行能力。

5 结论与展望

5.1 结论

随着无人机技术的快速发展和军事领域对智能化作战的迫切需求，基于强化学习的无人机对抗成为了备受关注的研究热点。传统的无人机作战主要依赖于预先设定的策略和人工操控，难以适应复杂多变的战场环境。强化学习为无人机自主决策提供了新的思路，使其能够根据环境反馈不断优化策略，在对抗中占据主动地位。然而，面对无人机的高度异构性、训练成本的高昂价格以及敌我双方博弈过程的复杂多变，传统的强化学习范式在收敛性、稳定性、鲁棒性等方面仍面临诸多挑战。同时，无人机群任务的高风险性与强对抗性，也对多智能体强化学习框架的建模与求解能力也提出了更高的要求。因此，本文旨在探索针对无人机对抗的强化学习框架，在异构对抗环境下提升强化学习框架的各方面性能，并在此基础上分析无人机集群对抗的策略特点和制胜关键，充分发挥群智决策的潜力。

5.2 创新点

本文的主要贡献包括：

(1) 本文的第一个工作提出了基于最优传输支撑下的行为策略优化算法（Optimal Transport Support Behavior Policy Optimization, OTSBPO），用于解决无人机对抗中强化学习面临的挑战。为了解决无人机对抗环境下的稀疏奖励和数据利用率低的问题，引入了最优传输定理，对未标注奖励的历史对抗轨迹数据进行奖励标签的自动化分配。通过构建专家轨迹与未标注轨迹之间的最优传输映射，将专家策略信息传递给未标注数据，从而实现对离线数据集的充分利用，为后续的策略优化提供更丰富的样本信息；针对离线数据集的分布偏移问题，通过引入性能差异定理来评估利用离线数据对当前策略进行改进的效果，并将策略改进约束在一定的比率范围内，使得更新后的策略不会过度偏离原有的行为策略分布，从而提升了策略优化的稳定性和样本效率；为了进一步提高无人机对抗策略的泛化能力和鲁棒性，设计了一种混合损失函数，结合策略比率约束和数据过滤机制，动态调整无人机对抗策略的优化方向。混合损失函数通过限制策略更新幅度和筛除偏差过大的样本数据，能够在复杂多变的对抗环境下实现策略的平稳优化，有效降低过拟合风险，增强策略的适应性。

(2) 本文的第二个工作提出了一种新颖的多智能体强化学习算法：惊喜最小化驱动的协作策略优化算法（Individual and Team Policy Bonding based on Surprise Minimization, ITPB-SM）。首先采用了一种图注意网络和专家知识混合的方法，将关键

关系联合推理为抽象关系图，这种成功的简化为后续算法学习奠定了基础。随后，将个体探索与团队协作有机结合。每个智能体被视为独立的探索单元，通过与环境的交互和试错来发现有效的行动模式，这些个体行动的真正目标是为团队策略的优化提供经验和知识，推动整个无人机群朝着更好的协同对抗方向发展。团队策略则通过持续地从个体的探索经验中汲取和融合有益信息，实现策略的迭代更新和完善。同时，为了平衡探索和利用，采用基于惊喜最小化的自适应探索机制。将智能体在某一状态下的惊喜程度定义为该状态分布的熵值。通过将惊喜最小化作为探索的额外奖励，鼓励智能体在执行任务的同时，主动寻求环境中较为确定和可预测的状态，减少对抗过程中的不确定性。在此驱动下，整个系统通过个体与团队策略的协同进化，最终收敛到一种高效的对抗策略。

5.3 展望

总结而言，本文主要针对智能化作战背景下的无人机对抗决策进行了研究，设计了无人机对抗决策模型，在稳定性、准确性和收敛速度等方面相比现有算法均取得了一定提升，对该领域的研究和发展起到了一定的推动与促进作用。然而，本研究仍存在一些局限性，一方面，本文在无人机对抗环境模拟中，对整体过程做了简化处理，对真实战场的复杂环境特征未考虑完全，气象条件、电磁干扰等因素难以完全模拟，无法满足实际作战的具体需求；另一方面，本文设计的无人机群空战决策方法只考虑了 4v4 场景效果，未能探讨大规模情况下可能出现的状态动作对的维度爆炸以及无人机数量的可扩展性问题；最后，强化学习作为一种黑盒模型，其决策过程缺乏可解释性，对于空战这种高风险、高责任的场景来说，决策的可信度和可靠性面临挑战。

针对以上局限性，未来的研究可以从以下几个方面入手：发展更加逼真的仿真三维环境，以更好地模拟实际作战条件；研究面向大规模集群对抗的自适应算法，解决状态动作维度爆炸和可扩展性问题；引入可解释性机制，提高决策的可信度。这将促进人工智能研究和智能化作战的发展，在未来智能化战争中具有重要的军事价值和广阔的应用前景。

参 考 文 献

- [1] Chen X., Liu X., Jing Y. A Study on Electronic Warfare System Based on UAV Swarm[J]. Modern Radar, 2020, 42(5): 9-12.
- [2] 张学明, 张书启. 解读美国空军新版小型无人机发展路线图[J]. 国防科技, 2016, 37(4): 81-84.
- [3] Mahmoudzadeh S., M.W Powers D., Sammut K., et al. A hierarchal planning framework for AUV mission management in a spatiotemporal varying ocean[J]. Computers & Electrical Engineering, 2018, 67: 741-760.
- [4] Dhainaut J.-F., Bassompierre F., Misse C., et al. Quelle stratégie française dans le cadre H2020?[J]. Therapies, 2015, 70(1): 95-102.
- [5] Kashin V. Defense innovation in Russia in the 2010s[J]. Journal of Strategic Studies, 2021, 44(6): 901-921.
- [6] Wei W., He X., Wang X., et al. Research on Swarm Munitions Cooperative Warfare[C]. Proceedings of 2021 International Conference on Autonomous Unmanned Systems (ICAUS 2021), Singapore, 2022: 717-727.
- [7] Lyons J. B., Miller C. A., Shively J., et al. Manned-Unmanned Teaming: Research and Applications Panel[J]. Proceedings of the Human Factors and Ergonomics Society Annual Meeting, 2021, 65(1): 321-325.
- [8] Wang X., Wang Y., Su X., et al. Deep reinforcement learning-based air combat maneuver decision-making: literature review, implementation tutorial and future direction[J]. Artificial Intelligence Review, 2023, 57(1): 1-39.
- [9] Roder A., Choo K. R. Unmanned Aerial Vehicles (UAVs) Threat Analysis and a Routine Activity Theory Based Mitigation Approach[C]. National Cyber Summit (NCS) Research Track, Cham, 2020: 99-115.
- [10] Liu H. Research on Optimization of Attack and Defence Area of Multi-UAV Based on Reinforcement Learning[C]. 2023 3rd International Conference on Consumer Electronics and Computer Engineering (ICCECE), GuangZhou, 2023: 864-870.
- [11] Wang F. Y., Zhang J. J., Zheng X., et al. Where does AlphaGo go: from church-turing thesis to AlphaGo thesis and beyond[J]. IEEE/CAA Journal of Automatica Sinica, 2016, 3(2): 113-120.
- [12] Webber M. The Kosovo war: a recapitulation[J]. International Affairs, 2009, 85(3): 447-459.
- [13] Das S. K. Modeling intelligent decision-making command and control agents: An application to air defense[J]. IEEE Intelligent Systems, 2013, 29(5): 22-29.
- [14] Poropudas J., Virtanen K. Game-theoretic validation and analysis of air combat simulation models[J]. IEEE Transactions on Systems, Man, and Cybernetics-Part A: Systems and Humans, 2010, 40(5): 1057-1070.
- [15] Cruz J. B., Simaan M. A., Gacic A., et al. Game-theoretic modeling and control of a military air operation[J]. IEEE Transactions on aerospace and electronic systems, 2001, 37(4): 1393-1405.
- [16] Austin F., Carbone G., Falco M., et al. Game theory for automated maneuvering during air-to-air combat[J]. Journal of Guidance, Control, and Dynamics, 1990, 13(6): 1143-1149.
- [17] Pan Q., Zhou D., Huang J., et al. Maneuver decision for cooperative close-range air combat based on state predicted influence diagram[C]. 2017 IEEE international conference on information and automation

- (ICIA), Macao, 2017: 726-731.
- [18]Ruan W., Duan H., Deng Y. Autonomous maneuver decisions via transfer learning pigeon-inspired optimization for UCAVs in dogfight engagements[J]. IEEE/CAA Journal of Automatica Sinica, 2022, 9(9): 1639-1657.
- [19]Rardin R. L., Uzsoy R. Experimental evaluation of heuristic optimization algorithms: A tutorial[J]. Journal of Heuristics, 2001, 7: 261-304.
- [20]Yan J., Daobo W., Tingting B., et al. Multi-UAV objective assignment using Hungarian fusion genetic algorithm[J]. IEEE Access, 2022, 10: 43013-43021.
- [21]Hu X., Luo P., Zhang X., Wang J. Improved ant colony optimization for weapon-target assignment[J]. Mathematical Problems in Engineering, 2018, 2018: 1-14.
- [22]Kaneshige J., Krishnakumar K. Artificial immune system approach for air combat maneuvering: Intelligent Computing[C]. Theory and Applications V, Tsingtao, 2007: 68-79.
- [23]Changqiang H., Kangsheng D., Hanqiao H., et al. Autonomous air combat maneuver decision using Bayesian inference and moving horizon optimization[J]. Journal of Systems Engineering and Electronics, 2018, 29(1): 86-97.
- [24]Huang C., Wei Z., Yang Y., et al. Knowledge acquisition for the air combat based on GWO[C]. Journal of Physics: Conference Series, Tsingtao, 2019: 012078.
- [25]Zhifei X., Yue L., Yingxin K., et al. An online ensemble semi-supervised classification framework for air combat target maneuver recognition[J]. Chinese Journal of Aeronautics, 2023, 36(6): 340-360.
- [26]Zhao K., Huang C. Air combat situation assessment for UAV based on improved decision tree[C]. 2018 Chinese Control And Decision Conference (CCDC), ShenYang, 2018: 1772-1776.
- [27]You S., Diao M., Gao L., et al. Target tracking strategy using deep deterministic policy gradient[J]. Applied Soft Computing, 2020, 95: 106490.
- [28]Li Y., Shi J., Jiang W., et al. Autonomous maneuver decision-making for a UCAV in short-range aerial combat based on an MS-DDQN algorithm[J]. Defence Technology, 2022, 18(9): 1697-1714.
- [29]Sarkar N. I., Gul S. Artificial intelligence-based autonomous UAV networks: A survey[J]. Drones, 2023, 7(5): 322.
- [30]Bayerlein H., Theile M., Caccamo M., et al. Multi-UAV path planning for wireless data harvesting with deep reinforcement learning[J]. IEEE Open Journal of the Communications Society, 2021, 2: 1171-1187.
- [31]Wu L., Wang C., Zhang P., et al. Deep reinforcement learning with corrective feedback for autonomous uav landing on a mobile platform[J]. Drones, 2022, 6(9): 238.
- [32]Yue L., Yang R., Zhang Y., et al. Deep reinforcement learning for UAV intelligent mission planning[J]. Complexity, 2022, 2022: 1-13.
- [33]Mnih V., Badia A. P., Mirza M., et al. Asynchronous methods for deep reinforcement learning[C]. International conference on machine learning, New York, 2016: 1928-1937.
- [34]Hessel M., Modayil J., Van Hasselt H., et al. Rainbow: Combining improvements in deep reinforcement learning[C]. Proceedings of the AAAI conference on artificial intelligence, New Orleans, 2018: 3215-3222.
- [35]Miao Q., Zheng W., Lv Y., et al. DAO to HANOI via DeSci: AI paradigm shifts from AlphaGo to ChatGPT[J]. IEEE/CAA Journal of Automatica Sinica, 2023, 10(4): 877-897.
- [36]Zhang H., Yu T. AlphaZero[J]. Deep Reinforcement Learning: Fundamentals, Research and

- Applications, 2020: 391-415.
- [37]Watkins C. J., Dayan P. Q-learning[J]. Machine learning, 1992, 8: 279-292.
- [38]Silver D., Graves A., Antonoglou I., et al. Playing atari with deep reinforcement learning[J]. DeepMind Lab arXiv, 2013, 1312.
- [39]Van Hasselt H., Guez A., Silver D. Deep reinforcement learning with double q-learning[C]. Proceedings of the AAAI conference on artificial intelligence, Phoenix, 2016: 2064-2100.
- [40]Schaul T., Quan J., Antonoglou I., et al. Prioritized experience replay[J]. arXiv preprint arXiv:151105952, 2015.
- [41]Hausknecht M., Stone P. Deep recurrent q-learning for partially observable mdps[C]. 2015 aaai fall symposium series, Austin, 2015: 29-37.
- [42]Sutton R. S., Mcallester D., Singh S., et al. Policy gradient methods for reinforcement learning with function approximation[J]. Advances in neural information processing systems, 1999, 12: 1057-1063.
- [43]Silver D., Lever G., Heess N., et al. Deterministic policy gradient algorithms[C]. International conference on machine learning, BeiJing, 2014: 387-395.
- [44]Lillicrap T. P., Hunt J. J., Pritzel A., et al. Continuous control with deep reinforcement learning[J]. arXiv preprint arXiv:150902971, 2015.
- [45]Schulman J., Levine S., Abbeel P., et al. Trust region policy optimization[C]. International conference on machine learning, Lille, 2015: 1889-1897.
- [46]Schulman J., Wolski F., Dhariwal P., et al. Proximal policy optimization algorithms[J]. arXiv preprint arXiv:170706347, 2017.
- [47]Silver D., Hasselt H., Hessel M., et al. The predictron: End-to-end learning and planning[C]. International Conference on Machine Learning, Sydney, 2017: 3191-3199.
- [48]Schrittwieser J., Antonoglou I., Hubert T., et al. Mastering atari, go, chess and shogi by planning with a learned model[J]. Nature, 2020, 588(7839): 604-609.
- [49]Li B., Bai S., Liang S., et al. Manoeuvre decision-making of unmanned aerial vehicles in air combat based on an expert actor-based soft actor critic algorithm[J]. CAAI Transactions on Intelligence Technology, 2023, 8(4): 1608-1619.
- [50]Fan Z., Xu Y., Kang Y., et al. Air combat maneuver decision method based on A3C deep reinforcement learning[J]. Machines, 2022, 10(11): 1033.
- [51]Austin F., Carbone G., Falco M., et al. Automated maneuvering decisions for air-to-air combat[C]. Guidance, navigation and control conference, Monterey, 1987: 659-669.
- [52]Rizk Y., Awad M., Tunstel E. W. Decision making in multiagent systems: A survey[J]. IEEE Transactions on Cognitive and Developmental Systems, 2018, 10(3): 514-529.
- [53]Prudencio R. F., Maximo M. R., Colombini E. L. A survey on offline reinforcement learning: Taxonomy, review, and open problems[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023: 1-23.
- [54]Littman M. L. Markov games as a framework for multi-agent reinforcement learning[M]. San Francisco: Machine Learning Proceedings, 1994: 157-163.
- [55]Lowe R., Wu Y. I., Tamar A., et al. Multi-agent actor-critic for mixed cooperative-competitive environments[J]. Advances in neural information processing systems, 2017, 30: 1-12.
- [56]Pomerleau D. A. Alvin: An autonomous land vehicle in a neural network[J]. Advances in neural

- information processing systems, 1988, 1: 305-313.
- [57]Cuturi M. Sinkhorn distances: Lightspeed computation of optimal transport[J]. Advances in neural information processing systems, 2013, 26: 1-9.
- [58]Kakade S., Langford J. Approximately optimal approximate reinforcement learning[C]. Proceedings of the Nineteenth International Conference on Machine Learning, Sydney, 2002: 267-274.
- [59]Zhuang Z., Lei K., Liu J., et al. Behavior proximal policy optimization[J]. arXiv preprint arXiv:230211312, 2023.
- [60]Fujimoto S., Gu S. S. A minimalist approach to offline reinforcement learning[J]. Advances in neural information processing systems, 2021, 34: 20132-20145.
- [61]Foerster J., Farquhar G., Afouras T., et al. Counterfactual multi-agent policy gradients[C]. Proceedings of the AAAI conference on artificial intelligence, New Orleans, 2018: 2974-2982.
- [62]Wang T., Wang J., Wu Y., Zhang C. Influence-based multi-agent exploration[J]. arXiv preprint arXiv:191005512, 2019.
- [63]Yu C., Velu A., Vinitsky E., et al. The surprising effectiveness of ppo in cooperative multi-agent games[J]. Advances in neural information processing systems, 2022, 35: 24611-24624.
- [64]Piao H., Han Y., Chen H., et al. Complex relationship graph abstraction for autonomous air combat collaboration: A learning and expert knowledge hybrid approach[J]. Expert Systems with Applications, 2023, 215: 119285.
- [65]Kuba J. G., Chen R., Wen M., et al. Trust region policy optimisation in multi-agent reinforcement learning[J]. arXiv preprint arXiv:210911251, 2021.
- [66]Zhao A., Lin M., Li Y., et al. A mixture of surprises for unsupervised reinforcement learning[J]. Advances in neural information processing systems, 2022, 35: 26078-26090.

攻读硕士学位期间科研项目及科研成果

已发表论文

[1] **Wang B**, Lin K*, Sun G. Offline Reinforcement Learning Via Optimal Transport And Improved Performance Difference Theorem: *2023 IEEE 35th International Conference on Tools with Artificial Intelligence (ICTAI)* [C], Atlanta. 2023: 619-626.
(CCF-C 会议论文, EI: 20240315405064, 本学位论文第三章)

待发表论文

[1] **Wang B**, Lin K*, Sun G. Improving Cooperative Multi-Agent Exploration via Surprise Minimization and Individual and Team Bonding Policy [J]. *IEEE Transactions on Knowledge and Data Engineering*, Under Review (本学位论文第四章)

发明专利

[1] 孙国瀚, 林恺, **王博艺**. 一种感知行动回路决策的内在奖励生成方法: 中国. 发明类别: 发明专利. 授权公告号: CN202211292921.0, 公开(或授权)日期: 2023.01.10. (本学位论文第四章)

参与科研项目

- [1] 装备预先研究领域基金项目(80912010302): 感知 XXXX 方法研究, 2022.03 – 2023.02, 负责人: 林恺.
- [2] 国家重点研发计划项目(2022YFC2405003): MR 兼容 ICD 的无线通信机理及应用适配研究, 2022.11 – 2027.10, 负责人: 林恺.
- [3] 国防科技创新特区 163 计划 12-37 重点项目: XXXX 指标体系构建与精准刻画关键技术研究. 19-XX-XX-XX-XX-XX-03. 2020.07-2022.06, 负责人: 林恺.

致 谢

总觉来日方长，毕业遥遥可及，但山水相逢，终有一别。

这篇毕业论文的完成，象征着我学生时代的暂别，即便深知人生必须前行，心中仍难免泛起一丝对“同学”身份的留恋。

感谢父母，父母之爱子，则为之计深远，儿子深知养育不易，感谢你们一路以来的支持，爱不挂口，常记于心。

感谢林恺导师在学业上的支持，生活上的关心与鼓励。林老师做事细心和严谨，为人宽厚且温和。在科研学习过程中，我一直视他为自己的榜样和努力的目标。得益于林老师的严格要求，我在科研之路上稳扎稳打。这三年里，在每个学术研讨会上，林老师都会耐心地和我们沟通讨论，很多的问题和瓶颈都会在意见交流以后柳暗花明，让我们茅塞顿开。他教导我们做学术要一丝不苟，也鼓励我们要不断创新。当遇到困难时，林老师也会像朋友一样对我们提供帮助和分享他的人生经历，在与老师交流的过程中往往会使我醍醐灌顶，豁然开朗。我很庆幸在研究生的这段时光中能够遇到林老师，对您的感激之情溢于言表。同时我的研究工作也得到了国家重点研发计划课题 MR 兼容 ICD 的无线通信机理及应用适配研究（编号 2022YFC2405003）的支持。

感谢我的挚友们，你总是在我脆弱失意时给予我安慰与包容，让我找回了前行的勇气和力量。感谢实验室的师兄师妹们，是你们让我的科研之路充满欢乐与收获。感谢我的室友，无论是学业上的困惑还是生活中的琐碎，你们总是陪伴在我身边，给予我无尽的支持与鼓励。

感谢读研三年来所有的相遇、离别与经历。

最后感谢我自己，经历了无数次的自责与自卑，最终还是选择一直努力下去。人生道路上永远相信：一重山有一重山的错落，我有我的平仄。