

编号：_____密级：_____公开

本科毕业论文

课题名称：结合领域规则的学习型决策行为建模方法研究

学 员 姓 名：	贺怡姝	学 号：	202105138003
首次任职专业：	相关专业技术与 指挥管理	学历教育专业：	大数据管理与 应用
命 题 学 院：	系统工程学院	年 级：	2021 级
指 导 教 员：	曾俊杰	职 称：	助理研究员
协助指导教员：	许凯	职 称：	讲师
所 属 单 位：	国防科技大学系统工程学院		

国防科技大学教育训练部制

目 录

目 录	I
图目录	IV
表目录	VI
摘 要	i
ABSTRACT.....	ii
1 前 言	1
1.1 研究背景.....	1
1.2 研究内容与意义.....	4
1.2.1 研究内容.....	4
1.2.2 研究意义.....	5
1.3 相关工作.....	5
1.3.1 基于知识工程的决策行为建模方法.....	6
1.3.2 基于机器学习的决策行为建模方法.....	10
1.3.3 深度强化学习与领域知识融合	14
1.4 论文创新点与组织结构	16
1.4.1 创新点.....	16
1.4.2 组织结构.....	17
2 面向多自由度 CGF 战术机动的问题定义与建模.....	19
2.1 深度强化学习概述.....	19
2.1.1 强化学习的基本概念	19
2.1.2 强化学习的基础方法	22
2.2 自研计算机生成兵力智能行为建模平台	24
2.2.1 平台的定位与目标	24
2.2.2 平台的架构与功能	24
2.2.3 平台的接口设计	26
2.3 基于行为树和深度强化学习的多自由度 CGF 导航问题建模	27

2.3.1	领域规则定义	27
2.3.2	仿真环境建模	28
2.3.3	动力学约束及相关参数	28
2.3.4	状态空间与动作空间设计	30
2.3.5	奖励设计与终止条件	31
2.3.6	问题剖析	33
2.4	本章小结	34
3	结合领域规则的深度强化学习算法研究	35
3.1	基于演员-评论家架构的深度强化学习算法	35
3.1.1	演员-评论家架构	35
3.1.2	孪生延迟深度确定性策略梯度算法	36
3.2	结合领域知识的学习型决策建模方法	38
3.2.1	领域规则引导的深度强化学习算法框架	38
3.2.2	行为树的初步设计与预实验	42
3.3	本章小结	45
4	仿真实验	47
4.1	实验设计	47
4.1.1	实验设计	47
4.1.2	评估指标	47
4.1.3	实现细节	47
4.2	基于行为树的仿真实验	48
4.2.1	行为树节点层级与规则设计	48
4.2.2	比例-积分-微分控制器	52
4.2.3	行为树的改进与评估	53
4.3	总体结果	54
4.4	消融实验	56
4.4.1	行为树引导的有效性验证	56
4.4.2	课程学习的有效性验证	57
4.5	敏感性分析	58

4.5.1	最大引导步长	58
4.5.2	非稀疏环境	59
4.6	泛化性分析	60
4.7	行为分析	61
4.8	其他实验	63
4.9	本章小结	66
5	总结与展望	68
5.1	总结	68
5.2	未来展望	69
致 谢		70
参考文献		71

图目录

图 1-1 行为树节点示意图.....	8
图 1-2 强化学习过程示意图.....	12
图 1-3 论文组织结构图	18
图 2-1 简单网格世界强化学习概念示意图.....	19
图 2-2 简单网格世界中智能体状态示意图.....	20
图 2-3 简单网格世界中确定性策略示意图.....	21
图 2-4 平台架构设计示意图.....	24
图 2-5 引擎接口的 python 化.....	25
图 2-6 标准化的 Python 环境类	25
图 2-7 仿真环境示意图	28
图 2-8 多自由度陆上履带式机动作战平台 CGF 示意图	29
图 2-9 CGF 雷达感知线示意图.....	29
图 3-1 基于 AC 架构的深度强化学习算法示意图.....	36
图 3-2 结合领域知识的学习型决策建模方法算法框架	39
图 3-3 预实验行为树回合步长频数分布直方图	43
图 3-4 预实验设计行为树实验结果.....	43
图 3-5 预实验行为树引导步数下降情况.....	44
图 3-6 传统 TD3 算法预实验结果	44
图 3-7 传统 TD3 算法计算步数	45
图 4-1 回合步长频数分布直方图.....	54
图 4-2 奖励频数分布直方图.....	54
图 4-3 训练地图	54
图 4-4 BT 引导的 TD3 算法与传统 TD3 算法和行为树获得平均奖励.....	55
图 4-5 BT 引导步长的下降	55
图 4-6 算法效率对比分析.....	56
图 4-7 BT 引导的 TD3 算法与随机引导步数获得平均奖励对比	57

图 4-8 BT 引导步长与随机引导步长.....	57
图 4-9 不同最大引导步长下的训练效果.....	58
图 4-10 不同最大引导步长下引导步数的下降.....	58
图 4-11 传统 TD3 算法稀疏环境与非稀疏环境对比分析.....	59
图 4-12 BT 引导的 TD3 算法稀疏环境与非稀疏环境对比分析.....	60
图 4-13 测试地图 1-4.....	61
图 4-14 测试地图 1-4 中算法的训练效果.....	61
图 4-15 行为树策略下的行为分析.....	62
图 4-16 经 TD3 算法纠正后的轨迹.....	63
图 4-17 测试地图 1 中不同最大引导步长下获得的平均回报值.....	63
图 4-18 测试地图 1 中不同最大引导步长下引导步长的下降.....	64
图 4-19 测试地图 3 中不同最大引导步长下获得的平均回报值.....	64
图 4-20 测试地图 3 中不同最大引导步长下引导步长的下降.....	65
图 4-21 测试地图 3 中不同引导步长下的 $lossactor$	65
图 4-22 测试地图 3 中不同引导步长下的 $losscritic$	66
图 4-23 BT 引导的 TD3 算法后期可能出现过拟合现象.....	66

表目录

表 2-1 状态空间参数	30
表 2-2 动作空间参数	31
表 3-1 TD3 算法伪代码	37
表 3-2 TD3 算法与 DDPG 的对比	38
表 3-3 行为树引导的 TD3 算法伪代码.....	40
表 4-1 本实验设计的行为树.....	49

摘要

在现代军事训练领域，计算机生成兵力（Computer-Generated Forces, CGF）的战术决策行为建模具有重要意义。随着战场环境复杂性的增加，对 CGF 行为建模提出了实时性、真实性和自适应性的需求。产生式规则、行为树（Behavior Tree, BT）等传统方法可解释性强、逻辑清晰，但存在自适应能力不足、难以应对动态环境变化的局限性；深度强化学习（Deep Reinforcement Learning, DRL）在处理高维输入和复杂决策任务中展现出强大潜力，可自主学习最优策略，但在稀疏奖励场景下易陷入局部最优，训练效率较低。

为此，本文针对战场环境下的战术决策行为建模问题，基于实验室自研 CGF 智能行为建模平台，面向多自由度 CGF 战术机动过程构建符合马尔科夫决策过程的模型。基于此，本文提出一种结合领域规则的学习型决策行为建模方法，使用行为树表征领域知识，将其与 DRL 相结合，以引导智能体学习方向，减少无效探索，提升训练效率与性能表现。

具体而言，在快速启动强化学习（Jump-Start Reinforcement Learning, JSRL）框架下，将行为树作为引导策略与孪生延迟深度确定性策略梯度算法（Twin Delayed Deep Deterministic policy gradient, TD3）算法相结合，逐步减少引导步数，实现从规则引导到自主探索的平滑过渡。通过行为树的结构化规则表征方法，将已有领域规则转化为动作约束，并引入比例-积分-微分（Proportional-Integral-Derivative, PID）控制器实现平滑动作映射，降低人工调参复杂度。

在仿真实验部分，通过对比行为树引导的 TD3 算法与传统 TD3 算法及单独行为树的性能表现和消融实验，验证了所提方法的有效性。实验结果表明，行为树引导的 TD3 算法在稀疏奖励场景下收敛速度提升约 3-4 倍，最终平均回报值更高，且对不同地图环境和参数变化具有良好的适应性和鲁棒性。此外，行为分析表明，结合领域规则的学习型决策行为建模方法能够优化智能体行为策略，使其在复杂战场环境中展现出更好的适应性和决策效能。

关键词：深度强化学习；领域规则；行为树；战术决策行为建模；计算机生成兵力

ABSTRACT

In the field of modern military training, the tactical decision-making behavior modeling of Computer-Generated Forces (CGF) is of great significance. With the increase of complexity of battlefield environment, the demand for real-time, realism, and adaptive behavioral modeling of CGF has been put forward. Traditional methods, such as generative rule and Behavior Tree (BT), are highly interpretable and logical, but have the limitations of insufficient adaptive ability and difficulty in coping with dynamic environment changes; Deep Reinforcement Learning (DRL) shows strong potential in handling high-dimensional inputs and complex decision-making tasks, and it can autonomously learn the optimal strategy, but in sparse reward scenarios, it is easy to fall into local optimization, and the training efficiency is low.

To this end, this paper addresses the problem of tactical decision-making behavior modeling in the battlefield environment, and builds obstacle avoidance and path planning scenarios in the 2D grid world based on the laboratory's self-developed CGF Intelligent Behavioral Modeling Platform to construct a model that conforms to the Markov decision-making process. Based on this, this paper proposes a learned decision-making behavior modeling method that combines domain rules, uses behavior trees to characterize domain knowledge, and combines them with DRL to guide the learning direction of intelligences, reduce invalid exploration, and improve training efficiency and performance.

Specifically, under the framework of Jump-Start Reinforcement Learning (JSRL), the behavior tree is used as a guidance policy in combination with the Twin Delayed Deep Deterministic policy gradient (TD3) algorithm to gradually reduce the number of bootstrapping steps and realize a smooth transition from rule-based guidance to autonomous exploration. Through the structured rule characterization method of behavior tree, the existing domain rules are transformed into action constraints, and the proportional-integral-derivative (PID) controller is introduced to realize smooth action mapping and reduce the complexity of manual parameter adjustment.

In the simulation experiment section, the effectiveness of the proposed method is verified by comparing the performance of the behavior tree-guided TD3 algorithm with that of the traditional TD3 algorithm and the behavior tree alone. The experimental results show that the behavioral tree-guided TD3 algorithm improves the convergence speed by about 3-4 times in sparse reward scenarios, has a higher final average reward value, and has good adaptability and robustness to different map environments and parameter changes. In addition, behavioral analysis shows that the learned decision-making behavioral modeling approach combined with domain rules can optimize the intelligent body behavioral strategies, so that it can show better adaptability and decision-making efficacy in complex battlefield environments.

KEY WORDS: Deep Reinforcement Learning; Domain Rules; Behavior Trees; Tactical Decision-Making Behavior Modeling; Computer-Generated Forces

1 前言

1.1 研究背景

在国防和军队现代化进程中，人民军队的打赢能力面临前所未有的挑战。在此背景下，传统训练方法的局限性逐渐显现。传统训练，通常指基于固定场景和条件的实地训练，未能充分涵盖突发状况和复杂环境，从而在实战中暴露出应变能力不足的问题。由于武器装备的迅猛发展和快速迭代，传统训练设备和技术可能已落后于现代武器系统，无法有效模拟其操作和使用。长期和平环境下的单一作战形式训练，也导致部分官兵存在训练盲区，缺乏实战检验。同时，地域差异和财力限制也影响了部分单位训练场地和器材的配备，制约了训练效果的进一步提升。

随着建模仿真和人工智能技术的兴起，训练仿真技术已经成为解决这一问题的有效途径之一。借助构建复杂战场环境与现代武器系统的模拟模型，训练仿真能够提供接近实战的训练平台，降低了组织训练的门槛，压缩了训练成本，提升了训练效益，从而增强了官兵的适应性和实战能力。分队级模拟训练系统是专为军事训练设计的一种仿真系统，其核心功能在于模拟真实的战场环境和作战条件，为分队指挥人员和战斗岗位人员提供接近实战的训练体验，旨在满足分队级部队在战斗指挥与对抗演练中的专业化训练需求。

计算机生成兵力（Computer-Generated Forces, CGF）作为分队级模拟训练系统的重要组成部分，是由计算机生成和控制的自主或半自主的仿真智能体，通过模拟实际战场环境中武器装备或人员等作战实体在战场中的各种复杂行为，提供“真实的战斗行动”与操作实装、模拟器的参训人员进行交互^[1]。将 CGF 引入作战仿真系统，一方面旨在减少仿真对人员和模拟器材的依赖，有助于进一步扩展仿真规模，削减仿真训练成本^[2]；另一方面，CGF 能够根据实际需求对真实或未来战场中敌我友各方作战和指挥实体进行灵活多样的仿真建模，进而实现对仿真的灵活控制和预测^[3]。

CGF 的核心在于其行为建模^[2]。行为建模主要指在军事仿真中对人的行为或表现进行建模的过程^[4]，其目的是生成尽可能接近真实对象行为模式的模型，以便基于该模型便捷地构造出行为合理的虚拟实体。行为建模主要分为物理行为建模和认

知行为建模^[4]，本文主要关注认知行为建模。认知行为建模是指利用计算机模拟和模型来研究和解释人类认知和行为的过程。认知行为建模的挑战之一在于如何捕捉人类思维的复杂性，包括感知、记忆、学习、推理和决策等相互影响并且受到情境和个体差异影响的多个环节。在 CGF 领域，认知行为建模通过映射敌我双方的动作时序逻辑，深刻解析战场态势演变规律，进而识别作战意图，有效构建更具针对性与适应性的战术应对框架，显著提升作战体系的决策效能。

认知行为建模为决策行为建模提供了更深层次的理论基础和认知过程的模拟支持，决策行为建模则是专注于模拟个体或集体在特定情境下的决策过程。它通过对决策者的特征属性、决策过程以及决策关联影响要素的分析，以构建决策行为的数学描述。决策行为建模可以用于模拟战争的不确定性和涌现性等特征，从而训练指挥人员指挥决策，并探索作战概念下战法创新^[5]。本研究主要关注战场环境下的战术决策行为建模。战术决策是指在执行军事行动过程中，作战主体为实现既定作战目标而进行的系统性规划、逻辑推理以及决策选择的高阶认知过程^[6]。具体而言，在分队级模拟训练系统中，决策行为模型具有以下实际需求：

（1）实时性需求：作战主体能够基于战场态势的实时变化灵活调整方案，进行动态决策^[3]。这就要求行为模型能够快速处理信息并做出决策，以适应战场的动态变化。

（2）真实性需求：行为模型的构建应充分确保其现实性和物理层面的真实性，满足动力学约束，准确反映作战实体在战术决策中的行为特征。

（3）自适应需求：由于真实战场环境具有高度的复杂性和不确定性，行为模型必须具有良好的自适应性，能够适应不同的战场条件、敌我态势变化以及战术策略的调整，并根据新的信息和环境变化及时调整决策策略。

在当前的分队级模拟训练系统中，产生式规则、有限状态机、行为树等基于知识工程的方法广泛使用领域规则构建 CGF 的决策模型，并凭借其良好的可解释性而在军事仿真领域被普遍采纳。然而，这些传统方法在建模效率和模型自适应性方面存在显著的局限性。由于缺乏灵活性和自适应能力，传统模型难以应对快速变化的战场环境和未知情况，限制了模拟训练系统的效果和应用范围。

深度强化学习（Deep Reinforcement Learning, DRL）作为一种融合深度学习（Deep Learning, DL）与强化学习（Reinforcement Learning, RL）的先进机器学习范式，已在多个领域展现出卓越的性能。深度学习作为机器学习的一个重要分支，

通过构建多层神经网络结构，即深度神经网络，致力于挖掘数据中的复杂模式，并在图像识别与语音识别等任务中取得了显著成就。强化学习则是一种智能体在与环境的动态交互过程中，通过选择动作以获得环境反馈（奖励）并学习最优决策策略的学习范式。在深度强化学习中，深度学习模型扮演着智能体的“大脑”，负责处理例如图像或视频帧等高维原始数据，并从中提取关键特征，这些特征随后被用于强化学习算法，以指导智能体的决策过程。深度学习与强化学习的结合，赋予了智能体处理更复杂任务的能力，例如在复杂的视频游戏中取得胜利、实现自动驾驶汽车的技术突破以及在机器人控制领域中的应用等。

然而，当 DRL 直接应用于决策行为建模时，在奖励通常延迟且稀疏的复杂应用场景中，难以高效地获取包含有效奖励信息的状态-动作样本。由于无法及时获得正反馈，智能体无法通过试错来学习有效的策略，导致训练过程效率低下，成本高昂且算法难以收敛，在某些情况下，这可能导致智能体无法学习到有效的策略^[7]。

为应对深度强化学习面临的挑战，学术界和工业界普遍采取的策略是将领域数据与 DRL 相结合，以提高学习效率和策略性能。然而，这一范式存在根本性局限，领域数据的获取往往伴随着高昂的成本和严格的限制。高质量交互数据不仅需要复杂的工程系统支撑，还可能因环境动态变化产生分布偏移。获取大量领域数据往往需要投入大量的人力、物力和时间，成本高昂，在一些新兴领域或小众领域，可获取的数据量本身就有限。

相较于被动依赖领域数据，人类知识或历史策略能够为智能体提供一定程度的先验知识和经验指导，帮助智能体更高效地进行探索和学习，避免从零开始的盲目试错，从而提高学习效率和策略性能。目前仅有少数研究者尝试将先验策略与 DRL 结合，以期获得更好的学习效果和策略泛化能力。这些尝试虽然具有创新性，但也存在一些问题。DRL 通常需要大量的与环境的交互才能学会解决复杂任务，这在现实世界中是不切实际的。引入先验策略虽然可以减少对样本的需求，但在某些情况下，先验策略可能无法完全覆盖环境的所有方面，导致智能体仍需要大量的探索来补充和调整先验策略。此外，先验策略不一定有效，尤其是在演员-评论家（Actor-Critic, AC）模型中，未经训练的随机初始化评论家容易提供错误的学习信号，导致良好的先验策略被遗忘^[8]。综上所述，本文致力于研究结合领域规则的深度强化学习方法，显著提升智能体在稀疏奖励场景下的学习效率与策略性能，实现优化战术决策行为建模的效果。

1.2 研究内容与意义

1.2.1 研究内容

本研究围绕结合领域规则的学习型决策行为建模方法展开,主要研究内容如下:

(1) 面向多自由度 CGF 战术机动的问题定义与建模

本部分旨在构建适用于战术决策行为建模的仿真环境与理论框架。实验室自主研发的计算机生成兵力智能行为建模平台采用模块化分层架构,实现战场环境动态建模、多智能体交互仿真与算法训练验证的一体化支撑,并设计标准化接口以兼容主流机器学习框架。针对战场环境下的战术决策行为建模问题,面向多自由度 CGF 战术机动过程,在该平台结合行为树和深度强化学习方法进行问题定义并构建马尔科夫决策过程。具体包括领域规则定义、仿真环境建模、动力学约束及相关参数定义、状态空间与动作空间设计、奖励设计与终止条件等,并剖析稀疏奖励场景下强化学习训练的难点。

(2) 结合领域规则的深度强化学习算法研究

本部分聚焦于算法设计与优化。首先介绍深度强化学习的基本概念及基于 AC 架构的典型算法,重点分析孪生延迟深度确定性策略梯度算法(Twin Delayed Deep Deterministic policy gradient, TD3)对深度确定策略梯度算法(Deep Deterministic Policy Gradient, DDPG)的改进。本文提出的结合领域知识的学习型决策行为建模方法,主要基于快速启动强化学习(Jump-Start Reinforcement Learning, JSRL)框架,将行为树作为引导策略与深度强化学习算法相结合,实现从规则引导到自主探索的平滑过渡,大幅提高了稀疏奖励环境下的训练效率和性能表现。其中,行为树部分通过构建基于行为树的结构化规则表征方法,将军事战术知识转化为动作约束,并引入比例-积分-微分(Proportional-Integral-Derivative, PID)控制器实现平滑动作映射,降低人工调参复杂度,提升算法的适应性和鲁棒性。

(3) 仿真实验验证

本部分旨在通过仿真实验验证所提方法的有效性和实用性。首先详细描述实验设计,包括实验场景的设定、评估指标的选择以及实现细节中的软件和硬件环境配置等。然后开展基于行为树的仿真实验,分析行为树节点层级与规则设计的细节,对行为树引导的 TD3 算法进行总体结果分析,对比其与传统 TD3 算法和单独行为树的性能表现,开展消融实验验证行为树引导和课程学习的有效性。此外,进行敏

感性分析和泛化性分析以展示算法对不同参数和环境的鲁棒性和适应性，并分析算法效率和行为表现。最后对其他实验现象和问题进行探讨，进一步完善研究成果。

1.2.2 研究意义

1.2.2.1 理论意义

1. 领域规则与深度强化学习的融合机制

本研究致力于探索领域规则与深度强化学习的融合机制，通过行为树将领域知识嵌入深度强化学习框架，弥补了传统 DRL 在稀疏奖励场景下的不足，为智能体决策行为建模提供了新的理论依据。

2. 深度强化学习算法的稳定性与收敛性

对深度强化学习算法的稳定性与收敛性进行深入分析，特别是在高维状态空间和复杂决策任务中，研究算法在奖励稀疏和延迟时的性能变化，推动了深度强化学习理论的发展，并为算法优化提供了新的方向。

1.2.2.2 应用意义

1. 分队级模拟训练的沉浸感和训练效果

本文所提出的结合领域规则的深度强化学习方法能够有效使 CGF 智能体快速地适应复杂多变的战场环境，高效构建“可敬畏的对手和可信赖的队友”，提高分队级模拟训练的沉浸感，从而增强军事训练的效果。

2. 军事仿真系统的智能化和仿真技术的发展

本文研究成果不仅有助于提升战术决策行为建模的智能化水平，还为军事仿真系统的智能化升级提供了技术支持，推动了军事训练仿真技术的发展，使其能够更好地满足现代军事训练的需求。

1.3 相关工作

为确保研究的创新性和可行性，本文系统调研了以下相关工作：一是基于知识工程的决策行为建模方法，包括产生式规则、行为树等在军事仿真中的应用现状与局限性；二是基于机器学习的决策行为建模方法，涵盖模仿学习和深度强化学习的最新进展；三是深度强化学习与领域知识融合的研究前沿，重点分析课程学习、模仿学习与强化学习结合以及示例引导强化学习等方法在解决稀疏奖励问题上的优势与不足。通过全面深入调研，明确了现有技术在军事仿真领域中的适用场景和未解

决问题，为本研究结合领域规则的学习型决策行为建模方法提供了坚实的理论支撑和创新方向。

1.3.1 基于知识工程的决策行为建模方法

在基于知识工程的决策行为建模方法相关工作调研中，本文重点关注了产生式规则和行为树这两类方法。产生式规则在军事仿真领域有着长期的实践基础，其“条件-动作”结构能够清晰地表达领域专家的知识，为智能体行为建模提供逻辑框架。而行为树凭借其层次化的图形结构和直观的节点组织方式，有效解决了有限状态机在复杂行为建模中的局限性，且在游戏和机器人领域已得到广泛应用并不断演进。本文选择介绍的这两种方法在军事仿真中具有代表性，广泛应用于战场态势评估和战术决策，它们的规则驱动特性与本文旨在结合领域规则的深度强化学习方法高度契合，为后续研究提供了可借鉴的规则表征和推理机制。

1.3.1.1 产生式规则

产生式规则的概念起源可追溯至 1943 年 Post 的形式化重写系统^[9]，但其真正系统性应用始于 20 世纪 70 年代专家系统的兴起。1972 年，A. Newell 与 H. Simon 提出“通用问题求解器”（General Problem Solver, GPS），首次将产生式规则用于模拟人类问题解决过程^[10]。随后，斯坦福大学 1976 年开发的 MYCIN 系统成功将产生式规则与不确定性推理相结合，开创了医疗诊断领域的规则驱动范式，有力验证了规则库在知识密集型任务中的有效性^[11]。

20 世纪 80 年代，军事需求推动了产生式规则的进一步发展。美国国家航天局开发的 CLIPS（C Language Integrated Production System，C 语言集成产生式系统）成为军事仿真中规则推理的标准工具，支持武器系统效能评估与作战方案推演。进入 21 世纪，随着模糊逻辑、贝叶斯网络与机器学习的融合，产生式规则在动态战场环境建模中展现出更强的适应性。

产生式规则通过构建多属性决策模型，显著提升了战场态势分析的智能化水平。在空袭目标威胁评估中，孙海文等设计了直觉模糊产生式规则推理框架，将敌方飞行轨迹、武器类型、电磁信号等动态参数转化为模糊隶属度，结合历史战例生成威胁等级^[12]。此类系统能够实时筛选多源情报，为指挥员提供优先级排序，有效降低人工决策的认知负荷。

然而，传统产生式规则依赖预先定义的静态知识库，难以适应瞬息万变的战场环境。在复杂电磁对抗中，敌方可能通过战术欺骗改变信号特征，导致基于历史数

据的规则失效。无人机群协同作战需在毫秒级完成路径规划与威胁规避，而传统规则引擎因串行执行模式难以满足时效需求，尽管分布式计算与并行化改进一定程度上提升了性能，但复杂规则链的推理延迟仍制约其在战术边缘设备的部署。军事仿真系统通常需要集成数万条规则以覆盖多域作战场景，容易导致规则冲突与推理效率下降。在联合火力打击仿真中，不同军种规则库的兼容性问题可能引发逻辑矛盾，需额外设计冲突消解机制。此外，规则权重分配依赖专家经验，主观偏差可能影响仿真结果的可信度。战场信息常具有高度模糊性与不完备性，在威胁判断中，敌方伪装或电子干扰可能导致传感器数据失真，单纯依赖 IF-THEN 规则易产生误判，虽然引入直觉模糊集（Fuzzy Intuitionistic Set, IFS）可增强不确定性表达，但其计算复杂度随规则数量指数增长，限制了大场景应用。

作为一种经典的基于知识工程的决策行为建模方法，产生式规则通过“条件-动作”结构对专家知识进行形式化表示，能够将军事战术原则、作战条例等领域的先验知识转化为智能体的行为决策逻辑，在军事仿真领域具有广泛的应用基础，为本文研究如何将领域规则与深度强化学习相结合提供了直观的切入点。通过分析产生式规则在军事仿真中的应用，本文可以借鉴其在知识表示和推理方面的成熟经验，探索如何将领域规则有效地嵌入到深度强化学习的框架中。产生式规则在面对高度动态和复杂的战场态势时，存在规则覆盖不全、更新困难和推理效率下降等问题，同样促使本文进一步思考如何利用深度强化学习的自适应学习能力，弥补领域规则的不足，实现其与数据驱动学习方法的优势互补，进而推动战术决策行为建模技术的发展。

1.3.1.2 行为树

行为树（Behavior Tree, BT）是一种在计算机科学领域用于构建和模拟实体行为的层次性图形化建模工具，以层次化的节点组织为特征，能够描述和规划复杂系统中各种实体的交互和决策。行为树最初是为计算机游戏而设计，用于模拟游戏中的自主角色行为。行为树提供了一种基于树形结构的任务表示方法，这种结构易于理解和扩展^[13]。行为树因其直观、易于设计和调试的特点，在游戏产业中得到了广泛的应用，许多备受瞩目的电子游戏，如《光晕》、《生化奇兵》和《孢子》等，都采用了行为树来模拟 NPC（non-player character，非玩家角色）的行为。

随着技术的发展，行为树逐渐受到机器人学家的关注。机器人学家 Rodney Brooks 于 1986 年在麻省理工大学（Massachusetts Institute of Technology, MIT）发

表的论文中描述了一种名为 **Subsumption Architecture** 的技术，其中“行为层次”部分对智能体的实际决策模型进行了层次设计^{[14][15]}。随着对行为树研究的不断深入，其理论体系也日益完善，如图 1-1 所示，研究者们提出了多种类型的节点和组合方式。作为行为树的内部节点，控制节点（**Composite Nodes**）负责根据子节点的状态来决定行为树的遍历方式，它们可以有任意数量的子节点，但在处理这些子节点时有所不同。具体而言，在控制节点中，顺序节点（**Sequence**）按照从左向右的既定顺序执行子节点，如果任何一个子节点返回失败或正在执行，则立即返回当前子节点状态结果，并终止继续选择子节点，只有所有的子节点返回成功，顺序节点才能返回成功^[3]；选择节点（**Fallback**）则依次尝试执行其子节点，直到存在一个子节点返回成功，如果所有子节点都返回失败，那么选择节点也返回失败；并行节点（**Parallel**）同时执行多个子节点，并根据预设的成功和失败阈值来决定整个并行节点的状态。动作节点（**Action Nodes**）是行为树的叶节点，代表智能体的具体行为，执行具体的操作，并返回成功、失败或运行中的状态。例如，一个动作节点可以代表执行动作“向下行走一格”。条件节点（**Condition Nodes**）同样是行为树的叶节点，用于进行简单的检查，并返回成功或失败的状态。条件节点通常代表简单判断，例如“是否超出环境边界？”“是否与障碍物碰撞？”。




图 1-1 行为树节点示意图

Razan Ghzouli 等人从开源存储库中挖掘使用行为树语言的机器人应用程序，并分析其使用情况，发现行为树在机器人项目中被用于定义复杂任务的协调和执行，展示了其在模块化和可重用性方面的优势，许多项目通过重用子树来实现任务的模块化^[13]。Matteo Iovino 等人在机器人和 AI（Artificial Intelligence，人工智能）领域详细探讨了行为树与有限状态机、决策树、子系统架构等其他任务切换架构之间的关系，并提出了多种行为树的扩展模型，如扩展行为树（**Extended Behavior Tree, eBT**）、并发行为树（**Concurrent Behavior Tree, CBT**）等，以解决标准行为树在并行操作、参数化等方面存在的问题^[16]。

行为树的研究不仅限于游戏和机器人学，还扩展到了其他领域。研究者们探讨

了行为树在不同领域的应用和发展趋势，包括交互式软件平台、无人自主系统和作战仿真系统^[8]。刘瑞峰等人^[16]在其研究中强调了行为树在人工智能军事应用中的重要性，从层次性、维护性、代码耦合度、扩展性、复用性等方面对比了行为树和有限状态机以及层次有限状态机的特点，并分析了行为树与机器学习、专家系统相结合的发展趋势，以及在交互式软件平台、无人自主系统、作战仿真系统方面的应用前景^[17]。郑东海和于海跃在其研究中进一步具体探讨了强化学习与行为树在智能体行为决策中的研究与应用，系统总结了强化学习相关智能体行为决策、基于行为树的智能体行为策略等相关研究现状和进展。他们展望了未来可能的研究方向，为提升智能体行为决策自主性、鲁棒性的技术方法提供了有益借鉴^[18]。张俊峰等人结合行为树与示例图，利用基于概率模型的势力图融合战场信息提供决策支撑，运用行为树组织战术行为节点，推理得到战术决策结果，有效提高了兵棋推演平台中 AI 指挥员决策的合理性和准确性^[19]。进化行为树方法作为一种利用进化算法自主生成和优化行为树模型的智能体行为建模方法，被广泛研究。相关研究基于遗传编程、语法演化、混合算法三类进化行为树算法以及相应改进算法，分析比较不同算法的优劣，并梳理总结了进化行为树方法在作战仿真、游戏人工智能、机器人等领域的具体应用^[20]。

综上所述，行为树作为一种层次化的图形化建模工具，在模拟实体行为和决策过程中展现出了其独特的优势。从研究现状来看，行为树不仅在游戏设计和机器人学领域得到了广泛应用，还在军事仿真、无人自主系统等领域展现出广阔的应用前景。行为树的结构化特性使其在定义复杂行为时更加直观和易于维护，同时，其与机器学习、专家系统的结合为智能体行为决策提供了新的研究路径。尽管如此，行为树在实际应用中仍面临一些挑战，如在处理高维状态空间和复杂决策任务时的效率问题，以及如何与深度强化学习等先进算法有效融合，提升智能体的自适应性和泛化能力。

针对本课题拟研究的问题背景，即结合领域规则的学习型决策行为建模方法研究，行为树的研究现状提供了重要的参考和启示。行为树的结构化表示方法可以作为领域规则嵌入深度强化学习框架的有效载体，通过行为树的节点设计，可以直观地将领域专家知识转化为智能体的行为指导策略。其次，行为树与深度强化学习的结合，有望在保持行为可预测性和可维护性的同时，赋予智能体更强的自主学习能力和环境适应性。因此，本课题将在现有研究的基础上，进一步探索行为树与深度

强化学习相结合的方法，以期在战术决策行为建模领域取得新的突破。

1.3.2 基于机器学习的决策行为建模方法

在基于机器学习的决策行为建模方法相关工作调研中，本文重点关注了模仿学习和深度强化学习这两类方法。模仿学习通过学习专家示范数据来训练智能体，能够在复杂任务中快速生成高质量策略，但其性能高度依赖专家数据的质量和泛化能力。深度强化学习则通过智能体与环境的交互学习最优策略，在处理高维输入和复杂决策任务中展现出强大潜力，但在稀疏奖励场景中面临探索效率低下的局限性。本文选择介绍这两种方法，是因为模仿学习和深度强化学习在军事仿真领域具有广泛的应用前景，它们分别代表了基于示范学习和自主探索学习的两类典型方法，与本文旨在结合领域规则提升强化学习效率的研究目标高度相关，为后续探索领域规则与深度强化学习的融合提供了重要的参考和借鉴。

1.3.2.1 模仿学习

模仿学习最初采用监督学习方法，通过观察完整的行为轨迹来学习目标策略。2009 年，Hal Daumé III 等人提出了 SEARN 概念，这一方法放弃了传统的全局模型学习与搜索，转而专注于学习一个分类器，以在每个决策点进行最优搜索^[21]。2010 年，Stephane Ross 和 Drew Bagnell 提出了两种新的模仿学习算法——前馈训练算法和随机混合迭代学习（SMILe）算法，用以替代传统的监督学习^[22]。同年，他们提出了数据聚合算法（Dataset Aggregation, DAgger），旨在解决从示范中学习的问题^[23]。次年，进一步提出了基于还原法的主动模仿学习算法（Reduction-based Active Imitation Learning, RAIL），该算法针对独立同分布（i.i.d）的主动学习器执行包含多次调用的序列^[24]。2012 年，Hal Daumé III 等人对 DAgger 算法进行了改进，提出了教练指导下的数据聚合算法（DAgger by coaching）^[25]。2013 年，Doina Precup 等人针对专家示范稀缺或非最优的情况，提出了有演示的近似策略迭代算法（Approximate Policy Iteration with Demonstration, APID）^[26]。Stephane Ross 和 Drew Bagnell 于 2014 年再次对 DAgger 算法进行了扩展，提出了聚合值模拟算法（Aggregate Values to Imitate, AggreVaTe）^[27]。近年来，模仿学习已经成为解决强化学习问题的一个流行框架，衍生出多种提升学习性能的算法和技术。模仿学习通过与图形图像学的最新研究成果相结合，在游戏人工智能、机器人控制和自动驾驶等领域发挥了重要作用^[28]。

传统军事仿真中的敌方行为多基于预编程规则，缺乏动态适应性。模仿学习通

通过分析历史作战数据或专家演示，可生成具备战术学习能力的虚拟对手。美国陆军开发的 VR-Forces 平台利用生成式 AI 模拟敌方单位的实时战术调整，其行为模型能够根据士兵行动反馈优化策略，显著提升训练环境的对抗真实性。在无人装备领域，模仿学习被用于优化自主控制策略，多水下无人自主航行器（Autonomous Underwater Vehicle, AUV）编队任务中，多智能体生成对抗交互式自模仿学习算法通过模仿人类操作员的轨迹数据并结合强化学习训练，实现避障与队形保持的协同优化，其性能超越提供的次优专家演示，接近甚至优于具有最佳演示的多智能体生成对抗性模仿学习算法的性能^[29]。

尽管模仿学习在军事仿真中展现潜力，其实际应用仍面临多重制约。模仿学习的性能高度依赖专家演示数据的质量，而军事场景中，保密性限制导致数据获取困难，真实作战数据可能存在噪声或信息缺失，敌方行为模式多样，有限的专家数据难以覆盖所有潜在战术变化，导致策略泛化能力不足。此外，多域作战要求模型同时处理物理域、信息域和认知域的动态交互，现有方法尚缺乏跨域推理的有效机制。高保真军事仿真需处理大规模地理数据与实体交互，对算力需求极高。数字孪生战场环境中，实时渲染 3D 地形与物理特效需依赖 GPU 集群，而模仿学习的迭代训练进一步加剧资源消耗。中小规模军队难以承担相关硬件投入，限制了技术的普及。

在探讨结合领域规则的学习型决策行为建模方法时，模仿学习的研究进展为该领域提供了宝贵的参考框架和启示。模仿学习作为一种高效的策略提取机制，能够直接从领域专家的行为中提炼出决策策略，从而加速智能体的学习进程，并显著降低对大规模标注数据集的依赖性。本文对模仿学习的系统调研旨在借鉴现有研究成果，实现高效且自主的决策行为模型生成。

1.3.2.2 深度强化学习

深度强化学习作为人工智能领域的新兴研究热点，其核心在于融合深度学习的感知能力与强化学习的决策能力，在多种需要感知高维度原始输入数据和决策控制的任务中取得了显著的突破，如在游戏、机器人控制、对话系统等领域发挥了重要作用^{[30][31]}。

DRL 是一种端对端的感知与控制系统，具有很强的通用性，如图 1-2 所示，其学习过程可以描述为：

（1）在每个时刻智能体与环境交互得到一组高维观察数据，并利用深度学习方法感知观察结果，以提取具体的状态特征表示；

(2) 基于预期回报来评价各动作的价值函数,并通过某种策略将当前状态映射为相应的动作;

(3) 环境对此动作做出反馈,智能体得到下一个观察结果。通过不断循环这一过程,最终可以得到实现目标的最优策略^[30]。




图 1-2 强化学习过程示意图

深度强化学习主要包括基于值函数的深度强化学习和基于策略梯度的深度强化学习。其中,基于值函数的深度强化学习方法通过设计一个用于学习状态动作值函数 $Q(s,a)$ 的深度神经网络 Q-network,并不断进行误差修正来更新 Q 网络权重,以指导政策的学习。这种方法虽然简单,但却能够在许多任务中达到良好性能,而且容易实施,是核心的基础方法和研究重点。基于策略梯度的深度强化学习方法则通过学习策略直接来指导决策过程,通常涉及到策略梯度算法,即通过计算策略梯度来调整策略参数,展示了深度强化学习在理论和应用方面的独特优势^{[31][32]}。

基于值函数的深度强化学习方法源自 1989 年, Watkins 在其博士论文中提出了 Q 学习算法 (Q-learning),该算法使得智能体能够在未知环境中通过探索与试错来学习最优策略,为后续的强化学习算法提供了重要的理论支持^[33]。2013 年,DeepMind 团队将深度学习与强化学习相结合,提出了深度 Q 网络 (Deep Q-Network, DQN)^[34]。DQN 在 Atari 2600 游戏上展现出了惊人的性能,标志着深度强化学习在复杂控

制任务中的潜力。基于深度强化学习的围棋程序 AlphaGo 在 2015 年问世,其在 2016 年击败了世界围棋冠军李世石,成为深度强化学习领域的一个重要里程碑^{[35][36]}。针对标准 DQN 中的目标值过高估计问题, Hasselt 等人提出了深度双 Q 网络算法 (Double Deep Q-Network, DDQN), 该算法通过使用两个价值函数来减少这种过高估计, 其中一个用于选择动作, 另一个用于评估动作的价值, 从而提高了算法的稳定性和性能^[37]。DDQN 在多个 Atari 游戏中的表现超过了传统的 DQN 算法, 证明了其在解决强化学习问题中的有效性。为应对高维状态空间和连续动作空间的挑战。Ziyu Wang 等在 2016 年提出了对抗深度 Q 网络算法 (Dueling Deep Q-Network, Duel-DQN), 该算法通过分离状态值函数和动作优势函数, 可以更有效地识别在策略评估期间的正确动作。在 Atari 2600 游戏测试平台上, Duel-DQN 相较于单流 Q 网络 (single-stream Q-networks) 取得了显著的性能提升, 成为新的性能基准^[38]。

基于策略梯度的 REINFORCE 算法是一种蒙特卡洛 (Monte Carlo, MC) 方法, 它使用从策略中采样得到的轨迹数据来计算策略参数的梯度, 并更新当前策略, 使其向最大化策略期望回报的目标靠近。该方法具有较好的收敛性质, 并且在连续动作空间中表现出较高的效率。然而, 容易收敛到局部最优解, 以及在策略评估时效率不高且方差较大等缺陷也在一定程度上限制了该算法的应用, 这些问题在后续的算法改进中得到了一定程度的解决, 如引入 baseline 的 REINFORCE 算法和 AC 算法^[39]。Lillicrap 等人提出的 DDPG 算法, 结合了 DQN 和策略梯度方法, 适用于连续动作空间的任务^[40]。DDPG 通过使用 AC 框架和经验回放, 提高了 DRL 在连续动作空间中的性能。

综上所述, 深度强化学习作为人工智能领域的一个活跃研究方向, 已经在多个复杂任务中展现出了其强大的潜力和优势。从 DQN 的提出到 AlphaGo 的突破, 再到各种 DRL 算法的不断演进, 这一领域在处理高维状态空间和连续动作空间的任务中取得了显著进展。然而, 针对结合领域规则的学习型决策行为建模方法研究, 当前的 DRL 研究仍然面临着一些挑战。特别是在军事仿真领域, 如何将领域规则有效地整合到 DRL 模型中, 提高模型的决策质量和学习效率, 是一个亟待解决的问题。此外, DRL 算法在高维状态空间和复杂决策任务中的稳定性和收敛性问题, 以及在面对奖励稀疏和延迟时的性能变化, 也是本课题需要重点关注和研究的方向。本课题将致力于结合领域规则, 优化 DRL 算法, 以提高模型在复杂战场环境中的自适应性和泛化能力, 从而为军事训练和作战决策提供更有效的支持。

1.3.3 深度强化学习与领域知识融合

近年来,强化学习与领域知识融合的研究在提升算法效率与策略性能方面取得了显著进展,其主要方法可归纳为课程学习、结合模仿学习与强化学习以及示例引导的强化学习三大方向。

课程学习通过设计渐进式难度递增的任务序列,将环境结构知识嵌入学习过程,引导智能体从简单子任务逐步过渡到复杂目标,以解决传统 RL 在稀疏奖励或高维状态空间中的探索难题,其核心思想是模仿人类“由易到难”的学习模式,通过先验知识引导智能体逐步掌握复杂技能。Florensa 等人提出的反向课程生成 (Reverse Curriculum Generation) 方法,从目标状态出发,逆向扩展任务难度范围。该方法首先在目标附近采样初始状态,逐步生成难度递增的中间任务,使智能体在接近目标区域获得密集奖励反馈,从而避免早期探索中的无效尝试^[41]。类似地, Ivanovic 等人的 BARC (Backward Reachability Curriculum, 反向可达性课程) 框架基于反向可达性分析,量化机器人策略在复杂环境中的状态可达性,并生成以目标为导向的课程,相比于随机探索, BARC 在两个具有代表性的动态机器人学习问题中通过动态调整课程难度显著提高了学习速度^[42]。Resnick 等人的回放方法 (Backplay) 则进一步优化了稀疏奖励场景下的课程设计,通过从目标状态反向生成训练轨迹,确保智能体在早期阶段即可接触关键状态,显著提高了迷宫导航等任务的收敛效率^[43]。综上所述,课程学习方法通过设计合理的任务序列和利用环境先验知识,为强化学习在稀疏奖励和复杂环境中的应用提供了有效解决方案。这些方法在多种任务中验证了其高效性和适应性,但同时也受限于任务分解的合理性和对环境拓扑结构的依赖。

模仿学习与强化学习的结合综合利用了模仿学习中专家示范数据提供的先验知识和强化学习在环境中的自主探索能力。具体来说,模仿学习通过专家示范数据预训练智能体,使其能够快速学习到有效的策略,减少早期探索中的无效尝试。而强化学习则在此基础上,通过与环境的交互进一步优化策略,提高策略的适应性和鲁棒性。早期经典研究如 Schaal 的 LfD (Learning from Demonstration, 从演示中学习) 已证明,通过动态运动基元编码示范轨迹,可直接生成符合物理约束的运动策略,为后续模仿学习与 RL 的融合奠定了基础^[44]。Vecerik 等人在机械臂操作任务中结合 DDPG 与人类示范,通过使用人类演示数据填充重放缓冲区和优先级重放机制自动调整演示数据和实际交互数据之间的采样比例,使智能体在稀疏奖励下仍能快速定

位高回报区域^[45]。对于高维连续控制任务，Rajeswaran 等人提出的演示增强策略梯度算法（Demonstration Augmented Policy Gradient, DAPG）通过少量的示例动作隐式地学习人类对于特定任务的先验知识，实验证明该算法可以用较低的样本复杂度来完成训练，且能够得到鲁棒的任务策略^[46]。Kober 等人则针对机器人运动控制任务，设计了感知与动作耦合的模仿学习模型，将视觉感知信息与关节运动编码为联合概率分布，确保策略在动态环境中的鲁棒性^[47]。模仿学习与强化学习相结合的方法在提升智能体在稀疏奖励和复杂任务中的学习效率方面展现了显著优势，有效减少了强化学习中的随机探索，加速了收敛过程。然而，其性能仍受限于示范数据的质量和任务分解的合理性。

示例引导的强化学习是一种通过参考示例来指导强化学习智能体学习策略的方法，借助参考示例以帮助智能体更高效地探索状态空间，从而更快地收敛到更优的策略，提升决策能力。Xue 等人的 DeepMimic 框架将运动捕捉数据转化为参考状态分布，并设计复合奖励函数，鼓励策略在跟踪示例动作的同时满足物理平衡与能量效率约束。实验表明，DeepMimic 可生成高度逼真的跑酷、空翻等复杂动作，且对未见过的地形扰动具备强适应性。其核心创新在于基于重要性加权的奖励机制，通过动态调整示例跟踪与任务目标的权重，平衡行为逼真性与功能有效性^[48]。示例引导 RL 已在游戏角色控制、仿生机器人等领域取得广泛应用，但其计算成本较高，且高度依赖示例数据的数量和质量。

尽管课程学习、结合模仿学习与强化学习以及示例引导的强化学习在特定场景下取得了显著进展，但现有方法仍面临诸多挑战。课程学习高度依赖于任务分解的合理性和环境拓扑结构，设计难度较大且对环境的适应性有限。结合模仿学习与强化学习的方法虽然能够利用专家示范数据加速学习过程，但其性能受制于示范数据的质量与泛化能力。示例引导的强化学习则因计算成本高昂和对示例数据的依赖性而难以广泛应用于复杂动态环境。在军事仿真领域，战场环境的复杂性与动态性对智能体的决策能力提出了更高要求，亟需一种能够有效整合领域知识、提升学习效率并增强策略适应性的新型方法。对此，JSRL 是一种由 Ikechukwu Uchendu 等人提出的深度强化学习算法^[9]，其主要目标是利用预先存在的策略、离线数据或示范来初始化和加速强化学习任务的学习过程，从而有效缓解强化学习在样本效率和学习速度方面的瓶颈问题，尤其适用于数据稀缺或样本获取成本较高的场景。

在 JSRL 框架下，引导策略被用来形成探索策略的起始状态课程，通过这种方

式将复杂的探索问题进行分解和简化，为智能体在早期学习阶段提供了更有前景的探索方向，大大缩短了探索的收敛时间。随着探索策略的不断改进和优化，引导策略的影响会按照预定的课程安排逐渐减弱，直至最终完全由探索策略自主控制学习过程，实现了从引导到自主探索的平滑过渡，既充分利用了先验知识，又避免了引导策略对学习过程的过度干预和限制。JSRL 的优势在模拟的机器人任务中得到了显著体现，其性能显著优于现有的模仿学习和强化学习算法，尤其是在数据较少的情况下^[8]。

JSRL 作为一种强化学习方法，在实际应用中展现出了显著的优势，但同时也存在一些局限性。现有 JSRL 框架下的算法主要利用强化学习得到的策略作为引导策略，这样的引导策略本身具有一定的黑箱性质，通常难以解释其决策背后的逻辑和依据，这使得 JSRL 在部分场景下的应用受到一定限制。其次，JSRL 需要依赖强化学习训练得到引导策略，同时后期仍然需要强化学习作为探索策略。一方面，前期引导策略的训练需要消耗大量的计算资源和时间成本。另一方面，强化学习训练过程的复杂性和不稳定性，可能导致引导策略的质量参差不齐，进而影响 JSRL 的整体性能。此外，强化学习训练过程中的超参数调整、环境建模等挑战也会进一步增加 JSRL 实现的难度。在本研究中，我们尝试在 JSRL 框架下使用领域规则来引导深度强化学习，以增强算法的可解释性，提升训练效率并降低训练的开销。

1.4 论文创新点与组织结构

1.4.1 创新点

1. 领域规则启发式引导深度强化学习的算法框架

本研究创新性将行为树的领域知识表征与深度强化学习相结合，巧妙地使用行为树作为引导策略并通过 JSRL 框架进行协同优化，充分发挥二者优势，实现高效的智能决策与行为控制。相较于传统强化学习算法，该方法在稀疏奖励场景下的收敛速度提升约 3-4 倍，有效解决了传统强化学习在稀疏奖励场景下探索效率低导致的训练周期长、易陷入局部最优的问题，提高了策略稳定性和收敛速度。为战术决策行为建模领域提供了全新的解决方案，显著提升了模型的训练效率和决策质量。

2. 面向 CGF 自适应的结构化规则表征方法

构建了一种基于行为树的可解释性领域规则表征范式，通过优先级节点划分机

制与参数自适应机制，依据军事战术知识对节点进行有序组织，将军事战术转化为动作约束，并创新性地通过 PID 控制器实现平滑动作映射，大幅降低了人工调参的复杂度，增强了模型对环境变化的自适应能力，为复杂战场环境下的智能体行为建模提供了可扩展的技术路径。

1.4.2 组织结构

论文的主要内容安排如图 1-3 所示。

第 1 章主要阐述研究背景，包括传统训练方法在国防和军队现代化进程中的局限性，以及训练仿真技术的兴起等；介绍研究内容与意义，明确具体研究内容，以及理论和应用方面的意义；梳理相关工作，涵盖基于知识工程的决策行为建模方法、基于机器学习的决策行为建模方法，以及深度强化学习与领域知识融合的研究进展；最后提出论文创新点和组织结构。

第 2 章概述深度强化学习的基本概念，包括强化学习的要素、贝尔曼方程等；介绍自研计算机生成兵力智能行为建模平台的定义、目标、架构和功能，以及接口设计；针对战场环境下的战术决策行为建模问题，面向多自由度 CGF 战术机动过程，结合行为树和深度强化学习方法，进行问题定义，构建马尔科夫决策过程，包括仿真环境的设定、动力学约束及相关参数、奖励设计与终止条件，并剖析问题难点。

第 3 章深入研究基于 AC 架构的深度强化学习算法，重点介绍 TD3 算法及其对 DDPG 算法的改进；阐述结合领域规则的深度强化学习算法，基于 JSRL 框架展开算法设计，将行为树作为引导策略与 TD3 算法相结合，通过课程学习递减引导步数，以实现从规则引导到自主探索的平滑过渡，并在此基础上开展预实验，为正式的仿真实验提供有效参考。

第 4 章进行仿真实验，详细描述实验设计，包括实验想定与设计、评估指标、实现细节；开展基于行为树的仿真实验，描述行为树节点层级与规则设计、PID 控制器应用，以及行为树的改进与评估；对行为树引导的 TD3 算法进行总体结果分析，并开展消融实验以验证行为树引导和课程学习的有效性；进行敏感性分析和泛化性分析，考察算法对不同参数和环境的鲁棒性和适应性；分析算法效率和行为表现；最后对其他实验现象和问题进行探讨。

第 5 章总结本文的研究工作，阐述方法核心贡献；对未来研究方向进行展望，如自动化领域规则生成、多智能体协同决策、跨领域迁移与应用扩展、安全性与可解释性增强等。




图 1-3 论文组织结构图

2 面向多自由度 CGF 战术机动的问题定义与建模

本研究在实验室自研计算机生成兵力智能行为建模平台上开展仿真实验。该平台以高实时性、高扩展性为核心设计目标，基于模块化分层架构，实现了战场环境动态建模、多智能体交互仿真与算法训练验证的一体化支撑。通过标准化强化学习接口封装，平台兼容主流机器学习框架（如 PyTorch、TensorFlow），支持行为树、深度强化学习等多模态决策模型的快速集成与对比实验。

本章将基于该仿真平台，针对 CGF 在复杂战场环境中的自主导航问题展开建模与分析。具体而言，面向多自由度 CGF 战术机动过程，结合领域规则与深度强化学习算法，构建行为树引导的学习型决策模型。通过明确问题定义、设计状态空间与奖励机制，本章旨在为后续算法研究与仿真实验奠定理论基础，同时验证自研平台在智能行为建模任务中的实用性与有效性。

2.1 深度强化学习概述

2.1.1 强化学习的基本概念

如图 2-1，考虑一个在网格世界中移动的机器人，该机器人也被称为智能体（agent），它可以在网格的相邻单元格之间移动。在每个时间步长中，它只能够占据其中的一个单元格。智能体可以进入非障碍物的单元格，不能进入障碍物单元格。




图 2-1 简单网格世界强化学习概念示意图

在网格世界中，存在一个智能体想要到达的目标单元格。智能体的最终目标是找到一个“好的”策略，使其能够从任意的初始单元格开始，到达目标单元格。对于策略的“好”的定义，基本思想是，智能体在不进入任何障碍物单元格，不走不必要的弯路且不与网格世界的边界相撞的情况下到达目标。在该过程中，智能体事先并不了解网格世界的任何信息，因此，智能体必须与环境进行交互，通过反复试验找到一个好的策略。

在强化学习过程中，需要重点关注智能体在环境中的状态（state）。如图 2-2，在网格世界中，状态一般对应于智能体的位置。所有状态的集合称为状态空间，表示为 $S = \{s_1, s_2, \dots, s_n\}$ 。




图 2-2 简单网格世界中智能体状态示意图

对于每个状态，智能体可以采取多种可能的动作（action），例如，前进、后退、左转、右转、原地不动等。所有动作的集合称为动作空间，表示为 $A = \{a_1, a_2, \dots, a_m\}$ 。不同的状态可以有不同的动作空间。

在执行动作时，智能体可以从一个状态转移到另一个状态，该过程被称为状态转移。普遍情况下，障碍物单元格允许智能体进入，但会受到惩罚。在本研究的网格世界中，障碍物单元格被严格禁止进入，若 CGF 智能体试图进入障碍物单元格，则判断 CGF 撞毁，该实验回合终止。

每个状态及其关联的动作都有其状态转移过程。在数学上，状态转移过程可以用条件概率来描述。例如，对于 s_1 和 a_2 ，条件概率分布为

$$p(s_1|s_1, a_2) = 0$$

$$p(s_2|s_1, a_2) = 1$$

$$p(s_3|s_1, a_2) = 0$$

$$p(s_4|s_1, a_2) = 0$$

... ..

$$p(s_n|s_1, a_2) = 0$$

这表明，当在 s_1 状态下执行 a_2 时，智能体移动到 s_2 的概率为 1，移动到其他状态的概率为 0。因此，在 s_1 状态下执行 a_2 一定会导致智能体状态转移到 s_2 。在更加普遍的情况下，状态转移并非完全确定。

策略（policy）告诉智能体在每个状态下执行哪些动作，表示为 $\pi(a|s)$ 。遵循策略，智能体可以生成一个从初始状态开始的轨迹。在数学上，策略可以用条件概率来描述，例如， s_1 的策略为：

$$\pi(a_1|s_1) = 0$$

$$\pi(a_2|s_1) = 0.5$$

$$\pi(a_3|s_1) = 0.5$$

$$\pi(a_4|s_1) = 0$$

... ..

$$\pi(a_m|s_1) = 0$$

在表明，在 s_1 状态下，智能体采取存在 a_2 或 a_3 动作的概率都是 0.5。存在如图 2-3 中确定性的策略，但策略通常是随机的。




图 2-3 简单网格世界中确定性策略示意图

奖励（reward）是强化学习中最独特的概念之一。在某一状态下执行某一动作后，智能体将获得一个奖励，表示为 r ，作为来自环境的反馈。奖励是状态 s 和动作 a

的函数，因此也被表示为 $r(s, a)$ 。奖励的值可以是正数、负数或零。不同的奖励对智能体最终学习的策略也有不同的影响。一般来说，奖励为正数时，鼓励智能体采取相应的动作；奖励为负数时，不鼓励智能体采取相应的动作。设计适当的奖励是强化学习的重要步骤，尤其对于复杂任务来说，奖励的设计可能十分复杂。此外，为了确定一个好的策略，我们必须考虑从长远来看获得的总回报，具有最大即时奖励的行为可能不会导致最大的总奖励。使用条件概率描述奖励过程，例如，对于状态 s_1 ，有

$$p(r = -1 | s_1, a_1) = 1$$

$$p(r \neq -1 | s_1, a_1) = 0$$

这表明，在 s_1 状态下执行 a_1 时，智能体确定地得到 $r = -1$ 。在这个例子中，奖励是确定性的，一般来说，奖励可以是随机的。

马尔科夫性质指无记忆的随机过程。从数学上讲：

$$\begin{aligned} p(s_{t+1} | s_t, a_t, s_{t-1}, a_{t-1}, \dots, s_0, a_0) &= p(s_{t+1} | s_t, a_t) \\ p(r_{t+1} | s_t, a_t, s_{t-1}, a_{t-1}, \dots, s_0, a_0) &= p(r_{t+1} | s_t, a_t) \end{aligned} \quad (2-1)$$

其中， t 表示当前时间步长， $t + 1$ 表示下一个时间步长。上式表明，下一个状态或奖励仅取决于当前状态和动作，并独立于之前的状态和动作。

轨迹（trajectory）是一个状态-动作-奖励链，轨迹的回报（return）被定义为沿着轨迹收集的所有奖励的总和，回报也被称为总回报或累积回报，可以用于评估策略。回报包括即时奖励和未来奖励。即时奖励是在该状态下采取行动后立即获得的奖励，未来奖励是在离开该状态后获得的奖励。有可能出现即时奖励为负，未来奖励为正的情况。因此，采取行动时应该避免短视，根据总回报而不是即时奖励来决定。在此基础上，我们引入折扣回报的概念。

$$discounted\ return = r_1 + \gamma r_2 + \gamma^2 r_3 + \dots \quad (2-2)$$

其中， $\gamma \in (0,1)$ 为折扣率。 γ 越接近 0 时，智能体更强调近期获得的奖励由此产生的政策相对短视； γ 越接近 1 时，智能体更重视未来的奖励，由此产生的政策更有远见，并且敢于在近期获得负数的回报。

当通过遵循策略与环境交互时，智能体可能会在某些终端状态停止，由此产生的轨迹可以称作一个回合（episode）。

2.1.2 强化学习的基础方法

状态值（state value）指的是智能体在该状态下遵循给定策略时可以获得的平均

奖励。状态值越大，对应的策略越好。状态值可以作为评估策略是否有效的度量。贝尔曼方程是一组描述所有状态值之间关系的线性方程组，是分析状态值的重要工具，通过求解贝尔曼方程可以得到状态值，这个过程被称为策略评估。

考虑一系列时间步长 $t = 0, 1, 2 \dots$ ，在 t 时刻，智能体处于状态 S_t ，并根据策略 π 采取动作 A_t ，下一个状态为 S_{t+1} ，获得的即时奖励为 R_{t+1} 。这个过程可以简洁地表示为 $S_t \xrightarrow{A_t} S_{t+1}, R_{t+1}$ ，其中 $S_t, A_t, S_{t+1}, R_{t+1}$ 均为随机变量，并且 $S_t, S_{t+1} \in S, A_t \in A(S_t), R_{t+1} \in R(S_t, A_t)$ 。

从 t 开始，可以得到一个状态-动作-奖励轨迹： $S_t \xrightarrow{A_t} S_{t+1}, R_{t+1} \xrightarrow{A_{t+1}} S_{t+2}, R_{t+2} \xrightarrow{A_{t+2}} S_{t+3}, R_{t+3} \dots$ ，根据定义，沿着轨迹的回报是 $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$ ，其中 $\gamma \in (0, 1)$ 为折扣率， $G_t, R_{t+1}, R_{t+2} \dots$ 都是随机变量。

计算 G_t 的期望 $v_\pi(s) = E(G_t | S_t = s)$ ， $v_\pi(s)$ 为价值-状态函数，也是 s 的状态值。注意， $v_\pi(s)$ 依赖于 s ，其定义为一个条件期望，条件为智能体从 $S_t = s$ 开始； $v_\pi(s)$ 依赖于 π ，由于轨迹是遵循策略 π 生成的，对于不同的策略，状态值可能不同； $v_\pi(s)$ 与 t 无关， $v_\pi(s)$ 在策略给定的瞬间就已经完全确定。

注意到 $G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = R_{t+1} + \gamma(R_{t+2} + \gamma R_{t+3} + \dots) = R_{t+1} + \gamma G_{t+1}$ ，由此可得

$$\begin{aligned} v_\pi(s) &= E[G_t | S_t = s] \\ &= E[R_{t+1} + \gamma G_{t+1} | S_t = s] \\ &= E[R_{t+1} | S_t = s] + \gamma E[G_{t+1} | S_t = s] \end{aligned} \quad (2-3)$$

其中，即时奖励均值为

$$\begin{aligned} E[R_{t+1} | S_t = s] &= \sum_{a \in A} \pi(a|s) E[R_{t+1} | S_t = s, A_t = a] \\ &= \sum_{a \in A} \pi(a|s) \sum_{r \in R} p(r|s, a) r \end{aligned} \quad (2-4)$$

由于马尔科夫性质，未来的奖励仅取决于当前状态，与此前状态无关，因此得到未来奖励均值为

$$\begin{aligned} E[G_{t+1} | S_t = s] &= \sum_{s' \in S} E[G_{t+1} | S_t = s, S_{t+1} = s'] p(s'|s) \\ &= \sum_{s' \in S} E[G_{t+1} | S_{t+1} = s'] p(s'|s) \\ &= \sum_{s' \in S} v_\pi(s') p(s'|s) \\ &= \sum_{s' \in S} v_\pi(s') \sum_{a \in A} p(s'|s, a) \pi(a|s) \end{aligned} \quad (2-5)$$

综上所述，对于所有的 $s \in S$ ，得到贝尔曼方程如下：

$$\begin{aligned} v_\pi(s) &= E[R_{t+1} | S_t = s] + \gamma E[G_{t+1} | S_t = s] \\ &= \underbrace{\sum_{a \in A} \pi(a|s) \sum_{r \in R} p(r|s, a) r}_{\text{mean of immediate rewards}} + \underbrace{\gamma \sum_{a \in A} \pi(a|s) \sum_{s' \in S} p(s'|s, a) v_\pi(s')}_{\text{mean of future rewards}} \quad (2-6) \\ &= \sum_{a \in A} \pi(a|s) [\sum_{r \in R} p(r|s, a) r + \gamma \sum_{s' \in S} p(s'|s, a) v_\pi(s')] \end{aligned}$$

其中, $v_{\pi}(s)$ 和 $v_{\pi}(s')$ 是待计算的未知状态值, $\pi(a|s)$ 是一个给定的策略, $p(r|s,a)$ 和 $p(s'|s,a)$ 表示系统模型。

2.2 自研计算机生成兵力智能行为建模平台

2.2.1 平台的定位与目标

本实验室自主研发的计算机生成兵力智能行为建模平台,旨在构建高实时性、高可扩展性的战场仿真环境,支持复杂战术算法的高效开发与验证。平台以 Python 为上层开发语言,底层基于 C++实现核心引擎,通过 OpenAI Gym 框架封装形成标准化的强化学习接口,可兼容主流机器学习算法库(如 PyTorch、TensorFlow)。

其核心目标包括:(1)实现战场环境动态建模与多智能体交互仿真;(2)提供算法训练与测试的统一接口;(3)支持战术行为可视化与性能量化分析。

2.2.2 平台的架构与功能

平台采用模块化分层设计,自下而上分为开发环境层和开发训练层。其中,开发环境层又分为仿真引擎层和环境封装层。




图 2-4 平台架构设计示意图

在图 2-4 中,仿真引擎层作为整个仿真系统的核心底层架构,承担着关键的运行与整合功能。其主要构成要素包括仿真引擎引接模块,该模块负责实现仿真引擎的初始化、模型和组件的初始化,确保仿真进程的顺畅启动与高效运行。Python 化接口的设计旨在为开发人员提供便捷、灵活且功能强大的编程接口,借助 Python 语

言的简洁语法与丰富库资源，促进仿真模型的快速构建与调试，提升开发效率，实现仿真业务逻辑的便捷编写与动态调整。图 2-5 展示了引擎接口的 python 化过程。其中，C++侧模型是一个代理模型，内部的业务逻辑由 Python 侧完成。代理模型的各种事件被触发时会调用对应的 Python 侧模型函数，以此实现模型和组件的智能化。




图 2-5 引擎接口的 python 化

环境封装层聚焦于构建想定场景与有效的交互机制。其中，想定场景模块依据特定的仿真需求与任务目标，精心设计并生成多样化的场景配置，涵盖地形地貌、环境参数、初始状态等关键要素，为仿真活动提供丰富、动态且贴合实际的背景环境，以满足不同应用领域下对仿真场景的特定要求。图 2-6 中的标准环境类则在 Python 化引擎接口的基础上，设计启停、重置和步进等交互逻辑，增加特征编码、动作映射和奖励函数等属性，实现标准化的环境类，确保整个仿真系统在环境特性描述、数据交互格式等方面的一致性与规范性，为各仿真组件之间的协同工作提供标准化的接口与数据框架，降低系统集成难度，增强系统的兼容性与互操作性。




图 2-6 标准化的 Python 环境类

具体来说，环境封装层的特征编码模块致力于对仿真环境中的各类信息进行高效编码与特征提取，将复杂的环境数据转化为易于处理与分析的特征向量或编码序列，为后续的智能算法应用、模型训练等提供简洁、有效的数据表示形式，同时也有助于实现对环境信息的快速检索、分类与识别，提升系统的智能化水平与信息处理效率。环境封装层的奖励设计模块紧贴仿真任务目标与系统优化方向，精心构建一套科学合理的奖励机制，通过量化评估仿真主体在特定行为下的表现与效果，赋予相应的奖励或惩罚信号，为强化学习算法等智能优化方法提供关键的反馈信息，引导仿真系统逐步向期望的性能目标收敛，实现对仿真行为的有效激励与优化控制。环境封装层的动作映射模块则负责实现仿真主体行为指令与实际操作动作之间的精准转换，将抽象的行为决策结果映射为具体的、可在仿真环境中执行的动作序列，确保仿真主体能够准确无误地执行预定任务，同时保证动作执行的物理合理性与环境适应性，促进仿真过程的连贯性与真实性。

开发训练层是仿真系统价值实现与性能提升的关键环节，主要聚焦于行为模型的开发与优化。该层包含算法场景模块，针对不同类型的仿真任务与问题特点，精选并设计多样化的算法应用场景，为各类智能算法提供丰富的测试与应用平台，促进算法的针对性改进与性能优化，以满足复杂多变的仿真需求。分布式训练架构模块则着眼于解决大规模仿真模型训练面临的计算资源瓶颈与效率问题，通过构建高效的分布式计算框架，将训练任务合理分配到多个计算节点上并行执行，实现计算资源的充分利用与训练过程的加速，显著提高模型训练的效率与规模上限，为复杂行为模型的训练提供强大支撑。行为可视化模块致力于将仿真主体的复杂行为过程以直观、形象的方式呈现出来，借助数据可视化技术，将行为数据转化为图形、图像、动画等形式，便于开发人员与研究人员对行为模式进行观察、分析与理解，及时发现行为异常与潜在问题，同时也有助于向非专业用户展示仿真成果，增强系统的可解释性与用户体验。模型部署模块关注模型从训练阶段到实际应用阶段的平滑过渡，通过制定严谨的部署流程与策略，确保训练好的行为模型能够在不同的硬件平台、操作系统以及实际应用场景中稳定、高效地运行，实现模型的快速推广应用，充分发挥仿真系统的实际应用价值。

2.2.3 平台的接口设计

平台接口遵循高内聚、低耦合原则，其设计注重易用性和扩展性，主要分为以下三类接口：

首先,对于环境交互接口,基于 Gym 环境标准封装仿真引擎,规范定义 `reset()`、`step()`等标准方法,提供统一的环境交互接口,支持重置、步进等核心功能,兼容 Stable Baselines3 等主流强化学习框架。用户可通过环境脚本进行环境测试与算法接入。

其次,对于数据和模型接口,通过代理模型实现 Python 业务模块与底层 C++ 引擎的数据交换。定义标准化的智能行为模型接口,包括输入特征格式、输出动作格式和奖励计算规范,支持行为树、神经网络等多类型模型的快速集成与替换。

最后,对于可视化接口,提供地形与实体状态的 2D 渲染 API,支持自定义图层叠加,并通过 `render()`方法实时输出战场态势。预留丰富的扩展接口,支持自定义地形加载、高度信息融合和打击效果可视化开发,满足多样化仿真需求。

2.3 基于行为树和深度强化学习的多自由度 CGF 导航问题建模

本章在实验室自研的 CGF 智能行为建模平台上面向多自由度 CGF 战术机动过程,主要研究的问题为仿真战术场景中 CGF 基于动力学方程的导航策略求解问题,即在未知的大小为 20×20 二维仿真战术环境中,存在如 U 型障碍物、死角、长栏等复杂静态障碍物,CGF 从环境中非障碍物的随机起点出发,寻找随机生成的目标点的过程。在使用传统的深度强化学习的情况下,求解效率较低,本课题拟使用行为树等领域规则对深度强化学习进行引导,并逐步减少引导步数,以达到在奖励延迟且稀疏的复杂应用场景中提高强化学习效率的目的。

2.3.1 领域规则定义

领域规则,定义为在特定领域或行业内,基于专业知识、经验、法律、标准及实践而形成的规则体系,旨在指导和规范该领域内的行为、决策和操作。这些规则根植于对领域复杂性的深刻洞察及长期实践的积累,既包括明确的规范、标准和协议,也涵盖隐含的最佳实践和常识。在本课题的研究框架内,领域规则特指那些指导智能体行为建模的军事战术、战略原则、作战规则及行为准则。此类规则有助于确保 CGF 实体的行为与现实世界的军事实践相一致,从而增强模拟训练的真实性和有效性。领域规则的整合能够使 CGF 实体在模拟环境中的行为更加贴近现实、合理,并能适应复杂的战场环境及战术变化,进而提升模拟训练的实战价值。在本问题中,领域规则来自于先验知识和经验,这些领域规则经过整理、总结和提炼形成行为树。

2.3.2 仿真环境建模

在现代军事作战中，装甲部队在丘陵、山地、峡谷等复杂地形中执行作战任务时，需在确保安全的前提下快速机动至指定位置。地形中的山丘、峡谷、河流等自然障碍物对部队行进路线产生限制，在仿真实验的环境中设置对应的障碍物以达到相应效果。在军事仿真场景中，多自由度 CGF 实体代表履带式装甲车辆，如主战坦克、装甲输送车等；目标点为敌方阵地、集结地或需控制的关键地形点；障碍物包括山丘、峡谷、河流、雷区等自然障碍物或人为设置的防御工事、地雷区等。此外，针对装甲车辆的动力学性能限制，在仿真实验中设计相应的动力学约束。当装甲部队在复杂地形中进行战术机动时，需规划合理行进路线以避免障碍物并以最短路线快速机动。此时，实验中的导航策略可优化装甲部队的行进路线，提升作战效率和生存能力。该实验场景对应真实军事场景，能为装甲部队在复杂地形中的作战提供理论基础和技术支持，具有重要的军事意义。

本文所采用的二维仿真环境大小设定为 20×20 。如图 2-7 所示，黑色网格为静态障碍物，蓝色网格为 CGF 当前所在位置，红色网格为目标点。CGF 的起点和目标点在网格世界中非障碍物的位置随机生成。




图 2-7 仿真环境示意图

2.3.3 动力学约束及相关参数

如图 2-8，以地图左上顶点为原点，分别向右向下建立 x 轴和 y 轴，形成笛卡尔平面直角坐标系，并以三元组 $(x_{CGF}, y_{CGF}, \theta_{CGF})$ 描述 CGF 的位置状态信息，其中，

x_{CGF}, y_{CGF} 对应 CGF 在地图全局中的横纵坐标, θ_{CGF} 表示 CGF 的朝向与横坐标轴正半轴之间顺时针方向夹角的大小。




图 2-8 多自由度陆上履带式机动作战平台 CGF 示意图

CGF 具备感知能力, 具体而言, 该感知模型将 360° 的感知范围以 15° 间隔进行如图 2-9 的离散处理, 划分成 24 条感知线, 且最大感知距离可达 7 个单位长度。




图 2-9 CGF 雷达感知线示意图

在本研究中, CGF 为陆上履带式机动作战平台, 为实现合理的控制效果并满足动力学约束条件, 使用连续的角加速度作为控制指令, 并满足公式:

$$\begin{pmatrix} \dot{x}_{CGF} \\ \dot{y}_{CGF} \\ \dot{\theta}_{CGF} \end{pmatrix} = R \begin{bmatrix} \frac{\cos\theta_{CGF}}{2} & \frac{\cos\theta_{CGF}}{2} \\ \frac{\sin\theta_{CGF}}{2} & \frac{\sin\theta_{CGF}}{2} \\ \frac{1}{l_{CGF}} & \frac{-1}{l_{CGF}} \end{bmatrix} \begin{pmatrix} \omega_l \\ \omega_r \end{pmatrix}, \quad (2-7)$$

$$\begin{pmatrix} \dot{\omega}_l \\ \dot{\omega}_r \end{pmatrix} = \begin{pmatrix} \frac{\partial \omega_l}{\partial t} \\ \frac{\partial \omega_r}{\partial t} \end{pmatrix}$$

其中, R 表示履带驱动轮的半径; ω_l 和 ω_r 表示左右驱动轮的角速度 (单位: $rad \cdot s^{-1}$), $\dot{\omega}_l$ 和 $\dot{\omega}_r$ 则表示左右驱动轮的角加速度 (单位: $rad \cdot s^{-2}$); l_{CGF} 为两条履带之间的间距。

2.3.4 状态空间与动作空间设计

在本研究中, 状态空间和动作空间是强化学习模型的两个关键组成部分。如表 2-1 所示, 状态空间 $S = \{R_1, R_2, \dots, R_{24}, sensorCounts, senseRadius[0], senseRadius[1], senseAngle, x_{CGF}, y_{CGF}, \theta_{CGF}, v_x, v_y, \omega, v, \omega_l, \omega_r, \dot{\omega}_l, \dot{\omega}_r, R, B, D, A, dst, arrived, D_{last}, \omega_{last}, \dot{\omega}_{last}, minDis, flag_{minDis}, \omega_{max}, \omega_{min}, \dot{\omega}_{max}, duration\}$ 共 54 维, 定义了智能体在环境中可感知的所有信息, 包括智能体的位置、速度、朝向、与目标点的距离和角度等, 以及通过传感器获取的环境信息, 如雷达感知线的长度和障碍物的位置。这些状态参数全面描述了智能体在导航任务中的情况, 为其决策提供了必要的信息基础。如表 2-2 所示, 二维动作空间 $A = \{\dot{\omega}_l, \dot{\omega}_r\}$ 定义了智能体在环境中可执行的所有操作, 具体表现为对智能体左右驱动轮的角加速度的控制。通过调整角加速度, 智能体能够实现前进、后退、转向等动作, 以在环境中移动并完成导航任务。状态空间和动作空间的精确定义对于构建有效的强化学习模型至关重要, 它们共同决定了智能体如何与环境交互并学习最优策略。

表 2-1 状态空间参数

参数	描述
R_i	雷达感知信息向量, 从坦克 6 点钟逆时针方向开始的所有归一化的感知线长度
$sensorCounts$	雷达感知线数量
$senseRadius$	感知半径, $senseRadius[0]$ 为最短距离, $senseRadius[1]$ 为最长距离, 最长距离不超过 7 个单位长度
$senseAngle$	感知角, 默认为 15°
x_{CGF}	CGF 的横坐标
y_{CGF}	CGF 的纵坐标
θ_{CGF}	CGF 的朝向与横坐标轴正半轴之间顺时针方向夹角的大小, 单位为 rad
v_x	CGF 在 x 方向上的速度
v_y	CGF 在 y 方向上的速度
ω	CGF 的角速度, 单位为 $rad \cdot s^{-1}$

v	CGF 的线速度
ω_l	CGF 左侧驱动轮的角速度，单位为 $rad \cdot s^{-1}$
ω_r	CGF 右侧驱动轮的角速度，单位为 $rad \cdot s^{-1}$
$\dot{\omega}_l$	CGF 左侧驱动轮的角加速度，单位为 $rad \cdot s^{-2}$ ，范围 $[-5,5]$
$\dot{\omega}_r$	CGF 右侧驱动轮的角加速度，单位为 $rad \cdot s^{-2}$ ，范围 $[-5,5]$
R	CGF 履带驱动轮半径
B	CGF 两个履带之间的宽度
D	当前时刻 CGF 与目标点之间的欧氏距离
A	CGF 朝向与 CGF 中心到目标点中心连线之间顺时针方向的夹角，单位为 rad
dst	目标点位置坐标， $dst[0]$ 为横坐标， $dst[1]$ 为纵坐标
$arrived$	布尔值，到达目标点为 1，否则为 0
D_{last}	上一时刻与目标点之间的距离
ω_{last}	上一时刻的角速度
$\dot{\omega}_{last}$	上一时刻的角加速度
$minDis$	从开始到当前时刻，CGF 到目标点的最短距离
$flag_{minDis}$	布尔值，最短距离缩小为 1，否则为 0
ω_{max}	最大角速度
ω_{min}	最小角速度
$\dot{\omega}_{max}$	最大角加速度
$duration$	CGF 存活时间

表 2-2 动作空间参数

参数	描述
$\dot{\omega}_l$	CGF 左侧驱动轮的角加速度，单位为 $rad \cdot s^{-2}$ ，范围 $[-5,5]$
$\dot{\omega}_r$	CGF 右侧驱动轮的角加速度，单位为 $rad \cdot s^{-2}$ ，范围 $[-5,5]$

2.3.5 奖励设计与终止条件

在强化学习中，奖励信号是用于引导智能体学习的关键部分。奖励信号有两种主要类型：稠密奖励（dense rewards）和稀疏奖励（sparse rewards）。稠密奖励为智能体在任务中的每一步都提供有用的反馈，而稀疏奖励仅在任务完成或关键事件发生时提供反馈。

在本实验的想定场景中，实验环境的奖励是稀疏的，也就是说，智能体并不能在每一个时间步长结束后就立即得到奖励，而是仅在整个回合结束后，才可以获得奖励，环境对智能体的反馈具有延迟和滞后性。

实验中出现以下情况之一时，认为本回合实验终止，智能体获得奖励：

- (1) 雷达感知信息向量 $senseVec$ 中存在两条及以上的雷达线长度 $d < 0.05$ ，即 CGF 与障碍物发生碰撞；
- (2) CGF 超出地图边界；
- (3) 超出最大时间限制。

本实验的奖励信号将在回合结束后，从距离、安全、完成度和时间等四个方面对整个轨迹进行评估计算，具体计算方式如下：

$$reward = \frac{reward_{dis} + reward_{safe} + reward_{arrived} + reward_{time}}{scale_{reward_rate}} \quad (2-8)$$

其中， $scale_{reward_rate}$ 是为了控制奖励数值范围，防止梯度爆炸或训练不稳定而设置的缩放因子。

距离奖励 $reward_{dis}$ 鼓励智能体向目标点移动，计算公式为：

$$reward_{dis} = (dis_{last_terminal} - dis_{terminal}) \times reward_factor \quad (2-9)$$

其中， $dis_{last_terminal}$ 指上一个回合结束时 CGF 到目标点之间的距离， $dis_{terminal}$ 指本次回合结束时 CGF 到目标点的距离， $reward_factor$ 为奖励因子。

安全奖励 $reward_{safe}$ 分为对齐奖励和避障惩罚，鼓励智能体保持朝向目标，同时避免碰撞。对齐奖励根据智能体与目标点的角度偏差计算，角度偏差越小，奖励越高。

$$reward_{safe1} = \sum_{t=0} (1 - \frac{|A|}{\pi}) \times reward_{step} \quad (2-10)$$

$reward_{step}$ 为每一步的奖励因子，用于使每个部分的奖励保持在同一数量级。

在此基础上，避障惩罚通过雷达感知信息向量 $senseVec$ 检测周围障碍物。若雷达探测到近距离障碍物，即正前方和正后方各三根感知线中存在至少一条长度 $d < 0.2$ 时，产生负奖励。

$$reward_{safe2} = \sum_{t=0} -(1 - \frac{d}{0.2}) \times \frac{reward_{step}}{60} \quad (2-11)$$

$$reward_{safe} = reward_{safe1} + reward_{safe2} \quad (2-12)$$

到达奖励 $reward_{arrived}$ 明确任务成功或失败的奖惩，加速收敛。若智能体到达目标点，给予正向奖励：

$$reward_{arrived} = \left(1 + \frac{dis_{start}}{dis_{map}}\right) \times reward_factor \quad (2-13)$$

其中, dis_{start} 表示起始时 CGF 到目标点的距离, dis_{map} 表示地图两对角之间的距离。若发生碰撞或超界, 给予负奖励:

$$reward_{arrived} = \left(-1 + \frac{dis_{start} - dis_{terminal}}{dis_{start}}\right) \times reward_factor \quad (2-14)$$

时间奖励 $reward_{time}$ 主要鼓励智能体尽快完成任务, 避免无效徘徊:

$$reward_{time} = -reward_{step} \quad (2-15)$$

2.3.6 问题剖析

稀疏奖励环境下的强化学习训练困难。首先, 稀疏奖励意味着智能体在绝大多数时间内无法获得有效反馈, 如某一阶段内奖励始终为 0, 仅在任务完成时等某些关键状态才会获得正或负奖励。导致智能体需要大量随机探索才能偶然触发奖励, 尤其在复杂或高维环境中, 这会导致训练时间指数级增长。在本实验的迷宫导航任务中, 只有到达终点才会获得奖励, 若迷宫路径复杂, 智能体可能长期困在局部区域而无法发现正确路径。

其次, 当智能体最终获得奖励时, 难以确定导致这一结果的具体动作序列。由于中间步骤缺乏反馈, 智能体无法判断哪些动作对最终结果有贡献, 导致策略优化效率低下。在本实验中, 智能体仅在最后一步获得奖励, 但是难以确定之前哪几步是关键的正确决策, 难以分辨是否发生绕行而并非最短路径。

稀疏奖励下, 大多数状态-动作对样本无法提供有效信息, 仅有极少数样本包含奖励信号。因此算法需要收集海量数据才能提取有用信息, 导致训练成本高昂。本实验的导航任务中, 只有在 CGF 成功到达目标点时才有奖励, 而失败尝试的数据一方面由于起始点和目标点的随机性, 另一方面由于失败后得到的奖励数值差距不大, 因此几乎不提供优化方向。

智能体可能过早收敛到一种能偶尔获得奖励的策略, 但该策略可能远非最优。缺乏持续的正向反馈导致智能体不愿探索其他可能更好的策略。在本实验的导航任务中, 智能体可能反复尝试一条已知的次优路径, 而放弃探索更高效的路径。

稀疏奖励本质上是强化学习中“信号缺失”问题, 导致智能体缺乏学习方向。其核心挑战在于如何在高维、复杂的环境中, 通过极少的反馈信号高效地探索和优化策略。本研究将使用领域规则引导深度强化学习来尝试解决这一问题。

2.4 本章小结

本章深入探讨了面向多自由度 CGF 战术机动的问题定义与建模,为后续研究奠定了坚实基础。首先,对深度强化学习的基本概念进行了详细阐述,包括强化学习的要素(智能体、环境、状态、动作、奖励等)、贝尔曼方程及其在分析状态值中的关键作用,为理解深度强化学习算法提供了理论基础。接着介绍了自研计算机生成兵力智能行为建模平台,该平台采用模块化分层架构,具备战场环境动态建模、多智能体交互仿真与算法训练验证的一体化支撑能力,其设计注重高内聚、低耦合原则,具备良好的易用性和扩展性。其次,针对战场环境下的战术决策行为建模问题,面向多自由度 CGF 的战术机动过程,详细定义和阐述了本文所研究的问题,明确了领域规则在智能体行为建模中的重要作用。进一步地,本章结合行为树和深度强化学习方法,对多自由度的 CGF 战术机动问题进行了建模。具体而言,介绍了仿真环境的设定、CGF 的动力学约束及相关参数,构建了符合马尔科夫决策过程的模型,并设计了包含距离奖励、安全奖励、完成奖励和时间奖励的综合奖励机制,以引导智能体的行为决策。最后剖析了本实验研究问题的难点所在。通过本章的研究,为后续算法设计与仿真实验提供了清晰的问题定义和理论建模框架。

3 结合领域规则的深度强化学习算法研究

深度强化学习在军事仿真领域展现出强大的决策潜力，却在稀疏奖励场景下面临探索效率低、易局部最优的困境。本章聚焦于结合领域规则的深度强化学习算法研究，探索如何借助领域规则在复杂战场环境下构建高效且适应性强的战术决策行为模型。首先，本章将深入剖析基于 AC 架构的深度强化学习算法，阐述其核心原理与优势，并对 DDPG、TD3 等典型算法进行对比评估，并进一步分析其在连续控制任务中的优势和局限性。接着，本章将重点研究如何将领域规则融入深度强化学习，提出一种创新的学习型决策建模方法。该方法在 JSRL 框架下，将行为树与 TD3 算法深度融合，以行为树为引导策略，为智能体初期探索提供方向，再通过 TD3 算法逐步优化策略，并使用课程学习机制逐步减少引导步数，实现从规则引导到自主探索的平滑过渡，从而有效解决稀疏奖励场景下强化学习的探索效率问题，提升智能体的学习效率和决策性能，旨在为军事仿真中的战术决策行为建模提供更高效、更具适应性的算法解决方案，为后续仿真实验奠定坚实的算法基础。

3.1 基于演员-评论家架构的深度强化学习算法

3.1.1 演员-评论家架构

AC 架构算法凭借其独特优势，在严肃游戏与军事领域发挥着重要的作用。在兵棋推演中，AC 算法使智能体在推演中根据战场情况做出更加合理的行动决策，从而为军事战略和战术的研究提供更准确的模拟和验证。通过对大量历史战例和实时战场数据的学习，AC 算法可以在复杂战场态势下快速分析当前战场形势，为指挥官提供多种可行的战术决策方案，并预测不同方案的可能结果，辅助指挥官做出更优的决策^[49]。因其在处理复杂决策问题时展现出的高效性和适应性，AC 架构逐渐成为解决严肃游戏与军事领域中众多难题的关键技术路径。具体而言，AC 架构作为深度强化学习中的核心框架，结合了策略梯度方法和值函数近似的优势。其中，Actor 负责生成动作和策略，直接与环境交互。Critic 负责评估状态或状态-动作对的价值，即 Q 值或状态值，指导 Actor 优化策略。

图 3-1 展示了基于 AC 架构的深度强化学习算法的基本原理，AC 架构下，Critic

能够提供比蒙特卡洛方法更稳定的梯度估计，支持在线学习连续交互和增量更新，具有较好的灵活性，适用于离散和连续动作空间。




图 3-1 基于 AC 架构的深度强化学习算法示意图

3.1.2 孪生延迟深度确定性策略梯度算法

基于 AC 架构的典型算法包括 A3C（异步优势动作评价算法，Asynchronous advantage actor-critic）、DDPG 等，其中 DDPG 是面向连续动作空间的 AC 算法，但存在 Q 值过估计、训练不稳定等问题。TD3 算法作为 DDPG 的改进版本，通过多项关键技术显著提升了稳定性和性能。

首先，为了抑制 Q 值过估计，提供更保守的价值评估，TD3 采用双 Critic 网络，即两个独立的 Critic 网络 Q1 和 Q2，计算目标 Q 值时取两者较小值：

$$y = r + \gamma \min(Q_{target,1}(s', a'), Q_{target,2}(s', a')) \quad (3-1)$$

其次，TD3 采用延迟策略更新，使 Actor 的更新频率低于 Critic，例如 Critic 更新 2 次后 Actor 更新 1 次，以确保 Critic 足够准确后再优化策略，减少策略振荡。

此外，TD3 在目标动作上添加噪声，以平滑 Q 函数对动作的敏感性，避免策略过拟合：

$$a' = \pi_{target}(s') + \epsilon, \epsilon \sim clip(\mathcal{N}(0, \sigma), -c, c) \quad (3-2)$$

最后，为了稳定训练过程，避免价值估计突变，TD3 通过指数移动平均（Exponential Moving Average, EMA）更新目标网络参数：

$$\theta_{target} \leftarrow \tau \theta + (1 - \tau) \theta_{target} \quad (3-3)$$

TD3 适用于连续动作空间任务，如机器人控制、自动驾驶等尤其是对策略稳定性要求较高的场景。表 3-1 展示了 TD3 算法的伪代码，具体描述如下：首先进行采

样，从经验池中抽取一批样本；在此基础上通过目标 Actor 生成动作并添加噪声；随后计算目标 Q 值，取双目标 Critic 的最小值；继而更新 Critic，最小化时序差分误差 TD error；此外，根据需要定期延迟更新 Actor，并通过最大化 Q 值优化策略；最后软更新目标网络，逐步同步目标网络参数。

表 3-1 TD3 算法伪代码

Algorithm 1 TD3

```

//  $Q_{\theta_1}, Q_{\theta_2}$ : 评论家网络
//  $\pi_\phi$ : 演员网络
//  $\theta_1, \theta_2, \phi$ : 随机参数
//  $\theta'_1, \theta'_2, \phi'$ : 目标网络
//  $B$ : 重放缓冲区

Initialize critic networks  $Q_{\theta_1}, Q_{\theta_2}$ , and actor network  $\pi_\phi$  with random parameters  $\theta_1, \theta_2, \phi$ 
Initialize target networks  $\theta'_1 \leftarrow \theta_1, \theta'_2 \leftarrow \theta_2, \phi' \leftarrow \phi$ 
Initialize replay buffer  $B$ 

for  $t = 1$  to  $T$  do
    Select action with exploration noise  $a \sim \pi_\phi(s) + \epsilon, \epsilon \sim \mathcal{N}(0, \sigma)$  and observe reward  $r$  and
    new state  $s'$ 

    Store transition tuple  $(s, a, r, s')$  in  $B$ 

    Sample mini-batch of  $N$  transitions  $(s, a, r, s')$  from  $B$ 

     $\tilde{a} \leftarrow \pi_{\phi'}(s') + \epsilon, \epsilon \sim \text{clip}(\mathcal{N}(0, \tilde{\sigma}), -c, c)$ 
     $y \leftarrow r + \gamma \min_{i=1,2} Q_{\theta'_i}(s', \tilde{a})$ 

    Update critics  $\theta_i \leftarrow \text{argmin}_{\theta_i} N^{-1} \sum (y - Q_{\theta_i}(s, a))^2$ 

    if  $t \bmod d$  then
        Update  $\phi$  by the deterministic policy gradient:
        
$$\nabla_\phi J(\phi) = N^{-1} \sum \nabla_a Q_{\theta_1}(s, a)|_{a=\pi_\phi(s)} \nabla_\phi \pi_\phi(s)$$


        Update target networks:
        
$$\theta'_i \leftarrow \tau \theta_i + (1 - \tau) \theta'_i$$

        
$$\phi' \leftarrow \tau \phi + (1 - \tau) \phi'$$


    end if

```

end for

表 3-2 TD3 算法与 DDPG 的对比

改进项	DDPG	TD3
Q 值估计	单 Critic，易过估计	双 Critic 取最小值，抑制过估计
策略更新频率	同步更新	延迟更新（Critic 更优先）
目标策略	无噪声	添加平滑噪声

综上所述，如表 3-2 所示，TD3 在 DDPG 的基础上通过双 Critic 网络、延迟更新和策略平滑三大创新，成为连续控制任务中的标杆算法，在强化学习中表现出更高的稳定性和性能，但仍存在一些局限性。TD3 需要通过大量样本进行训练以优化策略和值函数，这对计算资源和时间提出了较高要求。尤其在复杂环境中，数据采集成本高且训练周期长，限制了其在实时性要求高的场景中的应用。本研究中，我们主要采用 TD3 算法作为深度强化学习的基线算法，并在此基础上结合领域规则进行改进。

3.2 结合领域知识的学习型决策建模方法

3.2.1 领域规则引导的深度强化学习算法框架

如图 3-2 所示，本文提出了一种结合领域知识的学习型决策建模方法，具体而言，主要基于 JSRL 框架，将行为树作为引导策略与深度强化学习算法相结合，其整体框架主要包括以下几个关键部分。首先，行为树作为领域知识的表征工具，其节点结构按照领域规则中的优先级进行组织，条件节点用于感知环境并判断是否符合特定规则触发条件，动作节点则根据条件节点的判断执行相应的操作。行为树的引导策略通过其结构化规则为智能体提供初始的行为指导，确保智能体在早期探索阶段遵循领域规则进行决策。其次，TD3 作为探索策略，负责在行为树引导的基础上进一步优化智能体的行为策略，通过与环境的交互学习，不断调整策略网络和价值网络的参数，以最大化长期累积奖励。在 JSRL 框架下，算法通过设定引导步长控制引导策略和探索策略的参与程度，逐步实现从规则引导到自主探索的平滑过渡。此外，行为树引入了 PID 控制器来优化动作输出，通过闭环反馈机制对动作参数进

行动态调整，降低人工调参的复杂度，增强智能体行为的平滑性和适应性。

综上所述，该算法框架通过整合领域规则与深度强化学习的优势，以解决稀疏奖励场景下的高效探索问题，提升智能体的学习效率和决策性能。针对传统 JSRL 框架中引导策略的黑箱性质问题，该算法创新性地采用行为树作为引导策略，利用行为树的结构化规则表征能力，将军事战术知识转化为可解释的动作约束，增强了算法的可解释性。同时，为了避免 JSRL 对大量强化学习训练资源的依赖，本方法通过行为树的引导，减少了智能体在早期探索中的随机性，降低了对大规模样本的需求，提高了训练效率。




图 3-2 结合领域知识的学习型决策建模方法算法框架

表 3-3 展示了本文所提出算法的伪代码。作为一种通过预训练策略引导探索过程的高效强化学习框架，JSRL 是一个元算法，即可以使用任何形式的预先存在的策略来初始化任何类型的 RL 算法^[8]。本研究利用这一特性，使用行为树表征领域规则作引导策略，同时引入经典深度强化学习 TD3 算法构建探索策略，旨在充分发挥二者优势，实现高效的智能决策与行为控制。具体而言，在本研究的起始阶段，将依据既有的实验经验与既定的避障策略，采用人工设计的方式构建行为树。在 JSRL 框架下，引导策略可以是次优的，但需优于随机策略^[8]，因此本实验将通过大量的实验与反复的验证，对行为树的结构和参数不断进行调整与优化，以确保该行为树能够达到 JSRL 所需要的引导策略标准。在训练初期，行为树引导策略先执行固定步数，将智能体引导至高潜在价值状态区域，形成探索策略的起始状态课程。随后，TD3 探索策略基于引导策略所得状态接管智能体并继续在环境中执行，以学习如何到达目标状态。在算法的过渡阶段，随着训练的推进和 TD3 探索策略性能的提高，通过课程学习机制逐步减少行为树引导策略的干预步长，并相应增加 TD3 算法的探

索比例，智能体从依赖预训练策略逐渐转向自主探索。在最终成熟阶段，智能体决策将完全由 TD3 探索策略主导，形成“引导-优化”的闭环。

表 3-3 行为树引导的 TD3 算法伪代码

Algorithm 2 Behavior Tree Guided TD3

```

//  $BT, BT_{new}$ : 行为树，迭代得到的新行为树
//  $Root$ : 根节点;  $Node_{low}$ : 低效节点;  $Node_c, Node_a$ : 条件节点，动作节点
//  $threshold_c$ : 条件阈值
//  $\dot{\omega}_l, \dot{\omega}_r$ : 动作参数;  $\dot{\omega}_{base}$ : 基本动作参数
//  $rate_d, rate_e, rate_{new}$ : 行为树期望成功率，当前成功率，迭代后的成功率
//  $Q_{\theta_1}, Q_{\theta_2}$ : 评论家网络;  $\pi_\phi$ : 演员网络;  $\theta'_1, \theta'_2, \phi'$ : 目标网络
//  $B$ : 重放缓冲区
//  $\pi^{g-BT}$ : 行为树引导策略;  $\pi^{e-TD3}$ : TD3 探索策略
//  $\beta$ : 性能阈值
//  $H$ : 任务范围;  $H_1, H_2, \dots, H_n$ : 引导步数序列，对于所有的  $i \leq n, H_i \in [H]$ 
//  $\hat{Q}$ : Q 函数
//  $\mathcal{D}$ : 数据集

// Initialize the behavior tree
Create  $Root$  as a selector node
Define the priority order of child nodes based on domain knowledge
Set initial  $threshold_c$  for  $Node_c$  (e.g., distance thresholds for obstacle detection)
Configure  $Node_a$  with  $\dot{\omega}_{base}$ 
Establish connections between nodes according to the predefined logic
Get the initialized  $BT$ 

// Tune the behavior tree parameters
while  $rate_e < rate_d$ :
    Analyze the performance data to determine which  $Node_{low}$  need adjustment
    for node in  $Node_{low}$ :
        if node is  $Node_c$ :

```

```

    Adjust thresholdc

    else if node is  $Node_a$ :
        Optimize  $\dot{\omega}_l, \dot{\omega}_r$ 
    end if

end for

if necessary:
    Rebalance the priority of selector nodes
end if

Validate  $BT_{new}$  in a simulation episode to get new  $data_{e,new}$ 

if  $rate_{new} > rate_e$ :
     $BT = BT_{new}$ 
     $rate_e = rate_{new}$ 
end if

```

Initialize critic networks $Q_{\theta_1}, Q_{\theta_2}$, and actor network π_ϕ with random parameters θ_1, θ_2, ϕ

Initialize target networks $\theta'_1 \leftarrow \theta_1, \theta'_2 \leftarrow \theta_2, \phi' \leftarrow \phi$

Initialize replay buffer B

Initialize guide-policy with behavior tree $\pi^{g-BT} \leftarrow BT$.

Initialize exploration-policy π^{e-TD3} from scratch.

Initialize Q-function $\hat{Q}$ and dataset $\mathcal{D} \leftarrow \emptyset$.

for current guide step $h = H_1, H_2, \dots, H_n$ **do**

Set the non-stationary policy $\pi_{1:h} = \pi^{g-BT}, \pi_{h+1:H} = \pi^{e-TD3}$

for $t = h + 1$ to H **do**

Select action with exploration noise $a \sim \pi_\phi(s) + \epsilon, \epsilon \sim \mathcal{N}(0, \sigma)$ and observe reward r and new state s'

Store transition tuple (s, a, r, s') in B

Sample mini-batch of N transitions (s, a, r, s') from B

$$\tilde{a} \leftarrow \pi_{\phi'}(s') + \epsilon, \epsilon \sim \text{clip}(\mathcal{N}(0, \tilde{\sigma}), -c, c)$$

$$y \leftarrow r + \gamma \min_{i=1,2} Q_{\theta'_i}(s', \tilde{a})$$

```

Update critics  $\theta_i \leftarrow \operatorname{argmin}_{\theta_i} N^{-1} \sum \left( y - Q_{\theta_i}(s, a) \right)^2$ 
if  $t \bmod d$  then
    Update  $\phi$  by the deterministic policy gradient:
    
$$\nabla_{\phi} J(\phi) = N^{-1} \sum \nabla_a Q_{\theta_1}(s, a)|_{a=\pi_{\phi}(s)} \nabla_{\phi} \pi_{\phi}(s)$$

    Update target networks:
    
$$\theta'_i \leftarrow \tau \theta_i + (1 - \tau) \theta'_i$$

    
$$\phi' \leftarrow \tau \phi + (1 - \tau) \phi'$$

end if
end for

Roll out the policy  $\pi$  to get trajectory  $\{(s_1, a_1, r_1), \dots, (s_H, a_H, r_H)\}$ ; Append the trajectory to
the dataset  $\mathcal{D}$ .


$$\pi^{e-TD3}, \hat{Q} \leftarrow \operatorname{TRAINPOLICY}(\pi^{e-TD3}, \hat{Q}, \mathcal{D})$$


if  $\operatorname{EVALUATEPOLICY}(\pi) \geq \beta$  then
    Continue
end if
end for

```

3.2.2 行为树的初步设计与预实验

本文所提出算法存在两个关键点，即行为树的引导策略和引导步长，对于算法的性能表现有着重要影响。行为树作为引导策略，其结构设计和参数设置直接决定了智能体在初始阶段的探索方向与效率；引导步长则控制了行为树参与决策的深度与广度，影响着算法从规则引导向自主探索过渡的节奏。在开展正式实验之前，有必要进行预实验并对如何构建行为树和如何设定引导步长进行详尽分析，验证行为树的可行性与有效性，初步确定引导步长的合理范围，为正式实验中超参数的设定和分析提供依据。同时，在这一过程中可对行为树进行初步设计和优化，把握实验对行为树的基本要求和行为树的总体优化方向，据此调整其节点优先级与触发条件，使实验设计的行为树更贴合实际任务需求。在此基础上，根据领域规则设计行为树，并对所设计的行为树进行测试，通过观察可视化情况，反复迭代其条件阈值和动作参数直到满意。如图 3-3 所示，经测试和统计分析，首次编写的行为树在单回合最大执行步数为 3000，总步数为 2,000,000 的设定下，成功率为 74%，有 90% 的回合能在 800 步以内完成。




图 3-3 预实验行为树回合步长频数分布直方图

使用该行为树开展预实验，设定实验总步数为 1,000,000，根据测试结果，选择最大引导步数为 500 步，分 20 个阶段逐步减少引导步数。实验结果和引导步数下降情况如图 3-4 和图 3-5 所示，起点时的奖励值在 0.45 附近，证明该行为树在实验初期提供了较好的初始状态课程，但实验开始后奖励值出现下降，对应引导步数连续下降，中期奖励值有所回升，引导步数下降较慢，后期奖励值始终在初始值附近振荡，没有收敛，对应的引导步数仅下降到 350 步，未按照预想情况由 TD3 完全主导。实验结果有较高的起始奖励值且奖励值凹点基本对应引导步数下降点，证明引导策略起到了一定的正确引导作用。




图 3-4 预实验设计行为树实验结果




图 3-5 预实验行为树引导步数下降情况

为分析出现该情况的原因，观察由传统 TD3 算法在相同的超参数和实验环境下单独完成实验的情况，如图 3-6 和图 3-7 所示，传统 TD3 算法在实验初期网络性能较弱，所需计算步数在 90 步左右，简单学习后计算步数快速下降，奖励值随之不断上升，最终实验结果能够正常收敛在 1 附近，计算步数约 50 步左右。说明该实验环境能够正常用于强化学习算法训练，且探索环节不存在较大问题，预实验无法收敛的主要原因应从行为树的引导策略入手分析。




图 3-6 传统 TD3 算法预实验结果




图 3-7 传统 TD3 算法计算步数

由以上实验结果可得,传统 TD3 算法在每回合少于 100 步的情况下得到训练奖励,这与预实验设定的 500 步差距较大。预实验设定最大引导步数为 500 步,在实验初期引导步数下降 1~2 次后,TD3 算法即需要执行 50~100 步,几乎和传统的 TD3 算法单独训练时一致。由于本文所提出的算法在预实验初期引导步数下降较快,此时 TD3 算法的评论家 Critic 目标网络几乎没有经过任何训练,在随机作用下甚至扰乱了已有的引导策略给出的“好的”状态和策略,这也解释了为什么奖励值凹点和引导步数下降点基本对应。基于此,在正式实验中应当调整行为树的性能,适当牺牲成功率,将其完成实验的回合步数压缩到 100 步以内。

3.3 本章小结

本章聚焦于结合领域规则的深度强化学习算法研究,旨在为解决稀疏奖励场景下的智能体决策行为建模问题提供有效的算法支持。首先,本章重点研究了基于 AC 架构的深度强化学习算法,深入分析了 Actor-Critic 架构的优势,并对 TD3 算法进行了详细介绍,包括其对 DDPG 算法的改进措施,如双 Critic 网络、延迟策略更新和目标策略平滑等,同时也指出了 TD3 算法在计算资源需求和训练周期等方面的局限性。在此基础上,进一步介绍了结合领域知识的学习型决策建模方法,针对如何在 JSRL 框架下将行为树作为引导策略与 TD3 算法相结合进行设计。算法通过逐步递减引导策略以实现从规则引导到自主探索的平滑过渡,提高智能体在稀疏奖励环

境下的学习效率和策略性能。最后展示了本文所提出算法的基本框架和伪代码，并基于此开展了预实验，深入分析了实验现象的具体原因，为正式实验提供了改进方向和有效参考。本章的研究为后续仿真实验提供了核心算法支撑，也为探索领域规则与深度强化学习的融合机制提供了有益的思路。

4 仿真实验

4.1 实验设计

4.1.1 实验设计

为了有效地验证所提出的结合领域规则的深度强化学习策略在稀疏奖励场景下的策略优化能力,以及评估其在军事仿真场景中的应用效果。本研究拟在实验室自主研发的计算机生成兵力智能行为建模平台上开展一系列仿真实验:

1. 总体实验,观察行为树引导下的 TD3 算法能否解决奖励稀疏环境下的多自由度 CGF 战术机动问题。若能,分析算法效果;若不能,分析不能的原因。
2. 消融实验,拟对比行为树引导下的 TD3 算法和传统黑盒策略引导下的 TD3 算法、传统 TD3 算法、行为树基线算法,分析算法效率并验证行为树引导的有效性。此外,采用随机引导策略步数展开实验,说明按照课程学习减少引导步数的必要性。
3. 敏感性分析,观察超参数对实验效果的影响并总结规律,对比传统 TD3 算法和本文所提算法分别在奖励稀疏环境和非稀疏环境下的表现,说明本文所提算法对奖励稀疏环境的良好适应性。
4. 泛化性分析,选择不同的多张地图开展实验,验证本文所提算法的鲁棒性。
5. 观察实验中多自由度 CGF 在不同阶段的行为并进行简要分析。总结实验中遇到的现象,开展其他实验进行补充。

4.1.2 评估指标

主要评估指标为收敛所需时间步长 $timesteps_c$ 和平均回报 $reward_{mean}$ 。

对于时间步长,一般来说,收敛所需要的时间步长越短,则证明该算法具有更快的收敛速度,算法的训练效率越高。

对于平均回报,观察训练早期的平均回报值,该值越高时,算法的训练效果越好。针对最终收敛的回报值进行分析,部分算法可能会陷入局部最优或出现过拟合,因此无法收敛到预期平均回报值。

4.1.3 实现细节

4.1.3.1 软硬件环境

软件方面,采用 Win11 操作系统,python 3.10.16, pytorch 2.5.1 及其他适配版

本的 python 库。

硬件方面，处理器 i9-14900HX，拥有 24 核心 32 线程，包括 8 个性能核和 16 个能效核，NVIDIA GeForce RTX 4070 笔记本电脑 GPU，16GB 的运行内存(RAM) 和 1TB 的固态硬盘(SSD) 存储容量。

4.1.3.2 神经网络架构

本文所提算法的探索策略采用 TD3 算法，其神经网络架构由策略网络和双 Q 值网络构成。

策略网络 $\mu_{\theta}(s)$ 采用多层感知机结构，以环境状态 $s_t \in R^n$ 为输入，通过两个维度均为 256 的全连接隐藏层进行特征提取，输出层则通过 $\tanh$ 激活函数将动作值限制在 $[-1, 1]$ 范围内，输出确定性动作 $a_t \in R^m$ 。

双 Q 网络 $Q_{\phi_1}(s, a)$ 和 $Q_{\phi_2}(s, a)$ 采用并行结构设计，每个网络将状态 s_t 与动作 a_t 拼接为联合特征向量，经过两个维度均为 256 的全连接隐藏层处理后输出状态-动作价值估计。

网络激活函数均使用 ReLU 非线性单元，最后一层为线性输出层。目标网络通过软更新机制 $\theta' \leftarrow \tau\theta + (1 - \tau)\theta'$ ($\tau \ll 1$)与在线网络保持参数同步，并通过延迟策略更新策略确保训练稳定性。

4.1.3.3 超参数设计

本实验主要关系到以下几个超参数：

引导策略下降的阶段数量 n_{stage} ，即引导策略共分为 n_{stage} 个阶段减少。这里设置 $n_{stage} = 10$ 。

最大引导步长 $horizon_{max}$ ，即在一个回合中允许引导策略参与的最大步数。经前期预实验，行为树在最大时间步长为 100 步时，能够得到可行的成功率，因此设定 $horizon_{max} = 100$ 。

总时间步长 $timesteps_{total}$ ，本实验中所有回合花费的时间步长之和，设定 $timesteps_{total} = 1,000,000$ 。

TD3 算法的学习率 $rate_{learning}$ ，本实验中统一设定 $rate_{learning} = 0.001$ 。

4.2 基于行为树的仿真实验

4.2.1 行为树节点层级与规则设计

表 4-1 本实验设计的行为树

Algorithm 3 tank behavior tree

Root（选择节点）

- ├─ **U_Sequence**（顺序节点）
 - | ── IsMovingU（条件节点）
 - | ── U（动作节点）
- ├─ **Back_Sequence**（顺序节点）
 - | ── IsMovingBack（条件节点）
 - | ── MoveBack（动作节点）
- ├─ **Left_Sequence**（顺序节点）
 - | ── IsMovingLeft（条件节点）
 - | ── MoveLeft（动作节点）
- ├─ **Right_Sequence**（顺序节点）
 - | ── IsMovingRight（条件节点）
 - | ── MoveRight（动作节点）
- └─ **MoveToTarget**（动作节点）

根节点选择器（Selector）采用非记忆模式，按子节点顺序执行直至发现有效分支。优先级排序为：U型转向→后退→左转→右转→目标追踪。顺序节点同样采用非记忆模式，严格按预设逻辑顺序执行条件判断与对应动作。

在此基础上设计条件判断节点，节点类继承自 `py_trees.behaviour.Behaviour`，通过黑板机制获取环境观测值，其中传感器数据经过归一化处理，为方便调整参数，这里对其进行反归一化，阈值设定为实际物理量约束。动作执行节点动作节点实现简单状态返回机制，实际动作映射在 `tick()`方法中完成。动作参数生成策略采用基于规则的决策。

运行该行为树时，首先，环境观测值 `observation` 通过黑板传递至各条件节点，每帧调用 `tick()`更新行为树状态。其次，选择器按优先级遍历子节点，首个满足条件的顺序节点分支被执行。最后，根据激活节点状态选择预设动作参数，经 PID 优化后输出至执行器。

具体而言，我们设计行为树规则如下：

规则 1：U 型避障（U_Sequence）

触发条件:

所有雷达感知信息向量数据中存在 1-3 个超过 0.8 的值:

$$C_U = \sum_{i=1}^{24} \mathbb{I}(R_i > 0.8) \in [1, 3] \quad (4-1)$$

其中, R_i 为雷达感知信息向量数据; $\mathbb{I}$ 为指示函数, $\mathbb{I}(x) = \begin{cases} 1, & x \text{ is True} \\ 0, & \text{otherwise} \end{cases}$

决策行为:

设定基础加速度:

$$\dot{\omega}_{base} = 3 + \mathbb{I}(\frac{1}{3} \sum_{i=11}^{13} R_i > 0.6) + \mathbb{I}(\frac{1}{3} \sum_{i=11}^{13} R_i > 0.8) \quad (4-2)$$

对 CGF 附近障碍物等级进行判断:

$$level_{obstacle} = \sum_{i=8}^{16} \mathbb{I}(R_i < 0.2) \quad (4-3)$$

基于此确定转向因子:

$$factor_{turn} = \begin{cases} 3, & level_{obstacle} > 5 \\ 2, & level_{obstacle} > 2 \\ 1, & \text{otherwise} \end{cases} \quad (4-4)$$

确定最大的雷达感知信息向量数据所在方向, 当该数据处于 CGF 正前方, 即该数据为 CGF 正前方三个感知信息向量数据之一时, 直行:

$$\dot{\omega}_l = \dot{\omega}_{base}, \quad \dot{\omega}_r = \dot{\omega}_{base}$$

当该数据在 CGF 右侧且不在 CGF 正前方时, 控制 CGF 右转。当 $level_{obstacle} > 1$ 时:

$$\dot{\omega}_l = \dot{\omega}_{base}, \quad \dot{\omega}_r = -factor_{turn}$$

$level_{obstacle} \leq 1$ 时, 则有:

$$\dot{\omega}_l = \dot{\omega}_{base}, \quad \dot{\omega}_r = \dot{\omega}_{base} - 2$$

同理, 当该数据在 CGF 左侧且不在 CGF 正前方时, 控制 CGF 左转。当 $level_{obstacle} > 1$ 时:

$$\dot{\omega}_l = -factor_{turn}, \quad \dot{\omega}_r = \dot{\omega}_{base}$$

$level_{obstacle} \leq 1$ 时, 则有:

$$\dot{\omega}_l = \dot{\omega}_{base} - 2, \quad \dot{\omega}_r = \dot{\omega}_{base}$$

规则 2: 后退避障 (Back_Sequence)

触发条件:

CGF 正前方三个雷达感知信息向量数据的均值小于或等于 0.3:

$$C_{Back} = \frac{1}{3} \sum_{i=11}^{13} R_i \leq 0.3 \quad (4-5)$$

决策行为:

当左前侧雷达感知信息向量数据均值大于右侧时:

$$\frac{1}{3} \sum_{i=14}^{16} R_i > \frac{1}{3} \sum_{i=8}^{10} R_i \quad (4-6)$$

且 $level_{obstacle} > 1$ 时, 控制 CGF 右后转:

$$\dot{\omega}_l = -factor_{turn}, \quad \dot{\omega}_r = \dot{\omega}_{base}$$

$level_{obstacle} \leq 1$ 时, 则左前转:

$$\dot{\omega}_l = 0, \quad \dot{\omega}_r = \dot{\omega}_{base}$$

当左前侧雷达感知信息向量数据均值小于或等于右侧时:

$$\frac{1}{3} \sum_{i=14}^{16} R_i \leq \frac{1}{3} \sum_{i=8}^{10} R_i \quad (4-7)$$

且 $level_{obstacle} > 1$ 时控制 CGF 左后转:

$$\dot{\omega}_l = \dot{\omega}_{base}, \quad \dot{\omega}_r = -factor_{turn}$$

$level_{obstacle} \leq 1$ 时, 或右前转:

$$\dot{\omega}_l = \dot{\omega}_{base}, \quad \dot{\omega}_r = 0$$

规则 3: 左转避障 (Left_Sequence)

触发条件:

CGF 右前侧三个雷达感知信息向量数据的均值小于或等于 0.2:

$$C_{Left} = \frac{1}{3} \sum_{i=8}^{10} R_i \leq 0.2 \quad (4-8)$$

决策行为:

当 $level_{obstacle} > 1$ 时, 控制 CGF 右后转:

$$\dot{\omega}_l = -factor_{turn}, \quad \dot{\omega}_r = \dot{\omega}_{base}$$

$level_{obstacle} \leq 1$ 时, 则左前转:

$$\dot{\omega}_l = 0, \quad \dot{\omega}_r = \dot{\omega}_{base}$$

规则 4: 右转避障 (Right_Sequence)

CGF 左前侧三个雷达感知信息向量数据的均值小于或等于 0.2:

$$C_{Right} = \frac{1}{3} \sum_{i=14}^{16} R_i \leq 0.2 \quad (4-9)$$

决策行为:

当 $level_{obstacle} > 1$ 时控制 CGF 左后转:

$$\dot{\omega}_l = \dot{\omega}_{base}, \quad \dot{\omega}_r = -factor_{turn}$$

$level_{obstacle} \leq 1$ 时, 或右前转:

$$\dot{\omega}_l = \dot{\omega}_{base}, \quad \dot{\omega}_r = 0$$

规则 5: 调整方向 (MoveToTarget)

无触发条件。

决策行为:

使用 PID 控制器, 代入 CGF 朝向与 CGF 中心到目标点中心连线之间的夹角 A 和 $\dot{\omega}_{base}$ 计算并限制误差值:

$$err = clip(A, -\dot{\omega}_{base}, \dot{\omega}_{base}) \quad (4-10)$$

当 $err > 0$ 时, 朝向偏右, 向左调整:

$$\dot{\omega}_l = \dot{\omega}_{base} - err, \quad \dot{\omega}_r = \dot{\omega}_{base}$$

当 $err \leq 0$ 时, 朝向偏左, 向右调整:

$$\dot{\omega}_l = \dot{\omega}_{base}, \quad \dot{\omega}_r = \dot{\omega}_{base} - err$$

4.2.2 比例-积分-微分控制器

为实现连续动作空间的平滑控制, 在行为树中主要采用双通道 PID 控制器对原始动作指令进行动态优化。针对左右执行机构的独立控制需求, 分别设计左通道 PID 控制器 C_L 和右通道 PID 控制器 C_R , 构成具有抗饱和特性的闭环控制系统。对于任意通道 $k \in \{L, R\}$, 定义离散时间域 PID 控制律:

$$u_k(t) = K_p e_k(t) + K_i T_s \sum_{i=0}^t e_k(i) + K_d \frac{e_k(t) - e_k(t-1)}{T_s} \quad (4-11)$$

其中, $e_k(t) = r_k(t) - y_k(t)$ 为时刻 t 的跟踪误差, $r_k(t)$ 为参考输入, 即行为树生成的原始动作指令, $y_k(t)$ 为系统反馈量, 即归一化后的执行机构状态观测值, 设定 $K_p = 1.2, K_i = 0.001, K_d = 0.001$ 为经验整定参数, $T_s = 0.1$ 为采样周期。

对控制器输出进行抗饱和处理:

$$u_k^{clipped}(t) = clip(u_k(t), u_{min} = -5, u_{max} = 5) \quad (4-12)$$

使输出器具有微分平滑的理论特性。具体而言, 通过微分项抑制动作突变, 降低系统超调量, 满足:

$$\Delta u_k(t) = u_k(t) - u_k(t-1) \leq \gamma_{max} \quad (4-13)$$

其中, γ_{max} 由 K_d 参数约束。

并采用条件积分算法, 当输出饱和时停止积分累积, 避免 windup 效应:

$$\sum e_k(i) = \begin{cases} \sum e_k(i) & \text{if } |u_k(t)| < u_{max} \\ 0 & \text{otherwise} \end{cases} \quad (4-14)$$

此外, 双通道独立调节保证系统动力学对称性, 满足:

$$\frac{\partial u_L}{\partial y_R} = \frac{\partial u_R}{\partial y_L} = 0 \quad (4-15)$$

在基于行为树的决策框架中，PID 控制器通过闭环反馈机制有效降低了规则参数的敏感性，提升了 CGF 对环境的适应性，有效减少了行为树的人工调参的工作量。

4.2.3 行为树的改进与评估

根据基本的避障逻辑，对行为树进行初步设计，最初行为树的根节点仅有 Left_Sequence、Right_Sequence 和 MoveToTarget 三个子节点。经初步实验和观察分析实验过程发现，由于 Left_Sequence 和 Right_Sequence 节点在条件判断时仅使用了 CGF 左前侧和右前侧雷达感知信息向量数据，对观测值的考虑不够全面，导致 CGF 容易碰撞正前方特定障碍物。为改进该缺陷，增加 Back_Sequence，并使用正前方雷达感知信息向量数据的平均值进行判断。解决上述问题后，CGF 出现在 U 型障碍物中原地打转的情况，对此，增加 U_Sequence 对 U 型障碍物进行判断和处理。

在此基础上，我们发现：当阈值一定，动作空间参数较大时，即左右轮角加速度 $|\dot{\omega}_l| \geq 2$ 或 $|\dot{\omega}_r| \geq 2$ 时，避障较为迅速和精准，但由于旋转角度过大，CGF 无法通过障碍物之间较小的缺口；反之，动作空间参数较小时，避障不够灵敏，但能够找到障碍物之间的空隙以缩短探索距离。此外，当动作空间参数一定，阈值较大时，CGF 更加保守，倾向于规避障碍物让自己保持安全，但也因此难以准确找到障碍物之间的可供通过的缺口；阈值较小时，CGF 则有更多的碰撞风险。根据理论分析和多次试验，调整阈值和动作空间参数，寻找安全性和有效性之间的平衡点。为方便这一调参过程，尝试引入 PID 控制器。最终找到较为合适的阈值和动作空间参数。

经过上述改进和调整，基本得到现有行为树。设定实验总时间步长为 1,000,000 次，每个回合最大步数为 100 步时，该行为树成功率约为 35%，此时的平均奖励约为 0.15。通过前期预实验了解到：一般情况下，本实验收敛时的奖励在 1.2-1.3 之间，而未经过训练的智能体得到的奖励约为-2。由图 4-1 和图 4-2，根据 JSRL 对引导策略的要求，认为该行为树能够在较短的时间步长内将 CGF 智能体引导至目标点附近，可以用于下一步实验。




图 4-1 回合步长频数分布直方图




图 4-2 奖励频数分布直方图

4.3 总体结果




图 4-3 训练地图

使用图 4-3 作为地图环境开展实验，黑色部分为障碍物，白色部分可供 CGF 正常通行。在稀疏奖励的实验环境下，对比本文提出的算法与传统 TD3 算法和行为树。




图 4-4 BT 引导的 TD3 算法与传统 TD3 算法和行为树获得平均奖励

由图 4-4 可得，行为树引导的 TD3 算法在 80,000 时间步长以内的初始阶段中平均回报值集中在 0.2 附近。由预实验可知，未经训练的智能体所得到的初始奖励约为-2，行为树平均奖励值为 0.15，说明初始阶段的平均回报值是由行为树本身作用的，并且行为树的引导在实验初期为智能体提供了良好的方向和开端，加速了算法的收敛。行为树引导的 TD3 算法在时间步长为 200,000 时回报值已经收敛，收敛值为 1.22，最终收敛值与预实验结果相符，算法效果良好。




图 4-5 BT 引导步长的下降

由图 4-5，行为树引导步长在 100,000 步附近迅速下降，对应时间步长内，平

均回报值迅速上升收敛,说明在这一阶段前期行为树的引导作用已经基本发挥完善,算法即将进入由 TD3 独立探索的成熟阶段。

由于行为树不具有学习能力且整个过程具有较强的随机性,在图 4-4 中直接采用其总时间步长内的平均回报值作为数据。在实验初期,行为树引导的 TD3 算法平均回报值高于传统 TD3 算法,并在行为树的平均回报值上下振荡,后续以较快速度上升,最终在不到 200,000 步时已经收敛;而传统 TD3 算法收敛速度较慢,约在 750,000 步时收敛。

从最终收敛值来看,BT 引导的 TD3 算法的奖励值最终收敛于 1.22,与预实验的结果相符;而传统的 TD3 算法收敛于 0.98,可能是由于陷入局部最优导致的;行为树不具有学习能力,其平均回报值存在一个由行为树中蕴含的领域规则的好坏所决定的上限,而一般情况下,该上限要明显劣于强化学习得到的收敛值。

以上结果充分表明,结合领域知识的学习型决策建模方法在稀疏奖励场景下展现出显著的性能优势。与传统 TD3 算法相比,该方法大幅提升了收敛速度,有效避免了局部最优解的问题,最终收敛到更高的平均回报值。这主要归功于行为树引导策略提供的高效初始探索方向和 JSRL 框架下引导步数的渐进式减少机制,使得智能体能够在早期阶段快速接近目标区域,并逐步学习到更优的决策策略。

4.4 消融实验

4.4.1 行为树引导的有效性验证




图 4-6 算法效率对比分析

由图 4-6，TD3 引导的 TD3 算法在 150,000 时间步长内收敛，具有最高的效率和最优的初始平均回报值，从这一点来看，该算法最优。但 TD3 引导的 TD3 算法需要进行预训练，将传统 TD3 算法的训练结果作为模型保存，正式训练时加载该模型作为引导策略，实际的训练效率并不高。而行为树引导的 TD3 算法不需要预训练模型，可以直接运行，并且在 200,000 时间步长内已经收敛，收敛速度与 TD3 引导的 TD3 算法相差不大。此外，就最终收敛的平均回报值而言，行为树引导的 TD3 算法最终收敛于 1.22，TD3 引导的 TD3 算法收敛于 1.07，传统 TD3 算法收敛于 0.98，后两者均在不同程度上陷入了局部最优解，引导策略能在一定程度上解决这个问题。综上所述，可以认为行为树引导的 TD3 算法具有良好的训练效率和训练效果。

4.4.2 课程学习的有效性验证




图 4-7 BT 引导的 TD3 算法与随机引导步数获得平均奖励对比




图 4-8 BT 引导步长与随机引导步长

由图 4-7 和图 4-8，当随机选择引导策略步数时，在实验初期，由于随机引导步数少于本文提出的算法，行为树的引导效果未能充分发挥，因此平均回报值较低。实验中期随着行为树和 TD3 的共同作用，平均回报值趋于收敛，但由于受到不同步长的策略引导，振荡幅度较大，且很快陷入局部最优解，最终收敛值在 0.62 附近，说明按照课程学习减少引导步数是十分有必要的。

4.5 敏感性分析

4.5.1 最大引导步长




图 4-9 不同最大引导步长下的训练效果




图 4-10 不同最大引导步长下引导步数的下降

由图 4-9 和图 4-10 可得,最大引导步长主要影响的是算法平均回报值的起点,进一步影响算法的收敛速度。具体而言,对于本实验设计的行为树来说,最大引导步长 $horizon_{max} = 100$ 时,算法在 200,000 时间步长内收敛; $horizon_{max} = 80$ 时,算法在 300,000 时间步长内收敛; $horizon_{max} = 60$ 时,算法在 450,000 时间步长内收敛; $horizon_{max} = 40$ 时,算法在 950,000 时间步长内收敛。最终收敛的平均回报值稍有差异,但都集中在 1.2 附近,没有陷入明显的局部收敛。

综上所述,在 $[40,100]$ 的范围内,其它参数一定时, $horizon_{max}$ 越高,则算法收敛速度越快。由此可见, $horizon_{max}$ 对算法收敛速度有较为显著的影响,但最终收敛结果受到 $horizon_{max}$ 的影响较小。

4.5.2 非稀疏环境




图 4-11 传统 TD3 算法稀疏环境与非稀疏环境对比分析

由图 4-11,相较于非稀疏环境,稀疏环境下传统 TD3 算法的收敛速度显著减缓。具体而言,非稀疏环境下,传统 TD3 算法在时间步长为 200,000 时已经收敛且最终收敛值约为 1.2,而在稀疏环境下,传统 TD3 算法直到 750,000 步附近才收敛。综上所述,稀疏环境下传统 TD3 算法的效率下降了 3-4 倍且陷入了局部最优解。

对于行为树而言,由于不存在环境反馈优化的学习机制,奖励是否稀疏并不影响该算法的表现。





图 4-12 BT 引导的 TD3 算法稀疏环境与非稀疏环境对比分析

而对于行为树引导的 TD3 算法来说，由于探索策略为 TD3 算法，因此同样受到了奖励稀疏的一部分影响，但是该影响较小。图 4-12 中，在非稀疏环境下行为树引导的 TD3 算法的收敛速度稍快于稀疏环境下的收敛速度。证明相比于传统的 TD3 算法，行为树引导的 TD3 算法对于稀疏环境有更强的适应性。

4.6 泛化性分析






图 4-13 测试地图 1-4

使用图 4-13 的四张测试地图对算法的鲁棒性进行验证。经预实验结果分析，针对测试地图调整 $horizon_{max} = 20$ 。




图 4-14 测试地图 1-4 中算法的训练效果

由图 4-14，在测试地图 1-4 中，该算法都能在较少的时间步长内快速收敛，收敛结果均集中在 1.3 附近。说明行为树引导的 TD3 算法在面对这类导航避障问题时具有较好的泛化能力，能够在不同环境布局下有效学习并适应。尽管如此，为达成更优的泛化性能，需要根据地图实际情况对超参数 $horizon_{max}$ 进行调整。

4.7 行为分析

在行为树的策略下，周围不存在障碍物时，CGF 始终朝向目标点移动，碰到障碍物时再采取避障措施，此时可能出现绕远路的情况。

如图 4-15 所示，图中蓝色方块表示 CGF，红色方块表示目标点，红线表示 CGF 的轨迹，蓝色箭头表示 CGF 在周围没有障碍物时的朝向。为了绕过中间长条 S 形障碍物，行为树规则使 CGF 从右侧绕远路寻找目标点，而不是从左侧直接到达目标点。




图 4-15 行为树策略下的行为分析

而 TD3 的探索能力在一定程度上能够弥补这一点。如图 4-16，经过一段时间的充分探索学习后，行为树引导的 TD3 算法将路线纠正到较短路径上来，避免产生更多的时间惩罚或因超出最大步数而无法获得到达奖励。




图 4-16 经 TD3 算法纠正后的轨迹

4.8 其他实验

在不同的测试地图下，令 $horizon_{max} = 100$ 时，我们发现由于行为树得到的引导结果已经比较良好，探索策略的 TD3 算法难以达到或超越引导策略中行为树规则所达到的奖励程度，因此导致 $horizon$ 无法逐步递减，网络中的 $loss_{actor}$ 和 $loss_{critic}$ 发生爆炸，算法难以在早期收敛甚至无法收敛。

如图 4-17 和图 4-18 所示，以测试地图 1 为例，设置最大引导步长 $horizon_{max} = 100$ 时，算法直到 650,000 步附近才收敛，对应的时间步长内引导步长迅速下降。而令 $horizon_{max} = 20$ 时，算法起点较低，但能够正常迅速收敛，起到了良好的引导效果。




图 4-17 测试地图 1 中不同最大引导步长下获得的平均回报值




图 4-18 测试地图 1 中不同最大引导步长下引导步长的下降

如图 4-19 和图 4-20 以测试地图 3 为例, 设置最大引导步长 $horizon_{max} = 100$ 时, 算法始终无法收敛, 并在 0.15 附近振荡, 而 0.15 正是本实验设计的行为树能够获得平均值奖励, 对应的引导步长经历几次下降后保持在 $horizon = 50$, 直到实验结束都没有任何减少。而令 $horizon_{max} = 20$ 时, 算法起点较低, 但能够正常迅速收敛, 起到了良好的引导效果。




图 4-19 测试地图 3 中不同最大引导步长下获得的平均回报值






图 4-20 测试地图 3 中不同最大引导步长下引导步长的下降

由图 4-21 和图 4-22 进一步观察 $loss_{actor}$ 和 $loss_{critic}$ ，正常情况下，损失值集中在 0 附近，而 $horizon_{max} = 100$ 对应的损失值在后期发生爆炸，远远超出这一范围。

图 4-21 测试地图 3 中不同引导步长下的 $loss_{actor}$

图 4-22 测试地图 3 中不同引导步长下的 $loss_{critic}$

此外，在多次实验中，观察到本文所提算法在训练后期可能偶尔出现图 4-23 中过拟合的情况，这是由于算法的成熟阶段由 TD3 完全主导探索，而 TD3 算法在面对稀疏奖励环境时，由于奖励的延迟性，导致对未来奖励的观测能力变弱，折中选择下陷入了局部最优解，也说明实验的奖励设计依然不够完善。




图 4-23 BT 引导的 TD3 算法后期可能出现过拟合现象

4.9 本章小结

本章通过一系列仿真实验，全面验证了结合领域规则的学习型决策行为建模方

法的有效性和先进性。首先，详细介绍了实验设计，包括实验场景的设定、评估指标的选择以及实现细节中的软件和硬件环境配置。其次，对基于行为树的仿真实验进行了深入分析，展示了行为树节点层级与规则设计的细节，如 U 型避障、紧急避障、左转避障、右转避障和调整方向等规则的触发条件和决策行为，并引入 PID 控制器以实现连续动作空间的平滑控制，降低了人工调参的复杂度。通过不断改进行为树结构和参数，提高了其在导航避障任务中的成功率和适应性。接着，在总体结果分析中，对比了行为树引导的 TD3 算法与传统 TD3 算法和单独行为树的性能表现，结果表明在稀疏奖励环境下行为树引导的 TD3 算法在训练效率和性能表现方面有显著优势。消融实验则验证了行为树引导和课程学习的有效性。敏感性分析展示了算法对最大引导步长的鲁棒性，并对比了本文所提算法与传统 TD3 算法受到奖励是否稀疏的影响程度，说明了本文所提算法对奖励稀疏环境的强适应性。泛化性分析展示了算法在不同地图环境下的较好的泛化能力。行为分析揭示了 TD3 算法在纠正行为树保守路径选择方面的能力，表明结合领域规则的学习型决策行为建模方法能够生成更为优化和适应性强的智能体行为策略。最后，通过其他实验进行了补充，进一步证明结构化引导相较于随机引导的优越性，说明了算法的过拟合以及超参数的选择问题。

5 总结与展望

5.1 总结

本文针对现代军事训练领域中计算机生成兵力战术决策行为建模的迫切需求，提出了一种结合领域规则的学习型决策行为建模方法。通过将行为树的结构化领域知识表征与深度强化学习相结合，为解决稀疏奖励场景下强化学习探索效率低、易陷入局部最优的问题提供了创新性解决方案。本文从理论与实践相结合的角度出发，系统地开展了以下研究工作：首先，本文首先说明了研究背景，并分析基于知识工程的决策行为建模方法、基于机器学习的决策行为建模方法以及深度强化学习与领域知识融合算法的研究现状；其次，在课题组自研的军事仿真平台上面向多自由度 CGF 的战术机动过程进行问题定义，并构建了马尔科夫决策过程的模型；接着，设计了结合领域规则的学习型决策行为建模方法，在 JSRL 框架下，引入行为树作为引导策略并按课程学习递减引导步数，实现了从规则引导到自主探索的平滑过渡；最后，在实验室自主研发的 CGF 智能行为建模平台上进行了全面的仿真实验，验证了本文方法在稀疏奖励场景下的有效性和优越性，并在实验过程中利用 PID 控制器优化动作映射，降低了人工调参的复杂度。研究结果表明，该方法显著提升了模型的训练效率和决策质量，使 CGF 行为具有良好的可解释性和适应性，为军事仿真系统的智能化升级提供了有力的技术支撑。总结起来，本文主要有以下贡献：

贡献 1：提出结合领域规则的学习型决策行为建模框架，通过行为树规则与 TD3 算法的协同优化，解决了传统强化学习在稀疏奖励场景下探索效率低、易陷入局部最优解的问题。

贡献 2：设计了一种基于行为树的结构化领域规则表征方法，采用优先级节点划分，并通过 PID 控制器实现平滑动作映射，显著降低了人工调参复杂度，便于在实验过程中进一步调整和优化行为树。

贡献 3：在实验室自研 CGF 智能行为建模平台上构建了复杂战场环境，验证了结合领域规则的学习型决策行为建模方法框架在战术机动、避障导航等任务中的实用性。实验结果表明，行为树引导的 TD3 算法生成的策略能够良好地适应奖励稀疏环境下的目标导航和静态避障任务，该方法通过规则引导减少无效探索，缩短了智

能体从零学习的周期，为大规模战术推演提供了可行方案。此外，结合领域规则的行为模型能够模拟人类指挥员的战术逻辑，增强了 CGF 实体行为的可解释性和战场适应性，为分队级模拟训练系统的智能化升级提供了技术支撑。

5.2 未来展望

未来工作还可以从以下几个方面展开：

1. 自动化领域规则生成

结合元学习优化行为树结构，利用元学习算法动态调整行为树节点优先级与触发条件，减少对人工规则的依赖。通过大语言模型驱动规则设计，基于 GPT-4 等模型的语义理解能力，将作战条例、历史战例转化为结构化规则，实现领域知识的自动化提取与嵌入。

2. 多智能体协同决策

开发分布式知识共享机制，设计基于图神经网络的通信协议，支持智能体间实时交换态势感知与策略信息，提升编队任务的协作效率。进一步设计分层强化学习框架，将高层策略规划（如任务分配）与底层动作控制（如路径跟踪）解耦，通过课程学习逐步提升多智能体系统的复杂性。

3. 跨领域迁移与应用扩展

在民用机器人导航领域，将结合领域规则的学习型决策行为建模框架迁移至物流机器人、无人驾驶等领域，解决复杂环境下的路径规划与避障问题。

4. 安全性与可解释性增强

给智能体嵌入安全约束，引入屏障函数与风险敏感奖励机制，确保智能体在探索过程中严格遵守物理约束与作战规则。支持可视化决策溯源，开发交互式可视化工具，动态展示行为树节点激活状态与强化学习策略的决策依据，增强模型的可信度与可解释性。

致 谢

致谢提笔致谢,思绪繁杂,在滴滴答答的键盘声中等待着夏日和毕业季的到来。四年本科已接近尾声,纵使心中有万般不舍,也要和这段珍贵而充实的时光说一声再见。从懵懂稚嫩的十八岁一路走来,品尝过三号院里的风霜雨雪,在这里增长见识,雕琢自我,满怀着期待与感恩,在亲人、老师和战友的关怀与支持下不断成长。

首先,感谢我本科期间的全程导师葛斌教授。非常有幸在茫茫人海中成为葛教授的学生,葛教授平时忙于科研和教学,我们见面的次数算不上许多,但他总能在我迷茫和焦躁的时候为我指明方向,提供帮助,使我受益良多。在我大四住院手术期间,葛教授曾专门抽出时间来医院关心我的情况,感激之情,溢于言表。

其次,感谢本文的指导老师曾俊杰对我的悉心指导,从毕业设计选题到开题报告再到最后成文,离不开曾老师严谨而细致地帮我指出问题,给予修改意见。更重要的是,曾老师在这一过程中非常注重教会我如何思考,如何读文献,如何设计实验,如何找到合适的创新点以及如何形成自己的方式与方法,为我未来的学术之路奠定了良好的基础。

想得家中夜深坐,还应说着远行人。感谢我的父母贺建文、邓琼和小猫皮皮,作为我的家人给予我无条件的支持、鼓励与陪伴。离家千里求学于此,四年中回家的时间也屈指可数,但总可以从中获得安定而温和的力量,是我永远的港湾和心灵的慰藉。

愿岁并谢,与长友兮。感谢我的朋友们,我们是彼此青春的收藏家。感谢余晨阳和薛浚铨,我们一起参加过许许多多的数模竞赛,一起熬过无数昏昏沉沉的夜。感谢我的室友尹新蓉、莫雪彬、余晨阳和钱蓝慕以及康复师周哥和璇姐,在准备毕业联考的过程中给予我的鼓励和帮助。感谢本队的战友们,你们的青春意气 and 满腔热血始终感染着我。

感谢谭思昱副大队长、李海教导员、彭磊队长和其他大队领导在日常生活中对我的关心和爱护,使我度过了温暖而充实的大三大四。

艰难困苦,玉汝于成。感谢十八岁的自己,勇敢地选择科大,做出短短人生路中最重要的决定。也感谢二十二岁的自己,在最艰难的日子里没有放弃。

最后,衷心感谢评阅老师们在百忙之中抽出宝贵时间对我的论文进行审阅。

参考文献

- [1] 高昂,董志明,张国辉,等. LVC 训练系统中计算机生成兵力生成技术研究[J].系统仿真学报,2021,33(3): 745-752
- [2] 郑义.计算机生成兵力行为建模与实现技术研究[D]. 国防科学技术大学,2003.
- [3] 张琪. 学习驱动的 CGF 决策行为建模方法研究[D]. 国防科学技术大学,2018.
- [4] 付延昌. 基于行为树的 CGF 行为建模研究[D]. 国防科学技术大学,2016.
- [5] 高昂,段莉,张国辉,等. 计算机生成兵力行为建模发展现状[J]. 计算机工程与应用,2019,55(19): 43-51.
- [6] 许霄. 面向 CGF 战术决策的蒙特卡洛树搜索方法研究[D]. 国防科技大学,2018.
- [7] 曾俊杰,方淇,曾云秀,等. 一种智能体策略生成方法、装置、计算机设备和存储介质:202310652725[P]. 2023-07-04.
- [8] Ikechukwu Uchendu, Ted Xiao, Yao Lu, et al. (2023) Jump-start reinforcement learning. In Proceedings of the 40th International Conference on Machine Learning (ICML'23), Vol. 202. JMLR.org, Article 1439, 34556–34583.
- [9] E.L. Post, "Formal reductions of the general combinatorial decision problem" Amer. J. Math. , 65 : 2 (1943) pp. 197–215
- [10] Newell, A. & Simon, H. (1972). Human Problem Solving. Englewood Cliffs, NJ: Prentice-Hall.
- [11] Shortliffe, E. H. Books: Computer-Based Medical Consultations: MYCIN[J]. Journal of Clinical Engineering,1976,Vol.1(1): 69.
- [12] 孙海文,谢晓方,孙涛,等.基于直觉模糊产生式规则推理的空袭目标威胁等级判断 [J] .兵器装备工程学报,2019,40(5):33-37.
- [13] Razan Ghzouli, Thorsten Berger, Einar Broch Johnsen, et al. (2020) Behavior trees in action: a study of robotics applications. In Proceedings of the 13th ACM SIGPLAN International Conference on Software Language Engineering (SLE 2020). Association for Computing Machinery, New York, NY, USA, 196–209.
- [14] Brooks, R. A., and J. Connell, "Asynchronous Distributed Control System for a Mobile Robot", Proceedings of SPIE's Cambridge Symposium on Optical and Optoelectronic Engineering, Cambridge, MA, October 1986, pp. 77–84.

- [15] Brooks, R. A., "A Robust Programming Scheme for a Mobile Robot", Proceedings of NATO Advanced Research Workshop on Languages for Sensor-Based Control in Robotics, Castelvechio Pascoli, Italy, September 1986.
- [16] Iovino M , Scukins E , Styurd J ,et al. A survey of Behavior Trees in robotics and AI[J].Robotics and Autonomous Systems, 2022:154..
- [17] 刘瑞峰,王家胜,张灏龙,等.行为树技术的研究进展与应用[J].计算机与现代化,2020,(2): 76-82, 88
- [18] 郑东海,于海跃. 强化学习与行为树在智能体行为决策中的研究与应用[J]. 电脑校园,2023(6):440-443.
- [19] 张俊峰,薛青,张扬,等.融合行为树和势力图的作战决策建模方法[J].计算机仿真, 2021, 38(10):5.
- [20] 杨杰,张琪,曾俊杰,等.进化行为树方法研究综述[J].系统仿真学报,2021,33(10): 2315-2322
- [21] Daumé, H., Langford, J. and Marcu, D. Search-based structured prediction. Mach Learn 75, 297–325 (2009).
- [22] Ross, S. and Bagnell, D. (2010). Efficient reductions for imitation learning. Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics.
- [23] Ross, S.; Gordon, G. J. and Bagnell, J. A. (2010). No-regret reductions for imitation learning and structured prediction. CoRR, abs/1011.0686.
- [24] Judah, K.; Fern, A. and Dietterich, T. G. (2012). Active imitation learning via reduction to I.I.D. active learning. CoRR, abs/1210.4876.
- [25] He, H.; Daumé, III, H.; and Eisner, J. (2012). Imitation learning by coaching. Proceedings of the 25th International Conference on Neural Information Processing Systems. 2: 3149-3157.
- [26] Kim, B.; Farahmand, A.; Pineau, J. et al.(2013). Learning from limited demonstrations. Proceedings of the 26th International Conference on Neural Information Processing Systems. 2:2859-2867.
- [27] Ross, S. and Bagnell, J. A. (2014). Reinforcement and imitation learning via interactive no-regret learning. CoRR, abs/1406.5979.
- [28] 张超,白文松,杜歆,等. 模仿学习综述: 传统与新进展[J]. 中国图象图形学报,2023,28(6): 1585-1607.
- [29] Z. Fang, T. Chen, T. Shen, et al. "Multi-Agent Generative Adversarial Interactive Self-Imitation

- Learning for AUV Formation Control and Obstacle Avoidance," in IEEE Robotics and Automation Letters, vol. 10, no. 5, pp. 4356-4363, May 2025.
- [30] 刘全,翟建伟,章宗长,等. 深度强化学习综述[J].计算机学报,2018,第 41 卷,第 1 期,1-27
- [31] 刘建伟,高峰,罗雄麟. 基于值函数和策略梯度的深度强化学习综述[J].计算机学报,2019,第 42 卷,第 6 期,1406-1438
- [32] 万里鹏,兰旭光,张翰博,等. 深度强化学习理论及其应用综述[J].模式识别与人工智能,2019,第 32 卷,第 1 期,67-81
- [33] Watkins C J C H .Learning From Delayed Rewards[J].Robotics & Autonomous Systems, 1989.
- [34] Mnih, V., Kavukcuoglu, K., Silver, D., et al. (2013). Playing Atari with Deep Reinforcement Learning. ArXiv, abs/1312.5602.
- [35] 赵冬斌,邵坤,朱圆恒,等. 深度强化学习综述:兼论计算机围棋的发展[J].控制理论与应用,2016,第 33 卷,第 6 期,701-717
- [36] 唐振韬,邵坤,赵冬斌,等. 深度强化学习进展:从 AlphaGo 到 AlphaGo Zero[J].控制理论与应用,2017,第 34 卷,第 12 期,1529-1546
- [37] Hado van Hasselt, Arthur Guez, and David Silver. 2016. Deep reinforcement learning with double Q-Learning. In Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence (AAAI'16). AAAI Press, 2094–2100.
- [38] Ziyu Wang, Tom Schaul, Matteo Hessel, et al. 2016. Dueling network architectures for deep reinforcement learning. In Proceedings of the 33rd International Conference on International Conference on Machine Learning - Volume 48 (ICML'16). JMLR.org, 1995–2003.
- [39] RONALD J. WILLIAMS. Simple statistical gradient-following algorithms for connectionist reinforcement learning.[J]. Machine Learning,1992,Vol.8: 229-256.
- [40] Lillicrap, T.P., Hunt, J.J., Pritzel, A., et al. (2015). Continuous control with deep reinforcement learning. CoRR, abs/1509.02971.
- [41] Florensa C , Held D , Wulfmeier M , et al. Reverse Curriculum Generation for Reinforcement Learning[J]. 2017.
- [42] Boris Ivanovic, James Harrison, Apoorva Sharma, et al. BaRC: Backward Reachability Curriculum for Robotic Reinforcement Learning[J]. 2018,.
- [43] Cinjon Resnick, Roberta Raileanu, Sanyam Kapoor, et al. Backplay: "Man muss immer umkehren"[J]. 2018,.

- [44] Christopher G. Atkeson and Stefan Schaal. 1997. Robot Learning From Demonstration. In Proceedings of the Fourteenth International Conference on Machine Learning (ICML '97). Morgan Kaufmann Publishers Inc., San Francisco, CA, USA, 12–20.
- [45] Mel Vecerik, Todd Hester, Jonathan Scholz, et al. Leveraging Demonstrations for Deep Reinforcement Learning on Robotics Problems with Sparse Rewards[J]. 2018,.
- [46] Rajeswaran, Aravind et al. “Learning Complex Dexterous Manipulation with Deep Reinforcement Learning and Demonstrations.” ArXiv abs/1709.10087 (2017): n. pag.
- [47] Jens Kober, Jan Peters. Imitation and Reinforcement Learning: Practical Algorithms for Motor Primitives in Robotics[J]. IEEE robotics and automation magazine: A publication of the IEEE Robotics and Automation Society,2010,Vol.17(2): 55-62.
- [48] Xue Bin Peng, Abbeel, P., et al. DeepMimic: example-guided deep reinforcement learning of physics-based character skills[J]. ACM Transactions on Graphics,2018,Vol.37(4): 143.
- [49] 李琛,黄炎焱,张永亮,等. Actor-Critic 框架下的多智能体决策方法及其在兵棋上的应用[J]. 系统工程与电子技术,2021,43(3): 755-762.