



计算机工程

Computer Engineering

ISSN 1000-3428, CN 31-1289/TP

《计算机工程》网络首发论文

题目：面向时延环境的无人机强化学习智能控制方法
作者：张森, 李杰, 张建伟, 李辉, 吴寿英, 吴冯国
DOI: 10.19678/j.issn.1000-3428.0253200
网络首发日期: 2026-02-03
引用格式: 张森, 李杰, 张建伟, 李辉, 吴寿英, 吴冯国. 面向时延环境的无人机强化学习智能控制方法[J/OL]. 计算机工程.
<https://doi.org/10.19678/j.issn.1000-3428.0253200>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

面向时延环境的无人机强化学习智能控制方法

张森¹, 李杰^{1*}, 张建伟¹, 李辉¹, 吴寿英¹, 吴冯国²

(1.四川大学计算机学院, 四川 成都 610065; 2.四川大学视觉合成图形图像技术国家级重点实验室, 四川 成都 610065)

摘 要: 深度强化学习 (DRL) 在无人机 (UAV) 决策领域的最新研究中展现出强大潜力, 已在多种控制任务中取得显著成效。然而, 现有将 DRL 用于无人机控制的研究大多默认“零延迟”理想环境, 忽略了真实链路中普遍存在的信号延迟; 直接把在 MuJoCo 等基准任务中验证的通用延迟处理方法迁移到高动态无人机平台, 往往难以复现其原有效果, 甚至加剧性能衰减。本研究通过仿真实验验证了经过深度强化学习训练的无人机智能体在信号延迟下出现的显著性能下降, 并深入分析了性能衰退的原因。论文提出了一种状态预测与自适应决策增强框架 SPADE, 能够有效处理固定与非固定延迟, 在 1v1 近距离格斗任务中实现了与无延迟系统相媲美的控制效果: 在 300–2400 毫秒延迟区间内, SPADE 较基线方法平均胜率增幅为 19.4% (固定延迟) 13.0% (非固定延迟), 显著补偿了软演员-评论家 (SAC) 算法因延迟造成的性能衰减, 且优于现有缓解深度强化学习无人机控制延迟效应的方法。总体而言, 本研究揭示了信号延迟对无人机控制系统的负面影响, 并提出了创新的状态预测与决策增强框架 (SPADE) 以应对此挑战, 显著提升了在延迟条件下的无人机控制性能。

关键词: 无人机控制; 深度强化学习; 信号延迟; 近距空战; 状态预测; 自适应决策

中图分类号: TP181 **文献标志码:** A **DOI:** 10.19678/j.issn.1000-3428.0253200

SPADE: Reinforcement Learning UAV Decision-Making Under Delayed Conditions

Zhang Sen¹, Li Jie^{1*}, Zhang Jianwei¹, Li Hui¹, Wu Shouying¹, Wu Fengguo²

(1. School of Computer Science, Sichuan University, Chengdu, 610065, China;

2. Nation Key Laboratory of Fundamental Science on Synthetic Vision, Sichuan University, Chengdu, 610065, China)

【Abstract】 Recent advancements in Deep Reinforcement Learning (DRL) have shown strong capabilities in Unmanned Aerial Vehicle (UAV) decision-making, achieving significant results in various UAV control tasks. However, existing DRL studies on UAV control mostly assume an idealized “zero-delay” environment, overlooking the signal delays ubiquitous in real-world links. Directly transferring generic delay-handling methods validated on MuJoCo-like benchmarks to highly dynamic UAV platforms often fails to reproduce their original benefits and can even aggravate performance degradation. Through simulated experiments, this study verifies, in a simulated environment, the significant decline in performance experienced by DRL-trained UAV agents under signal delays, and provides an in-depth analysis of the causes. We propose the State-Prediction and Adaptive Decision-enhanced (SPADE), which effectively handles both fixed and non-fixed delays. In a 1v1 close-range combat task, SPADE achieves control performance comparable to that of a delay-free system. Within a delay range of 300–2400 milliseconds, SPADE demonstrates an average win rate improvement of 19.4% (for fixed delays) and 13.0% (for non-fixed delays) over baseline methods. It significantly compensates for the performance degradation of the Soft Actor-Critic (SAC) algorithm caused by delays and outperforms existing methods aimed at mitigating delay effects in deep reinforcement learning for UAV control. In general, this research highlights the negative impact of signal delay on the UAV control system and introduces SPADE as a robust solution to address these challenges, significantly improving UAV control performance under delay conditions.

【Key words】 unmanned aerial vehicle control; deep reinforcement learning; delay signal; short-range air combat; state prediction; adaptive decision-making

0 引言

近年来,深度强化学习在无人机控制领域发展迅速,在近距离格斗^[1,2,3]与导航控制^[4,5,6]等任务中取得显著成果。结合 Transformer 模型与虚拟目标的决策方法已被应用于无人机集群近距空战^[7,8,9],基于多智能体深度强化学习的框架被用于无人机协同机动决策^[10,11],而将 SAC 算法与并行自博弈方法相结合,有效解决了无人机机动决策的挑战^[12,13]。FRV-DDPG 算法通过模拟敌方机动行为并改进奖励机制,提升了无人机自主空战机动能力^[14]。此外,面向双无人机协同空战的自主决策框架也取得了良好效果^[15]。然而在众多相关研究中,验证实验通常基于无延迟仿真环境的假设进行,未能考虑信号延迟的影响。

信号延迟是无人机控制系统中的常见问题,许多研究者已探索解决该方法。例如,文献[16]提出了一种基于鲁棒预测器的滑模控制方法,用于多旋翼无人机,并在数值仿真中证明了其对通信和执行器延迟的鲁棒性。文献[17]利用多跳边缘计算将地面控制站(GCS)与基站共置,提高了蜂窝网络中无人机控制的准确性;然而,该研究也专注于多旋翼无人机。另一项研究中,文献[18]采用双递归扰动模糊神经网络,实现了固定翼无人机在故障和通信延迟下的容错协同跟踪控制。文献[19]开发了一种控制器,通过利用能量流监测和自适应阻尼元件,使固定翼无人机能够在通信延迟下着陆于移动平台。这些研究处理的场景通常比空战环境对延迟更不敏感,同时,这些与延迟相关的研究均未在无人机控制背景下融入深度强化学习。

在 DRL 的背景下,信号延迟意味着智能体可能无法立即观察当前环境状态,或其行动可能无法立即对环境产生影响^[20]。无人机控制系统是信号延迟存在的典型例子,被控对象——无人机——对实时控制高度敏感。无人机由地面控制站(GCS)远程控制操作,两者之间的数据处理和通信都引入延迟,这可能影响无人机操作员的性能,无论是飞行员、智能体还是两者的组合。现有研究表明,基线延迟范围可以从 116.4 到 1672 毫秒(ms)^[23]。

人类反应时间通常在 200 至 300 毫秒之间^[25],而深度强化学习智能体的等效指标是决策步长。这是一个灵活且通常较短的值,常为数百甚至数十毫秒。因此,数百乃至数千毫秒的延迟对于控制无人机的深度强化学习智能体构成重大挑战。无人机机动算法应具备足够的容错能力,以在此潜在延迟范围内保持控制性能,确保安全导航和任务顺利完成。鉴于无人机的高机动性,信号延迟对控制质量的影响尤为显著;2002 年 7 月 10 日与 2019 年 11 月 26 日全球鹰全自主无人机的坠毁等严重事故,即为这一问题敲响的警钟。

基于深度强化学习研究信号延迟对无人机机动决策的影响,并探索相应对策具有重要价值。令人惊讶的是,目前相关研究甚少。据调研,虽有研究者对无人机控制系统中的延迟问题展开详细研究并指出信号延迟的潜在影响^[23]、或针对其他领域延迟问题提出优化 DRL 方法^[24],但尚未有研究专门针对基于深度强化学习的无人机控制展开探讨。部分学者虽就深度强化学习中的通用延迟问题提出解决方案,但其方法仅在 MuJoCo 环境中得到验证^[20,21,22]。

目前尚未发现基于深度强化学习的无人机系统延迟控制相关研究。尽管深度强化学习在无人机机动决策领域取得成效,但关于延迟影响分析及应对方案的研究仍未获得足够重视。

本文旨在分析无人机控制系统中的延迟现象,并基于合理简化构建兼容深度强化学习的训练与决策框架,以有效应对信号延迟的影响。主要贡献概括如下:

- 揭示典型深度强化学习算法下信号延迟对无人机性能的负面影响,形成可复现的实验基准;
- 提出新型框架 SPADE,该框架能显著缓解信号延迟的影响,在模拟延迟环境下的典型近距作战任务中通过对抗实验实现了近乎无延迟的性能表现。

总体而言,本研究有助于深化对延迟环境下基于深度强化学习的无人机机动决策的理解,并提出创新性解决方案以应对相关挑战。

1 问题定义

本章概述研究所需的背景知识,并界定核心概念与关键问题。

1.1 无人机近距空战机动决策模型

1.1.1 六自由度固定翼无人机运动模型

六自由度运动建模描述了飞行器在三维空间中的线位移运动与角位移运动。在航空航天领域,飞行器的六自由度模型基于牛顿-欧拉运动方程和动力学基本原理^[23]。

表 1 无人机运动学状态

Table 1 UAV State

状态符号	边界范围	含义
alt	[1000m,10000m]	高度
V_n, V_e, V_d	[-400m/s,400m/s]	北、东、地速 度分量

a_n, a_e, a_d	[0G,9G]	北、东、地加 速度分量
ϕ	$[-\pi, \pi]$	滚转角
θ	$[-\pi/2, \pi/2]$	俯仰角
ψ	$[0, 2\pi]$	偏航角
P, Q, R	—	滚转、俯仰、 偏航角速度
α	$[0, \pi/3]$	迎角
β	$[-\pi/10, \pi/10]$	侧滑角
X, Y, Z	$[-6381km, 6381km]$	ECEF 坐标

表 1 列出了飞行器状态空间的配置参数。其中

V_n 、 V_e 、 V_d 表示北-东-地坐标系中的速度分量, a_n 、 a_e 、 a_d 则为对应的加速度分量。滚转角、俯仰角和偏航角设有明确的取值范围, P 、 Q 、 R 定义为各对应角的时间导数。攻角 α 与侧滑角 β 是描述飞行器空中姿态的两个关键气动参数,直接影响飞行器所受到的气动力,对飞行控制与稳定性具有重要作用。 X 、 Y 、 Z 表示地心地固坐标系中的坐标值。

表 2 无人机控制动作

Table 2 UAV Action

状态符号	边界范围	含义
δ_t	[-1, 1]	油门控制
δ_a	[-1, 1]	副翼控制
δ_e	[-1, 1]	升降舵控制
δ_r	[-1, 1]	方向舵控制

在六自由度固定翼无人机中,飞行控制系统通常通过油门、升降舵、副翼和方向舵四个操纵面来管理飞行器的姿态与运动。这些操纵面使无人机能够实现绕三轴(俯仰、滚转与偏航)的旋转运动以及沿三轴(前后、左右与上下)的平移运动。

表 2 描述了飞行器动作空间的配置,该设置与现有相关研究保持一致^[2]。油门 δ_t 主要控制发动机推力,通过调节油门可改变无人机的前飞速度与爬升高度——推力越大,速度与升力相应增加。位于

尾翼的升降舵 δ_e 通过偏转角度调节俯仰姿态,使机头上仰或下俯从而实现爬升与下降。安装在机翼外侧的副翼 δ_a 采用差动控制方式,通过左右不对称偏转产生滚转力矩,使飞行器绕纵轴旋转,这种滚转运动可改变机翼倾角以实现方向转向。垂直尾翼上的方向舵 δ_r 则通过控制飞行器绕垂直轴旋转来调节偏航姿态,既可用于航向调整也能维持航向稳定性。

1.1.2 近距空战规则

本节详细阐述 1v1 近距空战的裁决规则。每局对抗返回的结果将用于分析胜率等指标,相关符号定义见表 3。当达到最大回合时间时,将直接判定最终胜负结果。

$$\text{If } t \geq T: \text{ res} = \begin{cases} \text{Red Win,} & \text{if } h_r > h_b \\ \text{Blue Win,} & \text{if } h_b > h_r \\ \text{Draw,} & \text{if } h_r = h_b \end{cases} \quad (1)$$

空域边界判定: 在对抗过程中,若无人机超出空域边界,将被判定为失败。

$$\text{res} = \begin{cases} \text{Red Out,} & \text{if } h_r \notin [A_1, A_h] \\ \text{Blue Out} & \text{if } h_b \notin [A_1, A_h] \end{cases} \quad (2)$$

攻击事件判定: 当一方满足攻击条件时,对敌方造成一定伤害。

$$\begin{aligned} &\text{If } d_r \in [D_1, D_h] \text{ and } \theta_r \in [\theta_1, \theta_h] \\ &\text{then } k_r = \text{bd} \times \left(\frac{D_h - d_r}{D_h - D_1} + \frac{\theta_r - \theta_1}{\theta_h - \theta_1} \right) \end{aligned} \quad (3)$$

$$\begin{aligned} &\text{If } d_b \in [D_1, D_h] \text{ and } \theta_b \in [\theta_1, \theta_h] \\ &\text{then } k_b = \text{bd} \times \left(\frac{D_h - d_b}{D_h - D_1} + \frac{\theta_b - \theta_1}{\theta_h - \theta_1} \right) \end{aligned} \quad (4)$$

$$\begin{aligned} h_r &\leftarrow h_r - k_r \\ h_b &\leftarrow h_b - k_b \end{aligned} \quad (5)$$

击落事件判定: 战斗过程中,若任意一方生命值降至 0 以下,即判定为被击落,该回合立即结束。

$$\begin{aligned} &\text{If } h_r \leq 0 \text{ or } h_b \leq 0, \text{ then:} \\ &\text{res} = \begin{cases} \text{RED WIN,} & \text{if } h_r > h_b \\ \text{BLUE WIN,} & \text{if } h_b > h_r \\ \text{DRAW,} & \text{if } h_r = h_b \end{cases} \end{aligned} \quad (6)$$

表 3 交战规则术语定义

Table 3 Competition Rules Notation Definitions

状态符号	边界范围	含义
t	[0s,60s]	当前时间
T	60s	单局最大时长
h_r, h_b	[0,100]	红、蓝方实时血量
a_r, a_b	[1000m,10000m]	红、蓝方实时高度
A_1, A_h	[1000m,10000m]	有效空域高度
D_1, D_h	[100m,500m]	有效攻击距离
θ_1, θ_h	[0°,15°]	有效攻击角度
k_r, k_b	[0,2]	红、蓝方实时伤害值
bd	2	基础伤害
d_r, d_b	[0,20000m]	红、蓝方实时距离
θ_r, θ_b	[0°,180°]	红、蓝方实时攻击角度 (Antenna Train Angle)

1.2 无人机控制系统中的信号延迟

在快速变化的空战环境中,智能决策系统必须实时处理并响应信息。本节围绕集成智能决策的四个核心组件——观测系统、传感系统、智能推断系统与执行系统,重点探讨无人机控制系统中的信号延迟问题。这些组件分别在环境数据采集、解析、决策与执行环节发挥着关键作用。为明确阐述,本文借鉴经典马尔可夫决策过程,将控制流程划分为观测、感知、执行与达成四个阶段。此处所述的延迟特指系统组件间数据交换产生的时间滞后,更具体地说,是控制过程各阶段所耗费的时间。结合强化学习过程的特点,本文将延迟归纳为四种独立类型,每种类型对控制系统的影响各有不同:

- **观测延迟 d_o :** 该延迟源于自然信号从信号

源传输至传感器所需的时间，例如雷达波往返于敌方的传播过程。在强化学习中，它对应传感器观测环境所耗费的时间，导致时刻 t 接收的数据实际反映的是 $t - d_o$ 时刻的环境状态。

- **感知延迟 d_p** ：该延迟由传感器信号通过电路传输及处理器将信号转换为可用数据（如根据接收信号计算距离或速度）所引发。这类延迟不可避免，通常以微秒量级计量。

- **执行延迟 d_e** ：包含两部分时间消耗：智能体处理传感器数据并生成指令所需时间，以及物理操控部件（如油门与操纵杆）执行决策所需的实际动作时间。

- **达成延迟 d_a** ：指控制指令发出后，无人机推进系统等组件做出响应所需的时间。例如油门调节后发动机转速改变所经历的时间间隔。

延迟等效定理^[20]指出，无论延迟类型如何，只有它们的总和（记为 ΔT ）影响决策。为简化延迟组件，本文将总系统延迟定义为 $D_t = d_o + d_p + d_e + d_a$ 。在智能空战决策系统中，直接影响系统滞后和不稳定性的延迟被称为不良延迟，记为 Ξ 。该延迟表示从观测环境到执行动作的时间差，包括由硬件、软件以及飞行员或智能体决策过程引起的延迟。重要的是， Ξ 排除了达成延迟 d_a ，因为 d_a 发生在一个动作执行与后续状态观测之间。因此， $\Xi = d_o + d_p + d_e$ 。在这些组件中，执行延迟 d_e 通常是观测延迟 d_o 和感知延迟 d_p 的数十甚至数百倍，使其成为严重系统性能下降的主要来源。为模拟更广泛的条件，本文扩展了延迟范围，

将固定延迟设置为最高 2400 毫秒。

1.3 深度强化学习 (DRL)

强化学习 (RL) 智能体与环境交互，根据接收到的奖励信号调整行为。形式上，RL 可以被描述为一个由五元组 $\langle S, A, T, R, \gamma \rangle$ 表示的马尔可夫决策过程 (MDP)。

- S ：状态空间
- A ：动作空间
- T ：状态转移函数， $T(s_{t+1} | s_t, a_t)$ 将时间 t 的状态-动作对映射到时间 $t+1$ 的状态分布。
- R ：奖励函数，为每个状态-动作对提供即时反馈信号。
- γ ：状态空间折扣因子， $\gamma \in [0, 1]$ 用于平衡即时奖励与未来奖励。

强化学习的目标是找到一种能最大化期望累积折扣回报的策略。RL 方法依赖于价值函数，这些函数通过动态规划和蒙特卡洛方法等技术进行优化。深度强化学习 (DRL) 利用神经网络处理高维连续空间，从而通过价值函数近似、策略梯度以及执行者-评论者方法扩展了基本 RL 框架。执行者-评论者方法结合了基于价值函数和策略梯度的方法，使用两个模型：执行者 (Actor)：一种参数化策略，基于当前状态选择动作。评论者 (Critic)：通过提供价值函数的估计来评估执行者的动作。状态价值函数 $V(s; \theta_v)$ 及其参数 θ_v 被迭代更新，以反映处于特定状态的价值。动作价值函数 $Q(s, a; \theta_q)$ 及其参数 θ_q 同样被迭代更新，用于估计在状态 s 下采取动作 a 的价值。策略参数 θ_π 也使用由评论者计算的时间

差分误差 δ_t 进行更新。学习率 α 和 β 分别控制价值函数和策略参数的更新过程。

在 SAC 算法中,目标函数引入了一个熵项以鼓励探索,其中温度参数 α 用于平衡奖励与熵之间的权衡。其目标是最大化期望回报与策略熵的加权和:

$$\max_{\pi} \mathbb{E} \left[\sum_{t=0}^T \gamma^t (r(s_t, a_t) + \alpha H(\pi(\cdot | s_t))) \right] \quad (7)$$

$$H(\pi(\cdot | s_t)) = -\mathbb{E}_{a_t \sim \pi} [\log \pi(a_t | s_t)] \quad (8)$$

其中 $H(\pi(\cdot | s_t))$ 表示策略熵,用于促进多样化的动作选择。参数 α 调节探索程度,其值越大越倾向于增强探索性。

2 信号延迟给 UAV 智能体带来的挑战

为探究信号延迟对强化学习智能体控制无人机的影响,基于 1.1.2 节近距空战规则构建了可配置信号延迟的仿真环境进行对抗测试,仿真设置详见附录 6.1.1。基线智能体采用第 1.3 节所述的 SAC 算法训练,训练结果参考 4.2.1 节,实验智能体与基线采用相同决策模型但接收延迟信号,通过对比基线智能体表现分析延迟带来的影响。

实验区分固定延迟与非固定延迟两种场景:固定延迟组设置 300ms、600ms、1200ms 和 2400ms 四档延迟;非固定延迟组以上述延迟值为基础延迟,同时以特定变异概率引入 300ms - 900ms 范围内的随机延迟。实验记录 800 次对抗中的胜率及生命值差值,为获得普适性结果,每场对抗均采用随机初始场景,随机初始化算法详见 6.1.2 节。




图 1 延迟场景下对局胜率 (左图固定延迟, 右图非固定延迟)

Fig.1 Win Rate under Different Delay Conditions

实验结果证明,在固定延迟与非固定延迟两种场景下,智能体的胜率均随延迟增加而显著下降,如图 1 所示。图例中上标*表示非固定延迟。在固定延迟组中,2400 毫秒延迟导致胜率相比零延迟下降 35.1%;非固定延迟组降幅更大,达 36.1%,突显了非固定延迟带来的更大挑战。




图 2 延迟场景下对局平均生命值差异

Fig.2 Average delta HP under Different Delay Conditions

本文还记录了每场对抗结束时的归一化平均生命值差,用以表征智能体的战斗优势。图 2 表明,无延迟时采用相同决策模型的无人机表现相当;但在固定与非固定延迟场景中,即使微小延迟也会显著降低无人机性能,使其陷入劣势。当延迟达到 2400 毫秒时,由强化学习智能体控制的无人机难以维持任何战斗优势。第 1.2 节分析了无人机控制系统中的信号延迟问题,着重阐述了从数据观测到动作执

行之间的决策延迟挑战。地面控制站（GCS）基于无人机观测到的态势数据生成决策动作，但当这些动作传回并生效时，战场态势可能已发生变化，导致原定最优动作失效。图3直观展示了该问题：假设存在3个决策步长的延迟，在T1时刻红方无人机观测到蓝方位置并将信息传至GCS，GCS计算出调整航向以跟踪T1时刻蓝方位置为最优动作。然而当红方无人机在T4时刻接收并执行该指令时，蓝方位置已发生改变，致使原动作失去最优性。图(a)展现了延迟信号导致的反应迟滞现象，图(b)则演示了信号延迟如何使优势态势转为劣势。




图3 延迟灾难示意

Fig.3 Delay Disaster

为缓解这些问题，本文开发了深度融合深度强化学习与监督学习的训练框架，扩展了经典决策流程。通过实验验证了这些方法在应对无人机控制系统延迟挑战方面的有效性。

3 状态预测与自适应决策增强框架（SPADE）

3.1 增强上下文状态预测

在本文第2章中，分析了存在信号延迟时DRL智能体控制无人机性能下降的根本原因。最直接的解决方案是在训练环境中引入延迟，通过修改模型架构或状态空间使智能体学习延迟适应能力。该方法假设奖励模型不受环境延迟影响，近期多项针对信号延迟的DRL研究均采用此思路^[20,27]。本文选取

两种先进方法进行对比实验，将训练延迟配置为与测试基准延迟设置保持一致。为实现训练环境中的延迟模拟，本文采用了兼容gymnasium.Env API^[28]的封装器，该封装器维护一个长度等于步进延迟的队列，待队列填满后返回队列首端状态。该方法的实验结果已纳入对照组分析。

另一种解决方案是预测动作生效时的未来状态，确保所选动作在执行时仍保持最优性。若预测状态与实际状态的差异足够小，DRL控制的无人机性能应能逼近零延迟环境。该方法在保留零延迟环境训练特性的同时，将重点聚焦于提升预测精度。本文提出的方法正是基于该思想，旨在通过增强预测能力有效处理延迟信号。

长短期记忆网络^[29]作为一种强大的循环神经网络，能够有效缓解长时序依赖学习中的梯度爆炸与消失问题^[30]，特别适用于时间序列预测任务^[31]。本文利用长短期记忆网络（LSTM）构建预测器，使用智能体与环境交互产生的状态动作序列 $T = \{(\tilde{s}_i, a_{i-1})\}_{i=1}^N$ 组成预训练数据集 D 。训练获得DRL智能体模型和预测模型 P_θ ，该模型能够根据历史状态与动作序列预测未来环境状态。图4展示了整体训练框架：左侧为SAC算法的运行结构，右侧突出展示了用于预测器训练的核心模块。




图 4 异步上下文增强的智能体训练框架

Fig.4 Asynchronous Context-Enhanced Training Framework

为训练预测器，首先从通用缓冲区（用于构建训练数据的回放缓冲区）中选择样本数据，随后从完整轨迹集 $\mathcal{T}$ 中筛选符合条件轨迹 $\mathcal{T}$ 并加入训练集：

$$E = \{e \in E \mid R_e > 0.1 \times R_{\max} \text{ and } T_e > 200\} \quad (9)$$

$$D = \bigcup_{e \in E} e \quad (10)$$

这些标准可确保获得高质量训练数据，最大限度减少低质量回合的干扰，同时通过高效数据量管理避免过高的存储与时间成本。预测器训练流程总结于算法 1 中。该设计实现了智能体与预测器的同步训练：预测器不依赖数据生成的具体细节，理论上任何具备样本积累能力的算法均可替代框架中的 SAC 组件。这种模块化设计使深度强化学习算法能灵活集成至框架中。该方法的显著优势在于，能够将以无延迟条件表现优异的算法迁移至延迟环境，且仅伴随极小的性能损失。

算法 1 预测器训练算法

数据 根据对局分割的轨迹数据 T

输入 学习率 η ，训练轮数 E ，批次大小 B ，输入序列长度 L ，预测步数 F ，输入集合 I ，标签集合 L ，状态维度 d_s ，动作维度 d_a

输出 训练好的模型参数 θ

1. 随机初始化模型参数 θ
2. 对每条轨迹 $\ell \in \mathcal{T}$ 执行:

2.1 记轨迹 ℓ 长度为 l

2.2 对索引 i 从 0 到 $l-L-F$ 循环执行:

将 $\ell[i:i+L,:(d_s+d_a)]$ 加入 I // 截取长度为 L 的输入序列 (含状态与动作)

将 $\ell[i+L:i+L+F;d_c]$ 加入 L // 截取后

续 F 步的状态作为预测真值

3.由 I 与 L 构造数据集 D // 合并所有样本形成训练集

4.对训练轮数 epoch=1 到 E 执行:

4.1 打乱训练数据集 D // 每轮开始前重新随机排列样本顺序

4.2 对每个批次大小为 B 的小批量 $B \subset D$ 执行:

4.2.1 对 $(\tilde{\mathbf{s}}, \mathbf{a}) = (\tilde{s}_i, a_{i-1})|_{i=L-1}^i, \hat{\mathbf{s}} = (\tilde{s}_p|_{i+1}^{i+F}) \in \mathbf{B}$, 使用 $(\tilde{\mathbf{s}}, \mathbf{a})$ 进行前向传播, 计算预测值 $\hat{\mathbf{s}}$ 计算预测的损失 $L((\tilde{\mathbf{s}}, \mathbf{a}), \hat{\mathbf{s}})$;

4.2.2 计算小批量的平均损失执行反向传播，计算损失 L 关于参数 θ 的梯度，更新模型参数：

$$\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}$$

5. 返回模型参数 θ

3.2 预测性决策增强

预测器模型基于历史状态与动作预估未来状态,使得 DRL 智能体能够根据预估延迟对应的预测状态选择最优动作。现有研究已提出有效的延迟估计方法^[32,33],本文假设无人机能够准确估计延迟。

图 5 展示了处理固定与非固定延迟场景的决策框架。对于固定延迟场景，预测器通过选择已知延迟对应的预测状态直接推导最优动作。对于非固定延迟场景，引入动作管道机制：DRL 智能体在延迟范围内选择一组预测状态序列来估算最优动作。




图5 实时性预测的动作决策框架

Fig.5 Predictive Real-time Execution

Decision-making Process

在每个决策步骤中，智能体生成动作序列并根据预估延迟选择动作。当检测到延迟波动时，系统按顺序执行流水线中的动作，确保延迟变化下的连续性；当延迟稳定时，新的动作序列将更新流水线以保持适应延迟变化。其中延迟稳定的判定采用统计一致性+时间连续性双重逻辑，以适配无人机近距空战的高动态特性：在长度为 5 个决策步的滑动窗口内，若实际延迟的相对波动不大于 5%、绝对波动不大于 50ms，则判定为延迟稳定。动作管道使用和更新算法流程描述见算法 2：

算法 2 动作管道生成算法

输入 延迟范围 Δ ，预测状态序列 $\hat{S}$ ，预估的固定延迟 $\hat{\Delta}$ ，预估的非固定延迟 $\tilde{\Delta}$

输出 动作管道 A

1. 初始化动作管道 $A \leftarrow \{\}$ // 开始时动作管道为空

2. 每个决策步执行：

2.1 (地面控制系统)

在延迟范围 Δ 内预测状态序列 $\hat{S}$ ，为 $\hat{S}$ 中每个预测状态选择最优动作 a_0 ，将所有 a_0 追加到动作管道 A

2.2 (无人机系统)

如果延迟是稳定的根据 $\hat{\Delta}$ 选择动作 a ，否则根据 $\tilde{\Delta}$ 从管道 A 中选择动作

3. 如果延迟稳定，采用最新的动作序列更新管道

此外，最优智能体与对抗环境交互产生的数据被用于预测器的微调。仅更新 LSTM 层及后续多层感知机 (MLP)，冻结其他网络参数，并采用较低学习率。微调过程详见附录 6.2.2。

4 实验

本章为实验部分。第 4.1 节详细阐述了实验设

置与参数配置，并介绍了基线方法及控制组；第 4.2 节呈现智能体训练相关结果；第 4.3 节则对不同智能体组别的测试表现进行详细分析。

4.1 实验设计

实验部分通过模拟实验验证所提出方法的有效性。基于第 1.1.2 节所述的战斗规则，构建 1v1 无人机狗斗模拟场景，详细描述参考 6.1.1 节。采用各方法训练的智能体与基线智能体（通过标准 SAC 算法训练的模型）进行多轮独立对抗。每轮对抗根据第 6.1.2 节算法随机初始化场景，这种随机初始化使智能体能够通过追击此类基于简单规则的对手来学习可迁移的战斗技能。测试过程中，不同延迟组别的智能体会受到延迟效应影响，而对手始终保持无延迟状态。

本文核心方法 SPADE 整合了第 3.1 节与第 3.2 节所述的训练与决策框架。在正式实验前，使用 SAC, PPO、TD3、DDPG 算法训练基线智能体，其中 SAC 算法所训智能体收敛时的奖励值以及对测试的胜率最优，因此实验中采用 SAC 算法进行实验，对手则遵循直线飞行策略并保持初始航向。SAC 算法参数配置如下：执行者学习率 lr_a 为 0.0003，评论者学习率 lr_c 为 0.0003，回放缓冲区大小 c_b 为 1,000,000，折扣因子 γ 为 0.99，软更新系数 τ 为 0.005。状态空间维度 dim_s 为 16，动作空间维度 dim_a 为 4。智能体训练细节并非本方法核心内容，因此在附录 6.2.1 节提供状态空间与奖励函数设计的完整说明。该模型同时作为所有其他实验组的基准对手。此外，SPADE 通过样本重用训练预测器模型以缓解延迟效应：预测器采用三层架构——首层多层

感知机(MLP)包含[20,64]个单元,LSTM 层隐藏层维度为[64,256],末层 MLP 包含[256,16]个单元;学习率设为 0.001,批处理规模为 64,输入序列维度[20,20],输出序列维度[16,16],损失函数采用均方误差。

实验中设置基线组,该组双方对手均为采用标准 SAC 算法训练的模型,其参数设置与 SPADE 完全一致。同时引入四种基于现有相关工作的对比方法作为参照。

LSTM 行动器 (LSTM Actor)¹: RNN-SAC 在部分可观测马尔可夫决策过程 (POMDP) 环境中表现良好。鉴于延迟观测马尔可夫决策过程 (DOMDP) 是 POMDP 的子集,设置融合 LSTM 的改进型 SAC 算法作为对照方法:在标准 SAC 的 Actor 与 Critic 之前各接入两层、256 隐藏单元的 LSTM,形成 LSTM-Encoder + MLP-Head 的堆叠结构;输入序列长度固定为 20 步,每一步送入网络的特征为当前帧延迟状态与上一帧动作的拼接向量,总维度为 $(16+4) \times 20$;采用截断式反向传播,截断长度 20,与序列长度一致;优化器为 Adam,学习率 3×10^{-4} ,其余与基线 SAC 保持一致

延迟协调法 (Delay Reconciled)²: 该方法通过修正训练评论者网络时因延迟造成的数据错位,提升价值估计性能。具体来说,在离线阶段利用先进先出 (FIFO) 队列重建“无延迟”轨迹,用真实状态训练 Critic,而 Actor 仍接收延迟状态;在线阶段仅部署 Actor 用于推理。网络结构 Actor 和 Critic 输入维度

为 16,均使用双层 256 单元 MLP 和 tanh 激活函数。

状态增广法 (State Argumentation)²: 该方法将历史动作与当前状态拼接为智能体训练的状态空间,旨在通过扩展的状态空间获取额外信息以更好地推断最优动作。具体设置为:构建增广状态(原始状态拼接动作序列)作为 Actor 输入,维度为原始状态维度加动作维度 $\times \Delta T$ (增广动作序列维度),选取 $\Delta T=10$,编码器采用两层 256 单元 MLP,激活函数为 tanh;Critic 仍使用延迟协调后的无延迟状态,保持网络结构与非对称输入不变。

信息新鲜度马尔科夫决策过程 (AoI-MDP)³: 该方法将信息新鲜度 (Age of Information, AoI) 显式引入 MDP 的奖励函数,通过惩罚观测陈旧度迫使策略在延迟环境下自发缩短“采样-决策”间隔。与标准 SAC 不同,AoI-MDP 在即时奖励后追加时均 AoI 负项: $r_t \leftarrow r_t - \Delta(t)$,其中 $\Delta(t)$ 按 saw-tooth 公式逐帧计算,网络结构沿用基线 SAC 设置。

4.2 训练结果

4.2.1 基线方法表现

图 6 显示了基线方法在 6000 万次训练步数上的奖励变化情况。奖励值稳步上升,并在约第 2200 万步时开始收敛,表明训练已收敛。

¹ Tianwei Ni, Benjamin Eysenbach, and Ruslan Salakhutdinov. Recurrent model-free RL can be a strong baseline for many POMDPs. In International Conference on Machine Learning (ICML), pp. 16691–16723. PMLR, 2022.

² Wang W, Han D, Luo X, et al. Addressing signal delay in deep reinforcement learning[C]//The Twelfth International Conference on Learning Representations. 2023.

³ Ding Y, Xu J, Yang Y, et al. AoI-MDP: An AoI Optimized Markov Decision Process Dedicated in The Underwater Task (Student Abstract)[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2025, 39(28): 29348-29350.




图 6 基线、LSTM 行动器奖励曲线

Fig.6 Baseline and LSTM Actor Reward Line

4.2.2 对照方法训练表现

四种对比方法在 6000 万次训练步数中的奖励值表现：LSTM 行动器的奖励曲线如图 6 所示。与基线方法相比，其奖励上升阶段表现更不稳定，且收敛阈值低于基线方法。延迟协调法的奖励曲线如图 7 所示。随着延迟增加，其收敛阈值出现不同程度降低，而收敛速度基本保持不变。状态增广法的奖励曲线如图 8 所示。随着延迟增加，其收敛阈值有所下降，当延迟达到 2400 毫秒时，收敛速度较其他组别明显减缓。与延迟协调法相比，状态增广法的整体奖励值略有提升。AoI-MDP 的奖励曲线如图 9 所示。随着延迟增加，其收敛阈值有较明显下降。由于引入了基于信息新鲜度的负值奖励，因此收敛时整体奖励略低于其他组别。




图 7 延迟协调法奖励曲线

Fig.7 Delay Reconciled Agent Reward




图 8 状态增广法奖励曲线

Fig.8 State Augmentation Agent Reward




图 9 AoI-MDP 法奖励曲线

Fig.9 AoI-MDP Agent Reward

4.3 对战测试结果

本节通过多轮对抗测试中的各项指标，对比基线智能体评估了不同方法的性能表现。各方法进行独立的 8 轮测试，每轮设置为 1000 局，结果取测试平均值。

4.3.1 胜率




图 10 各实验组智能体对局胜率

Fig.10 Win Rate of Each Experimental Group's Agents

胜率用于衡量各方法对延迟的抵抗能力。图 10 展示了固定延迟与非固定延迟场景下智能体的测试胜率热力图，其中颜色越深的方格代表胜率越高，越浅则代表胜率越低。无延迟时胜率约为 50%，所

有组别表现均与基线相当。从 300 毫秒开始,随着延迟增加,基线组、LSTM 行动器组、延迟协调组、状态增广组和 AoI-MDP 组在固定与非固定延迟条件下均出现胜率下降现象,下面分析各组胜率下降幅度与潜在原因。

LSTM 行动器

LSTM 行动器组在延迟条件下胜率显著下降,固定延迟场景最大降幅达 34.1%,非固定延迟场景中降幅达 47.9%。此外,两种场景下的胜率均未呈现与延迟时长增加相关的明显规律。此外,在非固定延迟组中,LSTM 行动器的表现明显劣于基线方法,这可能是 LSTM 假设历史信息具有时序相关性,但在非固定延迟场景下,观测与动作之间的时序关系被动态打乱,LSTM 难以建立稳定映射,在高动态、非固定延迟的空战任务中,其结构优势未能有效转化为性能提升。

延迟协调法

延迟协调法在固定延迟场景中表现最差,最低胜率仅为 21%。与零延迟环境相比,该方法在 1200 毫秒固定延迟场景中胜率降幅达 55%,在非固定延迟场景中达 29.8%。该方法的性能显著弱于基线方案,其核心思想是通过修正 Q 值训练过程中的时间错位来缓解延迟影响,但其效果依赖于延迟时间已知且固定、价值函数估计准确性高。因此,在非固定延迟或延迟较大的场景中,延迟协调法的修正策略可能失效。

状态增广法

状态增广组在零延迟场景中取得了 60%的胜率,表明扩展状态空间能够提升性能。但在 600 毫秒延迟

条件下,相较无延迟场景有 43.4%的降幅。在非固定延迟场景中,胜率于 2400 毫秒时达到最低,相较零延迟条件降幅达 51.4%。该方法将历史动作作为延迟补偿的代理变量,在延迟固定且较小时能够保持对齐;延迟增大或随机波动时,序列错位可能使特征从信息变成噪声,胜率因此随延迟陡降。

AoI-MDP

AoI-MDP 在低延迟相较除 SPADE 外的方法有明显胜率优势,最大降幅仍达到了 17% (固定延迟) 和 28% (非固定延迟),且胜率随着延迟增加而降低的现象在非固定延迟场景尤为明显。这是一位内 AoI-MDP 设计和优化高度依赖于特定任务特点,在水下探索任务中表现良好,但其泛化能力到其他任务或环境可能有限。

SPADE

SPADE 组的胜率在不同延迟条件下波动极小。在固定与非固定延迟场景中,最大降幅仅 11.6%。值得注意的是,在非固定延迟场景中,1200 毫秒延迟下的胜率甚至超越零延迟环境——这种表现是因为预测状态既补偿了动作执行延迟,又弥补了动作发出与生效之间的时差,使智能体获得战术优势。

4.3.2 平均优势

图 11 展示了对抗测试中固定与非固定延迟场景下各智能体的标准化生命值优势。非固定延迟为分析性能表现提供了除胜率之外的另一视角。

高胜率结合高生命值优势表明具有明显优越性,正如 SPADE 组在两种延迟场景下 1200 毫秒与 2400 毫秒处的表现。该组别保持着 45%的平均胜率与 0.735 的生命值差值,显著优于其他组别。这表明其不仅获胜频繁,还具备显著的生命值优势,体

现出强大的战斗生存能力。相比之下，状态增广组在 0 毫秒时取得 59% 的胜率，虽超越基线水平，但其生命值优势位于平衡线下方，说明尽管胜率较高但表现不稳定。在 1200 毫秒与 2400 毫秒时，LSTM 执行器、延迟协调与状态增强三组同时呈现低胜率与负生命值差异，表明其处于持续劣势——不仅获胜次数稀少且损失惨重，在非固定延迟环境下尤为明显；在固定延迟场景下，AoI-MDP 方法的胜率并未随着延迟的增加而出现显著下降，表明该方法能够有效应对固定延迟条件下的信息滞后问题。然而，在非固定延迟场景中，AoI-MDP 的胜率和生命值差异均出现了较大降幅，这反映出该方法在处理非固定延迟模式时，难以充分缓解由此引起的信息错位问题，这表明尽管 AoI-MDP 在固定延迟环境中表现出一定的鲁棒性，但其在非固定延迟条件下的性能仍有待进一步提升。




图 11 延迟场景下各方法平均生命值差异

Fig.11 Normed Average Advantage under Different Delay Conditions

总体而言，本文提出的框架在胜率与生命值优势方面均展现出卓越性能，其表现与零延迟条件下的结果十分接近。这表明该方法能有效应对无人机控制中的信号延迟挑战。

4.4 关键模块消融实验

SPADE 框架由两大模块构成：

- ① 状态预测器 (State Predictor) —— 利用历史状态-动作序列估计未来延迟步长的观测，为决策提供逼近“实时”输入；
- ② 动作管道 (Action Pipeline) —— 在非固定延迟场景下，缓存并顺序执行预测器生成的一组动作，以抵消延迟波动造成的“动作-观测错位”。

其中状态预测器是动作管道的先决条件：管道所需的待执行动作序列必须由预测器提前给出，二者在实现上具有以来关系，因此消融时无法单独保留管道而去除预测器。

为量化上述模块的贡献，设计消融实验组：基线 SAC (Baseline) 提供基准性能参照，量化延迟对标准 SAC 的负面影响；SAC+状态预测器 (Predictor) 单独衡量“状态预测器”对延迟的补偿上限；排除动作管道的干扰；SAC+状态预测器+动作管道 (Predictor + Pipe)：量化动作管道在预测器基础上的边际增益，验证动作管道模块能否应对非固定延迟场景下的信息错位问题。




图 12 消融实验：各模块在不同延迟下的胜率对比

Fig.12 Ablation Study: Win Rate Comparison of Each Module Under Different Delays

图 12 显示了消融实验中各组胜率情况，固定延迟是非固定延迟的一种特殊情况^[16]，图例带有*上标代表非固定延迟组。

在固定延迟场景下，状态预测器作为核心补偿模块，相较于 Baseline 胜率平均增幅达 19%，在 300ms – 2400ms 延迟区间内维持约 43% – 48% 的胜率水平；而动作管道因延迟稳定、无需缓存动作序列，几乎与 predictor 组胜率持平，未带来增益。

在非固定延迟条件下，Baseline 组胜率随延迟幅度增加而急剧下降，在 2400ms 延迟时跌至最低值 33%；引入状态预测器后，2400ms 延迟下胜率回升至 36%，表明预测器仅带来微小增益。利用预测动作序列构建动作管道，Predictor + Pipe 组在 2400ms 延迟下胜率提升至 44%，各延迟组别平均胜率增幅相较 Baseline、Predictor 分别达 13%和 7%，表明动作管道在非固定延迟场景中能够带来明显增益。

上述结果表明，SPADE 的两级架构呈正交互补特性：预测器消除固定滞后，动作管道抑制延迟波动，二者协同显著降低了延迟环境对近距空战任务的负面影响。

5 结束语

本研究针对无人机控制中信号延迟严重影响深度强化学习性能的问题，提出 SPADE 框架，通过长短期记忆网络预测未来状态，并结合自适应决策机制，有效补偿动作执行与观测间的时间差。该框架使智能体在固定或波动延迟下仍能生成近似最优动作，显著提升系统在延迟环境中的鲁棒性。实验表明，SPADE 在多项指标上优于延迟协调、状态增广等方法，性能接近无延迟场景。研究证实了在高动态任务中主动补偿延迟的重要性，为强化学习在无人机控制中的实际应用提供了可行路径。未来工作可优化预测模型以适应复杂延迟模式，并引入注意力机制等进一步提升系统适应性。

6. 附录

6.1 附录 A

6.1.1 实验场景与仿真设置

本文基于 JSBSim 高保真六自由度动力学引擎构建 1v1 近距狗斗 (Within-Visual-Range, WVR) 仿真环境。每回合最大时长 60 s，仿真步长 0.01 s，智能体决策频率 15 帧/次 (≈ 6.67 Hz)。双方无人机均为同一固定翼动力学模型，毁伤模型采用连续射线检测方式，造成伤害按 1.1.2 节规则计算；初始生命 100 点，生命值小于等于 0 即判定为被击落，本回合立即结束。




图 13 对抗场景示意图

Fig.13 Engagement Scenario Illustration

空域设定为边长无限，高差 9 km 的立方体区域；任一方飞出有效空域高度 (1km~10km) 即被判负。初始想定由随机算法批量生成：红方（我方，由被测智能体控制）与蓝方（敌方，固定采用无延

迟 SAC 基线智能体) 在 1.5km-3km 空间距离 (保证高度处于 4km-6km 范围)、相对航向 0° - 360° 范围内均匀采样, 初始速度限定为 150 m s^{-1} - 200 m s^{-1} 。非固定延迟场景下, 延迟变异概率 0.3, 随机扰动 300ms-900 ms, 以模拟真实链路抖动。

6.1.2 随机想定生成

在每回合开始前, 系统调用该算法生成两组场景, 用于初始化红方和蓝方。初始化参数从配置文件中获取, 包括基准纬度 λ_0 和经度 ϕ_0 、高度 h_0 , 经纬度偏移范围 $\Delta\lambda$ 、 $\Delta\phi$, 高度范围 $[h_l, h_h]$, 距离范围 $[D_l, D_h]$, 朝向向量 $[o_x, o_y, o_z]$, 速度范围 $[v_l, v_h]$, 以及偏航角范围 $[\theta_l, \theta_h]$; R 表示地球半径。

首先, 利用基准值与偏移量生成红方的初始经度、纬度与高度:

$$\lambda_r = \lambda_0 + \Delta\lambda \cdot \text{rand}(-1, 1) \quad (11)$$

$$\phi_r = \phi_0 + \Delta\phi \cdot \text{rand}(-1, 1) \quad (12)$$

$$h_r = h_l + (h_h - h_l) \cdot \text{rand}(0, 1) \quad (13)$$

将经度、纬度和高度转换为 ECEF 坐标:

$$x_r = (R + h_r) \cos \phi_r \cos \lambda_r \quad (14)$$

$$y_r = (R + h_r) \cos \phi_r \sin \lambda_r \quad (15)$$

$$z_r = (R + h_r) \sin \phi_r \quad (16)$$

接着, 在朝向向量限制范围内随机采样蓝方的相对朝向 $\vec{d}_b$ 。系统在指定距离范围内生成一个随机距离, 并相应地对朝向向量进行缩放, 以计算蓝方的 ECEF 坐标, 再将其转换为纬度、经度和高度。预测模型的微调过程包括三个主要步骤。

$$D_b = D_l + (D_h - D_l) \cdot \text{rand}(0, 1) \quad (17)$$

$$\vec{p}_b = \vec{p}_r + D_b \cdot \vec{d}_b \quad (18)$$

其中, $\vec{p}_r = (x_r, y_r, z_r)$ 为红方的 ECEF 坐标, 蓝方采用相同的表示方式。

$$\phi_b = \arcsin \left(\frac{z_b}{\sqrt{x_b^2 + y_b^2 + z_b^2}} \right) \quad (19)$$

$$\lambda_b = \arctan 2(y_b, x_b) \quad (20)$$

$$h_b = \sqrt{x_b^2 + y_b^2 + z_b^2} - R \quad (21)$$

最后, 为双方随机生成速度与航向角, 以红方为例:

$$v_r = v_l + (v_h - v_l) \cdot \text{rand}(0, 1) \quad (22)$$

$$\theta_r = \theta_l + (\theta_h - \theta_l) \cdot \text{rand}(0, 1) \quad (23)$$

6.2 附录 B

6.2.1 智能体训练细节

状态空间和动作空间

智能体的观测空间由自身状态与探测到的敌态势组成。在与 Actor-Critic 网络交互时, 所有观测均归一化到 $[-1, 1]$ 区间; 智能体的动作也采用相同归一化方式。表 2 和表 5 分别列出了动作、观测空间中各维度对应的变量及其含义。

奖励函数

总奖励由若干局部奖励构成, 包括朝向奖励、距离奖励和攻击意图奖励。在奖励函数中, A_s 表示目标相对于攻击者的方位角 (Aspect Angle) 用, A_t 表示天线指向角 (Antenna Train Angle)。方位角的有效范围 θ_s 为 $[30^\circ, 180^\circ]$, 天线指向角的有效范围 θ_t 为 $[10^\circ, 180^\circ]$, 他们的有效计入距离 T 为 $[100 \text{ m}, 1500 \text{ m}]$, 分别用 T_l 和 T_h 表示, m 表示双方距离; 奖励权重 η 设为 0.5。

1. 朝向奖励

$$\begin{aligned} \text{if: } A_s \in \theta_s \text{ and } m \in T \\ \text{then: } r_{A,s} = \frac{T_h - m}{T_h - T_l} \end{aligned} \quad (24)$$

$$\begin{aligned} \text{if: } A_t \in \theta_t \text{ and } m \in T \\ \text{then: } r_{A,t} = \frac{T_h - m}{T_h - T_l} \end{aligned} \quad (25)$$

2. 距离奖励

$$\Delta m = \min(m, 5000) \quad (26)$$

$$\begin{aligned} \text{if } A_t < \frac{\pi}{2}: r_d = \frac{2500 - \Delta m}{2500} \\ \text{else if } A_t > \frac{\pi}{2}: r_d = -\frac{\Delta m}{5000} \end{aligned} \quad (27)$$

3. 攻击意图奖励

$$A_{s,n} = \frac{A_s}{\pi}, \quad A_{t,n} = \frac{A_t}{\pi} \quad (28)$$

$$r_a = 2 \times \left(\frac{1.0}{5.0 \times A_{s,n} + 1} + \frac{1.0}{10 \times A_{t,n} + 1} - 1 \right) \quad (29)$$

因此，总奖励为：

$$R_t = \eta \times (r_{A,s} + r_{A,t} + r_d + r_a). \quad (30)$$

表 4 初始想定参数

Table 4 Hyperparameters in Initialization Process

状态符号	边界范围	含义
λ_0, ϕ_0	(22.34°, 120.33°)	初始经纬度基准值
$\Delta\lambda, \Delta\phi$	(10000m, 10000m)	初始经纬度偏移量
$[h_l, h_h]$	[4000m, 6000m]	初始高度范围
$[D_l, D_h]$	[1500m, 3000m]	双方初始距离范围
$[o_x, o_y, o_z]$	[±1, ±1, ±1]	红方到蓝方方向向量
$[v_l, v_h]$	[150m/s, 200m/s]	初始速度范围
$[\theta_l, \theta_h]$	[0°, 360°]	初始偏航角范围

表 5 智能体观测空间

Table 5 Agent's Observation Space

状态符号	含义
a_m	我方高度
y_m	我方偏航角
p_m	我方俯仰角
r_m	我方滚转角
$v_{m,d}$	我方地速
$v_{m,e}$	我方东向速度
$v_{m,n}$	我方北向速度
α_m	我方攻角
β_m	我方侧滑角
a_e	敌方高度
$v_{e,d}$	敌方地速

$v_{e,e}$	敌方东向速度
$v_{e,n}$	敌方北向速度
$c_{e,x}$	敌方相对 x 坐标
$c_{e,y}$	敌方相对 y 坐标
$c_{e,z}$	敌方相对 z 坐标

6.2.2 预测器训练细节

首先，在对抗测试数据收集阶段，初始化对抗环境，预训练的最优智能体模型 M_{opt} 与此环境交互，收集高质量数据集 D 。接着，在预测模型数据集构建阶段，将收集到的数据集 D 格式化为输入-输出对，为训练预测模型做准备。最后，在预测模型微调阶段，加载预训练的预测模型，冻结除 LSTM 及其后续 MLP 层以外的所有层，设置较小的学习率 $\eta_{small} = 0.0001$ 。在每个训练步骤中，从数据集中采样一个小批量数据，通过 LSTM 和 MLP 层进行前向传播，计算预测损失。然后仅对未冻结的层进行反向传播，使用 η_{small} 更新 LSTM 和 MLP 层的参数。完成这些步骤后，获得微调后的预测模型。

6.2.3 实验数据表格

核心实验及消融实验数据均汇总于表 6，其中每个延迟组包含两列数据：左列为胜率，右列为血量值差异；各延迟组中表现最优的数据加粗标识。固定延迟场景中，由于延迟稳定，动作管道对智能体实际表现没有影响，因此合并了 Predictor 和 Predictor + Pipe 组。

表 6 核心及消融实验数据

Table 6 Core and ablation experimental data

实验组名称	固定延迟									
	0	300	600	1200	2400					
Baseline	0.507	1.5	0.483	-1.57	0.41	-4.54	0.33	-22.17	0.329	-17.458
LSTM Actor	0.499	-0.345	0.33	-21.961	0.358	-20.165	0.337	-13.971	0.329	-23.157
Delay Reconciled	0.469	-1.282	0.303	-17.458	0.315	-19.346	0.211	-35.846	0.276	-21.076
State Argumentation	0.595	-5.488	0.407	-8.152	0.337	-13.971	0.435	-11.129	0.358	-20.165
AoI-MDP	0.501	0.55	0.447	-12.51	0.428	-16.753	0.441	-16.792	0.417	-19.337
Predictor	0.492	0.405	0.456	-12.745	0.48	-8.078	0.435	-11.129	0.442	-5.889
SPADE(Predictor + Pipe)										
	非固定延迟									
	0*	300*	600*	1200*	2400*					
Baseline	0.507	1.495	0.452	-1.776	0.433	-7.202	0.425	-14.017	0.324	-16.666
LSTM Actor	0.499	-0.345	0.435	-12.016	0.26	-21.882	0.268	-20.179	0.275	-19.833
Delay Reconciled	0.469	-1.282	0.425	-10.035	0.387	-12.814	0.329	-18.421	0.36	-13.731
State Argumentation	0.595	-5.488	0.408	-6.601	0.397	-8.228	0.366	-17.636	0.289	-20.737
AoI-MDP	0.501	-1.22	0.458	-6.295	0.408	-11.8	0.382	-16.862	0.359	-18.407
Predictor	0.482	-1.45	0.439	-12.18	0.464	-8.53	0.483	-15.337	0.359	-19.258
SPADE(Predictor + Pipe)	0.492	0.405	0.443	-10.634	0.435	-10.688	0.504	-6.496	0.437	-3.56

参考文献

- [1] Wang L ,Wang J ,Liu H , et al.Decision-Making Strategies for Close-Range Air Combat Based on Reinforcement Learning with Variable-Scale Actions[J].Aerospace,2023,10(5):DOI:10.3390/AEROSPA CE10050401.
- [2] CHAI J, CHEN W, ZHU Y, et al. A Hierarchical Deep Reinforcement Learning Framework for 6-DOF UCAV Air-to-Air Combat[J/OL]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2023, 53(9): 5417-5429. <https://doi.org/10.1109/tsmc.2023.3270444>. DOI:10.1109/tsmc.2023.3270444.
- [3] ZHANG J, CHEN Z, ZHANG Y, et al. Reinforcement Learning of Aerial Combat Maneuver Decisions Based on UAVs Situation[C/OL]//2023 6th International Conference on Computer Network, Electronic and Automation (ICCNEA). IEEE, 2023: 370-375. <https://doi.org/10.1109/iccnea60107.2023.00085>. DOI:10.1109/iccnea60107.2023.00085.
- [4] Wang Z ,Li H ,Wang J , et al.Deep reinforcement learning based conflict detection and resolution in air traffic control[J].IET Intelligent Transport Systems,2019,13(6):1041-1047.DOI:10.1049/iet-its.2018.5357.
- [5] Qiming Y ,Jiandong Z ,Guoqing S , et al.Maneuver Decision of UAV in Short-Range Air Combat Based on Deep Reinforcement Learning[J].IEEE Access,2020,8363-378.DOI:10.1109/access.2019.2961426 .
- [6] ZHEN Y, HAO M. Aircraft Control Method Based on Deep Reinforcement Learning[C/OL]//2020 IEEE 9th Data Driven Control and Learning Systems Conference (DDCLS). IEEE, 2020: 912-917. <https://doi.org/10.1109/ddcls49620.2020.9275205>. DOI:10.1109/ddcls49620.2020.9275205.
- [7] Feilong J ,Minqiang X ,Yuqing L , et al.Short-range air combat maneuver decision of UAV swarm based on multi-agent Transformer introducing virtual objects[J].Engineering Applications of Artificial Intelligence,2023,123(PB):DOI:10.1016/J.ENGAPPAL.2023.106358.
- [8] 蒋俊哲.基于时序建模与层次搜索的空战机动决策研究[D]. 广西大学, 2025.DOI:10.27034/d.cnki.ggxu.2025.000894.
Jiang Junzhe. Research on air combat maneuver decision-making based on temporal modeling and hierarchical search [D]. Nanning: Guangxi University, 2025. DOI:10.27034/d.cnki.ggxu.2025.000894.
- [9] 张百川,毕文豪,张安,等.基于 Transformer 模型的空战飞行器轨迹预测误差补偿方法[J]. 航空学报,2023,44(09):291-304.
Zhang Baichuan, Bi Wenhao, Zhang An, et al. Error compensation method for trajectory prediction of air combat vehicles based on Transformer model[J]. Acta Aeronautica et Astronautica Sinica, 2023, 44(09): 291-304.
- [10] Zihao G ,Yang X ,Delin L .UAV Cooperative Air Combat Maneuvering Confrontation Based on Multi-agent Reinforcement Learning[J].Unmanned Systems, 2023, 11(03): DOI:10.1142/S2301385023410029.
- [11] 姚昌华,张晓慧,毕珊宁,等.电子战无人机与陆战多智能体协同决策[J/OL]. 计算机应用与软件,1-9[2025-10-24].<https://link.cnki.net/urlid/31.1260.tp.20250902.1117.004>.
Yao Changhua, Zhang Xiaohui, Bi Shaning, et al. Cooperative decision-making of electronic-warfare UAV and land-based multi-agent systems [J/OL]. *Computer Applications and Software*, 1-9 [2025-10-24]. <https://link.cnki.net/urlid/31.1260.tp.20250902.1117.004>.
- [12] LI B, HUANG J, BAI S, et al. Autonomous air combat decision - making of UAV based on parallel self - play reinforcement learning[J/OL]. CAAI Transactions on Intelligence Technology, 2022, 8(1): 64-81. <https://doi.org/10.1049/cit2.12109>. DOI:10.1049/cit2.12109.
- [13] 唐媛.基于深度强化学习的无人机编队避障导航关键技术研究[D]. 电子科技大学,2025. DOI:10.27005/d.cnki.gdzku.2025.002226.
Tang Yuan. Research on Key Technologies for Obstacle Avoidance and Navigation of UAV Formation Based on Deep Reinforcement Learning [D]. University of Electronic Science and Technology of China, 2025. DOI:10.27005/d.cnki.gdzku.2025.002226.
- [14] Yongfeng L ,Yongxi L ,Jingping S , et al.Autonomous

- Maneuver Decision of Air Combat Based on Simulated Operation Command and FRV-DDPG Algorithm[J]. *Aerospace*, 2022, 9(11): 658-658. DOI: 10.3390/AEROSPACE9110658.
- [15] HU J, WANG L, HU T, et al. Autonomous Maneuver Decision Making of Dual-UAV Cooperative Air Combat Based on Deep Reinforcement Learning[J/OL]. *Electronics*, 2022, 11(3): 467. <https://doi.org/10.3390/electronics11030467>. DOI: 10.3390/electronics11030467.
- [16] Lee S M, Shin M, Son H. Robust predictor-based control for multirotor UAV with various time delays[J]. *IEEE Transactions on Industrial Electronics*, 2022, 70(8): 8151-8162.
- [17] Wu Y H, Li C Y, Lin Y B, et al. Modeling control delays for edge-enabled UAVs in cellular networks[J]. *IEEE Internet of Things Journal*, 2022, 9(17): 16222-16233.
- [18] Yu Z, Zhang Y, Jiang B, et al. Refined fractional-order fault-tolerant coordinated tracking control of networked fixed-wing UAVs against faults and communication delays via double recurrent perturbation FNNs[J]. *IEEE Transactions on Cybernetics*, 2022, 54(2): 1189-1201.
- [19] Muskardin T, Coelho A, Della Noce E R, et al. Energy-based cooperative control for landing fixed-wing UAVs on mobile platforms under communication delays[J]. *IEEE Robotics and Automation Letters*, 2020, 5(4): 5081-5088.
- [20] Wang W, Han D, Luo X, et al. Addressing signal delay in deep reinforcement learning[C]//The Twelfth International Conference on Learning Representations. 2023.
- [21] Ivan Anokhin, Rishav Rishav, Matthew Riemer, et al. Handling Delay in Real-Time Reinforcement Learning. [C]//The Thirteenth International Conference on Learning Representations, 2025.
- [22] Lee J, Kim J, Jeong J, et al. Reinforcement Learning via Conservative Agent for Environments with Random Delays[J]. *arXiv preprint arXiv:2507.18992*, 2025.
- [23] De Vries S C. UAVs and control delays[R]. 2005.
- [24] Ding Y, Xu J, Yang Y, et al. AoI-MDP: An AoI Optimized Markov Decision Process Dedicated in The Underwater Task (Student Abstract)[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2025, 39(28): 29348-29350.
- [25] Kosinski R J. A literature review on reaction time[J]. *Clemson University*, 2008, 10(1): 337-344.
- [26] Stevens B L, Lewis F L, Johnson E N. Aircraft control and simulation: dynamics, controls design, and autonomous systems[M]. John Wiley & Sons, 2015.
- [27] Chen B, Xu M, Li L, et al. Delay-aware model-based reinforcement learning for continuous control[J]. *Neurocomputing*, 2021, 450: 119-128.
- [28] Towers M, Kwiatkowski A, Terry J, et al. Gymnasium: A standard interface for reinforcement learning environments[J]. *arXiv preprint arXiv:2407.17032*, 2024.
- [29] Hochreiter S, Schmidhuber J. Long short-term memory[J]. *Neural computation*, 1997, 9(8): 1735-1780.
- [30] Hochreiter S, Schmidhuber J. LSTM can solve hard long time lag problems[J]. *Advances in neural information processing systems*, 1996, 9.
- [31] Van Houdt G, Mosquera C, Nápoles G. A review on the long short-term memory model[J]. *Artificial intelligence review*, 2020, 53(8): 5929-5955.
- [32] Armah S K, Yi S. Analysis of time delays in quadrotor systems and design of control[M]//Time Delay Systems: Theory, Numerics, Applications, and Experiments. Cham: Springer International Publishing, 2017: 299-313.
- [33] Kali Y, Rodas J, Gregor R, et al. Attitude tracking of a tri-rotor UAV based on robust sliding mode with time delay estimation[C]//2018 International Conference on Unmanned Aircraft Systems (ICUAS). IEEE, 2018: 346-351.